

Taller Muestreo

Versión 1.0.1

Recursos Didácticos y Tecnológicos para la Enseñanza

Subsecretaria de Planeamiento Educativo - PBA

5 de febrero de 2026

Versión PDF. Consultar versión online para una experiencia más interactiva en
<https://planificacion-muestreo.netlify.app/>

1 Introducción

En este curso/taller vamos a ir interactuando entre algo de teoría, algo de datos y algo de código. Generalmente vamos a trabajar con un sólo insumo empírico que es una base de datos de establecimientos educativos de nivel primario de gestión estatal de la provincia de Buenos Aires. Con este insumo en una primera instancia nos vamos a focalizar en una serie de *diseños* clásicos de muestreo y en la construcción de ponderadores. En una segunda instancia vamos a ver diseños que implican o bien alguna combinación en más de un paso de estos diseños clásicos (muestras complejas) o diseños de un sólo paso (p.e. diseños balanceados y bien distribuidos) cuyos modos de proceder son diferentes al de los clásicos. Finalmente se verán algunas estrategias de calibración que, en principio, al ser instancias post-diseños, pueden ser aplicadas/combinadas con cualquiera de los anteriores diseños.

El código con que vamos a procesar los datos a lo largo del taller va a ser en lenguaje R. R es un lenguaje de programación que parece una opción razonable tanto para el diseño de la muestra como el posterior ajuste y análisis de los mismos. Si bien diseños de métodos de muestreo relativamente simples son posibles de realizarse en varios otros lenguajes la situación se complica un poco a medida que se quieren utilizar, y luego analizar, diseños más complejos. En esta última situación, ya no es posible conseguir librerías especializadas en muchos lenguajes aparte de R, Python, Julia y SAS.

Dentro del ecosistema de R, ejemplos de librerías para analizar datos producidos con diseños muestrales pueden considerarse [survey](#), [svrep](#) y su correspondiente versión tidy [srvyr](#). Estas librerías generalmente agregan meta-información al dataframe original que hace referencia al modo o diseño en que fue realizada la muestra. Esta información luego es utilizada para realizar estimaciones puntuales con sus respectivos errores estándar, intervalos de confianza o coeficientes de variación. La librería [survey](#) es una librería madura mantenida principalmente por [Thomas Lumley](#) (un personaje conocido dentro de la comunidad de R) y la librería [srvyr](#) puede considerarse como su sucesora más moderna, aunque como lo destacan sus propios autores, se trata de una librería más amigable para el usuario en donde la mayoría del trabajo sucio lo sigue haciendo por detrás la librería [survey](#). Algo similar resulta entre la relación entre [survey](#) y [svrep](#) ya que esta última se puede considerar una extensión de la primera para el cálculo de ponderadores replicados (*replicate weights*). Algo importante a destacar es la compatibilidad entre las 3 librerías y que, a pesar de la diferencia generacional (Lumley es el mayor) existe una relación afectuosa entre los diferentes autores. En efecto, [Ben Schneider](#), el creador de la librería [svrep](#), es un asiduo contribuidor de los 3 paquetes antes nombrados.¹

¹Existen más librerías que extienden a [survey](#). [robsurvey](#), para la realización de estimaciones robustas, es otro ejemplo.

Ejemplos de librerías que sirven para el diseño de las muestras y su posterior ajuste son [sampling](#), [balanced sampling](#) y [spbsampling](#). Al igual que con las librerías anteriores, aquí también existe relación entre los diferentes autores. La librería [sampling](#) es una librería madura creada bajo la tutela de Yver Tillé, que es otro personaje bastante conocido tanto en el mundo de la estadística académica como dentro de los organismos oficiales de estadística de diferentes países. La librería [balanced sampling](#) hace mucho de las funciones que la librería [sampling](#), pero es más moderna (corre en C++) y es mantenida por [Anton Grafstrom](#) que ha escrito con Tillé. Por otro lado, la librería [spbsampling](#) se especializa en muestreos espaciales ([balanced sampling](#) también tiene funciones para eso), se ejecuta en C++ y es mantenida por Roberto Benedetti. Tanto Benedetti como Grafstrom se reconocen entre ellos y algo interesante es que si, bien han trabajados con institutos oficiales de estadística, ambos se especializan en organismos de agricultura. De ahí que ambos muestren interés en la dimensión espacial de los diseños muestrales ya que esta es útil al hora de, por ejemplo, diseñar una buena muestra de la vegetación de un bosque.²

Por último para el cálculo de los tamaños muestrales con diferentes diseños (y otras yerbas) puede consultarse la librería [PracTools](#). No se trata de una librería muy sofisticada como algunas de las anteriores pero se trata de una librería útil y relativamente bien documentada. Un dato no menor es que uno de sus autores es Richard Valliant que, a su turno, es uno de los mayores exponentes de un enfoque importante dentro del mundo del muestreo como es el “*Model Assisted Sampling*”.³

1.1. Librerías utilizadas

Abajo hay un código para instalar y cargar las librerías que vamos a utilizar. El código se encarga de cargar las librerías y de instalar las mismas en el caso que no se encuentren previamente instaladas.

```
# Código para activar librerías. Instala también las librerías que se necesitan pero no e  
  
install.packages("pacman", repos = "http://cran.us.r-project.org")
```

```
pacman::p_load(survey,  
               svrep,  
               srvyr,  
               sampling,  
               BalancedSampling,  
               Spbsampling,
```

²Para aquel que le interesa agregar explícitamente la dimensión espacial en los diseños muestrales puede consultar la obra de Dick Brus “[Spatial sampling with R](#)”. Brus, un geólogo ahora ya retirado, es una eminencia mundial en la temática de los muestreos de suelo (*soil sampling*) y más en general, de los muestreos espaciales.

³Otras librerías que existen dentro del ecosistema de R pero que no veremos aquí son [SamplingStrata](#) y [surveyplanning](#).

```
PracTools,  
tidyverse,  
janitor,  
here,  
readxl,  
infer,  
gt,  
gtsummary,  
cardx,  
patchwort,  
gstat,  
sf,  
tmap)
```

2 Cuando y porqué hacer muestras

Una muestra es una parte de un todo. En los muestreos que aspiran a ser (en algún grado) representativos lo que se intenta lograr es que esa parte que se seleccione no sea muy diferente al todo o, como decían los romanos, que sea legítimo tomar una parte como el todo (*pars pro toto*). En este sentido, lo que vamos a hablar aquí sobre muestreo tiene mayor pertinencia cuando en la investigación se intenta maximizar la **representatividad** pero por alguna razón no es posible o conveniente la realización de un censo de todas las partes que conforman ese todo. Por otro lado, diseñar muestras también puede ser importante cuando se necesitan construir grupos de tratamiento y control en diseños experimentales, especialmente en los diseños experimentales aleatorios (Kish 1987). En efecto, la vinculación entre la bibliografía del diseño muestral y del diseños experimental suele ser útil si se aspira a entender las razones (y no sólo saber ejecutarlas en la práctica) de algunas recomendaciones metodológicas ya que muchos de los conceptos más abstractos son compartidos por ambas [Hedlin (2015)](Fienberg y Tanur 1988).

Nota

Las muestras que aspiran a ser representativas intentan captar la heterogeneidad de una determinada población para poder hablar legítimamente del todo a través de sólo una parte.

En algunas situaciones, más usuales en las ciencias naturales, la representatividad a veces se logra sin un mayor esfuerzo por parte del investigador por lo que no suele ser explícitamente un objetivo de la investigación sino un supuesto más o menos implícito a lo largo de ella. En otras palabras, la hipótesis de la homogeneidad forma parte del modelo mediante el cual se intenta aprender de la realidad. Entender la razón de esto último puede ayudar a hacer más transparente alguna especificidad de las ciencias sociales en este punto. En efecto, muchos investigadores consideran que en los niveles más bajos de la realidad (p.e. niveles estudiados por la física y la química) existe una mayor homogeneidad de los referentes básicos que estudian esas disciplinas. En cambio, en los niveles más superiores (p.e. niveles estudiados por ejemplo por la psicología y las ciencias sociales) la variabilidad inherentes de los referentes estudiados hace que sea necesario prestar especial atención al problema de la representatividad, En este sentido, el investigador suele realizar acciones específicas para poder captar la heterogeneidad que surge a nivel poblacional debido a la variabilidad individual de los referentes estudiados y, en ese camino, suele venir en ayuda el diseño muestral.

De manera derivada, lo anterior es una de las razones porque el método experimental ha sido bastante exitoso en la historia de las ciencias naturales ya que con unos pocos

experimentos sus resultados se pueden inferir a su respectiva **población** empírica actual. No sólo eso. Muchas veces también se puede inferir a lo que a veces se denomina su **universo** que estaría compuesto no sólo por la población actual sino también por la clase de esas poblaciones pasadas y futuras. Este tipo de problemáticas son conocidas por diferentes disciplinas. Desde la epistemología a veces se lo relaciona con el problema de los universales (Klima 2022) y desde la metodología se lo relaciona con el problema de la **validez externa** de las investigaciones (Campbell y Stanley 1963).

A modo de ejemplo, un físico que investiga el impacto del calor en el átomo de carbono puede tener una razonable confianza que el átomo de carbono que está hoy estudiando no sólo es muy similar a los otros átomos de carbono actuales en la Tierra (población) sino que también es similar a los pasados y los futuros átomos de carbono (universo). También puede tener confianza que los átomos de carbono encontrados en la Tierra son similares a los existentes en el resto del universo. En el otro extremo, estas suposiciones en general son difíciles de mantener en el nivel social.

Estas diferencias en cuanto a la validez externa no son tan marcadas cuanto se analiza la dimensión de la **validez interna** de las investigaciones. En la jerga de la bibliografía de los diseños de investigación se suele afirmar que en todas las investigaciones que se quiera realizar inferencias causales, independientemente si se trata de investigaciones físicas o sociales, el investigador se debe asegurar, en la fase de diseño de la investigación, de controlar o aleatorizar el conjunto de factores extraños que le sugiera/n la o las teorías utilizadas. Esto es lo que precisamente le asegurará que aquellos factores extraños no sigan existiendo como factores perturbadores que puedan invalidar las inferencias internas o locales en el momento de las conclusiones (Kish 1987). En el último tiempo la visión anterior se ha expandido aún más permitiendo mayor seguridad en diseños observacionales en situaciones en donde no es posible un diseño experimental aleatorio lo que es sumamente importante en el dominio de las ciencias sociales (Pearl 2018; Morgan y Winship 2015).

Dada la introducción anterior, ahora estamos en condiciones de expresar lo mismo pero en términos más simples:

i Nota

Donde no hay heterogeneidad con seguridad no hay problemas de representatividad. Si hay heterogeneidad, y el investigador no realiza acciones en su diseño para incluir esa heterogeneidad en su investigación, la misma sufrirá de un problema de representatividad que derivará en un problema de **validez externa**.

2.1. Muestras de qué?

Un primer paso importante cuando uno se preocupa por la representatividad es entender sobre qué población de referentes y de unidades de observación/experimentación uno va

a querer predicar sus inferencias. Para eso hay que analizar:

a) La clase de referencia de los conceptos utilizados que nos dirá el/los tipo/s de referente/s a investigar (individuos, organizaciones, etc.). Esto a veces se suele denominar **universo** o dominio de la teoría (Bunge 1974).

b) Los objetivos de la investigación que nos indicaran, entre otras cuestiones, el alcance (usualmente especificando tiempo y espacio) de los referentes anteriores junto con otras características pertinentes de cada unidad de observación/experimentación. Usualmente los objetivos remiten a una población empírica que podrá grande o pequeña, homogénea o heterogénea, dispersa o aglomerada, etc.

Dentro del muestreo al conjunto formado por todos los objetos reales que cumplan las condiciones de los puntos “a” y “b” se lo denomina **población**¹. En nuestra vida cotidiana, aunque sea sólo por vivir en un tiempo y espacio determinado (y aún si somos investigadores de profesión) usualmente sólo tenemos posibilidad de acceso empírico a un subconjunto de aquella población. Para empeorar las cosas, en las ciencias sociales muchas poblaciones son muy numerosas, heterogéneas y/o otras se encuentran muy separadas espacialmente lo que dificulta y hace costoso llegar a cada uno de las partes de aquellas. En el extremo, a veces el investigador tiene el problema adicional de trabajar con poblaciones “invisibles” de las que se sabe o se presupone que existen pero no se tienen datos agregados de ella y/o es sumamente difícil identificar/contactar a miembros de ella. Ante esta situación el investigador tiene 2 grandes opciones:

a) Se ajustan los objetivos de la investigación, especialmente en lo tocante al grado de alcance o generalidad de la investigación, hasta un punto que efectivamente la definición de la unidad de análisis construya una población en la que se pueda abordar empíricamente a cada una de las unidades que la componen y/o

b) Se realiza una **muestra** de aquella población.

En este sentido, en este taller se le prestará atención a las estrategias tipo ‘b’ como un modo de conocer el todo a través de sólo una parte de aquel. Más adelante también veremos que hay estrategias más eficientes que otras para con ‘poco’ inferir ‘bastante’, aun cuando, en muchos casos, no se sepa a ciencia cierta si ese ‘bastante’ es ‘suficiente’. En otras palabras, se verán las distintas características de diferentes diseños muestrales

¹Expresado en términos de propiedades generales y específicas podría afirmarse que las **propiedades generales**, como su nombre lo indica, sirven para construir **géneros** y todas los objetos reales que pertenecen a ese género tienen el mismo valor en todas sus propiedades generales. Ejemplo: Todo objeto real que se clasifique como “persona” deberá cumplir una serie de propiedades generales que hacen a la esencia de “persona” y se incluyen en su definición. Ser estudiante o residir en la provincia de Buenos Aires no pertenece a un valor de una propiedad general de las personas. En cambio, mamífero descendiente del mono, sí. Las propiedades generales son necesarios para identificar la clase de referencia pero no suficientes para construir la población sobre la cual se realizará la muestra.

Las **propiedades específicas**, también como su nombre lo sugiere, sirven para construir **especies de los géneros** en función de los diferentes valores en las propiedades específicas. Tiempo y espacio son típicas propiedades específicas que ayudan recortar al universo anterior delimitando una población empírica. Luego pueden existir otras propiedades específicas (como las anteriores de ser estudiante o vivir en Buenos Aires) que sirven para seguir delimitando aún más nuestra población.

que aspiran a algún grado de representatividad y comprender cual de ellos puede ser más idóneo en función de los objetivos, el presupuesto y los datos disponibles en cada caso.

Existen varios criterios para clasificar a las muestras. Siguiendo una clasificación clásica (Neyman 1934), todos los que se basan en algún modo en la aleatoriedad (*random*), ponen el acento en el **proceso** de la muestra y se las puede clasificar como **muestras probabilísticas**. Otros, como todos los que se basan en cuotas ponen más acento en las acciones y chequeos basados en las intenciones (*purposive*) del **resultado o producto final**. Aquí, más que usar el término de muestras intencionales de Neyman vamos a preferir el más amplio de muestras no probabilísticas ya que también engloba a otros diseños que tienen la similitud, al menos a primera vista, de no ser probabilísticos (Baker et al. 2013). Ejemplos pueden considerarse las muestras basadas en el criterio de saturación y la heterogeneidad observada, los muestreos por conveniencia, los muestreos por *matcheo* (en donde los cuotas de Neyman serían un ejemplo), los muestreos basados en redes, usuales para el estudio de poblaciones invisibles (en donde el bola de nieve sería un ejemplo).

Finalmente en el último tiempo, y en parte por el avance de una mayor disponibilidad de información secundaria, cada vez existen más métodos que permiten incorporar esa mayor información secundaria como información auxiliar (*auxiliary information*) tanto en el diseño de la muestra como en el posterior ajuste de los estimadores de la misma. Este último proceso en particular se suele denominar calibración. Ambos usos de la información secundaria (tanto si se usan para el diseño *ex-ante* o para el ajuste de los estimadores *ex-post*) son ejemplos de diseños muestrales asistidos por modelos que derivan de información secundaria (*model assisted*).

En el último párrafo, casi al pasar, se ha comentado que “en el último tiempo” ha habido cambios en el mundo del muestreo. Más allá que se pueda afirmar que en algunos momentos haya habido más cambios que otros, la historia de la incorporación de las diferentes teorías de muestreo en la estadística como disciplina (antes dominada por aplicaciones sobre poblaciones enteras o censos) o en el diseño de investigaciones (antes dominada por diseños experimentales) es sumamente interesante y recomendable (Hacking [1990] 2004, 2006; Gigerenzer et al. 1997).

3 La domesticación del azar como medio para lograr muestras (aproximadamente) representativas

Si ser muy profundos en cuanto a la teoría del muestreo o en cuanto a su justificación más académica en lo que sigue se intenta recordar que sucede si se realizan muestras aleatorias dentro de una población. Este enfoque tiene mucho que ver con lo que se suele denominar “*Design Based Sample*” en la literatura sobre muestreo. Básicamente, en línea con la clasificación de Neyman anteriormente utilizada, son muestras que ponen énfasis en el proceso aleatorio de la selección de los casos. Es una escuela clásica dentro del muestreo y tiene muchas subvariantes. Algunas de ellas las veremos más adelante pero ahora nos concentraremos en la parte que tienen en común todas ellas. Para eso vamos a simular que hacemos muchas muestras aleatorias simples sobre una población imaginaria no muy grande (<2000). Primero haremos, o más bien repetiremos, muestras relativamente pequeñas y luego haremos muestras algo más grandes.

Para tener una mejor experiencia de este simulador es aconsejable su ejecución a través de este [link](#).

Con este programa podemos jugar de varias formas. Aquí nos interesa las siguientes.

1. En primer lugar ver que pasa, en los términos de la figura “datos acumulativos de las muestras” cuando realizamos muchas muestras sobre una misma población (p.e. Población = “Opción 3”). Como veremos, estas distribuciones, en especial si la muestra contiene más de 30 casos, converge hacia un patrón de distribución “normal”. Lo interesante es que esta distribución emerge, con mayor o menor rapidez, de manera independiente de la forma de la población (Ver punto 2). También se puede probar escogiendo diferentes tamaños de las muestras (p.e. Tamaño de la muestra = 30 y 200).
2. Por otro lado se puede probar que sucede si, se hace el ejercicio anterior en diferentes poblaciones (p.e. con Población = “Opción 6”). Como se observará siempre se obtiene una distribución “normal” aunque en mayor tiempo y con una mayor varianza.

3.1. Población

Como se anticipó en la introducción, nuestra **población** será una población de establecimientos educativos de gestión estatal de nivel primario. Cada uno de los integrantes de esta población se pueden considerar como **unidades de selección**, el subconjunto

Tabla 3.1: Información de la base de escuelas

clave	region	nombre_distrito	localidad	ambito	cueanexo	matricu
0001PP0001	01	La Plata	LA PLATA	Urbano	060882200	6
0001PP0002	01	La Plata	LA PLATA	Urbano	060881800	4
0001PP0003	01	La Plata	ANGEL ETCHEVERRY	Urbano	060886200	4

finalmente seleccionado será la **muestra** y la cantidad de los miembros seleccionados será el **tamaño de la muestra**. En este caso, como se observa en Tabla 3.1, se tiene información variada sobre cada una de las escuelas. Como veremos más adelante, tener más información sobre las unidades de selección puede ayudar para la efectiva realización de diferentes diseños muestrales. Algunos de esos diseños servirán cuando el objetivo sea tener una muestra de escuelas (muestreos de una sola etapa) y otros, generalmente más complejos, podrán servir como un primer paso para luego realizar una muestra a estudiantes, directivos, etc. (muestreos polietápicos).

Como puede observarse se trata de una base de escuelas en el sentido que en cada fila hay un establecimiento diferente que contiene una serie de propiedades de los mismos en cada una de las columnas. Algunas de esas propiedades se podrían considerar como intrínsecas de cada escuela (clave, región, ámbito, etc.), otras pueden considerarse como propiedades agregadas de los establecimientos en el sentido que devienen de agregaciones de los estudiantes que son parte de cada escuela (p.e. prueba_x) o de los directivos de los mismos (p.e. direct_x). Estas distinciones son importantes cuando se quiere realizar una muestra porque esto indica límites y posibilidades sobre a qué población se puede realizar una “buena” muestra desde este archivo. En este contexto, la información de este archivo es particularmente buena para realizar una muestra de colegios pero quizá no tan apropiada para realizar una muestra de estudiantes o directivos... al menos si se lo compara, respectivamente, con tener acceso a una lista de estudiantes o una de directivos. Como veremos más adelante, si se tiene en mente este último punto es posible minimizar algunos de esos problemas aplicando algunas estrategias (p.e. seleccionar pocos estudiantes de cada colegio seleccionado) o, de forma más explícita, hacer una muestra proporcional al tamaño de la matrícula de cada establecimiento.¹

Por ahora trabajaremos con este archivo para realizar diferentes tipos de muestras de establecimientos educativos. Un plus pedagógico de esta estrategia es que vamos a tener a mano los valores de las estimaciones de las diferentes muestras que se vayan realizando y los respectivos valores de los parámetros poblacionales para comparar resultados. Algunos de esos valores poblacionales se podrán considerar como información secundaria en el

¹Si el conjunto de los estudiantes (así como los maestros y los directivos) de la provincia hubiera sido sorteado para ingresar a cualquier colegio de la provincia y si todos los colegios tendrían la misma matrícula (así como maestros y directivos), realizar una muestra aleatoria de colegios con el objetivo de realizar una muestra aleatoria de estudiantes (o de maestros y directivos) no sería un mayor problema. El primer criterio tiene que ver con las diferencias de cada colegio y el segundo con el modo de agregar esas diferencias en una muestra cuyo primer paso es la selección de unidades agregadas (colegios) para estimar valores de unidades de selección menores (estudiantes, maestras y directivos).

sentido que el interés de la muestra no es estimar esos parámetros. Otros de esos valores se los podrá considerar como los parámetros a estimar en la muestra. Esta última situación no es la usual porque si ya se tiene el parámetro poblacional no es necesario la realización de una muestra para su estimación.

Dentro de los parámetros poblacionales vamos a calcular los siguientes:

- Matrícula
- Secciones
- Sondeo primero
- Sondeo segundo
- Región
- Ámbito

Algunas de las variables anteriores son categóricas (región, ámbito) y otras no. Vamos a ver que esto importa porque no es lo mismo estimar un parámetro continuo que uno categórico. Dentro de estos últimos tampoco es lo mismo estimar una variable con 25 categorías (p.e. región) que una variable categórica de 3 categorías (p.e. ámbito).

En la Tabla 3.2 puede observarse algunos de los valores de estos parámetros. Para el caso de las variables continuas (Matrícula, Secciones, sondeo primero, sondeo segundo) se ha calculado la media junto con los valores del primer y tercer cuartil. En el caso de las variables categóricas (región, ámbito) se han calculado los respectivos porcentajes de cada categoría. Esta distinción es importante porque mientras algunas muestras se esfuerzan por estimar medidas de tendencia central, otras se esfuerzan por estimar medidas de dispersión central y otras intentan hacer ambos tipos de estimaciones. Otra distinción importante es la anteriormente mencionada sobre la población que se quiera muestrear. Por ejemplo, el valor de la media del primer sondeo puede ser útil para estimar si la media de la **población de colegios** arroja un valor similar que la media de la/s muestra/s realizada/s de esos colegios. Sin embargo, no hay que olvidar que esos datos, sí con ellos se quiere referir a la **población de estudiantes**, habría que ponderarlos por la matrícula de cada colegio, esto es, habría que calcular su media ponderada.

Estos parámetros “conocidos” van a tener 2 funciones en este taller. Por un lado, nos van a servir para cotejar, *ex-ante*, la media de las medias muestrales realizadas con azar simple y, por otro lado, nos pueden servir, *ex-post*, para mejorar las muestras concretas efectivamente obtenidas. Esto último, más allá de las técnicas específicas que se utilicen, es importante por lo siguiente:

Las muestras que se hacen en la realidad son “únicas” o “individuales” en el sentido que no se repiten. En cambio, una buena parte de la teoría del muestreo supone una distribución de muestras (como las simulaciones anteriores en donde se realizaban varias muestras de una misma población). La mayoría de las veces el investigador que sale a campo dispone de solo una muestra y el objetivo es que “esa” muestra (y no cualquier otra posible) sea de las mejores y no de las peores. En este sentido, es útil tener herramientas

Tabla 3.2: Valores poblacionales de las escuelas

Característica	N = 4.168 ^I
matricula	267,9
Desconocido	9
secciones	11,2
Desconocido	9
sondeo_primer	57,3
Desconocido	560
sondeo_segundo	69,5
Desconocido	570
region	
01	4,5 % (189)
02	5,4 % (223)
03	5,0 % (210)
04	5,1 % (213)
05	4,7 % (194)
06	3,6 % (148)
07	3,3 % (138)
08	3,6 % (149)
09	4,9 % (205)
10	5,4 % (224)
11	4,0 % (166)
12	3,7 % (155)
13	3,1 % (131)
14	4,1 % (169)
15	4,2 % (174)
16	3,0 % (125)
17	3,2 % (133)
18	3,8 % (160)
19	2,8 % (118)
20	3,8 % (159)
21	2,8 % (117)
22	3,7 % (153)
23	3,7 % (153)
24	4,7 % (196)
25	4,0 % (166)
ambito	
Urbano	65,4 % (2.727)
Rural Disperso	25,7 % (1.073)
Rural Agrupado	8,8 % (368)

^IMedia; % (n)

Tabla 3.3: Medias de las medias muestrales

Característica	N = 1.000 ¹
matricula	269 (15)
secciones	11,18 (0,49)
sondeo_primer	57,27 (0,95)
sondeo_segundo	69,53 (0,91)
¹ Media (DE)	

que permitan saber si la muestra es de las buenas o de las malas y, si se trata de este último caso, como mejorarlas.

3.2. Muestreo por azar simple

Dentro de los métodos aleatorios el método del azar simple (*random sampling*) es un método tradicional y particularmente útil desde un punto de vista pedagógico para comenzar ya que muchos otros métodos son variaciones (usualmente más complejas) de este. El método del azar simple es el que intuitivamente se ha utilizado en la simulación anterior.


Desde una perspectiva amplia, en la actualidad se podría afirmar que este método de muestreo se encuentra en el medio de un continuo de situaciones en cuando al grado de información exigida para su realización. Lo “único” que pide es una lista de “contactos” de la población que se quiere analizar. La razón por la que “único” se encuentra entre comillas es la siguiente: La necesidad de la una lista puede ser algo exigente en algunas investigaciones (p.e. poblaciones invisibles) aunque algo insuficiente para otras (p.e. diseños con muestras estratificadas). La idea de “contacto” es algo polisémica, pero aquí apunta a que el caso seleccionado se pueda contactar de alguna forma (p.e. dirección de domicilio, mail, celular, etc.) para realizarle las observaciones/mediciones correspondientes.

A continuación vamos a realizar unas 1000 muestras de 300 casos cada una sobre el total de las 4168 escuelas. Esto es una relación entre el tamaño de la población y la muestra de casi el 14 %. Hacemos esta cantidad de muestras para observar la distribución de los valores de las medias de cada muestra y ver si sucede algo similar a lo encontrado en el simulador anterior. Para facilitar la comparación lo haremos solo con las variables numéricas y dejaremos de lado las categóricas como *Ámbito* y *Región*. El resultado de estas simulaciones se puede observar en la Tabla 3.3.

Como se puede comparar entre Tabla 3.2 y Tabla 3.3 los valores entre los parámetros poblacionales y la media de las estimaciones muestrales coincide. No solo eso. También podemos chequear que la distribución de esas medias sigue una distribución aproximadamente normal. Esto es lo que precisamente hacemos en la Figura 3.1.

En la figura anterior se observa que la distribución de las 1000 muestras que tomamos, si

Figura 3.1: Distribución de las medias muestrales



bien se aproximan, no son idénticas a una distribución normal. Seguramente, si haríamos más muestras nos acercariamos aún más a una distribución muestral pero quizá este ejemplo baste para explicitar el siguiente punto: Si haríamos muchas muestras vamos a saber con cierta seguridad que la media de las muestras será aproximadamente similar al parámetro poblacional. Sin embargo, quedan abiertas otras preguntas como ¿Qué sucede si solo tomamos una sola muestra? ¿Cómo sabemos si nuestra (única) muestra es de las buenas o de las malas? ¿Cómo sabemos que nuestra muestra no es alguna de las que están en el extremo izquierdo o derecho de la Figura 3.1?

Ahí es donde entra la ayuda de las librerías específicas. En la introducción se había comentado sobre la existencia de librerías específicas para el análisis de datos muestrales. Estas librerías le van a prestar atención a varios detalles del proceso de selección y nos van a pedir que los explicitemos. Por ejemplo, El tipo de muestras que nos van a interesar generalmente son “sin reemplazo” en el sentido que no queremos que, por ejemplo, un mismo colegio aparezca dos veces seleccionado en una muestra de colegios. También, casi todas las librerías de este estilo, nos van a pedir información de algunos totales de la población para construir ponderadores y otras librerías nos a pedir esos ponderadores utilizarlos en el análisis de los datos. En el caso de una muestra aleatoria simple ese ponderador, al menos en la fase de diseño, suele ser la probabilidad inversa de haber ingresado en la muestra (N/n , donde N es el tamaño de la población y n el tamaño de la muestra). En este tipo de diseño el valor del ponderador es el mismo para todas las unidades seleccionadas.

Ahora que estamos analizando solo una muestra podemos empezar a ver algunas

Tabla 3.4: Estimaciones con azar simple

Característica	Azar simple		Parámetro Pob.
	N = 4.168 ¹	95 % CI	N = 4.168 ²
matricula	276,6 (2,9)	271, 282	267,9
secciones	11,6 (0,1)	11, 12	11,2
sondeo_primerο	56,2 (0,2)	56, 57	57,3
Desconocido	472		560
sondeo_segundo	69,8 (0,2)	69, 70	69,5
Desconocido	556		570
region			
01	2,3 % (n=7)	2,0 %, 2,7 %	4,5 % (189)
02	6,3 % (n=19)	5,8 %, 6,9 %	5,4 % (223)
03	5,3 % (n=16)	4,9 %, 5,8 %	5,0 % (210)
04	7,0 % (n=21)	6,5 %, 7,6 %	5,1 % (213)
05	2,7 % (n=8)	2,3 %, 3,0 %	4,7 % (194)
06	3,7 % (n=11)	3,3 %, 4,1 %	3,6 % (148)
07	3,7 % (n=11)	3,3 %, 4,1 %	3,3 % (138)
08	5,3 % (n=16)	4,9 %, 5,8 %	3,6 % (149)
09	6,7 % (n=20)	6,1 %, 7,2 %	4,9 % (205)
10	6,7 % (n=20)	6,1 %, 7,2 %	5,4 % (224)
11	4,3 % (n=13)	3,9 %, 4,8 %	4,0 % (166)
12	2,3 % (n=7)	2,0 %, 2,7 %	3,7 % (155)
13	2,7 % (n=8)	2,3 %, 3,0 %	3,1 % (131)
14	4,0 % (n=12)	3,6 %, 4,4 %	4,1 % (169)
15	3,3 % (n=10)	3,0 %, 3,7 %	4,2 % (174)
16	2,0 % (n=6)	1,7 %, 2,3 %	3,0 % (125)
17	3,3 % (n=10)	3,0 %, 3,7 %	3,2 % (133)
18	3,0 % (n=9)	2,7 %, 3,4 %	3,8 % (160)
19	2,7 % (n=8)	2,3 %, 3,0 %	2,8 % (118)
20	3,7 % (n=11)	3,3 %, 4,1 %	3,8 % (159)
21	2,0 % (n=6)	1,7 %, 2,3 %	2,8 % (117)
22	4,0 % (n=12)	3,6 %, 4,4 %	3,7 % (153)
23	4,7 % (n=14)	4,2 %, 5,1 %	3,7 % (153)
24	3,0 % (n=9)	2,7 %, 3,4 %	4,7 % (196)
25	5,3 % (n=16)	4,9 %, 5,8 %	4,0 % (166)
ambito			
Urbano	67,0 % (n=201)	66 %, 68 %	65,4 % (2.727)
Rural Disperso	20,3 % (n=61)	19 %, 21 %	25,7 % (1.073)
Rural Agrupado	12,7 % (n=38)	12 %, 13 %	8,8 % (368)
Desconocido			9
Desconocido			9

¹Media (SE); % (n=n (unweighted))

²Media; % (n)

15

Abreviacion: CI = Intervalo de confianza

distancias entre los parámetros poblacionales y las estimaciones que surgen de la muestra. Esto es especialmente más notorio en los casos de las categorías menos difundidas de las variables categóricas como puede ser algunas de las regiones.

3.3. Muestreo Sistemático

El muestreo sistemático no ofrece muchas diferencias apreciables de cálculo con el azar simple aunque tiene una diferencia logística importante. No es necesario tener en el momento del diseño una lista centralizada de “contactos” a quien seleccionar. Esto hace que el muestreo sistemático, especialmente en muestras polietápicas, sea un buen candidato a aplicar en las últimas instancias de selección en donde cada encuestador, de manera descentralizada, sí tiene acceso, *in situ*, a esa información. Es importante, de todos modos, suponer que la lista en cuestión no esconda un sesgo particular en su orden o, ante esta presuposición, poder reordenarla bajo algún criterio que fuerce el azar.

Como ejemplo podemos analizar la siguiente situación. Se quiere realizar una muestra de estudiantes y a) no se cuenta con información nominal en el momento del diseño de la muestra aunque b) sí se cuenta con una buena base de los colegios y c) se asume que dentro de cada colegio sí existe acceso a una lista de contactos de los estudiantes. En este contexto, se puede sortear una cantidad de colegios en una primera etapa y luego, en una segunda etapa, se puede indicar al directivo, encuestador, etc. de cada escuela seleccionada que, una vez con acceso a la lista de estudiantes, seleccione una X cantidad de los mismos. Para realizar esa última selección el proceso será sortear al primer estudiante, seleccionarlo y luego, desde allí, saltar K estudiantes para seleccionar al segundo estudiante y así sucesivamente. En general, K representa el cociente entre el tamaño de la población a seleccionar N como el tamaño de la lista de estudiantes del colegio seleccionado y el tamaño de la muestra n como la cantidad de estudiantes que se quiere seleccionar de esa lista.

$$K = \frac{N}{n}$$

Siguiendo este ejemplo, supongamos que el encuestador tenga que elegir 5 estudiantes de una lista de 50. En ese caso se podría aplicar siguiente código:

Cambiando lo que haya que cambiar, el código anterior también se podría aplicar si se quiere utilizar para seleccionar los 300 establecimientos que antes se habían seleccionado con el diseño del azar simple.

3.4. Muestreo Estratificado

El muestreo estratificado es un tipo de muestreo que se realiza sobre la base de estratos que, en principio, cumplen el criterio de que sean parecidos en su interior y diferentes entre ellos. Otra característica distintiva de los estratos es que estos son discretos, esto es, pueden tener a lo sumo un orden entre ellos, pero los límites entre ellos son puntuales más que continuos.

Si se recuerda los comentarios realizados en la introducción, cuanto menos heterogeneidad exista entre las unidades a seleccionar menor es el problema de la representatividad. Esto es precisamente lo que intenta aprovechar la idea del muestreo estratificado. En el extremo, si todos los miembros de cada estrato son iguales entre sí y los tamaños de cada estrato también son iguales entre sí, solo habría que seleccionar a un caso por estrato como razón suficiente para obtener una muestra representativa de la población. Si los tamaños de los estratos fueran diferentes también se podría seleccionar un caso por estrato, pero la condición para que esta muestra sea representativa es que luego se incluyan ponderadores diferentes para cada estrato de la muestra en función de la inversa de la probabilidad de entrar en la muestra.

Para que el muestreo estratificado produzca ventajas (en comparación con el azar simple) los estratos deben tener una heterogeneidad interna menor a la heterogeneidad del conjunto de la población aunque aquella se encuentre lejos del ejemplo extremo del párrafo anterior. Los estratos son variables discretas que conforman subpoblaciones mutuamente excluyentes y exhaustivas de toda población aunque se pueden construir los mismos en función de datos categóricos, continuos (p.e. agrupaciones de años de antigüedad) o espaciales (p.e. Regiones). En una base de datos educativa puede haber muchas variables que pueden ser considerados como estratos. En este caso, a modo de ejemplo, nos quedaremos con “Ámbito” que posee 3 categorías que asumimos, como diría Platón en el Fedro, que cortan la realidad por sus articulaciones naturales (Platón 2002 [370AVC], pág. 55). Por otro lado, utilizar “Ámbito” como estrato tiene otra virtud pedagógica que deviene de la diferente distribución de cada categoría. Esto lo hace un buen candidato para mostrar la utilidad del muestreo estratificado en su versión proporcional y no proporcional ya que la categoría “Rural Agrupado” posee un menor porcentaje de casos y, a igualdad de otras condiciones, eso dificulta su posterior análisis.

Usualmente los estratos se construyen con base en antecedentes teóricos, pero nada impide que estos sean constructos estadísticos con un significado no muy claro como los que se pueden producir luego de un análisis de clústers. Tampoco la técnica tiene una limitación en cuanto a la cantidad de categorías.

	Estratificado Proporcional	Estratificado no Proporcional
Estratos Teóricos	Estrato teórico (p.e. Ámbito) con probabilidad proporcional	Estrato teórico (p.e. Ámbito) con probabilidad no proporcional
Estratos Empíricos	Estrato estadístico con probabilidad proporcional	Estrato estadístico con probabilidad no proporcional

3.4.1. Estratos teóricos con asignación proporcional

En este subtipo de muestreo estratificado utilizaremos la variable “Ámbito” como estrato y respetaremos, aproximadamente, la distribución que ese estrato posee en la

población. Decimos “aproximadamente” porque aquí siempre existe un factor de redondeo que deviene de la necesidad de realizar la muestra sobre una cantidad de casos discretos. Esta última necesidad hace que, al igual que cuando se intenta respetar las proporciones de los votos de una elección para la renovación de bancas de la Cámara de Diputados, casi siempre existan pequeñas diferencias entre las proporciones poblacionales y las muestrales.

Seleccionada la muestra ahora le especifico los detalles del diseño mediante la librería `survey` o `srvyr`.

Y luego realizo la Tabla 3.5 con la información de algunas variables y esa misma tabla lo comparo con los valores de la Tabla 3.4 que refería al diseño con azar simple.

3.4.2. Estratos teóricos con asignación no proporcional

En el tipo de diseño anterior hubo una variable (Ámbito) que se usó para estratificar la muestra. En ese caso, salvo variaciones menores debido a los factores de redondeo antes comentados, las proporciones de la muestra respetan las proporciones poblacionales. Eso es lo que precisamente se intenta modificar con el muestreo teórico con una asignación no proporcional. Usualmente, la idea que está detrás de esta estrategia es poder incrementar la cantidad de casos en aquellas categorías de los estratos que tienen una escasa de cantidad de casos para luego usarlos como dominios de estimación². Si se respeta la proporción y existen categorías que poseen una distribución muy baja, nos vamos a quedar con pocos casos y con un alto error estándar en esos análisis. Aquí, para extremar esta lógica, vamos a realizar una muestra como si la distribución de la variable Ámbito fuera igual para sus 3 categorías.

3.5. Muestreo por Clústers

El muestreo por clúster es otra manera de aplicar el azar para diseñar muestras. A diferencia del muestreo estratificado en el muestreo por clúster el investigador considera a estos como “racimos” de casos que, usualmente, se encuentran cercanos geográficamente pero no necesariamente socialmente o, más en general, no son homogéneos en las variables de estudio. En efecto, la ventaja de este tipo de muestreo es que abarata costos en la ejecución de muestras espacialmente extensas y especialmente si en ese espacio extenso hay numerosos racimos de casos como, por ejemplo, una multitud de pequeños poblados urbanos de 50.000 personas. El precio que usualmente se paga (a igual cantidad de casos) es un aumento en el error standard pero, justamente, el quid de la cuestión es que dado la baja del costo unitario de cada caso ahora es posible, con igual presupuesto, agregar más casos a la muestra para bajar la precisión hasta el valor deseado.

²Un dominio o subclase de estimación es una partición de la población o de la muestra sobre la cual se espera realizar inferencias. A veces se usa la denominación que los dominios denotan subpoblaciones (de la población) y las subclases reflejan esas divisiones en la muestra (Kish 1980, 209). En cualquier caso es conveniente introducir estos dominios en el diseño de la muestra para poder controlar su tamaño poblacional (Brus 2022, cap. 14).

Tabla 3.5: Tablas comparativas entre resultados azar simple y estratificado

Característica	Estratificado P.		Azar simple	
	N = 4.168 ¹	95 % CI	N = 4.168 ¹	95 % CI
matricula	262,3 (1,9)	258, 266	276,6 (2,9)	271, 282
Desconocido	28			
secciones	10,9 (0,1)	11, 11	11,6 (0,1)	11, 12
Desconocido	28			
sondeo_primer	57,9 (0,2)	58, 58	56,2 (0,2)	56, 57
Desconocido	712		472	
sondeo_segundo	69,8 (0,2)	69, 70	69,8 (0,2)	69, 70
Desconocido	572		556	
region				
01	2,7 % (n=8)	2,3 %, 3,0 %	2,3 % (n=7)	2,0 %, 2,7 %
02	6,3 % (n=19)	5,8 %, 6,9 %	6,3 % (n=19)	5,8 %, 6,9 %
03	6,3 % (n=19)	5,8 %, 6,9 %	5,3 % (n=16)	4,9 %, 5,8 %
04	6,3 % (n=19)	5,8 %, 6,9 %	7,0 % (n=21)	6,5 %, 7,6 %
05	4,6 % (n=14)	4,2 %, 5,1 %	2,7 % (n=8)	2,3 %, 3,0 %
06	4,0 % (n=12)	3,6 %, 4,4 %	3,7 % (n=11)	3,3 %, 4,1 %
07	4,3 % (n=13)	3,9 %, 4,8 %	3,7 % (n=11)	3,3 %, 4,1 %
08	3,3 % (n=10)	3,0 %, 3,7 %	5,3 % (n=16)	4,9 %, 5,8 %
09	4,0 % (n=12)	3,6 %, 4,4 %	6,7 % (n=20)	6,1 %, 7,2 %
10	4,0 % (n=12)	3,6 %, 4,5 %	6,7 % (n=20)	6,1 %, 7,2 %
11	2,7 % (n=8)	2,3 %, 3,0 %	4,3 % (n=13)	3,9 %, 4,8 %
12	3,0 % (n=9)	2,7 %, 3,4 %	2,3 % (n=7)	2,0 %, 2,7 %
13	3,7 % (n=11)	3,3 %, 4,1 %	2,7 % (n=8)	2,3 %, 3,0 %
14	5,0 % (n=15)	4,6 %, 5,5 %	4,0 % (n=12)	3,6 %, 4,4 %
15	4,4 % (n=13)	3,9 %, 4,8 %	3,3 % (n=10)	3,0 %, 3,7 %
16	2,3 % (n=7)	2,0 %, 2,7 %	2,0 % (n=6)	1,7 %, 2,3 %
17	5,0 % (n=15)	4,6 %, 5,5 %	3,3 % (n=10)	3,0 %, 3,7 %
18	5,0 % (n=15)	4,6 %, 5,5 %	3,0 % (n=9)	2,7 %, 3,4 %
19	2,3 % (n=7)	2,0 %, 2,7 %	2,7 % (n=8)	2,3 %, 3,0 %
20	4,0 % (n=12)	3,6 %, 4,5 %	3,7 % (n=11)	3,3 %, 4,1 %
21	1,3 % (n=4)	1,1 %, 1,6 %	2,0 % (n=6)	1,7 %, 2,3 %
22	4,7 % (n=14)	4,3 %, 5,2 %	4,0 % (n=12)	3,6 %, 4,4 %
23	5,0 % (n=15)	4,6 %, 5,5 %	4,7 % (n=14)	4,2 %, 5,1 %
24	2,7 % (n=8)	2,3 %, 3,0 %	3,0 % (n=9)	2,7 %, 3,4 %
25	3,0 % (n=9)	2,7 %, 3,4 %	5,3 % (n=16)	4,9 %, 5,8 %
ambito				
Urbano	65,4 % (n=197)	65 %, 65 %	67,0 % (n=201)	66 %, 68 %
Rural Disperso	25,7 % (n=77)	26 %, 26 %	20,3 % (n=61)	19 %, 21 %
Rural Agrupado	8,8 % (n=26)	8,8 %, 8,8 %	12,7 % (n=38)	12 %, 13 %

¹Media (DE); % (n sin ponderar)

Abreviacion: CI = Intervalo de confianza

Tabla 3.6: Tablas comparativas entre muestra estratificada proporcional y no proporcional

Característica	Estratificado P		Estratificado no P	
	N = 4.168 ¹	95 % CI	N = 4.168 ¹	95 % CI
matricula	262,3 (1,9)	258, 266	271 (2)	267, 275
Desconocido	28		38	
secciones	10,9 (0,1)	11, 11	11 (0)	11, 11
Desconocido	28		38	
sondeo_primero	57,9 (0,2)	58, 58	57 (0)	57, 58
Desconocido	712		577	
sondeo_segundo	69,8 (0,2)	69, 70	70 (0)	69, 70
Desconocido	572		533	
region				
01	2,7 % (n=8)	2,3 %, 3,0 %	4,2 % (n=14)	3,8 %, 4,6 %
02	6,3 % (n=19)	5,8 %, 6,9 %	3,9 % (n=6)	3,5 %, 4,4 %
03	6,3 % (n=19)	5,8 %, 6,9 %	4,6 % (n=7)	4,2 %, 5,0 %
04	6,3 % (n=19)	5,8 %, 6,9 %	8,5 % (n=13)	7,9 %, 9,1 %
05	4,6 % (n=14)	4,2 %, 5,1 %	6,6 % (n=11)	6,1 %, 7,2 %
06	4,0 % (n=12)	3,6 %, 4,4 %	6,4 % (n=11)	5,9 %, 6,9 %
07	4,3 % (n=13)	3,9 %, 4,8 %	3,3 % (n=5)	2,9 %, 3,7 %
08	3,3 % (n=10)	3,0 %, 3,7 %	2,0 % (n=3)	1,7 %, 2,3 %
09	4,0 % (n=12)	3,6 %, 4,4 %	3,9 % (n=6)	3,5 %, 4,4 %
10	4,0 % (n=12)	3,6 %, 4,5 %	5,6 % (n=20)	5,1 %, 6,1 %
11	2,7 % (n=8)	2,3 %, 3,0 %	4,0 % (n=7)	3,6 %, 4,5 %
12	3,0 % (n=9)	2,7 %, 3,4 %	1,5 % (n=7)	1,2 %, 1,7 %
13	3,7 % (n=11)	3,3 %, 4,1 %	3,5 % (n=15)	3,1 %, 4,0 %
14	5,0 % (n=15)	4,6 %, 5,5 %	4,0 % (n=19)	3,6 %, 4,4 %
15	4,4 % (n=13)	3,9 %, 4,8 %	4,3 % (n=24)	3,9 %, 4,7 %
16	2,3 % (n=7)	2,0 %, 2,7 %	2,7 % (n=12)	2,4 %, 3,1 %
17	5,0 % (n=15)	4,6 %, 5,5 %	4,4 % (n=15)	4,0 %, 4,8 %
18	5,0 % (n=15)	4,6 %, 5,5 %	3,5 % (n=12)	3,2 %, 4,0 %
19	2,3 % (n=7)	2,0 %, 2,7 %	2,6 % (n=6)	2,2 %, 2,9 %
20	4,0 % (n=12)	3,6 %, 4,5 %	3,0 % (n=9)	2,7 %, 3,4 %
21	1,3 % (n=4)	1,1 %, 1,6 %	2,1 % (n=7)	1,8 %, 2,4 %
22	4,7 % (n=14)	4,3 %, 5,2 %	3,1 % (n=13)	2,8 %, 3,5 %
23	5,0 % (n=15)	4,6 %, 5,5 %	4,6 % (n=26)	4,1 %, 5,0 %
24	2,7 % (n=8)	2,3 %, 3,0 %	5,8 % (n=22)	5,3 %, 6,3 %
25	3,0 % (n=9)	2,7 %, 3,4 %	2,1 % (n=10)	1,8 %, 2,4 %
ambito				
Urbano	65,4 % (n=197)	65 %, 65 %	65 % (n=100)	65 %, 65 %
Rural Disperso	25,7 % (n=77)	26 %, 26 %	26 % (n=100)	26 %, 26 %
Rural Agrupado	8,8 % (n=26)	8,8 %, 8,8 %	8,8 % (n=100)	8,8 %, 8,8 %

¹Media (DE); % (n sin ponderar)

Abreviacion: CI = Intervalo de confianza

3.6. Muestreo Proporcional al tamaño (PPS)

Muchas veces, especialmente en diseños polietápicos, se desea que en la primera etapa las unidades de selección sean escogidas en función de alguna variable que sirva como indicador de su tamaño. Esta técnica se suele denominar muestreo proporcional al tamaño (PPS)³ y puede considerarse como un caso especial del muestreo por clústers (Lumley 2010, pág. 46). En el caso de unidades geográficas esa variable podrá ser el tamaño espacial o área (p.e. km^2) y en variables no espaciales podrá ser la cantidad de personas (p.e. votantes en distritos). En el caso de una muestra de colegios, variables como el tamaño de la matrícula pueden ser buenas candidatas a utilizar en este tipo de muestras. Sin embargo, esto, por diseño, va a otorgar una mayor probabilidad de salir en la muestra a los colegios con mayor matrícula y estos pueden poseer características particulares como, por ejemplo, encontrarse abrumadoramente en ámbitos urbanos. De este modo ya podemos intuir que, con respecto a la población de establecimientos, una muestra PPS (sin ponderar) obtendrá como resultado un valor de la matrícula mayor y una sobrerrepresentación de los **establecimientos** de ámbito urbano aunque no necesariamente de los **estudiantes** de ámbito urbano. Esto último depende, especialmente en un diseño polietápico, que se haga después de haber realizado la selección primaria, esto es, que se haga después de la primera etapa.

A pesar de cierta idea intuitiva acerca del objetivo del muestreo PPS, su efectiva aplicación (especialmente en muestreos sin reemplazo) tiene sus complejidades a nivel de los algoritmos a utilizar. Esto en parte es algo compartido por todos los muestreos sin reemplazo (versus los con reemplazos) pero aquí está presente la dificultad adicional de que las probabilidades de inclusión son diferentes. En efecto, el muestreo PPS puede ser considerado como un tipo de muestreo con probabilidades de inclusión diferentes (*unequal probabilities*) pero con la particularidad que esas probabilidades diferentes se calculan en función del tamaño de las unidades a seleccionar en primera instancia. A continuación vamos a utilizar un algoritmo que tiene que ver con la idea de “*local pivotal*” que vamos a ver con mayor profundidad cuando veamos las muestras bien dispersas (Sección 4.3)⁴.

Para visualizar esto vamos primero vamos a construir a realizar 2 ejemplos. Uno en donde se realiza un PPS en donde luego solo se expande por un ponderador que simula que todos los establecimientos tenían las mismas chances de haber entrado (o, expresado de otro modo, que expande pero no pondera) y otro en donde, a esa misma muestra, se la pondera por la probabilidad inversa de haber ingresado en la muestra, esto es, un ponderador que haga pesar menos a aquellos establecimientos con mayor tamaño. Siguiendo con el ejemplo de los colegios, si el proceso es seleccionar los colegios por tamaño y luego realizar un censo (esto es, ninguna muestra) de estudiantes dentro de cada uno de los colegios seleccionados, tanto los colegios como los estudiantes de ámbito

³La sigla PPS viene de la expresión “**P**robability **P**roportional to **S**ize” que es como se lo conoce en la bibliografía de muestreo.

⁴Existen otros algoritmos para realizar un muestreo PPS. Muchos de ellos son algoritmos especializados en probabilidades desiguales (en donde la desigualdad por tamaño sería un caso especial) por lo que muchos de sus nombres suelen empezar con UP (*unequal probabilities*). Algunos son los siguientes: UPtillé, UPpivotal, UPpoisson (Tillé y Matei 2023).

urbano se encontrarán sobrerrepresentados por lo que un ponderador que tenga en cuenta las probabilidades inversas en función del tamaño puede ser útil.

En efecto, en la Tabla 3.7 puede observarse que si trabajamos en una muestra PPS solo expandiendo pero sin ponderar (primera tabla desde la izquierda) vemos como el valor promedio de la matrícula es alto (529) y que la abrumadora mayoría de los establecimientos seleccionados son del ámbito urbano (95 %). Si luego analizamos la muestra ponderada por la probabilidad inversa en función del tamaño vemos como la mayoría de los valores se acercan a los valores conocidos de la población, especialmente aquellos que refieren a propiedades intrínsecas de los establecimientos como la región y el ámbito. Sin embargo, esta operación tiene sus riesgos porque hace depender mucho al ponderador de la matrícula y esta puede ser sumamente heterogénea. Por poner un ejemplo, en el muestreo PPS fueron seleccionados 5 establecimientos de la región 25 que es una región que se caracteriza por tener un porcentaje de establecimientos rurales mayor a la media (alrededor de 40 % son urbanos). Pero dado que en el PPS los establecimientos más grandes tienen más chances de entrar en la muestra se seleccionaron 4 establecimientos urbanos (con matrícula típica de ámbitos urbanos) y solo 1 de ámbito rural. En este contexto el ponderador luego hace que esos 4 pesen menos y que ese único establecimiento rural (que tiene una matrícula de 7 estudiantes) pese mucho más que lo que descuentan los 4 urbanos. El resultado es que la región 25, cuando se trabaja con el ponderador, salta desde un 1,7 % sin ponderar hasta un 14 % ponderado. Algo similar sucede con la región 18. Por esta razón, es interesante también observar que en muchos casos el intervalo de confianza con la muestra ponderada se expande (p.e. región 18 y 25). Esto se debe a que el ponderador ahora hace pesar más en la estimación a situaciones en donde se encuentran pocos casos y, por lo tanto, al estar basadas en menos casos esas estimaciones poseen un margen de error mayor.

Si en cambio, luego en una segunda etapa, se realiza un muestro de una cantidad fija (p.e. 10 estudiantes por colegio seleccionado) la muestra de colegios sin ponderar seguirá sobrerrepresentando a los **establecimientos** del ámbito urbano pero tiene muchas chances de representar aceptablemente a la población de **estudiantes**. Esto último justamente puede ser algo buscado explícitamente si se utiliza la selección de los colegios como unidades de selección primarias y luego a los estudiantes como unidades de selección secundaria o final. En otras palabras, se trata de un efecto buscado por diseño, justamente porque ahora el objetivo está puesto en lograr una muestra representativa de la población de estudiantes a través de una población de establecimientos que contiene variables agregadas de los estudiantes.

Para fijar las ideas, en el ejemplo anterior se seleccionarían en primera instancia unos 300 establecimientos, luego se obtendría una muestra final de 3000 estudiantes porque en la segunda instancia se seleccionaron 10 estudiantes por establecimiento. Una virtud práctica de este último ejemplo es que, aparte de reducir costos de logística en comparación a un muestreo por azar simple de un solo paso, es que otorga un mismo ponderador a cada caso seleccionado lo que facilita algunos análisis posteriores. Esto es un típico ejemplo de muestra compleja en donde la muestra se realiza en más de una etapa y en cada una de ellas se utilizan técnicas diferentes.

En relación con lo anterior y de manera aparentemente paradójica, la muestra PPS

Tabla 3.7: Tablas comparativas entre PPS con ponderador y sin ponderador

Característica	PPS expandida pero no ponderada	PPS ponderada por PI en fu	95
	N = 4.159 ¹	N = 4.012 ¹	
matricula	529,5 (2,90)	277,7 (9,08)	26
secciones	19,7 (0,08)	11,6 (0,34)	1
sondeo_primer	54,1 (0,13)	58,6 (1,12)	5
Desconocido	83	153	
sondeo_segundo	67,9 (0,12)	74,2 (0,65)	7
Desconocido	97	678	
region			
01	6,3 % (n=19)	4,7 % (n=19)	4,2 %
02	7,0 % (n=21)	4,5 % (n=21)	4,0 %
03	9,7 % (n=29)	5,5 % (n=29)	5,0 %
04	13,7 % (n=41)	7,6 % (n=41)	6,9 %
05	7,0 % (n=21)	3,4 % (n=21)	3,0 %
06	3,7 % (n=11)	3,3 % (n=11)	2,9 %
07	2,7 % (n=8)	2,6 % (n=8)	2,2 %
08	5,7 % (n=17)	2,8 % (n=17)	2,5 %
09	11,3 % (n=34)	4,9 % (n=34)	4,4 %
10	5,0 % (n=15)	4,1 % (n=15)	3,6 %
11	5,0 % (n=15)	3,6 % (n=15)	3,1 %
12	2,0 % (n=6)	3,5 % (n=6)	2,8 %
13	1,3 % (n=4)	3,9 % (n=4)	3,0 %
14	3,0 % (n=9)	2,3 % (n=9)	1,9 %
15	2,3 % (n=7)	3,4 % (n=7)	2,8 %
16	0,0 % (n=0)	0,0 % (n=0)	0,00 %
17	0,7 % (n=2)	1,3 % (n=2)	0,95 %
18	3,7 % (n=11)	14,6 % (n=11)	11 %
19	1,3 % (n=4)	1,2 % (n=4)	0,98 %
20	1,3 % (n=4)	1,6 % (n=4)	1,2 %
21	1,3 % (n=4)	1,7 % (n=4)	1,3 %
22	2,3 % (n=7)	1,6 % (n=7)	1,3 %
23	1,3 % (n=4)	3,9 % (n=4)	3,1 %
24	0,7 % (n=2)	0,4 % (n=2)	0,33 %
25	1,7 % (n=5)	14,0 % (n=5)	10 %
ambito			
Urbano	95,3 % (n=286)	62,1 % (n=286)	58 %
Rural Disperso	1,7 % (n=5)	25,2 % (n=5)	21 %
Rural Agrupado	3,0 % (n=9)	12,7 % (n=9)	11 %

¹Media (EST); % (n sin ponderar)

Abreviacion: CI = Intervalo de confianza

Tabla 3.8: Medias de las notas según tipo de muestra y población

Característica	PPS sin ponderar	Pob. media ponderada	Pob. media sin ponderar
sondeo__primero	54	54	57
sondeo__segundo	68	68	70

sin ponderar estima mejor las variables agregadas como el valor del primer y segundo sondeo que un análisis censal de toda la población de colegios (como se hizo en Tabla 3.2). Lo paradójico de esto es que una muestra, esto es, una parte de un todo, logre un mejor acercamiento a un respectivo parámetro poblacional que un censo, esto es, un registro de cada una de las partes del todo. La solución a esta paradoja es entender que la Tabla 3.2 hace referencia a la población de colegios y, en ese sentido, sus valores son correctos. Ahora bien, si con esos datos (censales, pero de la población de establecimientos) se quiere hacer afirmaciones sobre la población de estudiantes la información de la Tabla 3.2 no es la más idónea o al menos hay que tratarla de manera diferente. En las variables que se pueden considerar como variables agregadas de estudiantes (p.e. sondeo__primero, sondeo__segundo) más que calcular la media habría que haber calculado la media ponderada por matrícula y ese cálculo sería un mejor estimador de la media de las notas de la población de estudiantes. En ese caso, el resultado de ese cálculo sí se podría considerar como un parámetro de la población de estudiantes y contra esos valores se debería comparar las estimaciones del diseño PPS sin ponderar. Esto precisamente se puede observar en la Tabla 3.8.

4 Muestreos balanceados y bien distribuidos

```
library(here)
library(readxl)
library(janitor)
library(tidyverse)
library(gt)
library(sampling)
library(gtsummary)
library(infer)
library(patchwork)
library(srvyr)
library(survey)
library(cardx)
library(downloadthis)
library(ggplot2)
library(sampling)
library(gstat)
library(sf)
library(tmap)
library(BalancedSampling)

i_am("cubo.qmd")

theme_gtsummary_language(
  language = "es",
  decimal.mark = ",",
  big.mark = ".")
```

4.1. Muestras Balanceadas (por el método del cubo)

Las muestras balanceadas son un método particular dentro del espectro de las técnicas disponibles en la que felizmente se juntan las potencialidades del enfoque del “*Design Based*” y del “*Model Assisted*”. Este tipo de técnica permite diseñar muestras balanceadas en el sentido que las medias muestrales de las covariables sean (aproximadamente) iguales a las medias poblacionales de esas covariables. Esto, como mínimo, es una estrategia efectiva para evitar caer en el pequeño subconjunto de muestras aleatorias que son muy

sesgadas (Tillé 2011, pag. 221). En este sentido, se recuerda que cuando realizamos diseños por azar tenemos chances (si bien bajas) de obtener muestras muy sesgadas. El muestreo balanceado evita esta situación y, la mayoría de las veces (siempre que las covariables estén empíricamente relacionadas con las variables de estudio) suele ofrecer muestras con las que luego es posible realizar una estimación con una mayor precisión que el azar simple. Si se agregan más covariables al diseño y, nuevamente, estas se encuentran linealmente relacionadas con las variables de estudio, el estimador de la media poblacional también mejorará aún más su precisión.¹

Lo anterior puede considerarse un viejo *desideratum* de los diseños muestrales aunque antes no había disponible algún algoritmo de cálculo aplicable de una manera generalizable y precisa que pudiera ser ejecutado o calculado de manera viable (Deville y Tillé 2004). Eso es lo que precisamente logra el método del cubo. De manera alternativa, las muestras balanceadas pueden ser vistas como un tipo de calibración (Capítulo 5) integrada en el diseño de la muestra más que a la estimación de los estimadores (Tillé 2011, pag. 216).

Por lo tanto, el contexto actual de:

- a) un mayor acceso a fuentes secundarias de datos y
- b) una mayor capacidad computacional,

parece ser un contexto particularmente propicio para la aplicación y difusión de este tipo de diseños porque, justamente, se trata de un diseño demandante en cuanto a datos secundarios (en forma de información auxiliar o covariables) y demandante con respecto a recursos computacionales (para ejecutar el algoritmo del método del cubo).

Antes de pasar a la aplicación de este diseño con la base de establecimientos de nivel primario vamos a considerar un ejemplo trivial con variables espaciales en donde se puede simular fácilmente la linealidad de la variable de estudio con respecto a otras covariables. Esto también servirá como un anticipo para cuando intentaremos incorporar explícitamente variables espaciales (a través de coordenadas) en la muestra (Sección 4.3).²


Supongamos una población como un bosque en donde tenemos alguna variable continua que nos interesa investigar. Supongamos además que, a efectos pedagógicos, nosotros sabemos la distribución de esa variable y, para forzar el pensamiento espacial, vamos a suponer que esa variable continua es una representación de la densidad de la vegetación de cada celda de una grilla de coordenadas. El valor de esa densidad lo vamos a visualizar indicando un valor amarillo para sus valores más altos y azul para sus valores más bajos. Con respecto a la grillas que representan distintas partes del bosque se las puede ubicar con un valor en el eje “Hacia el Norte” y otro valor en el eje “Hacia el Este”.

¹Más adelante veremos que indagar sobre la precisión de la estimación es posible pero difícil en las muestras realizadas con el método del cubo. Por esta razón, si bien es posible comparar la precisión de estas muestras contra, por ejemplo, el muestreo por azar simple, acá se tomará como un supuesto y se remite al lector a fuentes en donde se prueba lo anterior [Brus (2022), cap. 9](Schneider 2024). El principal problema es que, por ahora, las librerías de análisis de datos de encuestas (p.e. survey) todavía no tienen el instrumental adecuado para especificar este tipo de diseños y, por lo tanto, para calcular la precisión de sus estimaciones.

²El ejemplo y el respectivo código fue adaptado del libro “Spatial sampling with R” (Brus 2022).

Este ejemplo espacial es útil porque permite construir y visualizar fácilmente la linealidad de las covariables o variables auxiliares (“Hacia el Norte” y “Hacia el Este”) con la variable de estudio (“Densidad de la vegetación”). En el caso de la Figura 4.1 se observa como a medida que vamos hacia el Norte la vegetación es algo más espesa. Lo mismo puede decirse en cuanto si vamos hacia el Este. En este sentido, el valor más alto de densidad se encuentra en la intersección de los valores más altos de los ejes anteriores o, expresado de manera alternativa, en el cuadrante superior derecho de la población. Esto quiere decir que estas variables auxiliares se encuentran empíricamente relacionadas de **forma lineal** con el valor de la densidad de vegetación.

Figura 4.1: Muestra balanceada ‘Hacia el Este’ (E) y ‘Hacia el Este y el Norte’ (E y N)



Por otro lado, en la Figura 4.1 también se observan 2 muestras balanceadas de la población descrita en el párrafo anterior. Cada una de 4 casos cada una representadas por los cuadrados blancos. La de la izquierda se encuentra balanceada solamente por el eje “Hacia el Este” y, acorde con esto, los casos seleccionados se esparcen de Este al Oeste. La muestra de la derecha, en cambio, se encuentra balanceada por ambos ejes por lo que la distribución de los casos seleccionados no sólo varían de Esta a Oeste sino que también lo hacen de Norte a Sur. En este sentido específico, se puede afirmar que la segunda muestra es más balanceada que la primera y, de manera intuitiva, se puede afirmar que aquella es más representativa que esta.

4.2. Muestras Balanceadas sobre base de establecimientos

Ahora pasaremos a aplicar este diseño a la base de escuelas que venimos trabajando. Esta vez vamos a incorporar una mayor cantidad de información secundaria que se encuentra disponible en la base de establecimientos. Como en muchas otras técnicas, la introducción de más variables no es garantía de un mejor resultado ya que en este caso la agregación de más variables, especialmente si no están linealmente relacionadas con las variables de estudio, puede ser contraproducente (Tillé 2011, pag. 222). Ese es precisamente una de las utilidades del ejemplo anterior de la Figura 4.1 ya que en él era fácil construir y visualizar la linealidad de la relación entre las covariables y la variable de estudio. Por esta razón, en este proceso de selección es importante recordar cual/es van a ser las variables de estudio para luego examinar cuales covariables, de las variables disponibles como información secundaria, es conveniente utilizar.

En este caso, nos focalizaremos en diferentes tipos de objetivos para demostrar la flexibilidad de la técnica. En primer lugar nos interesará tener una muestra de los establecimientos desde la base de los establecimientos (Sección 4.2.1) y luego una muestra de los estudiantes desde esa misma base (Sección 4.2.2).

Las lista de covariables que serán incluidas, con fines más metodológicos que teóricos, serán las siguientes:

- Matrícula
- Secciones
- Región
- Ámbito

La lista anterior funciona a modo de ejemplo aunque tiene la virtud de trabajar con información secundaria casi completa ya que se trata de variables con muy baja tasa de no respuesta. En efecto, aquí usaremos estas covariables tanto cuando nos interese averiguar características de los establecimientos como de los estudiantes pero un análisis más real implicaría usar un conjunto diferente para cada muestra porque al ser diferentes las variables de estudio también podrían/deberían ser las covariables seleccionadas.

Dicho lo anterior parece pertinente el siguiente comentario. Cuando algunos establecimientos no tienen datos en algunas de las covariables utilizadas estos no forman parte de la muestra. Esto recuerda algo que se había comentado cuando se vio el muestreo por azar simple (Sección 3.2). El muestreo por azar simple sólo exige una lista (y/o algún dato que luego permita su contacto empírico) de los miembros de la población. El método del cubo exige, además, el acceso a otras variables de la población en cuestión en forma de información auxiliar. Si existen casos que no tienen esa información, estos no podrán ingresar a la muestra y esto tiene diferentes tipos de consecuencias.

La primera consecuencia es que el investigador se puede enfrentar a la disyuntiva sobre si se prefiere usar covariables completas (en el sentido que no tienen casos faltantes) pero con una menor relación con la/s variable/s de estudio o covariables incompletas pero más

fuertemente relacionadas con estas últimas. Siempre pensando en casos algo extremos, en el primer caso el balanceo será efectivo pero quizá contraproducente porque balanceará la muestra con variables que no se encuentran empíricamente relacionadas con la variable de estudio. En el segundo caso se aumentan los problemas de cobertura (*undercoverage error*) y se disminuye la precisión de la muestra por trabajar con menos casos.

Para poner un ejemplo, las variables “sondeo_primer” y “sondeo_segundo” podrían ser opciones como covariables (siempre igual dependiendo de que se quiera investigar) pero tienen una alta tasa de no respuesta o de dato faltante (+ de 550 casos). Y parece ser que esta ausencia de datos se distribuye de manera desigual entre la población de los establecimientos, ya que los mismos se concentran en establecimientos con una matrícula de menos de 10 estudiantes. En este caso su uso como covariables generaría un sesgo (*bias*) muestral por el problema de la falta de cobertura porque los casos que integran la muestra (p.e. Ámbito Urbano) son diferentes a los que no integran (p.e. Ámbitos Rurales). En otras palabras, la ausencia de datos no es aleatoria por lo que los van a quedar dentro de la muestra serán, por diseño, diferentes a los que quedaran fuera de la misma.³

4.2.1. Muestra Balanceada - Población Establecimientos

En esta primera aplicación del muestreo del cubo con la base de establecimientos vamos a tener como objetivo tener una muestra de la población de establecimientos y no, por ejemplo, de los estudiantes. En el primer caso, en principio, las probabilidades de inclusión son iguales para cada establecimiento. Como veremos más adelante (Sección 4.2.2) esta técnica también permite realizar muestras con diferentes probabilidades de inclusión.

```
base = read_rds(here("Outputs", "base.rds"))

# Es importante que se puedan convertir a numeros las categorias de las variables. Esto :

tb = base |>
select(matricula, secciones, sondeo_primer, sondeo_segundo, ambito, region, clave) |>
drop_na(matricula, secciones, ambito, region) |>
rowid_to_column() |>
mutate(ambito_n = case_when(
  ambito == "Urbano" ~ 1,
  ambito == "Rural Disperso" ~ 2,
  ambito == "Rural Agrupado" ~ 3))
```

³En este sentido, más que nada por razones pedagógicas, aquí se han elegido como covariables, un conjunto de variables con poco margen de no respuesta. Esto se debe a que, si se hubieran escogido covariables con una alta tasa de no respuesta, se presenta el problema de contra que conjunto de datos testear las bondades de la técnica del balanceo. Esto es así dado que si los resultados de la técnica del cubo se comparan contra los totales poblacionales de los colegios (Tabla 3.2) es esperable que los resultados vayan a ser diferentes porque, estrictamente, el balanceo se realiza sólo sobre los establecimientos que tienen la información auxiliar pertinente. Lo mismo, *mutatis mutandi*, si se compara la técnica del balanceo con la respectiva muestra de azar simple de toda la población de colegios (Tabla 3.4).

```

N = nrow(tb)
n = 300
X = cbind(rep(1, times = N),
           as.numeric(tb$matricula),
           as.numeric(tb$secciones),
           as.numeric(tb$region),
           as.numeric(tb$ambito))

pi_colegio = rep(n / N, times = N)

# Agrego las probabilidades de inclusión a la base

tb = bind_cols(tb, as.data.frame(pi_colegio)) |>
relocate("pi_colegio", .after = "rowid")

set.seed(314)

# Aplico el método del cubo de la librería "Balanced Sampling"

muestra_balanceada_colegios = cube(prob = pi_colegio,
                                   x = X,
                                   eps = 1e-12)

# Me quedo con los casos seleccionados y creo expansores

muestra_cubo_colegios = tb[muestra_balanceada_colegios, ] |>
mutate(pw = N/n,
       fpc = sqrt((N-n)/(N-1)))

muestra_cubo_colegios_sv = muestra_cubo_colegios |>
as_survey_design(id = 1,
                 weights = pw,
                 fpc = fpc)

# Lo ordeno porque esto es necesario para la estratificación

tb = tb |>
  arrange(ambito)

N = nrow(tb)
n = 300
X2 = cbind(rep(1, times = N),

```

```

        tb$matricula,
        tb$secciones,
        tb$region)

pi_colegio = rep(n / N, times = N)

strata = as.integer(tb$ambito_n)

muestra_bal_estratificada =
    cubestratified(prob = pi_colegio,
                   x = X2,
                   integerStrata = strata,
                   eps = 1e-4)

```

En la Tabla 4.1 se puede observar los resultados de la muestra balanceada para colegios. En esta tabla los resultados se comparan contra los resultados anteriores de la muestra de azar simple y los respectivos totales poblacionales. Como se aclaró anteriormente en estas tablas no se van a incluir ni el error estándar ni los intervalos de confianza dada lo incómodo de su cálculo y posterior visualización en tablas. De todos modos, se alcanza a visualizar que en muchas de las variables analizadas existe una pequeña mejora con la excepción de algunas categorías de la variable Región.⁴

```

tbl_cubo_colegios = muestra_cubo_colegios_sv |>
tbl_svsummary(
  include = c(matricula, secciones, sondeo_primer, sondeo_segundo, region, ambito),
  statistic = list(all_continuous() ~ "{mean}",
                   all_categorical() ~ "{p}% (n={n_unweighted})"),
  digits = list(all_continuous() ~ c(1),
                 all_categorical() ~ c(1,0))) |>
  # add_ci() |>
  modify_footnote(all_stat_cols() ~ "Media (DE);% (n sin ponderar)")

muestra_azar_simple_sv = read_rds(here("Outputs", "muestra_azar_simple_sv.rds"))

tbl_azar_simple = muestra_azar_simple_sv |>
tbl_svsummary(
  include = c(matricula, secciones, sondeo_primer, sondeo_segundo, region, ambito),
  statistic = list(all_continuous() ~ "{mean}",
                   all_categorical() ~ "{p}% (n={n_unweighted})"),

```

⁴Es posible que parte de los mayores sesgos en algunas categorías de la variable Región se deban a que la falta de datos en algunas de las covariables elegidas sea desigual según Región. De todos modos, la cantidad de casos (establecimientos) que no tenían las covariables completas era 9.

```

digits = list(all_continuous() ~ c(1),
              all_categorical() ~ c(1,0))) |>
modify_footnote(all_stat_cols() ~ "Media (DE);% (n sin ponderar)")

tbl_pob_param = read_rds(here("Outputs", "tbl_pob_param.rds"))

tbl_merge(
  tbls = list(tbl_cubo_colegios, tbl_azar_simple, tbl_pob_param),
  tab_spanner = c("**Balanceo Colegios**", "**Azar Simple**", "**Pob. Colegios**")
)

```

4.2.2. Muestra Balanceada - Población Estudiantes

En esta pequeña sección vamos a observar la flexibilidad de la técnica del cubo obteniendo una muestra en donde las probabilidades de inclusión son diferentes. En este caso particular se aplicará el criterio que esas probabilidades sean proporcionales al tamaño de la matrícula. Esto tiene consecuencias similares a lo visto en el muestreo PPS (Sección 3.6) en donde, por diseño, los establecimientos con mayor matrícula tienen una mayor chance de ser incluidos en la muestra. La diferencia con el muestreo PPS es que el muestreo balanceado permite, además, un trabajar con un conjunto de otras covariables que, nuevamente, reducen las chances que la muestra finalmente seleccionada sean una de las pocas (muy) sesgadas.

A continuación, en la Tabla 4.2 puede observarse como esta muestra tiene resultados aceptables en cuanto a su cercanía con los respectivos parámetros poblacionales (que fueron ponderados por el valor de la matrícula). En cuanto a su comparación con la muestra PPS sin ponderar no parece registrarse mejoras sustanciales dado que, por azar, la muestra PPS ya era lo suficientemente buena. La diferencia es que la técnica de balanceo, gracias al algoritmo del cubo, asegura que que no saldrá una mala muestra mientras que con el PPS se trata de confiar en que uno no tendrá mala suerte para que, por azar, se produzca una mala muestra.

```

# Acá la probabilidad de inclusión es por el tamaño de la matrícula

pi_matricula = inclusionprobabilities(tb$matricula, n)

tb = bind_cols(tb, as.data.frame(pi_matricula)) |>
relocate("pi_matricula", .after = "rowid")

N = nrow(tb)
n = 300
X = cbind(rep(1, times = N),
          as.numeric(tb$matricula),
          as.numeric(tb$secciones),

```


Tabla 4.1: Estimaciones con muestra balanceada para colegios

	Balanceo Colegios	Azar Simple	Pob. Colegios
Característica	N = 4.159 ¹	N = 4.168 ¹	N = 4.168 ²
matricula	269,2	276,6	267,9
secciones	11,2	11,6	11,2
sondeo_primer	57,4	56,2	57,3
Desconocido	610	472	560
sondeo_segundo	69,1	69,8	69,5
Desconocido	638	556	570
region			
01	4,0 % (n=12)	2,3 % (n=7)	4,5 % (189)
02	4,7 % (n=14)	6,3 % (n=19)	5,4 % (223)
03	5,0 % (n=15)	5,3 % (n=16)	5,0 % (210)
04	4,0 % (n=12)	7,0 % (n=21)	5,1 % (213)
05	3,7 % (n=11)	2,7 % (n=8)	4,7 % (194)
06	3,3 % (n=10)	3,7 % (n=11)	3,6 % (148)
07	2,7 % (n=8)	3,7 % (n=11)	3,3 % (138)
08	3,7 % (n=11)	5,3 % (n=16)	3,6 % (149)
09	5,0 % (n=15)	6,7 % (n=20)	4,9 % (205)
10	6,0 % (n=18)	6,7 % (n=20)	5,4 % (224)
11	6,0 % (n=18)	4,3 % (n=13)	4,0 % (166)
12	4,3 % (n=13)	2,3 % (n=7)	3,7 % (155)
13	3,0 % (n=9)	2,7 % (n=8)	3,1 % (131)
14	5,0 % (n=15)	4,0 % (n=12)	4,1 % (169)
15	3,7 % (n=11)	3,3 % (n=10)	4,2 % (174)
16	5,3 % (n=16)	2,0 % (n=6)	3,0 % (125)
17	6,0 % (n=18)	3,3 % (n=10)	3,2 % (133)
18	4,3 % (n=13)	3,0 % (n=9)	3,8 % (160)
19	2,7 % (n=8)	2,7 % (n=8)	2,8 % (118)
20	2,3 % (n=7)	3,7 % (n=11)	3,8 % (159)
21	3,3 % (n=10)	2,0 % (n=6)	2,8 % (117)
22	3,3 % (n=10)	4,0 % (n=12)	3,7 % (153)
23	3,0 % (n=9)	4,7 % (n=14)	3,7 % (153)
24	4,0 % (n=12)	3,0 % (n=9)	4,7 % (196)
25	1,7 % (n=5)	5,3 % (n=16)	4,0 % (166)
ambito			
Urbano	64,0 % (n=192)	67,0 % (n=201)	65,4 % (2.727)
Rural Disperso	28,7 % (n=86)	20,3 % (n=61)	25,7 % (1.073)
Rural Agrupado	7,3 % (n=22)	12,7 % (n=38)	8,8 % (368)
Desconocido			9
Desconocido			9

¹Media (DE); % (n sin ponderar)

²Media; % (n)

```

      as.numeric(tb$region),
      as.numeric(tb$ambito))

set.seed(314)

muestra_balanceada_matricula = cube(prob = pi_matricula,
                                     x = X,
                                     eps = 1e-12)

muestra_cubo_matricula = tb[muestra_balanceada_matricula, ] |>
mutate(fpc = sqrt((N-n)/(N-1)),
       pw = N / n)

muestra_cubo_matricula_sv = muestra_cubo_matricula |>
as_survey_design(id = 1,
                 weights = pw,
                 # strata = ambito,
                 fpc = fpc,
                 pps = "brewer")

```

```

##/ tbl-cap: "Estimaciones con muestra balanceada para población de estudiantes"

```

```

tbl_cubo_matricula = muestra_cubo_matricula_sv |>
tbl_svsummary(
include = c(matricula, secciones, sondeo_primer, sondeo_segundo, region, ambito),
statistic = list(all_continuous() ~ "{mean}",
                 all_categorical() ~ "{p}% (n={n_unweighted})"),
digits = list(all_continuous() ~ c(1),
              all_categorical() ~ c(1,0)),
missing = "no") |>
modify_footnote(all_stat_cols() ~ "Media (DE);% (n sin ponderar)")

```

```

tbl_pob_pond_matricula = tb |>
as_survey_design(ids = rowid,
                 weights = matricula) |>
tbl_svsummary(include = c(matricula, secciones,sondeo_primer, sondeo_segundo, region, a
statistic = list(all_continuous() ~ "{mean}",
                 all_categorical() ~ "{p}% (n={n_unweighted})"),
digits = list(all_continuous() ~ c(1),
              all_categorical() ~ c(1,0)),
missing = "no")

muestra_pps_sin_ponderar_sv = read_rds(here("Outputs", "muestra_pps_sin_ponderar_sv.rds"))

```

```
tbl_pps_sin_ponderar = muestra_pps_sin_ponderar_sv |>
tbl_svsummary(
  include = c(matricula, secciones, sondeo_primer, sondeo_segundo, region, ambito),
  statistic = list(all_continuous() ~ "{mean}",
                   all_categorical() ~ "{p}% (n={n_unweighted})"),
  digits = list(all_continuous() ~ c(1),
                all_categorical() ~ c(1,0)),
  missing = "no")

tbl_merge(
  tbls = list(tbl_cubo_matricula, tbl_pps_sin_ponderar, tbl_pob_pond_matricula),
  tab_spanner = c("**Cubo Matrícula**", "**PPS sin ponderar**", "**Pob. matrícula**")
) |>
modify_header((all_stat_cols() ~ "")) |>
modify_footnote(everything() ~ NA)
```

4.3. Muestreos bien distribuidos

Como se dijo en la Sección 4.1 en los muestreos balanceados por el método del cubo el esfuerzo está en que los valores de la tendencia central de los estimadores de determinadas variables de la muestra se acerquen a los valores de tendencia central de las covariables existentes como información secundaria, esto es, a los parámetros conocidos de la población. En el muestreo bien distribuido o bien extendido (*well spread*) es objetivo es similar pero con una restricción adicional que implica que la distribución de la/s covariable/s de la muestra se acerque a la distribución de la/s covariable/s en la población. El precio de esta mejora es que se debe conocer la distribución de esas variables en la población algo que, hasta ahora, nunca habían requerido los diseños anteriores. En el caso particular de la distribución espacial el diseño exige la introducción de las coordenadas de cada miembro de la población y no solo el promedio poblacional de ellas.

En este contexto cobra importancia el ejemplo inicial de la Figura 4.1 en donde se usaron covariables espaciales. Allí, de manera intuitiva, se asoció que una muestra bien distribuida es una muestra balanceada. Esta afirmación, útil como una primera aproximación, es verdadera pero su inversa no. En otras palabras, toda muestra balanceada no es bien distribuida, pero toda muestra bien distribuida sí es, también, una muestra balanceada.

A continuación trabajaremos con los misma muestra balanceada de colegios de la sección anterior pero le agregaremos la condición de que esa muestra *también* sea bien distribuida en los valores de las coordenadas geográficas de los establecimientos. Para eso primero agregaremos las coordenadas a la base de los establecimientos y luego nos quedaremos con sólo aquellos establecimientos que tengan las coordenadas.

Tabla 4.2: Comparación muestra balanceada por la matrícula y muestra PPS sin ponderar y poblacion de establecimientos ponderada por matrícula

	Cubo Matrícula	PPS sin ponderar	Pob. matricula
Característica			
matricula	524,4	529,5	524,2
secciones	19,7	19,7	19,6
sondeo_primero	54,0	54,1	53,8
sondeo_segundo	68,0	67,9	67,7
region			
01	6,3 % (n=19)	6,3 % (n=19)	5,8 % (n=189)
02	8,7 % (n=26)	7,0 % (n=21)	7,9 % (n=222)
03	8,7 % (n=26)	9,7 % (n=29)	9,9 % (n=210)
04	9,3 % (n=28)	13,7 % (n=41)	9,2 % (n=213)
05	10,7 % (n=32)	7,0 % (n=21)	9,5 % (n=194)
06	2,3 % (n=7)	3,7 % (n=11)	4,2 % (n=148)
07	4,0 % (n=12)	2,7 % (n=8)	3,7 % (n=138)
08	6,0 % (n=18)	5,7 % (n=17)	6,1 % (n=149)
09	10,0 % (n=30)	11,3 % (n=34)	10,5 % (n=204)
10	2,7 % (n=8)	5,0 % (n=15)	4,1 % (n=221)
11	9,0 % (n=27)	5,0 % (n=15)	6,3 % (n=166)
12	2,7 % (n=8)	2,0 % (n=6)	2,4 % (n=155)
13	1,3 % (n=4)	1,3 % (n=4)	1,5 % (n=131)
14	1,0 % (n=3)	3,0 % (n=9)	1,7 % (n=169)
15	1,3 % (n=4)	2,3 % (n=7)	1,7 % (n=172)
16	1,0 % (n=3)	0,0 % (n=0)	0,9 % (n=125)
17	1,0 % (n=3)	0,7 % (n=2)	0,8 % (n=133)
18	2,0 % (n=6)	3,7 % (n=11)	2,0 % (n=160)
19	2,0 % (n=6)	1,3 % (n=4)	2,9 % (n=118)
20	1,0 % (n=3)	1,3 % (n=4)	1,8 % (n=159)
21	1,0 % (n=3)	1,3 % (n=4)	0,9 % (n=117)
22	4,3 % (n=13)	2,3 % (n=7)	2,8 % (n=153)
23	1,3 % (n=4)	1,3 % (n=4)	0,9 % (n=151)
24	0,7 % (n=2)	0,7 % (n=2)	1,1 % (n=196)
25	1,7 % (n=5)	1,7 % (n=5)	1,4 % (n=166)
ambito			
Urbano	96,3 % (n=289)	95,3 % (n=286)	96,1 % (n=2.723)
Rural Disperso	1,3 % (n=4)	1,7 % (n=5)	1,9 % (n=1.070)
Rural Agrupado	2,3 % (n=7)	3,0 % (n=9)	2,1 % (n=366)

```
coordenadas = read_xlsx(here("Inputs", "Nómina de establecimientos 20241020.xlsx")) |>
select(latitud, longitud, clave)
```

```
tb = tb |>
left_join(coordenadas, by = "clave") |>
filter(!is.na(latitud)) |>
filter(!is.na(longitud))
```

Agregadas las coordenadas ahora se puede aplicar la técnica del cubo con el adicional que el balanceo no sólo se realice por los valores de tendencia central de la sección anterior, sino también con los valores de dispersión de las coordenadas de los establecimientos.

En cierto sentido, la inclusión de las variables “Ámbito” y “Región” en el diseño balanceado (Sección 4.2.1) ya mejoraban la distribución geográfica o espacial de la muestra (con respecto a una muestra de azar simple) pero lo hacían focalizándose en sus valores de tendencia central. Los valores de las coordenadas permiten una información de un grano más fino sobre la distribución espacial de la muestra lo que no es un dato menor. Si se asume que el espacio es una especie de metavariante en las ciencias sociales (Small y Adler 2019), controlar la muestra por el espacio ayuda a controlar una serie de otras características, usualmente inobservables o de difícil registro. Expresado en la jerga del diseño estadísticos de las investigaciones, este tipo de mejoras ayudan a controlar una serie de variables extrañas que, de otro modo, serían variables perturbadoras (Kish 1987). De todos modos, cabe destacar que las coordenadas son de los establecimientos y no de los estudiantes o, más en general, de las personas. El supuesto implícito es que la ubicación de los establecimientos guarda una relación estrecha con la ubicación de los estudiantes y, más en general, con la distribución de las personas.

Desde un costado más operativo el algoritmo que se utiliza es el algoritmo del “*local cube*” (Tillé y Grafström 2013) que ya había sido utilizado en el muestro PPS. Este algoritmo penaliza si se seleccionan 2 casos “localmente” cercanos entre sí y luego de haber seleccionado un caso hay pocas chances que se seleccione otro caso muy cercano. La idea de distancia entre los casos es abstracta aunque en nuestro ejemplo se puede interpretar como distancia espacial.

```
N = nrow(tb)
n = 300
X = cbind(rep(1, times = N),
          as.numeric(tb$matricula),
          as.numeric(tb$secciones),
          as.numeric(tb$region),
          as.numeric(tb$ambito))

pi_colegio = rep(n / N, times = N)

xy = cbind(tb$latitud, tb$longitud)
```

```

set.seed(314)

muestra_bien_distribuida = lcube(Xbal = X,
                                Xspread = xy ,
                                prob = pi_colegio,
                                eps = 1e-12)

muestra_bien_distribuida = tb[muestra_bien_distribuida,] |>
mutate(pw = N/n,
       fpc = sqrt((N-n)/(N-1)))

muestra_bien_distribuida_sv = muestra_bien_distribuida |>
as_survey_design(id = 1,
                 weights = pw,
                 fpc = fpc)

write_rds(muestra_bien_distribuida_sv,
          here("Outputs", "muestra_bien_distribuida_sv.rds"))

tbl_bien_distribuida = muestra_bien_distribuida_sv |>
tbl_svsummary(
include = c(matricula, secciones, sondeo_primer, sondeo_segundo, region, ambito),
statistic = list(all_continuous() ~ "{mean} ({mean.std.error})",
                 all_categorical() ~ "{p}% (n={n_unweighted})"),
digits = list(all_continuous() ~ c(1),
               all_categorical() ~ c(1,0)),
missing = "no") |>
# add_ci() |>
modify_footnote(all_stat_cols() ~ "Media (DE);% (n sin ponderar)")

write_rds(tbl_bien_distribuida,
          here("Outputs", "tbl_bien_distribuida.rds"))

tbl_merge(
tbls = list(tbl_bien_distribuida, tbl_cubo_colegios, tbl_pob_param),
tab_spanner = c("**Bien distribuida**", "**Balanceo colegios**", "**Pob. Colegios**")
)

```

Como puede observarse en Tabla 4.3, al usarse la distribución de las coordenadas como covariables se aprecia una leve mejora en los valores que tienen una fuerte influencia espacial (p.e “Ambito” y “Región”). Sin embargo, una manera más visual de captar esta mejora es, al igual que en la Figura 4.1, a través de un mapa como el de la **Figura 4.2: Mapa de la muestra bien distribuida**.

Tabla 4.3: Comparación entre muestra bien distribuida, balanceada y población de establecimientos

	Bien distribuida	Balanceo colegios	Pob. Colegios
Característica	N = 4.156 ¹	N = 4.159 ¹	N = 4.168 ²
matricula	268,0 (2,8)	269,2	267,9
secciones	11,1 (0,1)	11,2	11,2
sondeo_primerio	58,0 (0,2)	57,4	57,3
sondeo_segundo	68,5 (0,2)	69,1	69,5
region			
01	4,3 % (n=13)	4,0 % (n=12)	4,5 % (189)
02	5,7 % (n=17)	4,7 % (n=14)	5,4 % (223)
03	5,0 % (n=15)	5,0 % (n=15)	5,0 % (210)
04	5,0 % (n=15)	4,0 % (n=12)	5,1 % (213)
05	4,3 % (n=13)	3,7 % (n=11)	4,7 % (194)
06	3,7 % (n=11)	3,3 % (n=10)	3,6 % (148)
07	3,3 % (n=10)	2,7 % (n=8)	3,3 % (138)
08	3,7 % (n=11)	3,7 % (n=11)	3,6 % (149)
09	5,3 % (n=16)	5,0 % (n=15)	4,9 % (205)
10	5,3 % (n=16)	6,0 % (n=18)	5,4 % (224)
11	3,7 % (n=11)	6,0 % (n=18)	4,0 % (166)
12	4,0 % (n=12)	4,3 % (n=13)	3,7 % (155)
13	2,7 % (n=8)	3,0 % (n=9)	3,1 % (131)
14	3,7 % (n=11)	5,0 % (n=15)	4,1 % (169)
15	5,0 % (n=15)	3,7 % (n=11)	4,2 % (174)
16	2,3 % (n=7)	5,3 % (n=16)	3,0 % (125)
17	3,7 % (n=11)	6,0 % (n=18)	3,2 % (133)
18	3,7 % (n=11)	4,3 % (n=13)	3,8 % (160)
19	3,0 % (n=9)	2,7 % (n=8)	2,8 % (118)
20	3,3 % (n=10)	2,3 % (n=7)	3,8 % (159)
21	3,3 % (n=10)	3,3 % (n=10)	2,8 % (117)
22	4,0 % (n=12)	3,3 % (n=10)	3,7 % (153)
23	4,0 % (n=12)	3,0 % (n=9)	3,7 % (153)
24	4,7 % (n=14)	4,0 % (n=12)	4,7 % (196)
25	3,3 % (n=10)	1,7 % (n=5)	4,0 % (166)
ambito			
Urbano	65,0 % (n=195)	64,0 % (n=192)	65,4 % (2.727)
Rural Disperso	26,7 % (n=80)	28,7 % (n=86)	25,7 % (1.073)
Rural Agrupado	8,3 % (n=25)	7,3 % (n=22)	8,8 % (368)
Desconocido		610	560
Desconocido		638	570
Desconocido			9
Desconocido			9

¹Media (DE); % (n sin ponderar) 39

²Media; % (n)

```

tb = tb |>
st_as_sf(coords = c("longitud", "latitud"),
          dim = "XY",
          sf_column_name = "geom_escuela",
          crs = 4326) |>
select(ambito, region)

muestra_bien_distribuida = muestra_bien_distribuida |>
st_as_sf(coords = c("longitud", "latitud"),
          dim = "XY",
          sf_column_name = "geom_escuela",
          crs = 4326) |>
select(ambito, region)

tmap_mode("view")

fig_bien_distribuida = tm_basemap(server = "CartoDB.Positron",
                                alpha = 0.5) +
tm_shape(tb,
          name = "Población") +
tm_dots(fill_alpha = 0.20,
        fill = "black") +
tm_shape(muestra_bien_distribuida,
          name = "Muestra bien distribuida") +
tm_dots(fill_alpha = 0.9,
        fill = "blue")

fig_bien_distribuida

```

```

tb = tb |>
st_as_sf(coords = c("longitud", "latitud"),
          dim = "XY",
          sf_column_name = "geom_escuela",
          crs = 4326) |>
select(ambito, region)

muestra_bien_distribuida = muestra_bien_distribuida |>
st_as_sf(coords = c("longitud", "latitud"),
          dim = "XY",
          sf_column_name = "geom_escuela",
          crs = 4326) |>
select(ambito, region)

```



```


tmap_mode("plot")

fig_bien_distribuida_pdf = tm_basemap(server = "CartoDB.Positron",
    alpha = 0.5) +
tm_shape(tb,
    name = "Población") +
tm_dots(fill_alpha = 0.20,
    fill = "black") +
tm_shape(muestra_bien_distribuida,
    name = "Muestra bien distribuida") +
tm_dots(fill_alpha = 0.9,
    fill = "blue")

fig_bien_distribuida_pdf

```

Figura 4.2: Distribución de la población de los establecimientos (puntos negros) y de la muestra bien distribuida (puntos azules)



5 Calibración

La estrategia de la calibración esta compuesta por un conjunto de prácticas que aspiran a lograr objetivos similares al proceso del balanceo del cubo pero con métodos cualitativamente diferentes. La principal diferencia radica en que la calibración se realiza *ex-post* la ejecución de la muestra (o sea, en el momento de la estimación) y no *ex-ante* (o sea, en el momento del diseño) (Deville y Tillé 2004, pag. 907). Esto es una diferencia fundamental que emparenta a la calibración con el enfoque del “*Model Assisted*” y la aleja del “*Design Based*”¹. En efecto, tanto el balanceo como la calibración pueden considerarse prácticas relativamente generales que, en su interior, incluyen otras prácticas más específicas. Esto es lo que habilita a afirmar que, por ejemplo, la estratificación es un caso particular del balanceo así como la post-estratificación es un caso particular de la calibración (Tillé 2011, pag. 223).

Otra diferencia entre el balanceo y la calibración es que para realizar la calibración en algunas situaciones (esto depende de la técnica específica seleccionada) sólo es necesario los totales de la población y no, como en el balanceo, los valores de cada unidad que compone esa población.

Las características anteriores hacen que el proceso de calibración sea muy útil en momentos en donde existe conocimientos sobre algunos totales de la población y no se haya podido controlar mucho el proceso de diseño de la muestra (p.e. diseños no probabilistas) o diseños probabilistas pero con una alta tasa de no respuesta. Estas características hacen al proceso de calibración algo muy deseado para muchas investigaciones contemporáneas en donde pueda admitirse que se conocen algunos parámetros poblacionales y, por ejemplo, se ha realizado una muestra que se difundió de manera virtual a través de un link que circuló por diferentes redes sociales. Esto deja en pie la discusión sobre que “tan buenos” podrán ser los resultados de esa investigación pero no parece haber muchas dudas que la investigación del ejemplo anterior será mejor si se le realiza un proceso de calibración mientras que será peor si no se realiza ese proceso.²

En cuanto a su pertinencia, siempre que haya disponibilidad de tiempo (y el saber necesario para realizarlo) es aconsejable realizar una calibración. Esto es cierto al menos

¹En cambio el balanceo, si bien en su origen tiene una fuerte vinculación con el enfoque del “*Model Assisted*”, no se encuentra tan alejado del “*design based*” dado que el algoritmo del cubo selecciona muestras balanceadas dentro del conjunto de muestras aleatorias (Tillé 2010, pag. 39).

²Este tipo de discusiones ha enfrentado (y por ahora continua enfrentando) a los representantes de los enfoques de la “*design based sample*” y del “*model assisted*”. Los primeros suelen dudar de los beneficios de aplicar la calibración sobre diseños no probabilísticos aunque no suelen tener objeciones cuando la calibración se realiza sobre diseños probabilísticos (Elliott y Valliant 2017). En el fondo lo que está en juego son los grados de garantía que ofrece cada técnicas acerca de la representatividad no sólo sobre las heterogeneidades observables (algo mantenido por ambos enfoques) sino también sobre las heterogeneidades no observables (algo históricamente mantenido por el enfoque de la “*design*”).

porque el balanceo tiene el problema del redondeo (las muestras son muestras de números enteros) y la calibración no, ya que puede construirse calibradores con números racionales. Por esta misma razón, aún cuando se haya realizado una muestra con un diseño por balanceo, es recomendable calibrar con los totales de las variables que se usaron en el proceso de balanceo.

Detalladas algunas diferencias entre la calibración y el balanceo ahora se pasa a diferenciar la calibración (de una muestra) de la imputación (de variables específicas).

- En cuanto a su producto, la calibración produce como resultado un calibrador (o un nuevo ponderador en la situación que el diseño de la muestra ya cuente con un ponderador) que es único para cada caso seleccionado en la muestra. En cambio la imputación, al menos como acá se la está entendiendo, es un proceso que tiene como objetivo estimar el valor faltante de una variable de los casos que respondieron de forma incompleta la muestra. En este sentido, un caso efectivamente seleccionado en la muestra puede tener más un valor imputado (p.e. para la variable ingresos y para la variable autopercepción de género) y, en cambio, otro caso puede que no tenga ninguno (p.e. si ese caso tuvo respuestas en todas las variables). En otros contextos se suele diferenciar a ambos procesos afirmando que la calibración ayuda a mitigar el problema del *unit-not-response* y la imputación ayuda a mitigar el problema del *item-not-response* [Lumley (2010), pag. 136](Lundström y Särndal 2009, pag. 9).
- En cuanto a los insumos, la calibración necesita los totales poblacionales y, en cambio, la imputación necesita los valores de las otras variables que el caso a imputar ha respondido así como los valores de las covariables y la variable a imputar de los otros casos.
- En cuanto al momento de la investigación, siempre que se usen ambos procesos, usualmente primero se imputa los casos particulares de la variables que se considera pertinente y luego se calibra la muestra incluyendo los valores de los casos imputados. Este orden es particularmente importante si se confía en el proceso de la imputación y la/s variable/s imputadas son parte del proceso de calibración como covariables.

Por último, a veces se suele asimilar como sinónimos en término calibración con el término post-estratificación. Más arriba ya se había comentado que el segundo puede considerarse como un caso particular (aunque quizás el más difundido) del primero en donde sólo se utilizan variables categóricas (estratos) para el proceso de la calibración. Lo mismo puede afirmarse del método menos difundido del “raking” que permite la calibración de múltiples variables categóricas sin la necesidad de realizar cruces entre ellas con el riesgo de no tener casos en la muestra de algunas de las celdas de los múltiples cruces (Lumley 2010, pag. 139). Por esta razón, aquí usaremos directamente el método de la calibración por ser el más general ya que permite la inclusión tanto de variables categóricas como continuas y no presenta los riesgos de la post-calibración en cuanto a la posible ausencia de casos frutos de los cruces de las variables categóricas.

A continuación vamos a trabajar con 2 ejemplos alternativos. Uno, en donde la calibración se realiza sobre la muestra aleatoria simple y otra que se realiza sobre la muestra balanceada y bien distribuida. En función de lo visto anteriormente (Sección 3.2, Sección 4.1 y Sección 4.3) ya sabemos que ambas calibraciones van a partir desde un punto de inicio diferente. Veremos que tanta distancia entre sí y con respecto a los parámetros poblacionales van a tener los respectivos puntos de llegada (esto es, las estimaciones de ambas muestras) luego de realizar la calibración. En otras palabras, la muestra balanceada y bien distribuida ya se encontraba (en general) bastante cerca de los parámetros poblacionales por lo que, a priori, cuenta con alguna ventaja desde su puesto de largada.

5.1. Calibración muestra azar simple

Comenzaremos haciendo la calibración sobre nuestra muestra realizada por azar simple y su resultado lo comparemos con la respectiva muestra de azar simple (sin calibrar) y con los respectivos parámetros poblacionales. Vamos a ver que, en comparación con otras técnicas, la mayor flexibilidad de la calibración se paga con una mayor especificación de los parámetros de sus funciones³.

Para eso vamos a recuperar el objeto con el cual le informábamos a R que habíamos realizado una muestra aleatoria simple (Sección 3.2). Ese va a ser nuestro primer insumo al cual le vamos a realizar la calibración y para eso es importante el proceso de la selección y armado de las covariables. Esta parte es similar en espíritu a lo realizado en el proceso de balanceo pero la parte operativa tiene pequeñas diferencias como se observa en el siguiente código.

```
Sample:  [1] "(Intercept)"          "matricula"            "ambitoRural Disperso"
[4] "ambitoRural Agrupado" "region02"             "region03"
[7] "region04"             "region05"             "region06"
[10] "region07"             "region08"             "region09"
[13] "region10"             "region11"             "region12"
[16] "region13"             "region14"             "region15"
[19] "region16"             "region17"             "region18"
[22] "region19"             "region20"             "region21"
[25] "region22"             "region23"             "region24"
[28] "region25"
Popltn:  [1] "" "" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n"
[20] "n" "n" "n" "n" "n" "n" "n" "n" "n"
```

Como puede observarse en Tabla 5.1 la calibración ha mejorado sensiblemente la muestra de azar simple en casi todas las variables, aún en aquellas que no se usaron

³En otras palabras, si ya se sabe de antemano que se va a realizar una post-estratificación es más simple utilizar una función específica para post-estratificar (p.e. la función “poststratify” de la librería survey o “poststrata” de la librería sampling).

Tabla 5.1: Calibración muestra azar simple

Característica	AS Calibrado		AS sin calibrar		Poblacion
	N = 4.168 ¹	95 % CI	N = 4.168 ¹	95 % CI	N = 4.168 ²
matricula	267 (0)	267, 267	276,6 (2,9)	271, 282	267,9
secciones	11 (0)	11, 11	11,6 (0,1)	11, 12	11,2
sondeo_primerο	57 (0)	56, 57	56,2 (0,2)	56, 57	57,3
Desconocido	568		472		560
sondeo_segundo	70 (0)	69, 70	69,8 (0,2)	69, 70	69,5
Desconocido	647		556		570
region					
01	4,5 % (n=7)	4,5 %, 4,5 %	2,3 % (n=7)	2,0 %, 2,7 %	4,5 % (189)
02	5,4 % (n=19)	5,4 %, 5,4 %	6,3 % (n=19)	5,8 %, 6,9 %	5,4 % (223)
03	5,0 % (n=16)	5,0 %, 5,0 %	5,3 % (n=16)	4,9 %, 5,8 %	5,0 % (210)
04	5,1 % (n=21)	5,1 %, 5,1 %	7,0 % (n=21)	6,5 %, 7,6 %	5,1 % (213)
05	4,7 % (n=8)	4,7 %, 4,7 %	2,7 % (n=8)	2,3 %, 3,0 %	4,7 % (194)
06	3,6 % (n=11)	3,6 %, 3,6 %	3,7 % (n=11)	3,3 %, 4,1 %	3,6 % (148)
07	3,3 % (n=11)	3,3 %, 3,3 %	3,7 % (n=11)	3,3 %, 4,1 %	3,3 % (138)
08	3,6 % (n=16)	3,6 %, 3,6 %	5,3 % (n=16)	4,9 %, 5,8 %	3,6 % (149)
09	4,9 % (n=20)	4,9 %, 4,9 %	6,7 % (n=20)	6,1 %, 7,2 %	4,9 % (205)
10	5,4 % (n=20)	5,4 %, 5,4 %	6,7 % (n=20)	6,1 %, 7,2 %	5,4 % (224)
11	4,0 % (n=13)	4,0 %, 4,0 %	4,3 % (n=13)	3,9 %, 4,8 %	4,0 % (166)
12	3,7 % (n=7)	3,7 %, 3,7 %	2,3 % (n=7)	2,0 %, 2,7 %	3,7 % (155)
13	3,1 % (n=8)	3,1 %, 3,1 %	2,7 % (n=8)	2,3 %, 3,0 %	3,1 % (131)
14	4,1 % (n=12)	4,1 %, 4,1 %	4,0 % (n=12)	3,6 %, 4,4 %	4,1 % (169)
15	4,2 % (n=10)	4,2 %, 4,2 %	3,3 % (n=10)	3,0 %, 3,7 %	4,2 % (174)
16	3,0 % (n=6)	3,0 %, 3,0 %	2,0 % (n=6)	1,7 %, 2,3 %	3,0 % (125)
17	3,2 % (n=10)	3,2 %, 3,2 %	3,3 % (n=10)	3,0 %, 3,7 %	3,2 % (133)
18	3,8 % (n=9)	3,8 %, 3,8 %	3,0 % (n=9)	2,7 %, 3,4 %	3,8 % (160)
19	2,8 % (n=8)	2,8 %, 2,8 %	2,7 % (n=8)	2,3 %, 3,0 %	2,8 % (118)
20	3,8 % (n=11)	3,8 %, 3,8 %	3,7 % (n=11)	3,3 %, 4,1 %	3,8 % (159)
21	2,8 % (n=6)	2,8 %, 2,8 %	2,0 % (n=6)	1,7 %, 2,3 %	2,8 % (117)
22	3,7 % (n=12)	3,7 %, 3,7 %	4,0 % (n=12)	3,6 %, 4,4 %	3,7 % (153)
23	3,7 % (n=14)	3,7 %, 3,7 %	4,7 % (n=14)	4,2 %, 5,1 %	3,7 % (153)
24	4,7 % (n=9)	4,7 %, 4,7 %	3,0 % (n=9)	2,7 %, 3,4 %	4,7 % (196)
25	4,0 % (n=16)	4,0 %, 4,0 %	5,3 % (n=16)	4,9 %, 5,8 %	4,0 % (166)
ambito					
Urbano	65 % (n=201)	65 %, 65 %	67,0 % (n=201)	66 %, 68 %	65,4 % (2.727)
Rural Disperso	26 % (n=61)	26 %, 26 %	20,3 % (n=61)	19 %, 21 %	25,7 % (1.073)
Rural Agrupado	8,8 % (n=38)	8,8 %, 8,8 %	12,7 % (n=38)	12 %, 13 %	8,8 % (368)
Desconocido					9
Desconocido					9

¹Media (SE); % (n=n (unweighted))

²Media; % (n) 45

Abreviacion: CI = Intervalo de confianza

Tabla 5.2: Ponderadores y calibradores. Base muestra azar simple.

matricula	secciones	ambito	sondeo_primer	sondeo_segundo	pond_weight	cal_weight
100	6	Urbano	42.46154	52.88889	13.89333	12.51390
122	6	Urbano	57.11538	50.27273	13.89333	14.50510
78	6	Urbano	79.93750	75.41667	13.89333	23.16509

activamente en la matriz de calibración. En efecto, en la mayoría de las variables los valores de la muestra calibrada se acercan mucho a los parámetros poblacionales.

Un paso adicional que se puede realizar si luego se quiere trabajar en una planilla de cálculo o, más en general, por fuera de R, es agregar los respectivos ponderadores del proceso de calibración al objeto para así tenerlos como una variable más. En este sentido, la base de datos con los casos seleccionados de la muestras ahora pasaría a tener 2 variables especiales que servirían para el proceso de expansión de la muestra a la población. Uno, un ponderador que ya existía luego de haber realizado el azar simple (y que era igual para todos los casos) y otro recientemente agregado, el calibrador, que es específico para cada caso.

5.2. Calibración muestra bien distribuida

En el caso de la calibración de la muestra bien distribuida el proceso de calibración es similar con la diferencia que cambia el insumo al cual se le realiza la calibración. Aquí el código es un poco más simple porque se reutiliza la matriz de covariables construida para la calibración de la muestra de azar simple.

```
Sample: [1] "(Intercept)"          "matricula"          "ambitoRural Disperso"
[4] "ambitoRural Agrupado" "region02"          "region03"
[7] "region04"            "region05"          "region06"
[10] "region07"            "region08"          "region09"
[13] "region10"            "region11"          "region12"
[16] "region13"            "region14"          "region15"
[19] "region16"            "region17"          "region18"
[22] "region19"            "region20"          "region21"
[25] "region22"            "region23"          "region24"
[28] "region25"
Popltn: [1] "" "" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n" "n"
[20] "n" "n" "n" "n" "n" "n" "n" "n" "n"
```

Al igual que con la calibración de la base de la muestra de azar simple, aquí vamos a extraer los calibradores para luego agregarlos a la base de datos.

Es interesante destacar, como se observa en la Tabla 5.4 (y a diferencia de lo visto en la Tabla 5.1) que acá no sólo los calibradores son diferentes entre sí sino que también lo eran ponderadores de la muestra bien distribuida.

Tabla 5.3: Calibración muestra bien distribuida

Característica	BD calibrado		BD sin calibrar	Poblacion
	N = 4.168 ¹	95 % CI	N = 4.156 ²	N = 4.168 ³
matricula	267 (0)	267, 267	268,0 (2,8)	267,9
secciones	11 (0)	11, 11	11,1 (0,1)	11,2
sondeo_primerio	58 (0)	58, 58	58,0 (0,2)	57,3
Desconocido	478			560
sondeo_segundo	69 (0)	68, 69	68,5 (0,2)	69,5
Desconocido	543			570
region				
01	4,5 % (n=13)	4,5 %, 4,5 %	4,3 % (n=13)	4,5 % (189)
02	5,4 % (n=17)	5,4 %, 5,4 %	5,7 % (n=17)	5,4 % (223)
03	5,0 % (n=15)	5,0 %, 5,0 %	5,0 % (n=15)	5,0 % (210)
04	5,1 % (n=15)	5,1 %, 5,1 %	5,0 % (n=15)	5,1 % (213)
05	4,7 % (n=13)	4,7 %, 4,7 %	4,3 % (n=13)	4,7 % (194)
06	3,6 % (n=11)	3,6 %, 3,6 %	3,7 % (n=11)	3,6 % (148)
07	3,3 % (n=10)	3,3 %, 3,3 %	3,3 % (n=10)	3,3 % (138)
08	3,6 % (n=11)	3,6 %, 3,6 %	3,7 % (n=11)	3,6 % (149)
09	4,9 % (n=16)	4,9 %, 4,9 %	5,3 % (n=16)	4,9 % (205)
10	5,4 % (n=16)	5,4 %, 5,4 %	5,3 % (n=16)	5,4 % (224)
11	4,0 % (n=11)	4,0 %, 4,0 %	3,7 % (n=11)	4,0 % (166)
12	3,7 % (n=12)	3,7 %, 3,7 %	4,0 % (n=12)	3,7 % (155)
13	3,1 % (n=8)	3,1 %, 3,1 %	2,7 % (n=8)	3,1 % (131)
14	4,1 % (n=11)	4,1 %, 4,1 %	3,7 % (n=11)	4,1 % (169)
15	4,2 % (n=15)	4,2 %, 4,2 %	5,0 % (n=15)	4,2 % (174)
16	3,0 % (n=7)	3,0 %, 3,0 %	2,3 % (n=7)	3,0 % (125)
17	3,2 % (n=11)	3,2 %, 3,2 %	3,7 % (n=11)	3,2 % (133)
18	3,8 % (n=11)	3,8 %, 3,8 %	3,7 % (n=11)	3,8 % (160)
19	2,8 % (n=9)	2,8 %, 2,8 %	3,0 % (n=9)	2,8 % (118)
20	3,8 % (n=10)	3,8 %, 3,8 %	3,3 % (n=10)	3,8 % (159)
21	2,8 % (n=10)	2,8 %, 2,8 %	3,3 % (n=10)	2,8 % (117)
22	3,7 % (n=12)	3,7 %, 3,7 %	4,0 % (n=12)	3,7 % (153)
23	3,7 % (n=12)	3,7 %, 3,7 %	4,0 % (n=12)	3,7 % (153)
24	4,7 % (n=14)	4,7 %, 4,7 %	4,7 % (n=14)	4,7 % (196)
25	4,0 % (n=10)	4,0 %, 4,0 %	3,3 % (n=10)	4,0 % (166)
ambito				
Urbano	65 % (n=195)	65 %, 65 %	65,0 % (n=195)	65,4 % (2.727)
Rural Disperso	26 % (n=80)	26 %, 26 %	26,7 % (n=80)	25,7 % (1.073)
Rural Agrupado	8,8 % (n=25)	8,8 %, 8,8 %	8,3 % (n=25)	8,8 % (368)
Desconocido				9
Desconocido				9

¹Media (SE); % (n=n (unweighted))

²Media (DE); % (n sin ponderar) 47

³Media; % (n)

Abreviacion: CI = Intervalo de confianza

Tabla 5.4: Ponderadores y calibradores. Base muestra bien distribuida.

matricula	secciones	ambito	sondeo_primer	sondeo_segundo	pond_weight	cal_weight
533	24	Urbano	58.11111	70.60484	13.85333	14.46208
668	24	Urbano	38.02857	73.39394	13.85333	14.32084
340	14	Urbano	60.08219	85.81707	13.85333	14.66400

5.3. Comparación calibración muestra balanceada y azar simple

Finalmente vamos a realizar una comparación entre los resultados de los procesos de calibración antes realizados y los respectivos parámetros poblacionales. Esto es lo que precisamente se observa en la Tabla 5.5.

En la Tabla 5.5 puede observarse como ambas estrategias de calibración parecen igual de eficaces ya que ambas arrojan resultados muy similares entre sí y, a su vez, muy similares con los parámetros poblacionales. En este contexto se recuerda que, si bien los valores finales son muy similares, la mejora realizada en el proceso de calibración es mayor sobre el diseño de azar simple ya que esa muestra no era tan precisa como la muestra bien distribuida y, por lo tanto, existía la oportunidad de mejorar bastante.

Tabla 5.5: Comparación entre calibración de las muestras bien distribuidas, de azar simple y los respectivos parámetros poblacionales

Característica	BD calibrado		AS calibrado		Poblacion
	N = 4.168 ¹	95 % CI	N = 4.168 ¹	95 % CI	N = 4.168 ²
matricula	267 (0)	267, 267	267 (0)	267, 267	267,9
secciones	11 (0)	11, 11	11 (0)	11, 11	11,2
sondeo_primerio	58 (0)	58, 58	57 (0)	56, 57	57,3
Desconocido	478		568		560
sondeo_segundo	69 (0)	68, 69	70 (0)	69, 70	69,5
Desconocido	543		647		570
region					
01	4,5 % (n=13)	4,5 %, 4,5 %	4,5 % (n=7)	4,5 %, 4,5 %	4,5 % (189)
02	5,4 % (n=17)	5,4 %, 5,4 %	5,4 % (n=19)	5,4 %, 5,4 %	5,4 % (223)
03	5,0 % (n=15)	5,0 %, 5,0 %	5,0 % (n=16)	5,0 %, 5,0 %	5,0 % (210)
04	5,1 % (n=15)	5,1 %, 5,1 %	5,1 % (n=21)	5,1 %, 5,1 %	5,1 % (213)
05	4,7 % (n=13)	4,7 %, 4,7 %	4,7 % (n=8)	4,7 %, 4,7 %	4,7 % (194)
06	3,6 % (n=11)	3,6 %, 3,6 %	3,6 % (n=11)	3,6 %, 3,6 %	3,6 % (148)
07	3,3 % (n=10)	3,3 %, 3,3 %	3,3 % (n=11)	3,3 %, 3,3 %	3,3 % (138)
08	3,6 % (n=11)	3,6 %, 3,6 %	3,6 % (n=16)	3,6 %, 3,6 %	3,6 % (149)
09	4,9 % (n=16)	4,9 %, 4,9 %	4,9 % (n=20)	4,9 %, 4,9 %	4,9 % (205)
10	5,4 % (n=16)	5,4 %, 5,4 %	5,4 % (n=20)	5,4 %, 5,4 %	5,4 % (224)
11	4,0 % (n=11)	4,0 %, 4,0 %	4,0 % (n=13)	4,0 %, 4,0 %	4,0 % (166)
12	3,7 % (n=12)	3,7 %, 3,7 %	3,7 % (n=7)	3,7 %, 3,7 %	3,7 % (155)
13	3,1 % (n=8)	3,1 %, 3,1 %	3,1 % (n=8)	3,1 %, 3,1 %	3,1 % (131)
14	4,1 % (n=11)	4,1 %, 4,1 %	4,1 % (n=12)	4,1 %, 4,1 %	4,1 % (169)
15	4,2 % (n=15)	4,2 %, 4,2 %	4,2 % (n=10)	4,2 %, 4,2 %	4,2 % (174)
16	3,0 % (n=7)	3,0 %, 3,0 %	3,0 % (n=6)	3,0 %, 3,0 %	3,0 % (125)
17	3,2 % (n=11)	3,2 %, 3,2 %	3,2 % (n=10)	3,2 %, 3,2 %	3,2 % (133)
18	3,8 % (n=11)	3,8 %, 3,8 %	3,8 % (n=9)	3,8 %, 3,8 %	3,8 % (160)
19	2,8 % (n=9)	2,8 %, 2,8 %	2,8 % (n=8)	2,8 %, 2,8 %	2,8 % (118)
20	3,8 % (n=10)	3,8 %, 3,8 %	3,8 % (n=11)	3,8 %, 3,8 %	3,8 % (159)
21	2,8 % (n=10)	2,8 %, 2,8 %	2,8 % (n=6)	2,8 %, 2,8 %	2,8 % (117)
22	3,7 % (n=12)	3,7 %, 3,7 %	3,7 % (n=12)	3,7 %, 3,7 %	3,7 % (153)
23	3,7 % (n=12)	3,7 %, 3,7 %	3,7 % (n=14)	3,7 %, 3,7 %	3,7 % (153)
24	4,7 % (n=14)	4,7 %, 4,7 %	4,7 % (n=9)	4,7 %, 4,7 %	4,7 % (196)
25	4,0 % (n=10)	4,0 %, 4,0 %	4,0 % (n=16)	4,0 %, 4,0 %	4,0 % (166)
ambito					
Urbano	65 % (n=195)	65 %, 65 %	65 % (n=201)	65 %, 65 %	65,4 % (2.727)
Rural Disperso	26 % (n=80)	26 %, 26 %	26 % (n=61)	26 %, 26 %	25,7 % (1.073)
Rural Agrupado	8,8 % (n=25)	8,8 %, 8,8 %	8,8 % (n=38)	8,8 %, 8,8 %	8,8 % (368)
Desconocido					9
Desconocido					9

¹Media (SE); % (n=n (unweighted)) 49

²Media; % (n)

Abreviacion: CI = Intervalo de confianza

6 Referencias Bibliográficas

- Baker, Reg, Michael Brick, Nancy Bates, et al. 2013. *Report of the AAPOR task force on non-probability sampling*.
- Brus, Dick. 2022. *Spatial sampling with R*. Chapman & Hall /CRC.
- Bunge, M. 1974. *Semantics*. Dordrecht. Reidel.
- Campbell, Donald, y Julian Stanley. 1963. *Experimental and quasi-experimental designs for research*. Houghton Mifflin Company.
- Deville, Jean, y Yves Tillé. 2004. «Efficient balanced sampling: The cube method». *Biometrika* 91 (4): 893-912.
- Elliott, Michael, y Richard Valliant. 2017. «Inference for nonprobability samples». *Statistical Science* 32 (2): 249-64.
- Fienberg, Stephen, y Judith Tanur. 1988. «From the inside out and the outside in: Combining experimental and sampling structures». *The Canadian Journal of Statistics* 16 (2): 135-51.
- Gigerenzer, Gerd, Zeno Swijtink, Theodore Porter, John Beatty, y Lorenz Krüger. 1997. *The empire of chance*. Cambridge University Press.
- Hacking, Ian. (1990) 2004. *The taming of chance*. Cambridge University Press.
- Hacking, Ian. 2006. *The emergence of probability: A philosophical study of early ideas about probability, induction and statistical inference*. Cambridge University Press.
- Hedlin, Dan. 2015. *Why are design in survey sampling and design of randomised experiments separate areas of statistical science?*
- Kish, Leslie. 1980. «Design and estimations for domains». *The Statistician* 29 (4): 209-22.
- Kish, Leslie. 1987. *Statistical design for research*. John Wiley.
- Klima, Gyula. 2022. *The medieval problem of universals*. Spring 2022. Editado por Edward Zalta. Stanford University.

- Lumley, Thomas. 2010. *Complex surveys. A guide to analysis using R*. John Wiley & Sons.
- Lundström, Sixten, y Carl Erik Särndal. 2009. *Calibration of weights in surveys with nonresponse and frame imperfections*. (Bilbao), enero 26.
- Morgan, Stephen, y Christopher Winship. 2015. *Counterfactuals and Causal Inference*. Second Edition. Cambridge University Press.
- Neyman, Jerzy. 1934. «On the Two Different Aspects of the Representative Method: The Method of Stratified Sampling and the Method of Purposive Selection». *Journal of the Royal Statistical Society* 97 (4): 558-625.
- Pearl, J. 2018. *The Book of Why*. New York. Basic Books.
- Platón. 2002 [370AVC]. *Phaedrus*. Oxford University Press.
- Schneider, Ben. 2024. *Simulation-based variance estimation for the cube method*. <https://www.practicalsignificance.com/posts/cube-method-simulating-joint-probs/>.
- Small, Mario, y Laura Adler. 2019. «The role os space in the formation of social ties». *Anual Review of Sociology* 45: 111-32.
- Tillé, Yves. 2010. *Balanced sampling by means of the cube method*. (Euskal).
- Tillé, Yves. 2011. «Ten years of balanced sampling with the cube method: An appraisal». *Survey Methodology* 37 (2): 215-26.
- Tillé, Yves, y Anton Grafström. 2013. «Doubly balanced spatial sampling with spreading and restitution of auxiliary totals». *Environmetrics* 24 (2): 120-31.
- Tillé, Yves, y Alina Matei. 2023. *Package "sampling"*.