

Taller Muestreo

**Recursos Didácticos y Tecnológicos para la
Enseñanza**

Índice

1	Introducción	11
1.1	Librerías utilizadas	12

I

Diseños muestrales

2	Cuándo y por qué hacer muestras	15
2.1	¿Muestras de qué?	16
3	La domesticación del azar como medio para lograr muestras (aproximadamente) representativas	19
3.1	Población	19
3.2	Muestreo por azar simple	23
3.3	Muestreo Sistemático	26
3.4	Muestreo Estratificado	26
3.4.1	Estratos con asignación proporcional	27
3.4.2	Estratos con asignación no proporcional	29
3.5	Muestreo por Clústers	31
3.6	Muestreo Proporcional al Tamaño (PPS)	31
4	Muestreos balanceados y bien distribuidos	37
4.1	Muestras Balanceadas (por el método del cubo)	37
4.2	Muestras Balanceadas sobre base de establecimientos	38
4.2.1	Muestra Balanceada - Población Establecimientos	39
4.2.2	Muestra Balanceada - Población Estudiantes	42
4.3	Muestreos bien distribuidos	44
5	Calibración	47
5.1	Calibración muestra azar simple	48
5.2	Calibración muestra bien distribuida	51
5.3	Comparación calibración muestra balanceada y azar simple	54

II

Aplicaciones prácticas

6	Muestras PEB 2025	59
6.1	Muestra 2023	59
6.1.1	Descripción	59
6.1.2	Clasificación	60
6.1.3	Evaluación actual de la muestra usada en 2024	63
6.2	Muestra 2025	64

6.3	Primera Etapa	65
6.4	Distribución a nivel de establecimientos	66
6.5	Simulación a nivel de estudiantes	67
6.6	Segunda etapa	69
7	Calibración con Metas Cuasicensales (PEB 2025)	73
7.1	Análisis <i>ex-post</i> . Construcción de ponderadores base, ponderadores por no respuesta y ponderadores de calibración.	73
7.2	Tercer Año	73
7.2.1	No respuesta	76
7.3	Calibración	83
7.3.1	Contraste muestra calibrada vs. parámetros poblacionales censo PEB (3.er Año)	87
7.3.2	Contraste muestra calibrada vs. parámetros oblaconales marco muestral (3.er Año)	87
7.4	Sexto año	89
7.4.1	Objetivos poblacionales Censo PEB	89
7.4.2	Carga del Marco Muestral	89
7.4.3	Construcción de Ponderadores de Diseño y No Respuesta	90
7.4.4	Calibración y Diagnóstico	90
7.4.5	Contraste muestra calibrada vs. parámetros poblacionales censo PEB	91
7.4.6	Contraste muestra calibrada vs. parámetros oblaconales marco muestral	92
7.4.7	Diagnóstico Comparado de Ponderadores (3.er vs. 6.º Año)	94
7.5	Exportación de Bases de Estudiantes con Ponderadores	94
8	Muestra EJAYAM	95
8.1	Introducción	95
8.2	Objetivos	95
8.3	Población objetivo	96
8.4	Marco muestral	98
8.5	Dominios de estimación	105
8.5.1	Dominios de estimación originales	106
8.5.2	Comentarios sobre los dominios	107
8.5.3	Dominios en el espacio	108
8.6	Alternativas muestrales	108
8.6.1	Traducción de Margen de Error (MOE) a Coeficiente de Variación (CV)	110
8.6.2	Cálculo del <i>Def f</i> y del <i>Ess</i>	111
8.6.3	El Efecto del Diseño (<i>Def f</i>) y la Correlación Intracluster (ρ)	111
8.6.4	Alternativas de la segunda etapa para reducir el <i>DEFF</i>	112
8.6.5	Simulación del impacto de la Correlación Intracluster (ρ) y el tamaño del cluster (<i>b</i>)	113
8.7	Diseño muestra	115
8.8	Construcción de ponderadores y expansores	116
8.9	Testeo de la muestra seleccionada	116
8.9.1	Análisis de robustez o sensibilidad de la muestra	121
9	Muestra Paro - 03/08/26	127
9.1	Introducción y objetivos	127
9.2	Metodología	127

9.3	Cálculo del Tamaño Muestral	128
9.3.1	Visualización del Efecto PPS en la distribución de la Matrícula	131
9.3.2	Validación del Balance de Afectación de Paros (Estratificación Implícita)	132
9.4	Simulación y Validación (Muestra vs. Población)	133
	Anexos	135
A	Referencias Bibliográficas	137

Índice de figuras

Índice de tablas

1. Introducción

En este curso/taller vamos a ir interactuando entre algo de teoría, algo de datos y algo de código. Generalmente, vamos a trabajar con insumos empíricos que provengan del mundo educativo. Típicamente con bases de datos de establecimientos educativos con alguna información agregada de sus estudiantes. Con base en este tipo de insumo en una primera instancia nos vamos a focalizar en una serie de *diseños* clásicos de muestreo y en la construcción de ponderadores simples. En una segunda instancia vamos a ver diseños que implican: {#sec-introduccion}

- a) Alguna combinación en más de una etapa de estos diseños clásicos (muestras complejas) o
- b) diseños de un solo paso cuyos supuestos o modo de proceder son algo diferentes al de los clásicos (p.e. diseños balanceados y bien distribuidos).

Finalmente, se verán algunas estrategias de calibración que, en principio, al ser instancias post-diseños, pueden ser aplicadas/combinadas con cualquiera de los anteriores diseños.

El código con que vamos a procesar los datos a lo largo del taller va a ser en lenguaje R. R es un lenguaje de programación que parece una opción razonable tanto para el diseño de la muestra como su posterior calibración y análisis de los datos. Si bien diseños de métodos de muestreo relativamente simples son posibles de realizarse en varios otros lenguajes la situación se complica un poco a medida que se quieren utilizar, y luego analizar, diseños más complejos. En esta última situación, ya no es posible conseguir librerías especializadas en muchos lenguajes aparte de R, Python, Julia y SAS.

Dentro del ecosistema de R, ejemplos de librerías para analizar datos producidos con diseños muestrales pueden considerarse [survey](#), [svrep](#) y su correspondiente versión tidy [srvyr](#). También cuentan otras más modernas (basadas en objetos S7) aunque todavía no tan maduras, que pertenecen al ecosistema surveyverse como [surveycore](#), [surveytidy](#) y [surveywts](#). Estas librerías generalmente agregan meta-información al dataframe original que hace referencia al modo o diseño en que fue realizada la muestra. Esta información luego es utilizada para realizar estimaciones puntuales con sus respectivos errores estándar, intervalos de confianza o coeficientes de variación.

En este contexto, la librería [survey](#) es una librería madura mantenida principalmente por [Thomas Lumley](#). Lumley es un personaje conocido dentro de la comunidad estadística en general y en la en R en particular y tuvo el gran mérito de implementar muchos algoritmos del mundo estadístico a un lenguaje de programación como R y, no menos importante, la idea de incorporar bajo el paraguas de los metadatos estructurados una serie de información importante acerca del proceso del diseño de la muestra (Lumley, 2010). La librería [srvyr](#) puede considerarse como su sucesora más moderna, aunque como lo destacan sus propios autores, se trata de una librería más amigable para el usuario en donde la mayoría del trabajo sucio lo sigue haciendo por detrás la librería [survey](#). Algo similar resulta entre la relación entre [survey](#) y [svrep](#) ya que esta última se puede considerar una extensión de la primera para el cálculo de ponderadores replicados (*replicate weights*). Algo importante a destacar es la compatibilidad entre las 3 librerías y que, a pesar de la diferencia generacional (Lumley es el mayor) existe una relación afectuosa entre los diferentes autores. En efecto, [Ben Schneider](#), el creador de la librería [svrep](#), es un asiduo contribuidor de los 3 paquetes antes nombrados.¹ Por otro lado, el ecosistema [surveycore](#) es mantenido actualmente por [Jacob Dennen](#), un personaje, al menos por ahora, mucho más *outsider* de la comunidad estadística.

Ejemplos de librerías que sirven para el diseño de las muestras y su posterior ajuste son [sampling](#), [balanced sampling](#) y [spbsampling](#). Al igual que con las librerías anteriores, aquí también existe relación entre los diferentes autores. La librería [sampling](#) es una librería madura creada bajo la tutela de [Yver Tillé](#), que es otro personaje bastante conocido tanto en el mundo de la estadística académica como dentro de los organismos oficiales de estadística de diferentes países. La librería [balanced sampling](#) hace mucho de las funciones que la librería [sampling](#), pero es más moderna (corre en C++) y es mantenida por [Anton Grafstrom](#) que ha escrito con Tillé. Por otro lado, la librería [spbsampling](#) se especializa en muestreos espaciales ([balanced sampling](#) también tiene funciones para eso), se ejecuta en C++ y es mantenida por [Roberto Benedetti](#). Tanto Benedetti como Grafstrom se reconocen entre ellos y algo interesante es que si, bien ambos han trabajado con institutos oficiales de estadística, ambos se especializan en organismos de

¹En cambio, el balanceo, si bien en su origen tiene una fuerte vinculación con el enfoque del «*Model Assisted*», no se encuentra tan alejado del «*Design Based*» dado que el algoritmo del cubo selecciona muestras balanceadas dentro del conjunto de muestras aleatorias (Tillé, 2010, pág. 39).

agricultura. De ahí que ambos muestren interés en la dimensión espacial de los diseños muestrales porque esta es útil a la hora de, por ejemplo, diseñar una buena muestra de la vegetación de un bosque.²

Por último, para el cálculo de los tamaños muestrales con diferentes diseños (y otras yerbas) puede consultarse la librería [PracTools](#). No se trata de una librería muy sofisticada como algunas de las anteriores, pero se trata de una librería útil, relativamente bien documentada y bastante madura (Valliant et al., 2018). Un dato no menor es que uno de sus autores es [Richard Valliant](#) que, a su turno, es uno de los mayores exponentes de un enfoque importante dentro del mundo del muestreo como es el «*Model Assisted Sampling*».³

1.1 Librerías utilizadas

Abajo hay un código para instalar y cargar las librerías que vamos a utilizar. El código se encarga de cargar las librerías y de instalar las mismas en el caso de que no se encuentren previamente instaladas. Esto es específicamente para R y la parte muestral.

La sección de las aplicaciones prácticas, principalmente por cuestiones de confidencialidad, no son reproducibles. Por otro lado, algunos *chunks* incuyen código de Python.

²Este tipo de discusiones ha enfrentado (y por ahora continúa enfrentando) a los representantes de los enfoques de la «*design based sample*» y del «*model assisted*». Los primeros suelen dudar de los beneficios de aplicar la calibración sobre diseños no probabilísticos, aunque no suelen tener objeciones cuando la calibración se realiza sobre diseños probabilísticos (Elliott & Valliant, 2017). En el fondo, lo que está en juego son los grados de garantía que ofrece cada técnica acerca de la representatividad y esto no solo incluya la discusión sobre las heterogeneidades observables (algo mantenido por ambos enfoques), sino también sobre las heterogeneidades no observables (algo históricamente mantenido por el enfoque de «*design based*»).

³En otras palabras, si ya se sabe de antemano que se va a realizar una post-estratificación es más simple utilizar una función específica para post-estratificar (p.e. la función `poststratify` de la librería `survey` o `poststrata` de la librería `sampling`).

I

Diseños muestrales

2	Cuándo y por qué hacer muestras . .	15
2.1	¿Muestras de qué?	16
3	La domesticación del azar como medio para lograr muestras (aproximadamente) representativas .	19
3.1	Población	19
3.2	Muestreo por azar simple	23
3.3	Muestreo Sistemático	26
3.4	Muestreo Estratificado	26
3.5	Muestreo por Clústers	31
3.6	Muestreo Proporcional al Tamaño (PPS)	31
4	Muestreos balanceados y bien distribuidos	37
4.1	Muestras Balanceadas (por el método del cubo) .	37
4.2	Muestras Balanceadas sobre base de establecimientos	38
4.3	Muestreos bien distribuidos	44
5	Calibración	47
5.1	Calibración muestra azar simple	48
5.2	Calibración muestra bien distribuida	51
5.3	Comparación calibración muestra balanceada y azar simple	54

2. Cuándo y por qué hacer muestras

Una muestra es una parte de un todo. En los muestreos que aspiran a ser (en algún grado) representativos lo que se intenta lograr es que esa parte que se seleccione no sea muy diferente al todo o, como decían los romanos, que sea legítimo tomar una parte como el todo (*pars pro toto*). En este sentido, lo que vamos a hablar aquí sobre muestreo tiene mayor pertinencia cuando en la investigación se intenta maximizar la **representatividad**, pero por alguna razón no es posible o conveniente la realización de un censo de todas las partes que conforman ese todo. Por otro lado, diseñar muestras también puede ser importante cuando se necesitan construir grupos de tratamiento y control en diseños experimentales, especialmente en los diseños experimentales aleatorios (Kish, 1987). En efecto, la vinculación entre la bibliografía de los diseños muestrales y los diseños experimentales suele ser útil si se aspira a entender las razones (y no solo saber ejecutarlas en la práctica) de algunas recomendaciones metodológicas, ya que muchos de los conceptos más abstractos son compartidos por ambas [Hedlin (2015)](Fienberg & Tanur, 1988).

Nota

Las muestras que aspiran a ser representativas intentan captar la heterogeneidad de una determinada población para poder hablar legítimamente del todo a través de solo una parte.

En algunas situaciones, más usuales en las ciencias naturales, la representatividad a veces se logra sin un mayor esfuerzo por parte del investigador por lo que no suele ser explícitamente un objetivo de la investigación sino un supuesto más o menos implícito a lo largo de ella. En otras palabras, la hipótesis de la homogeneidad forma parte del modelo mediante el cual se intenta aprender de la realidad. Entender la razón de esto último puede ayudar a hacer más transparente alguna especificidad de las ciencias sociales en este punto. En efecto, muchos investigadores consideran que en los niveles más bajos de la realidad (p.e. niveles estudiados por la física y la química) existe una mayor homogeneidad de los referentes básicos que estudian esas disciplinas. En cambio, en los niveles más superiores (p.e. niveles estudiados por ejemplo por la psicología y las ciencias sociales) la variabilidad inherente de los referentes estudiados hace que sea necesario prestar especial atención al problema de la representatividad. En este sentido, el investigador suele realizar acciones específicas para poder captar la heterogeneidad que surge a nivel poblacional debido a la variabilidad individual de los referentes estudiados y, en ese camino, suele venir en ayuda el diseño muestral.

De manera derivada, lo anterior es una de las razones por lo cual el método experimental ha sido bastante exitoso en la historia de las ciencias naturales, ya que con unos pocos experimentos sus resultados se pueden inferir a su respectiva **población** empírica actual. No solo eso. Muchas veces también se puede inferir a lo que a veces se denomina su **universo** que estaría compuesto no solo por la población actual sino también por la clase de esas poblaciones pasadas y futuras. Este tipo de problemáticas son conocidas por diferentes disciplinas. Desde la epistemología a veces se lo relaciona con el problema de los universales (Klima, 2022) y desde la metodología se lo relaciona con el problema de la **validez externa** de las investigaciones (Campbell & Stanley, 1963).

A modo de ejemplo, un físico que investiga el impacto del calor en el átomo de carbono puede tener una razonable confianza que el átomo de carbono que está hoy estudiando no solo es muy similar a los otros átomos de carbono actuales en la Tierra (población) sino que también es similar a los pasados y los futuros átomos de carbono (universo). También puede tener confianza que los átomos de carbono encontrados en la Tierra son similares a los existentes en el resto del universo. En el otro extremo, este tipo de suposiciones en general son difíciles de mantener en el nivel social.

Estas diferencias en cuanto a la validez externa no son tan marcadas cuanto se analiza la dimensión de la **validez interna** de las investigaciones. En la jerga de la bibliografía de los diseños de investigación se suele afirmar que en todas las investigaciones que se quiera realizar inferencias causales, independientemente si se trata de investigaciones físicas o sociales, el investigador se debe asegurar, en la fase de diseño de la investigación, de controlar o aleatorizar el conjunto de factores extraños que le sugiera/n la o las teorías utilizadas. Esto es lo que precisamente le asegurará que aquellos factores extraños no sigan existiendo como factores perturbadores que puedan invalidar las inferencias internas o locales en el

momento de las conclusiones (Kish, 1987). En el último tiempo la visión anterior se ha expandido aún más permitiendo mayor seguridad en diseños observacionales en situaciones en donde no es posible un diseño experimental aleatorio lo que es sumamente importante en el dominio de las ciencias sociales (Morgan & Winship, 2015; Pearl, 2018).

Dada la introducción anterior, ahora estamos en condiciones de expresar lo mismo pero en términos más simples:

Nota

Donde no hay heterogeneidad con seguridad no hay problemas de representatividad. Si hay heterogeneidad, y el investigador no realiza acciones en su diseño para incluir esa heterogeneidad en su investigación, la misma sufrirá de un problema de representatividad que derivará en un problema de **validez externa**.

2.1 ¿Muestras de qué?

Un primer paso importante cuando uno se preocupa por la representatividad es entender sobre qué población de referentes y de unidades de observación/experimentación uno va a querer predicar sus inferencias. Para eso hay que analizar:

a) La clase de referencia de los conceptos utilizados que nos dirá el/los tipo/s de referente/s a investigar (individuos, organizaciones, etc.). Esto a veces se suele denominar **universo** o dominio de la teoría (Bunge, 1974).

b) Los objetivos de la investigación que nos indicaran, entre otras cuestiones, el alcance (usualmente especificando tiempo y espacio) de los referentes anteriores junto con otras características pertinentes de cada unidad de observación/experimentación. Usualmente los objetivos remiten a una población empírica que podrá grande o pequeña, homogénea o heterogénea, dispersa o aglomerada, etc.

Dentro del muestreo al conjunto formado por todos los objetos reales que cumplan las condiciones de los puntos «a» y «b» se lo denomina **población**⁴. En nuestra vida cotidiana, aunque sea solo por vivir en un tiempo y espacio determinado (y aun si somos investigadores de profesión) usualmente solo tenemos posibilidad de acceso empírico a un subconjunto de aquella población. Para empeorar las cosas, en las ciencias sociales muchas poblaciones son muy numerosas, heterogéneas y/u otras se encuentran muy separadas espacialmente lo que dificulta y hace costoso llegar a cada una de las partes de aquellas. En el extremo, a veces el investigador tiene el problema adicional de trabajar con poblaciones «invisibles» de las que se sabe o se presupone que existen, pero no se tienen datos agregados de ella y/o es sumamente difícil identificar/contactar a miembros de ella. Ante esta situación el investigador tiene 2 grandes opciones:

a) Se ajustan los objetivos de la investigación, especialmente en lo tocante al grado de alcance o generalidad de la investigación, hasta un punto que efectivamente la definición de la unidad de análisis construya una población en la que se pueda abordar empíricamente a cada una de las unidades que la componen y/o

b) Se realiza una **muestra** de aquella población.

En este sentido, en este taller se le prestará atención a las estrategias tipo “b” como un modo de conocer el todo a través de solo una parte de aquel. Más adelante también veremos que hay estrategias más eficientes que otras para con “poco” inferir “bastante”, aun cuando, en muchos casos, no se sepa a ciencia cierta si ese “bastante” es “suficiente”. En otras palabras, se verán las distintas características de diferentes diseños muestrales que aspiran a algún grado de representatividad con el objetivo de comprender cuál

⁴Expresado en términos de propiedades generales y específicas podría afirmarse que las **propiedades generales**, como su nombre lo indica, sirven para construir **géneros** y todos los objetos reales que pertenecen a ese género tienen el mismo valor en todas sus propiedades generales. Ejemplo: Todo objeto real que se clasifique como «persona» deberá cumplir una serie de propiedades generales que hacen a la esencia de «persona» y se incluyen en su definición. Ser estudiante o residir en la provincia de Buenos Aires no pertenece a un valor de una propiedad general de las personas. En cambio, mamífero descendiente del mono, sí. Las propiedades generales son necesarias para identificar la clase de referencia, pero no suficientes para construir la población sobre la cual se realizará la muestra.

Las **propiedades específicas**, también como su nombre lo sugiere, sirven para construir **especies de los géneros** en función de los diferentes valores en las propiedades específicas. Tiempo y espacio son típicas propiedades específicas que ayudan recortar al universo anterior delimitando una población empírica. Luego pueden existir otras propiedades específicas (como las anteriores de ser estudiante o vivir en Buenos Aires) que sirven para seguir delimitando aún más nuestra población.

de ellos puede ser más idóneo en función de los objetivos, el presupuesto y los datos disponibles en cada caso.

Existen varios criterios para clasificar a las muestras. Siguiendo una clasificación clásica (Neyman, 1934), todos los que se basan en algún modo en la aleatoriedad (*random*), ponen el acento en el **proceso** de la muestra y se las puede clasificar como **muestras probabilísticas**. Otros, como todos los que se basan en cuotas ponen más acento en las acciones y chequeos basados en las intenciones (*purposive*) del **resultado o producto final**. Aquí, más que usar el término de muestras intencionales de Neyman vamos a preferir el más amplio de muestras no probabilísticas, ya que también engloba a otros diseños que tienen la similitud, al menos a primera vista, de no ser probabilísticos (Baker et al., 2013). Ejemplos pueden considerarse las muestras basadas en el criterio de saturación y la heterogeneidad observada, los muestreos por conveniencia, los muestreos por matcheo (en donde las cuotas de Neyman serían un ejemplo), los muestreos basados en redes, usuales para el estudio de poblaciones invisibles (en donde el bola de nieve o snowball sería un ejemplo).

Finalmente en el último tiempo, y en parte por el avance de una mayor disponibilidad de información secundaria, cada vez existen más métodos que permiten incorporar esa mayor información secundaria como información auxiliar (*auxiliary information*) tanto en el diseño de la muestra como en el posterior ajuste de los estimadores de la misma. Este último proceso en particular se suele denominar calibración. Ambos usos de la información secundaria (tanto si se usan para el diseño *ex-ante* o para el ajuste de los estimadores *ex-post*) son ejemplos de diseños muestrales asistidos por modelos que derivan de información secundaria (*model assisted*).

En el último párrafo, casi al pasar, se ha comentado que «en el último tiempo» ha habido cambios en el mundo del muestreo. Más allá que se pueda afirmar que en algunos momentos haya habido más cambios que otros, la historia de la incorporación de las diferentes teorías de muestreo en la estadística como disciplina (antes dominada por aplicaciones sobre poblaciones enteras o censos) o en el diseño de investigaciones (antes dominada por diseños experimentales) es sumamente interesante y recomendable (Gigerenzer et al., 1997; Hacking, 1990/2004, 2006).

3. La domesticación del azar como medio para lograr muestras (aproximadamente) representativas

Si ser muy profundos en cuanto a la teoría del muestreo o en cuanto a su justificación más académica en lo que sigue se intenta recordar que sucede si se realizan muestras aleatorias dentro de una población. Este enfoque tiene mucho que ver con lo que se suele denominar «*Design Based Sample*» en la literatura sobre muestreo. Básicamente, en línea con la clasificación de Neyman anteriormente utilizada, son muestras que ponen énfasis en el proceso aleatorio de la selección de los casos. Es una escuela clásica dentro del muestreo y tiene muchas subvariantes. Algunas de ellas las veremos más adelante pero ahora nos concentraremos en la parte que tienen en común todas ellas. Para eso vamos a simular que hacemos muchas muestras aleatorias simples sobre una población imaginaria no muy grande (<2000). Primero haremos, o más bien repetiremos, muestras relativamente pequeñas y luego haremos muestras algo más grandes.

Para tener una mejor experiencia de este simulador es aconsejable su ejecución a través de este [link](#).

Con este programa podemos jugar de varias formas. Aquí nos interesa las siguientes.

1. En primer lugar ver que pasa, en los términos de la figura «datos acumulativos de las muestras» cuando realizamos muchas muestras sobre una misma población (p.e. Población = «Opción 3»). Como veremos, estas distribuciones, en especial si la muestra contiene más de 30 casos, converge hacia un patrón de distribución «normal». Lo interesante es que esta distribución emerge, con mayor o menor rapidez, de manera independiente de la forma de la población (Ver punto 2). También se puede probar escogiendo diferentes tamaños de las muestras (p.e. Tamaño de la muestra = 30 y 200).
2. Por otro lado se puede probar que sucede si, se hace el ejercicio anterior en diferentes poblaciones (p.e. con Población = «Opción 6»). Como se observará siempre se obtiene una distribución «normal» aunque en mayor tiempo y con una mayor varianza.

3.1 Población

Como se anticipó en la introducción, nuestra **población** será una población de establecimientos educativos de gestión estatal de nivel primario. Cada uno de los integrantes de esta población se pueden considerar como **unidades de selección**, el subconjunto finalmente seleccionado será la **muestra** y la cantidad de los miembros seleccionados será el **tamaño de la muestra**. En este caso, como se observa en Tabla 3.1, se tiene información variada sobre cada una de las escuelas. Como veremos más adelante, tener más información sobre las unidades de selección puede ayudar para la efectiva realización de diferentes diseños muestrales. Algunos de esos diseños servirán cuando el objetivo sea tener una muestra de escuelas (muestreos de una sola etapa) y otros, generalmente más complejos, podrán servir como un primer paso para luego realizar una muestra a estudiantes, directivos, etc. (muestreos polietápicos).

improvement in the performance of the model. The results are shown in Table 1.

Model	Accuracy	Precision	Recall	F1 Score
La-A	0.60	0.60	0.60	0.60
Ur-bano	0.60	0.60	0.60	0.60
ta-A	0.60	0.60	0.60	0.60
AN-	0.60	0.60	0.60	0.60
La-GEL	0.60	0.60	0.60	0.60
Ur-	0.60	0.60	0.60	0.60
pano	0.60	0.60	0.60	0.60
ta-CHE-	0.60	0.60	0.60	0.60
VERRY	0.60	0.60	0.60	0.60

Por ahora trabajaremos con este archivo para realizar diferentes tipos de muestras de establecimientos educativos. Un plus pedagógico de esta estrategia es que vamos a tener a mano los valores de las estimaciones de las diferentes muestras que se vayan realizando y los respectivos valores de los parámetros poblacionales para comparar resultados. Algunos de esos valores poblacionales se podrán considerar como información secundaria en el sentido que el interés de la muestra no es estimar esos parámetros. Otros de esos valores se los podrá considerar como los parámetros a estimar en la muestra. Esta última situación no es la usual porque si ya se tiene el parámetro poblacional no es necesario la realización de una muestra para su estimación.

- Matrícula
- Secciones
- Sondeo primero
- Sondeo segundo

20

- Región
- Ámbito

Algunas de las variables anteriores son categóricas (región, ámbito) y otras no. Vamos a ver que esto importa porque no es lo mismo estimar un parámetro continuo que uno categórico. Dentro de estos últimos tampoco es lo mismo estimar una variable con 25 categorías (p.e. región) que una variable categórica de 3 categorías (p.e. ámbito).

En la Tabla 3.2 puede observarse algunos de los valores de estos parámetros. Para el caso de las variables continuas (Matrícula, Secciones, sondeo primero, sondeo segundo) se ha calculado la media junto con los valores del primer y tercer cuartil. En el caso de las variables categóricas (región, ámbito) se han calculado los respectivos porcentajes de cada categoría. Esta distinción es importante porque mientras algunas muestras se esfuerzan por estimar medidas de tendencia central, otras se esfuerzan por estimar medidas de dispersión central y otras intentan hacer ambos tipos de estimaciones. Otra distinción importante es la anteriormente mencionada sobre la población que se quiera muestrear. Por ejemplo, el valor de la media del primer sondeo puede ser útil para estimar si la media de la **población de colegios** arroja un valor similar que la media de la/s muestra/s realizada/s de esos colegios. Sin embargo, no hay que olvidar que esos datos, sí con ellos se quiere referir a la **población de estudiantes**, habría que ponderarlos por la matrícula de cada colegio, esto es, habría que calcular su media ponderada.

Tabla 3.2: Valores poblacionales de las escuelas

Característica	N = 4.168
matricula, Media	267,9
Desconocido	9
secciones, Media	11,2
Desconocido	9
sondeo_primer, Media	57,3
Desconocido	560
sondeo_segundo, Media	69,5
Desconocido	570
region, % (n)	
01	4,5% (189)
02	5,4% (223)
03	5,0% (210)
04	5,1% (213)
05	4,7% (194)
06	3,6% (148)
07	3,3% (138)
08	3,6% (149)
09	4,9% (205)
10	5,4% (224)
11	4,0% (166)
12	3,7% (155)
13	3,1% (131)
14	4,1% (169)
15	4,2% (174)
16	3,0% (125)
17	3,2% (133)
18	3,8% (160)
19	2,8% (118)
20	3,8% (159)
21	2,8% (117)
22	3,7% (153)
23	3,7% (153)
24	4,7% (196)
25	4,0% (166)
ambito, % (n)	
Urbano	65,4% (2.727)
Rural	34,6% (1.441)
Grupado	28,8% (1.193)

Estos parámetros «conocidos» van a tener 2 funciones en este taller. Por un lado, nos van a servir para cotejar, *ex-ante*, la media de las medias muestrales realizadas con azar simple y, por otro lado, nos pueden servir, *ex-post*, para mejorar las muestras concretas efectivamente obtenidas. Esto último, más allá de las técnicas específicas que se utilicen, es importante por lo siguiente:

Las muestras que se hacen en la realidad son «únicas» o «individuales» en el sentido que no se repiten. En cambio, una buena parte de la teoría del muestreo supone una distribución de muestras (como las simulaciones anteriores en donde se realizaban varias muestras de una misma población). La mayoría de las veces el investigador que sale a campo dispone de solo una muestra y el objetivo es que «esa» muestra (y no cualquier otra posible) sea de las mejores y no de las peores. En este sentido, es útil tener herramientas que permitan saber si la muestra es de las buenas o de las malas y, si se trata de este último caso, como mejorarlas.

3.2 Muestreo por azar simple

Dentro de los métodos aleatorios el método del azar simple (*random sampling*) es un método tradicional y particularmente útil desde un punto de vista pedagógico para comenzar ya que muchos otros métodos son variaciones (usualmente más complejas) de este. El método del azar simple es el que intuitivamente se ha utilizado en la simulación anterior.

Desde una perspectiva amplia, en la actualidad se podría afirmar que este método de muestreo se encuentra en el medio de un continuo de situaciones en cuando al grado de información exigida para su realización. Lo «único» que pide es una lista de «contactos» de la población que se quiere analizar. La razón por la que «único» se encuentra entre comillas es la siguiente: La necesidad de la una lista puede ser algo exigente en algunas investigaciones (p.e. poblaciones invisibles) aunque algo insuficiente para otras (p.e. diseños con muestras estratificadas). La idea de «contacto» es algo polisémica, pero aquí apunta a que el caso seleccionado se pueda contactar de alguna forma (p.e. dirección de domicilio, mail, celular, etc.) para realizarle las observaciones/mediciones correspondientes.


A continuación vamos a realizar unas 1000 muestras de 300 casos cada una sobre el total de las 4168 escuelas. Esto es una relación entre el tamaño de la población y la muestra de casi el 14%. Hacemos esta cantidad de muestras para observar la distribución de los valores de las medias de cada muestra y ver si sucede algo similar a lo encontrado en el simulador anterior. Para facilitar la comparación lo haremos solo con las variables numéricas y dejaremos de lado las categóricas como Ámbito y Región. El resultado de estas simulaciones se puede observar en la Tabla 3.3.

Tabla 3.3: Medias de las medias muestrales

Característica	N = 1.000
matricula, Media (DE)	269 (15)
secciones, Media (DE)	11,18 (0,49)
sondeo_primero, Media (DE)	57,27 (0,95)
sondeo_segundo, Media (DE)	69,53 (0,91)

Como se puede comparar entre Tabla 3.2 y Tabla 3.3 los valores entre los parámetros poblacionales y la media de las estimaciones muestrales coincide. No solo eso. También podemos chequear que la distribución de esas medias sigue una distribución aproximadamente normal. Esto es lo que precisamente hacemos en la Figura 3.1.

Figura 3.1: Distribución de las medias muestrales



En la figura anterior se observa que la distribución de las 1000 muestras que tomamos, si bien se aproximan, no son idénticas a una distribución normal. Seguramente, si haríamos más muestras nos acercaríamos aún más a una distribución muestral pero quizá este ejemplo baste para explicitar el siguiente punto: Si haríamos muchas muestras vamos a saber con cierta seguridad que la media de las muestras será aproximadamente similar al parámetro poblacional. Sin embargo, quedan abiertas otras preguntas como ¿Qué sucede si solo tomamos una sola muestra? ¿Cómo sabemos si nuestra (única) muestra es de las buenas o de las malas? ¿Cómo sabemos que nuestra muestra no es alguna de las que están en el extremo izquierdo o derecho de la Figura 3.1?

Ahí es donde entra la ayuda de las librerías específicas. En la introducción se había comentado sobre la existencia de librerías específicas para el análisis de datos muestrales. Estas librerías le van a prestar atención a varios detalles del proceso de selección y nos van a pedir que los explicitemos. Por ejemplo, El tipo de muestras que nos van a interesar generalmente son «sin reemplazo» en el sentido que no queremos que, por ejemplo, un mismo colegio aparezca dos veces seleccionado en una muestra de colegios. También, casi todas las librerías de este estilo, nos van a pedir información de algunos totales de la población para construir ponderadores y otras librerías nos a pedir esos ponderadores utilizarlos en el análisis de los datos. En el caso de una muestra aleatoria simple ese ponderador, al menos en la fase de diseño, suele ser la probabilidad inversa de haber ingresado en la muestra (N/n , donde N es el tamaño de la población y n el tamaño de la muestra). En este tipo de diseño el valor del ponderador es el mismo para todas las unidades seleccionadas.

Tabla 3.4: Estimaciones con azar simple

Característica	Azar simple		Parámetro Pob.
	N = 4.168	95% CI	N = 4.168
matricula, Media (SE)	276,6 (2,9)	271, 282	267,9
secciones, Media (SE)	11,6 (0,1)	11, 12	11,2
sondeo_primero, Media (SE)	56,2 (0,2)	56, 57	57,3
Desconocido	472		560
sondeo_segundo, Media (SE)	69,8 (0,2)	69, 70	69,5
Desconocido	556		570
region, % (n=n (un-weighted))			
01	2,3% (n=7)	2,0%, 2,7%	4,5% (189)
02	6,3% (n=19)	5,8%, 6,9%	5,4% (223)
03	5,3% (n=16)	4,9%, 5,8%	5,0% (210)
04	7,0% (n=21)	6,5%, 7,6%	5,1% (213)
05	2,7% (n=8)	2,3%, 3,0%	4,7% (194)
06	3,7% (n=11)	3,3%, 4,1%	3,6% (148)
07	3,7% (n=11)	3,3%, 4,1%	3,3% (138)
08	5,3% (n=16)	4,9%, 5,8%	3,6% (149)
09	6,7% (n=20)	6,1%, 7,2%	4,9% (205)
10	6,7% (n=20)	6,1%, 7,2%	5,4% (224)
11	4,3% (n=13)	3,9%, 4,8%	4,0% (166)
12	2,3% (n=7)	2,0%, 2,7%	3,7% (155)
13	2,7% (n=8)	2,3%, 3,0%	3,1% (131)
14	4,0% (n=12)	3,6%, 4,4%	4,1% (169)
15	3,3% (n=10)	3,0%, 3,7%	4,2% (174)
16	2,0% (n=6)	1,7%, 2,3%	3,0% (125)
17	3,3% (n=10)	3,0%, 3,7%	3,2% (133)
18	3,0% (n=9)	2,7%, 3,4%	3,8% (160)
19	2,7% (n=8)	2,3%, 3,0%	2,8% (118)
20	3,7% (n=11)	3,3%, 4,1%	3,8% (159)
21	2,0% (n=6)	1,7%, 2,3%	2,8% (117)
22	4,0% (n=12)	3,6%, 4,4%	3,7% (153)
23	4,7% (n=14)	4,2%, 5,1%	3,7% (153)
24	3,0% (n=9)	2,7%, 3,4%	4,7% (196)
amplio, % (n=n (un-weighted))	5,3% (n=16)	4,9%, 5,8%	4,0% (166)
Desconocido	62,0% (n=257)	60%, 63%	65,4% (2702)

Abreviación: CI = Intervalo de confianza

Ahora que estamos analizando solo una muestra podemos empezar a ver algunas distancias entre los parámetros poblacionales y las estimaciones que surgen de la muestra. Esto es especialmente más notorio en los casos de las categorías menos difundidas de las variables categóricas como puede ser algunas de las regiones.

3.3 Muestreo Sistemático

El muestreo sistemático no ofrece muchas diferencias apreciables de cálculo con el azar simple aunque tiene una diferencia logística importante. No es necesario tener en el momento del diseño una lista centralizada de «contactos» a quien seleccionar. Esto hace que el muestreo sistemático, especialmente en muestras polietápicas, sea un buen candidato a aplicar en las últimas instancias de selección en donde cada encuestador, evaluador o *data entry*, de manera descentralizada, sí tiene acceso, *in situ*, a esa información. Es importante, de todos modos, explicitar el supuesto que la lista en cuestión no esconda un sesgo particular en su orden o, ante esta presuposición, poder reordenarla bajo algún criterio que fuerce el azar. De todos modos, ante la existencia de algún patrón subyacente, el muestreo sistemático, versus opciones como «elegir a los x primeros (o últimos)» parece mejor equipado. Sin embargo, estas últimas opciones tienen el beneficio de (usualmente) ser más simples de implementar para el operador final.

Como ejemplo podemos analizar la siguiente situación. Se quiere realizar una muestra de estudiantes y a) no se cuenta con información nominal en el momento del diseño de la muestra aunque b) sí se cuenta con una buena base de los colegios y c) se asume que dentro de cada colegio sí existe acceso a una lista de contactos de los estudiantes. En este contexto, se puede sortear una cantidad de colegios en una primera etapa (p.e. mediante la técnica Sec. 3.6) y luego, en una segunda etapa, se puede indicar al directivo, encuestador, etc. de cada escuela seleccionada que, una vez con acceso a la lista de estudiantes, seleccione una X cantidad de los mismos. Para realizar esa última selección el proceso será sortear al primer estudiante, seleccionarlo y luego, desde allí, saltar K estudiantes para seleccionar al segundo estudiante y así sucesivamente. En general, K representa el cociente entre el tamaño de la población a seleccionar N como el tamaño de la lista de estudiantes del colegio seleccionado y el tamaño de la muestra n como la cantidad de estudiantes que se quiere seleccionar de esa lista.

$$K = \frac{N}{n} \quad (3.1)$$

Siguiendo este ejemplo, supongamos que el encuestador tenga que elegir 5 estudiantes de una lista de 50. En ese caso se podría aplicar el siguiente código:

Cambiando lo que haya que cambiar, el código anterior también se podría aplicar si se quiere utilizar para seleccionar los 300 establecimientos que antes se habían seleccionado con el diseño del azar simple.

3.4 Muestreo Estratificado

La estratificación es un método que permite el uso de información auxiliar en el diseño muestral (Tillé, 2020, pág. 65). Esta definición tipo paraguas va de la mano de que la información auxiliar del marco muestral es necesaria para la construcción de estratos que, en principio, cumplen el criterio de que sean similares en su interior y diferentes entre ellos. Otra característica distintiva de los estratos es que estos son discretos, esto es, pueden tener, a lo sumo, un orden entre ellos, pero los límites entre ellos son puntuales más que continuos.⁶ Como regla general, si existe información auxiliar disponible, (casi) siempre es una buena idea estratificar (Tillé, 2020, pág. 65)

Si se recuerda los comentarios realizados en la introducción, cuanto menos heterogeneidad exista entre las unidades a seleccionar menor es el problema de la representatividad. Esto es precisamente una idea que intentan lo que intentan aprovechar la mayoría de los diseños estratificados. En el extremo, si todos los miembros de cada estrato son iguales entre sí y los tamaños o cantidad de casos de cada estrato también son iguales entre sí, solo habría que seleccionar a un caso por estrato como razón suficiente para obtener una muestra representativa de la población. Si los tamaños de los estratos fueran diferentes también se podría seleccionar un caso por estrato, pero la condición para que esta muestra sea representativa es que luego se incluyan ponderadores diferentes para cada estrato de la muestra en función de la inversa de la probabilidad de entrar en la muestra. Esta diferencia, es la diferencia central entre el muestreo estratificado proporcional y el no proporcional con asignación óptima que veremos más adelante.

⁶Más adelante veremos que existe un método denominado «estratificación implícita» que, si bien se considera una opción de muestreo sistemático, en la práctica se trata de un modo de agregar una variable cuantitativa a la estratificación (Cochran, 1977, pág. 205).

Para que el muestreo estratificado produzca ventajas en términos de precisión (en comparación con el azar simple) los estratos deben tener una heterogeneidad interna menor a la heterogeneidad del conjunto de la población aunque aquella se encuentre lejos del ejemplo extremo del párrafo anterior. Los estratos conforman subpoblaciones mutuamente excluyentes y exhaustivas de toda población aunque se pueden construir los mismos en función de datos categóricos, agregaciones de datos continuos (p.e. agrupaciones de años de antigüedad) o espaciales (p.e. Regiones). En una base de datos educativa puede haber muchas variables que pueden ser considerados candidatos para la formación de estratos. En este caso, a modo de ejemplo, nos quedaremos con «Ámbito» que posee 3 categorías que asumimos, como diría Platón en el Fedro, que cortan la realidad por sus articulaciones naturales (Platón, 2002 [370AVC], pág. 55). Por otro lado, utilizar «Ámbito» como estrato tiene otra virtud pedagógica que deviene de la diferente distribución porcentual de cada categoría. Esto lo hace un buen candidato para mostrar algunas características del muestreo estratificado en su versión proporcional y no proporcional, ya que la categoría «Rural Agrupado» posee un menor porcentaje de casos y, a igualdad de otras condiciones, veremos como eso dificulta su posterior análisis si se mantienen en la muestra las proporciones originales de la población. Veremos también que para decidir entre estos tipos de diseño también será útil indagar en el significado de un término clásico del muestreo como es el «dominio» de estimación.

A veces los estratos se construyen con base en antecedentes teóricos, pero nada impide que estos sean constructos estadísticos con un significado no muy claro como los que se pueden producir luego de un análisis de clústers (Everitt et al., 2011). Tampoco la técnica tiene una limitación en cuanto a la cantidad de categorías. Cabe aclarar que cualquier estrato debe ser capaz de construirse tanto a nivel poblacional como posible de identificarse/seleccionarse a nivel muestral. En este sentido, más allá si tiene un origen más teórico o estadístico, es claro que, como la muestra la definición de Tillé de más arriba, esta técnica exige tener acceso empírico a una mayor cantidad de variables en comparación con, por ejemplo, el azar simple.

3.4.1 Estratos con asignación proporcional

En este subtipo de muestreo estratificado utilizaremos la variable «Ámbito» como estrato y respetaremos, aproximadamente, la distribución que ese estrato posee en la población. Decimos «aproximadamente» porque aquí siempre existe un factor de redondeo que deviene de la necesidad de realizar la muestra sobre una cantidad de casos discretos. Esta última necesidad hace que, al igual que cuando se intenta respetar las proporciones de los votos de una elección para la renovación de bancas de la Cámara de Diputados, casi siempre existan pequeñas diferencias entre las proporciones poblacionales y las muestrales.

Seleccionada la muestra ahora le especifico los detalles del diseño mediante la librería `survey` o `srvyr`.

Y luego realizo la Tabla 3.5 con la información de algunas variables y esa misma tabla lo comparo con los valores de la Tabla 3.4 que refería al diseño con azar simple.

Tabla 3.5: Tablas comparativas entre resultados azar simple y estratificado

Característica	Estratificado P.		Azar simple	
	N = 4.168 ¹	95% CI	N = 4.168 ¹	95% CI
matricula, Media (SE)	262,3 (1,9)	258, 266	276,6 (2,9)	271, 282
Desconocido	28			
secciones, Media (SE)	10,9 (0,1)	11, 11	11,6 (0,1)	11, 12
Desconocido	28			
sondeo_primero, Media (SE)	57,9 (0,2)	58, 58	56,2 (0,2)	56, 57
Desconocido	712		472	
sondeo_segundo, Media (SE)	69,8 (0,2)	69, 70	69,8 (0,2)	69, 70
Desconocido	572		556	
region, % (n=n (unweighted))				
01	2,7% (n=8)	2,3%, 3,0%	2,3% (n=7)	2,0%, 2,7%
02	6,3% (n=19)	5,8%, 6,9%	6,3% (n=19)	5,8%, 6,9%
03	6,3% (n=19)	5,8%, 6,9%	5,3% (n=16)	4,9%, 5,8%
04	6,3% (n=19)	5,8%, 6,9%	7,0% (n=21)	6,5%, 7,6%
05	4,6% (n=14)	4,2%, 5,1%	2,7% (n=8)	2,3%, 3,0%
06	4,0% (n=12)	3,6%, 4,4%	3,7% (n=11)	3,3%, 4,1%
07	4,3% (n=13)	3,9%, 4,8%	3,7% (n=11)	3,3%, 4,1%
08	3,3% (n=10)	3,0%, 3,7%	5,3% (n=16)	4,9%, 5,8%
09	4,0% (n=12)	3,6%, 4,4%	6,7% (n=20)	6,1%, 7,2%
10	4,0% (n=12)	3,6%, 4,5%	6,7% (n=20)	6,1%, 7,2%
11	2,7% (n=8)	2,3%, 3,0%	4,3% (n=13)	3,9%, 4,8%
12	3,0% (n=9)	2,7%, 3,4%	2,3% (n=7)	2,0%, 2,7%
13	3,7% (n=11)	3,3%, 4,1%	2,7% (n=8)	2,3%, 3,0%
14	5,0% (n=15)	4,6%, 5,5%	4,0% (n=12)	3,6%, 4,4%
15	4,4% (n=13)	3,9%, 4,8%	3,3% (n=10)	3,0%, 3,7%
16	2,3% (n=7)	2,0%, 2,7%	2,0% (n=6)	1,7%, 2,3%
17	5,0% (n=15)	4,6%, 5,5%	3,3% (n=10)	3,0%, 3,7%
18	5,0% (n=15)	4,6%, 5,5%	3,0% (n=9)	2,7%, 3,4%
19	2,3% (n=7)	2,0%, 2,7%	2,7% (n=8)	2,3%, 3,0%
20	4,0% (n=12)	3,6%, 4,5%	3,7% (n=11)	3,3%, 4,1%
amplitud, % (n=n (unweighted))	4,2% (n=14)	1,1%, 1,6%	2,0% (n=6)	1,7%, 2,3%
desarrollo, % (n=n (unweighted))	2,0% (n=7)	1,0%, 1,8%	2,0% (n=7)	1,0%, 1,8%
Media (DE), % (n sin ponderar)				

Abreviacion: CI = Intervalo de confianza

Una característica importante de este tipo de muestreo es que sus factores de expansión o expansores, al menos en la fase de diseño, son iguales para todos los estratos. Esto suele ser una pequeña ventaja para el momento del análisis ya que requiere mano de obra algo menos especializada.

3.4.2 Estratos con asignación no proporcional

En el tipo de diseño anterior hubo una variable (Ámbito) que se usó para estratificar la muestra. En ese caso, salvo variaciones menores debido a los factores de redondeo antes comentados, las proporciones de la muestra respetan las proporciones poblacionales. Eso es lo que precisamente se intenta modificar con el muestreo con una asignación no proporcional. Usualmente, la idea que está detrás de esta estrategia es poder reducir el desvío estándar de aquellos estratos que más suman al desvío estándar de toda la muestra. El desvío estándar de cada estrato es una función entre la heterogeneidad propia de cada estrato (p.e. que tan iguales son entre sí los establecimientos «Rural Agrupado») con la cantidad de casos de ese estrato (a mayor cantidad de casos menor desviación estándar). Si en la muestra se respeta la proporción original de la población (aun en el caso de que los establecimientos de ámbitos urbanos tengan una misma heterogeneidad que el resto) es claro que los estratos rurales poseen una distribución muy baja y, por lo tanto, nos vamos a quedar con pocos casos en la muestra y, de manera derivada, con un alto error estándar en esos análisis. La propuesta original de Neyman (Neyman, 1934) justamente trata de como asignar de manera eficiente (desde el punto de vista estadístico) la cantidad de casos a cada estrato, haciendo que, para nuestro ejemplo, los estratos rurales se encuentren sobrerrepresentados y los urbanos subrepresentados. Esta estrategia permite que, para una igual cantidad de casos que un muestreo estratificado proporcional, se puedan hacer inferencias (bastante) más confiables para dominios de estimación más pequeños a cambio de perder (un poco) de confiabilidad en los dominios de estimación más grandes⁷.

La contraparte de esta ventaja es que ahora es necesario construir expansores diferentes para cada estrato para que se le devuelva la probabilidad que se encontraba en la población. En este sentido, el factor de expansión del estrato urbano será mayor al de los estratos rurales.

Aquí, para extremar esta lógica, vamos a realizar una muestra como si la distribución de la variable Ámbito fuera igual para sus 3 categorías.

⁷Un dominio o subclase de estimación es una partición de la población o de la muestra sobre la cual se espera realizar inferencias. A veces se usa la denominación que los dominios denotan subpoblaciones (de la población) y las subclases reflejan esas divisiones en la muestra (Kish, 1980, p. 209). En cualquier caso es conveniente introducir estos dominios en el diseño de la muestra para poder controlar su tamaño poblacional (Brus, 2022, Capítulo 14). En el ejemplo del cuerpo del texto se asume que esos dominios de estimación coinciden con los estratos aunque esto no tiene nada de necesario.

Tabla 3.6: Tablas comparativas entre muestra estraificada proporcional y no proporcional

Característica	Estratificado P		Estratificado no P	
	N = 4.168 ¹	95% CI	N = 4.168 ¹	95% CI
matricula, Media (SE)	262,3 (1,9)	258, 266	271 (2)	267, 275
Desconocido	28		38	
secciones, Media (SE)	10,9 (0,1)	11, 11	11 (0)	11, 11
Desconocido	28		38	
sondeo_primero, Media (SE)	57,9 (0,2)	58, 58	57 (0)	57, 58
Desconocido	712		577	
sondeo_segundo, Media (SE)	69,8 (0,2)	69, 70	70 (0)	69, 70
Desconocido	572		533	
region, % (n=n (unweighted))				
01	2,7% (n=8)	2,3%, 3,0%	4,2% (n=14)	3,8%, 4,6%
02	6,3% (n=19)	5,8%, 6,9%	3,9% (n=6)	3,5%, 4,4%
03	6,3% (n=19)	5,8%, 6,9%	4,6% (n=7)	4,2%, 5,0%
04	6,3% (n=19)	5,8%, 6,9%	8,5% (n=13)	7,9%, 9,1%
05	4,6% (n=14)	4,2%, 5,1%	6,6% (n=11)	6,1%, 7,2%
06	4,0% (n=12)	3,6%, 4,4%	6,4% (n=11)	5,9%, 6,9%
07	4,3% (n=13)	3,9%, 4,8%	3,3% (n=5)	2,9%, 3,7%
08	3,3% (n=10)	3,0%, 3,7%	2,0% (n=3)	1,7%, 2,3%
09	4,0% (n=12)	3,6%, 4,4%	3,9% (n=6)	3,5%, 4,4%
10	4,0% (n=12)	3,6%, 4,5%	5,6% (n=20)	5,1%, 6,1%
11	2,7% (n=8)	2,3%, 3,0%	4,0% (n=7)	3,6%, 4,5%
12	3,0% (n=9)	2,7%, 3,4%	1,5% (n=7)	1,2%, 1,7%
13	3,7% (n=11)	3,3%, 4,1%	3,5% (n=15)	3,1%, 4,0%
14	5,0% (n=15)	4,6%, 5,5%	4,0% (n=19)	3,6%, 4,4%
15	4,4% (n=13)	3,9%, 4,8%	4,3% (n=24)	3,9%, 4,7%
16	2,3% (n=7)	2,0%, 2,7%	2,7% (n=12)	2,4%, 3,1%
17	5,0% (n=15)	4,6%, 5,5%	4,4% (n=15)	4,0%, 4,8%
18	5,0% (n=15)	4,6%, 5,5%	3,5% (n=12)	3,2%, 4,0%
19	2,3% (n=7)	2,0%, 2,7%	2,6% (n=6)	2,2%, 2,9%
20	4,0% (n=12)	3,6%, 4,5%	3,0% (n=9)	2,7%, 3,4%
amplitud, % (n=n (unweighted))	4,2% (n=14)	3,8%, 4,6%	2,7% (n=9)	2,3%, 3,1%
Barra dispersa, Media (SE), % (n sin ponderar)	2,7% (n=8)	2,3%, 3,0%	4,0% (n=7)	3,6%, 4,5%

Abreviacion: CI = Intervalo de confianza

3.5 Muestreo por Clústers

El muestreo por clúster es otra manera de aplicar el azar para diseñar muestras. A diferencia del muestreo estratificado en el muestreo por clúster el investigador considera a estos como «racimos» de casos que, usualmente, se encuentran cercanos geográficamente pero no necesariamente socialmente o, más en general, no son homogéneos en las variables de estudio. En efecto, la ventaja de este tipo de muestreo es que abarata costos en la ejecución de muestras espacialmente extensas y especialmente si en ese espacio extenso hay numerosos racimos de casos como, por ejemplo, una multitud de pequeños poblados urbanos de 50.000 personas. El precio que usualmente se paga (a igual cantidad de casos) es un aumento en el error standard pero, justamente, el quid de la cuestión es que dado la baja del costo unitario de cada caso ahora es posible, con igual presupuesto, agregar más casos a la muestra para bajar la precisión hasta el valor deseado.

3.6 Muestreo Proporcional al Tamaño (PPS)

Históricamente, los diseños muestrales tradicionales asignaban probabilidades iguales de selección a todas las unidades de la población (como en el Muestreo Aleatorio Simple). Sin embargo, en poblaciones de establecimientos o unidades con tamaños sumamente dispares (por ejemplo, escuelas con matrículas que van desde menos de 10 estudiantes hasta más de 1500), seleccionar escuelas con igual probabilidad puede resultar ineficiente desde un punto de vista estadístico y, asumiendo un costo fijo por acercarse a cualquier establecimiento, oneroso desde un punto de vista económico.

El hito fundamental en esta teoría lo constituyó el trabajo de Hansen y Hurwitz (Hansen & Hurwitz, 1943), quienes introdujeron el muestreo con **probabilidades proporcionales al tamaño (PPS)**⁸. El PPS fue uno de los primeros diseños en donde se trabajó, explícitamente, con probabilidades de inclusión conocidas y, principalmente, diferentes. Una de las limitaciones de ese primer enfoque era que se asumía una selección con reemplazo lo que permitía que un cluster volviera a ser reelegido. Esto cambió unos años después gracias al trabajo de Horvitz y Thompson en donde se propuso un estimador insesgado para probabilidades conocidas y diferentes en contextos de selecciones sin reemplazo (Horvitz & Thompson, 1952).

Este enfoque demostró que si la variable bajo estudio está correlacionada con el tamaño del cluster (establecimientos educativos en muchos de nuestros casos), es posible seleccionar unidades con probabilidades diferentes —y conocidas— de forma tal que se reduzcan drásticamente las varianzas de los estimadores agregados, manteniendo estimaciones no sesgadas. Este es uno de los principales beneficios estadísticos de este tipo de diseños. Sin embargo, posee otras características que lo hacen deseable en los casos en donde el supuesto que la/s variable/s bajo estudio no estén correlacionadas con el tamaño del cluster. Posiblemente la más interesante es que, en diseños polietápicos y en ausencia de no respuesta, la muestra es autoponderada y relativamente económica porque los cluster más grandes tienen mayor chance de salir en la muestra y, por lo tanto, se amortiza más el costo fijo de ir a cada cluster.

Muchas veces, especialmente en diseños polietápicos, se desea que en la primera etapa las unidades de selección (llamadas justamente unidades de selección primarias) sean escogidas en función de alguna variable que sirva como indicador de su tamaño. Esta técnica se puede considerarse como un caso especial del muestreo por clústers (Lumley, 2010, pág. 46). En el caso de unidades geográficas esa variable podrá ser el tamaño espacial o área (p.e. km²) y en variables no espaciales podrá ser la cantidad de personas (p.e. votantes en distritos). En el caso de una muestra de colegios, variables como el tamaño de la matrícula pueden ser buenas candidatas a utilizar en este tipo de muestras.

Un PPS, por diseño, va a otorgar una mayor probabilidad de salir en la muestra a los colegios con mayor matrícula y estos pueden poseer características particulares como, por ejemplo, encontrarse abrumadoramente en ámbitos urbanos. De este modo, ya podemos intuir que, con respecto a la población de establecimientos, una muestra PPS (sin ponderar) obtendrá como resultado (quizá no buscado) una sobrerrepresentación de los **establecimientos** de ámbito urbano al tiempo que también habrá una sobrerrepresentación (esta vez buscada) de aquellos establecimientos con mayor matrícula. Aunque parezca algo paradójico, esto es justamente para darles a todos los **estudiantes** (y no solo los del ámbito urbano) una misma chance de salir en la muestra. Esto último depende, especialmente en un diseño polietápico, que se haga efectivamente después de haber realizado la selección primaria, esto es, que se haga después de la primera etapa.

⁸La sigla PPS viene de la expresión «Probability Proportional to Size» que es como se lo conoce en la bibliografía de muestreo.

A pesar de cierta idea intuitiva acerca del objetivo del muestreo PPS, su efectiva aplicación (especialmente en muestreos sin reemplazo) tiene sus complejidades a nivel de los algoritmos a utilizar. Esto en parte es algo compartido por todos los muestreos sin reemplazo (versus los con reemplazos), pero aquí está presente la dificultad adicional de que las probabilidades de inclusión son diferentes. En efecto, el muestreo PPS puede ser considerado como un tipo de muestreo con probabilidades de inclusión diferentes (*unequal probabilities*), pero con la particularidad específica que esas probabilidades diferentes se calculan en función del tamaño de las unidades a seleccionar en primera instancia. A continuación vamos a utilizar un algoritmo que tiene que ver con la idea de «*local pivotal*» que vamos a ver con mayor profundidad cuando veamos las muestras bien dispersas (Sec. 4.3)⁹.

Para visualizar esto vamos primero vamos a construir a realizar 2 ejemplos. Uno en donde se realiza un PPS en donde luego solo se expande por un ponderador que simula que todos los establecimientos tenían las mismas chances de haber entrado (o, expresado de otro modo, que expande pero no pondera) y otro en donde, a esa misma muestra, se la pondera por la probabilidad inversa de haber ingresado en la muestra, esto es, un ponderador que haga pesar menos a aquellos establecimientos con mayor tamaño. Siguiendo con el ejemplo de los colegios, si el proceso es seleccionar los colegios por tamaño y luego realizar un censo (esto es, ninguna muestra) de estudiantes dentro de cada uno de los colegios seleccionados, tanto los colegios como los estudiantes de ámbito urbano se encontrarán sobrerrepresentados por lo que un ponderador que tenga en cuenta las probabilidades inversas en función del tamaño puede ser útil.

⁹Existen otros algoritmos para realizar un muestreo PPS. Muchos de ellos son algoritmos especializados en probabilidades desiguales (en donde la desigualdad por tamaño sería un caso especial) por lo que muchos de sus nombres suelen empezar con UP (*unequal probabilities*). Algunos son los siguientes: UPtillé, UPpivotal, UPpoisson (Tillé & Matei, 2023).

Tabla 3.7: Tablas comparativas entre PPS con ponderador y sin ponderador

Característica	PPS expandida pero no ponderada	PPS ponderada por PI en función del tamaño	
	N = 4.159 ¹	N = 4.012 ¹	95% CI
matricula, Media (SE)	529,5 (2,90)	277,7 (9,08)	260, 296
secciones, Media (SE)	19,7 (0,08)	11,6 (0,34)	11, 12
sondeo_primer, Media (SE)	54,1 (0,13)	58,6 (1,12)	56, 61
Desconocido	83	153	
sondeo_segundo, Media (SE)	67,9 (0,12)	74,2 (0,65)	73, 75
Desconocido	97	678	
region, % (n=n (un-weighted))			
01	6,3% (n=19)	4,7% (n=19)	4,2%, 5,3%
02	7,0% (n=21)	4,5% (n=21)	4,0%, 5,0%
03	9,7% (n=29)	5,5% (n=29)	5,0%, 6,1%
04	13,7% (n=41)	7,6% (n=41)	6,9%, 8,3%
05	7,0% (n=21)	3,4% (n=21)	3,0%, 3,7%
06	3,7% (n=11)	3,3% (n=11)	2,9%, 3,8%
07	2,7% (n=8)	2,6% (n=8)	2,2%, 3,0%
08	5,7% (n=17)	2,8% (n=17)	2,5%, 3,2%
09	11,3% (n=34)	4,9% (n=34)	4,4%, 5,4%
10	5,0% (n=15)	4,1% (n=15)	3,6%, 4,7%
11	5,0% (n=15)	3,6% (n=15)	3,1%, 4,1%
12	2,0% (n=6)	3,5% (n=6)	2,8%, 4,3%
13	1,3% (n=4)	3,9% (n=4)	3,0%, 5,0%
14	3,0% (n=9)	2,3% (n=9)	1,9%, 2,6%
15	2,3% (n=7)	3,4% (n=7)	2,8%, 4,1%
16	0,0% (n=0)	0,0% (n=0)	0,00%, 0,00%
17	0,7% (n=2)	1,3% (n=2)	0,95%, 1,7%
18	3,7% (n=11)	14,6% (n=11)	11%, 18%
19	1,3% (n=4)	1,2% (n=4)	0,98%, 1,5%
20	1,3% (n=4)	1,6% (n=4)	1,2%, 2,0%
21	1,3% (n=4)	1,7% (n=4)	1,3%, 2,1%
22	2,3% (n=7)	1,6% (n=7)	1,3%, 1,8%
23	1,3% (n=4)	3,9% (n=4)	3,1%, 5,0%
amplito, % (n=n (un-weighted))	99,7% (n=416)	62,4% (n=25)	0,30%, 100%
Media (EST); % (n sin ponderar)			

Abreviacion: CI = Intervalo de confianza

En efecto, en la Tabla 3.7 puede observarse que si trabajamos en una muestra PPS solo expandiendo, pero sin ponderar (primera tabla desde la izquierda) vemos como el valor promedio de la matrícula es alto (529) y que la abrumadora mayoría de los establecimientos seleccionados son del ámbito urbano (95%). Si luego analizamos la muestra ponderada por la probabilidad inversa en función del tamaño vemos como la mayoría de los valores se acercan a los valores conocidos de la población, especialmente aquellos que refieren a propiedades intrínsecas de los establecimientos como la región y el ámbito. Sin embargo, esta operación tiene sus riesgos porque hace depender mucho al ponderador de la matrícula y esta puede ser sumamente heterogénea. Por poner un ejemplo, en el muestreo PPS fueron seleccionados 5 establecimientos de la región 25 que es una región que se caracteriza por tener un porcentaje de establecimientos rurales mayor a la media (alrededor del 40% son urbanos). Pero dado que en el PPS los establecimientos más grandes tienen más chances de entrar en la muestra se seleccionaron 4 establecimientos urbanos (con matrícula típica de ámbitos urbanos) y solo 1 de ámbito rural. En este contexto el ponderador luego hace que esos 4 pesen menos y que ese único establecimiento rural (que tiene una matrícula de 7 estudiantes) pese mucho más que lo que descuentan los 4 urbanos. El resultado es que la región 25, cuando se trabaja con el ponderador, salta desde un 1,7% sin ponderar hasta un 14% ponderado. Algo similar sucede con la región 18. Por esta razón, es interesante también observar que en muchos casos el intervalo de confianza con la muestra ponderada se expande (p.e. región 18 y 25). Esto se debe a que el ponderador ahora hace pesar más en la estimación a situaciones en donde se encuentran pocos casos y, por lo tanto, al estar basadas en menos casos esas estimaciones poseen un margen de error mayor.

Si en cambio, luego en una segunda etapa, se realiza un muestro de una cantidad fija (p.e. 10 estudiantes por colegio seleccionado) la muestra de colegios sin ponderar seguirá sobrerrepresentando a los **establecimientos** del ámbito urbano pero tiene muchas chances de representar aceptablemente a la población de **estudiantes**. Esto último justamente una de las características más apreciadas del PPS en diseños polietápicos. En efecto, aplicado al mundo educativo, puede ser algo buscado explícitamente si se utiliza la selección de los colegios como unidades de selección primarias y luego a los estudiantes como unidades de selección secundaria o final. En otras palabras, se trata de un efecto buscado por diseño, justamente porque ahora el objetivo está puesto en lograr una muestra representativa de la población de estudiantes a través de una población de establecimientos que contiene variables agregadas de los estudiantes.

Para fijar las ideas, en el ejemplo anterior se seleccionarían en primera instancia unos 300 establecimientos, luego se obtendría una muestra final de 3000 estudiantes porque en la segunda instancia se seleccionaron 10 estudiantes por establecimiento. Una virtud práctica de este último ejemplo es que, aparte de reducir costos de logística en comparación a un muestreo por azar simple de un solo paso (porque se van a menos unidades de selección primarias), es que otorga un mismo ponderador a cada caso seleccionado (se dice que la muestra es autoponderada) lo que facilita muchos análisis posteriores. Esto es un típico ejemplo de muestra compleja en donde la muestra se realiza en más de una etapa y en cada una de ellas se utilizan técnicas diferentes.

En relación con lo anterior y de manera aparentemente paradójica, la muestra PPS sin ponderar estima mejor las variables agregadas como el valor del primer y segundo sondeo que un análisis censal de toda la población de colegios (como se hizo en Tabla 3.2). Lo paradójico de esto es que una muestra, esto es, una parte de un todo, logre un mejor acercamiento a un respectivo parámetro poblacional que un censo, esto es, un registro de cada una de las partes del todo. La solución a esta paradoja es entender que la Tabla 3.2 hace referencia a la población de colegios y, en ese sentido, sus valores son correctos. Ahora bien, si con esos datos (censales, pero de la población de establecimientos) se quiere hacer afirmaciones sobre la población de estudiantes la información de la Tabla 3.2 no es la más idónea o, al menos, hay que tratarla de manera diferente. En las variables que se pueden considerar como variables agregadas de estudiantes (p.e. sondeo_primer, sondeo_segundo) más que calcular la media habría que haber calculado la media ponderada por matrícula y ese cálculo sería un mejor estimador de la media de las notas de la población de estudiantes. En ese caso, el resultado de ese cálculo sí se podría considerar como un parámetro de la población de estudiantes y contra esos valores se debería comparar las estimaciones del diseño PPS sin ponderar. Esto precisamente se puede observar en la Tabla 3.8.

Tabla 3.8: Medias de las notas según tipo de muestra y población

Característica	PPS sin ponderar	Pob. media ponderada	Pob. media sin ponderar
sondeo_primero, Media	54	54	57
sondeo_segundo, Media	68	68	70

Tabla 3.9: Tablas comparativas entre PPS y estratificado proporcional

4. Muestreos balanceados y bien distribuidos

4.1 Muestras Balanceadas (por el método del cubo)

Las muestras balanceadas son un método particular dentro del espectro de las técnicas disponibles en la que felizmente se juntan las potencialidades del enfoque del «*Design Based*» y del «*Model Assisted*». En este contexto, Tillé afirma que:

«En un diseño muestral balanceado, las probabilidades de inclusión son decididas antes de la muestra. Un muestreo balanceado puede ser visto como un tipo de calibración que es directamente integrada dentro del diseño de la muestra» (Tillé, 2011, pág. 216).

Este tipo de técnica permite diseñar muestras balanceadas en el sentido que las medias muestrales de las covariables sean (aproximadamente) iguales a las medias poblacionales de esas covariables. Esto, como mínimo, es una estrategia efectiva para evitar caer en el pequeño subconjunto de muestras aleatorias que son muy sesgadas (Tillé, 2011, pág. 221). En este sentido, se recuerda que cuando realizamos diseños por azar tenemos chances (si bien bajas) de obtener muestras muy sesgadas. El muestreo balanceado evita esta situación y, la mayoría de las veces (siempre que las covariables disponibles estén empíricamente relacionadas con las variables de estudio) suele ofrecer muestras con las que luego es posible realizar una estimación con una mayor precisión que las realizadas con el azar simple. Si se agregan más covariables al diseño y, nuevamente, estas se encuentran linealmente relacionadas con las variables de estudio, el estimador de la media poblacional también mejorará aún más su precisión.¹⁰

Lo anterior puede considerarse un viejo *desideratum* de los diseños muestrales aunque antes no había disponible algún algoritmo de cálculo aplicable de una manera generalizable y precisa que pudiera ser ejecutado o calculado de manera viable (Deville & Tillé, 2004). Eso es lo que precisamente logra el método del cubo. De manera alternativa, las muestras balanceadas pueden ser vistas como un tipo de calibración (Cap. 5.) que se encuentra integrada en el diseño de la muestra, y por lo tanto se trata de un proceso *ex-ante* la ejecución de la misma, más que algo *ex-post* a la misma como la estimación de los estimadores (Tillé, 2011, pág. 216).

Por lo tanto, el contexto actual de:

- a) un mayor acceso a fuentes secundarias de datos y
- b) una mayor capacidad computacional,

parece ser un contexto particularmente propicio para la aplicación y difusión de este tipo de diseños porque, justamente, se trata de un diseño demandante en cuanto a datos secundarios (en forma de información auxiliar o covariables) y demandante con respecto a recursos computacionales (para ejecutar el algoritmo del método del cubo).

Antes de pasar a la aplicación de este diseño con la base de establecimientos de nivel primario vamos a considerar un ejemplo trivial con variables espaciales en donde se puede simular fácilmente la linealidad de la variable de estudio con respecto a otras covariables. Esto también servirá como un anticipo para cuando intentaremos incorporar explícitamente variables espaciales (a través de coordenadas) en la muestra (Sec. 4.3).¹¹


¹⁰En cambio, el balanceo, si bien en su origen tiene una fuerte vinculación con el enfoque del «*Model Assisted*», no se encuentra tan alejado del «*Design Based*» dado que el algoritmo del cubo selecciona muestras balanceadas dentro del conjunto de muestras aleatorias (Tillé, 2010, pág. 39).

¹¹Este tipo de discusiones ha enfrentado (y por ahora continúa enfrentando) a los representantes de los enfoques de la «*design based sample*» y del «*model assisted*». Los primeros suelen dudar de los beneficios de aplicar la calibración sobre diseños no probabilísticos, aunque no suelen tener objeciones cuando la calibración se realiza sobre diseños probabilísticos (Elliott & Valliant, 2017). En el fondo, lo que está en juego son los grados de garantía que ofrece cada técnica acerca de la representatividad y esto no solo incluya la discusión sobre las heterogeneidades observables (algo mantenido por ambos enfoques), sino también sobre las heterogeneidades no observables (algo históricamente mantenido por el enfoque de «*design based*»).

Supongamos una población como un bosque en donde tenemos alguna variable continua que nos interesa investigar. Supongamos además que, a efectos pedagógicos, nosotros sabemos la distribución de esa variable y, para forzar el pensamiento espacial, vamos a suponer que esa variable continua es una representación de la densidad de la vegetación de cada celda de una grilla de coordenadas. El valor de esa densidad lo vamos a visualizar indicando un valor amarillo para sus valores más altos y azul para sus valores más bajos. Con respecto a las grillas que representan distintas partes del bosque se las puede ubicar con un valor en el eje «Hacia el Norte» y otro valor en el eje «Hacia el Este».

Este ejemplo espacial es útil porque permite construir y visualizar fácilmente la linealidad de las covariables o variables auxiliares («Hacia el Norte» y «Hacia el Este») con la variable de estudio («Densidad de la vegetación»). En el caso de la Figura 4.1 se observa como a medida que vamos hacia el Norte la vegetación es algo más espesa. Lo mismo puede decirse en cuanto si vamos hacia el Este. En este sentido, el valor más alto de densidad se encuentra en la intersección de los valores más altos de los ejes anteriores o, expresado de manera alternativa, en el cuadrante superior derecho de la población. Esto quiere decir que estas variables auxiliares se encuentran empíricamente relacionadas de **forma lineal** con el valor de la densidad de vegetación.

Figura 4.1: Muestra balanceada “Hacia el Este” (E) y “Hacia el Este y el Norte” (E y N)



Por otro lado, en la Figura 4.1 también se observan las 2 muestras balanceadas de la población descritas en el párrafo anterior. Cada muestra posee 4 casos representados por los cuadrados blancos. La de la izquierda se encuentra balanceada solamente por el eje «Hacia el Este» y, acorde con esto, los casos seleccionados se esparcen de Este al Oeste. La muestra de la derecha, en cambio, se encuentra balanceada por ambos ejes por lo que la distribución de los casos seleccionados no solo varían de Esta a Oeste, sino que también lo hacen de Norte a Sur. En este sentido específico, se puede afirmar que la segunda muestra es más balanceada que la primera y, de manera intuitiva, se puede afirmar que aquella es más representativa que esta.

4.2 Muestras Balanceadas sobre base de establecimientos

Ahora pasaremos a aplicar este diseño a la base de escuelas que venimos trabajando. Esta vez vamos a incorporar una mayor cantidad de información secundaria que se encuentra disponible en la base de establecimientos. Como en muchas otras técnicas, la introducción de más variables no es garantía de un mejor resultado, ya que en este caso la agregación de más variables, especialmente si no están linealmente relacionadas con las variables de estudio, puede ser contraproducente (Tillé, 2011, pág. 222). Ese es

precisamente una de las utilidades del ejemplo anterior de la Figura 4.1, ya que en él era fácil construir y visualizar la linealidad de la relación entre las covariables y la variable de estudio. Por esta razón, en este proceso de selección es clave tener claras las variables de estudio, para luego determinar qué covariables de la información secundaria disponible es conveniente incluir.

En este caso, nos focalizaremos en diferentes tipos de objetivos para demostrar la flexibilidad de la técnica. En primer lugar, nos interesará tener una muestra de los establecimientos desde la base de los establecimientos (Sec. 4.2.1) y luego una muestra de los estudiantes desde esa misma base (Sec. 4.2.2).

Las lista de covariables que serán incluidas, con fines más metodológicos que teóricos, serán las siguientes:

- Matrícula
- Secciones
- Región
- Ámbito

La lista anterior funciona a modo de ejemplo aunque tiene la virtud de trabajar con información secundaria casi completa, ya que se trata de variables con muy baja tasa de no respuesta. En efecto, aquí usaremos estas covariables tanto cuando nos interese averiguar características de los establecimientos como de los estudiantes, pero un análisis más real implicaría usar un conjunto diferente para cada muestra. La razón de esto es al ser diferentes las variables de estudio también podrían/deberían ser las covariables disponibles y/o usadas.

Dicho lo anterior parece pertinente el siguiente comentario. Cuando algunos establecimientos no tienen datos en algunas de las covariables utilizadas estos no forman parte de la muestra. Esto recuerda algo que se había comentado cuando se vio el muestreo por azar simple (Sec. 3.2). El muestreo por azar simple solo exige una lista (y/o algún dato que luego permita su contacto empírico) de los miembros de la población. El método del cubo exige, además, el acceso a otras variables de la población en cuestión en forma de información auxiliar. Si existen casos que no tienen esa información, estos no podrán ingresar a la muestra y esto tiene diferentes tipos de consecuencias.

La primera consecuencia es que el investigador se puede enfrentar a la disyuntiva sobre si se prefiere a) usar covariables completas (en el sentido que no tienen casos faltantes) pero con una menor relación con la/s variable/s de estudio o si se prefiere b) covariables incompletas pero más fuertemente relacionadas con estas últimas. Siempre pensando en casos algo extremos, en el primer caso el balanceo será efectivo, pero quizá contraproducente porque balanceará la muestra con variables que no se encuentran empíricamente relacionadas con la variable de estudio. En el segundo caso se aumentan los problemas de cobertura (*undercoverage error*) y se disminuye la precisión de la muestra por trabajar con menos casos.

Para poner un ejemplo, las variables «sondeo_primero» y «sondeo_segundo» podrían ser opciones como covariables (siempre igual dependiendo de que se quiera investigar) pero tienen una alta tasa de no respuesta o de dato faltante (+ de 550 casos). Y parece ser que esta ausencia de datos se distribuye de manera desigual entre la población de los establecimientos, ya que los mismos se concentran en establecimientos con una matrícula de menos de 10 estudiantes. En este caso su uso como covariables generaría un sesgo (*bias*) muestral por el problema de la falta de cobertura porque los casos que integran la muestra (p.e. Ámbito Urbano) son diferentes a los que no integran (p.e. Ámbitos Rurales). En otras palabras, la ausencia de datos no es aleatoria por lo que los van a quedar dentro de la muestra serán, por diseño, diferentes a los que quedaran fuera de la misma.¹²

4.2.1 Muestra Balanceada - Población Establecimientos

En esta primera aplicación del muestreo del cubo con la base de establecimientos vamos a tener como objetivo tener una muestra de la población de establecimientos y no, por ejemplo, de los estudiantes. En el primer caso, en principio, las probabilidades de inclusión son iguales para cada establecimiento. Como veremos más adelante (Sec. 4.2.2) esta técnica también permite realizar muestras con diferentes probabilidades de inclusión.

En la Tabla 4.1 se puede observar los resultados de la muestra balanceada para colegios. En esta tabla los resultados se comparan contra los resultados anteriores de la muestra de azar simple y los respectivos totales poblacionales. Como se aclaró anteriormente en estas tablas no se van a incluir ni el error estándar ni los intervalos de confianza dada lo incómodo de su cálculo y posterior visualización en tablas. De todos

¹²En otras palabras, si ya se sabe de antemano que se va a realizar una post-estratificación es más simple utilizar una función específica para post-estratificar (p.e. la función `poststratify` de la librería `survey` o `poststrata` de la librería `sampling`).

modos, se alcanza a visualizar que en muchas de las variables analizadas existe una pequeña mejora con la excepción de algunas categorías de la variable Región.¹³

¹³Es posible que parte de los mayores sesgos en algunas categorías de la variable Región se deban a que la falta de datos en algunas de las covariables elegidas sea desigual según Región. De todos modos, la cantidad de casos (establecimientos) que no tenían las covariables completas era 9.

Tabla 4.1: Estimaciones con muestra balanceada para colegios

	Balanceo Colegios	Azar Simple	Pob. Colegios
Característica	N = 4.159¹	N = 4.168¹	N = 4.168
matricula, Media	269,2	276,6	267,9
secciones, Media	11,2	11,6	11,2
sondeo_primero, Media	57,4	56,2	57,3
Desconocido	610	472	560
sondeo_segundo, Media	69,1	69,8	69,5
Desconocido	638	556	570
region, % (n=n (un-weighted))			
01	4,0% (n=12)	2,3% (n=7)	4,5% (189)
02	4,7% (n=14)	6,3% (n=19)	5,4% (223)
03	5,0% (n=15)	5,3% (n=16)	5,0% (210)
04	4,0% (n=12)	7,0% (n=21)	5,1% (213)
05	3,7% (n=11)	2,7% (n=8)	4,7% (194)
06	3,3% (n=10)	3,7% (n=11)	3,6% (148)
07	2,7% (n=8)	3,7% (n=11)	3,3% (138)
08	3,7% (n=11)	5,3% (n=16)	3,6% (149)
09	5,0% (n=15)	6,7% (n=20)	4,9% (205)
10	6,0% (n=18)	6,7% (n=20)	5,4% (224)
11	6,0% (n=18)	4,3% (n=13)	4,0% (166)
12	4,3% (n=13)	2,3% (n=7)	3,7% (155)
13	3,0% (n=9)	2,7% (n=8)	3,1% (131)
14	5,0% (n=15)	4,0% (n=12)	4,1% (169)
15	3,7% (n=11)	3,3% (n=10)	4,2% (174)
16	5,3% (n=16)	2,0% (n=6)	3,0% (125)
17	6,0% (n=18)	3,3% (n=10)	3,2% (133)
18	4,3% (n=13)	3,0% (n=9)	3,8% (160)
19	2,7% (n=8)	2,7% (n=8)	2,8% (118)
20	2,3% (n=7)	3,7% (n=11)	3,8% (159)
21	3,3% (n=10)	2,0% (n=6)	2,8% (117)
22	3,3% (n=10)	4,0% (n=12)	3,7% (153)
23	3,0% (n=9)	4,7% (n=14)	3,7% (153)
24	4,0% (n=12)	3,0% (n=9)	4,7% (196)
amplito, % (n=n (un-weighted))	1,7% (n=5)	5,3% (n=16)	4,0% (166)
Desconocido	2,9% (n=12)	22,5% (n=93)	25,4% (1052)
Media (DE); % (n sin ponderar)			

4.2.2 Muestra Balanceada - Población Estudiantes

En esta pequeña sección vamos a observar la flexibilidad de la técnica del cubo obteniendo una muestra en donde las probabilidades de inclusión son diferentes. En este caso particular se aplicará el criterio que esas probabilidades sean proporcionales al tamaño de la matrícula aunque, claro está, esas probabilidades de inclusión diferentes podrían ser diferentes. Por ejemplo, se podría especificar que en una muestra tipo panel, que los establecimientos que entraron en la muestra el año pasado tengan más chances de (volver a) entrar en la misma. Esto tiene consecuencias similares a lo visto en el muestreo PPS (Sec. 3.6) en donde, por diseño, los establecimientos con mayor matrícula tienen una mayor chance de ser incluidos en la muestra. La diferencia con el muestreo PPS es que el muestreo balanceado permite, además, un trabajar con un conjunto de otras covariables que, nuevamente, reducen las chances que la muestra finalmente seleccionada sean una de las pocas (muy) sesgadas.

A continuación, en la Tabla 4.3 puede observarse como esta muestra tiene resultados aceptables en cuanto a su cercanía con los respectivos parámetros poblacionales (que fueron ponderados por el valor de la matrícula). En cuanto a su comparación con la muestra PPS sin ponderar no parece registrarse mejoras sustanciales dado que, por azar, la muestra PPS ya era lo suficientemente buena. La diferencia es que la técnica de balanceo, gracias al algoritmo del cubo, **asegura** que no saldrá una mala muestra mientras que con el PPS se trata de confiar en que uno no tendrá mala suerte para que, por azar, se produzca una mala muestra.

Tabla 4.2: Estimaciones con muestra balanceada para población de estudiantes

Tabla 4.3: Comparación muestra balanceada por la matrícula y muestra PPS sin ponderar y población de establecimientos ponderada por matrícula

Característica	Cubo Matrícula	PPS sin ponderar	Pob. matrícula
matricula, Media	524,4	529,5	524,2
secciones, Media	19,7	19,7	19,6
sondeo_primer, Media	54,0	54,1	53,8
sondeo_segundo, Media	68,0	67,9	67,7
region, % (n=n (un-weighted))			
01	6,3% (n=19)	6,3% (n=19)	5,8% (n=189)
02	8,7% (n=26)	7,0% (n=21)	7,9% (n=222)
03	8,7% (n=26)	9,7% (n=29)	9,9% (n=210)
04	9,3% (n=28)	13,7% (n=41)	9,2% (n=213)
05	10,7% (n=32)	7,0% (n=21)	9,5% (n=194)
06	2,3% (n=7)	3,7% (n=11)	4,2% (n=148)
07	4,0% (n=12)	2,7% (n=8)	3,7% (n=138)
08	6,0% (n=18)	5,7% (n=17)	6,1% (n=149)
09	10,0% (n=30)	11,3% (n=34)	10,5% (n=204)
10	2,7% (n=8)	5,0% (n=15)	4,1% (n=221)
11	9,0% (n=27)	5,0% (n=15)	6,3% (n=166)
12	2,7% (n=8)	2,0% (n=6)	2,4% (n=155)
13	1,3% (n=4)	1,3% (n=4)	1,5% (n=131)
14	1,0% (n=3)	3,0% (n=9)	1,7% (n=169)
15	1,3% (n=4)	2,3% (n=7)	1,7% (n=172)
16	1,0% (n=3)	0,0% (n=0)	0,9% (n=125)
17	1,0% (n=3)	0,7% (n=2)	0,8% (n=133)
18	2,0% (n=6)	3,7% (n=11)	2,0% (n=160)
19	2,0% (n=6)	1,3% (n=4)	2,9% (n=118)
20	1,0% (n=3)	1,3% (n=4)	1,8% (n=159)
21	1,0% (n=3)	1,3% (n=4)	0,9% (n=117)
22	4,3% (n=13)	2,3% (n=7)	2,8% (n=153)
23	1,3% (n=4)	1,3% (n=4)	0,9% (n=151)
24	0,7% (n=2)	0,7% (n=2)	1,1% (n=196)
25	1,7% (n=5)	1,7% (n=5)	1,4% (n=166)
ambito, % (n=n (un-weighted))			
Urbano	96,3% (n=289)	95,3% (n=286)	96,1% (n=2.723)
Rural Disperso	1,3% (n=4)	1,7% (n=5)	1,9% (n=1079)
Rural Agrupado	2,3% (n=7)	3,0% (n=9)	2,7% (n=366)

4.3 Muestreos bien distribuidos

Como se dijo en la Sec. 4.1, en los muestreos balanceados por el método del cubo el esfuerzo está en que los valores de la tendencia central de los estimadores de determinadas variables de la muestra se acerquen a los valores de **tendencia central** de las covariables existentes como información secundaria, esto es, a los parámetros conocidos de la población. En el muestreo bien distribuido o bien extendido (*well spread*) es objetivo es similar, pero con una restricción adicional que implica que **la distribución** de la/s covariable/s de la muestra se acerque a la distribución de la/s covariable/s en la población. El precio de esta mejora es que se debe conocer la distribución de esas variables en la población algo que, hasta ahora, nunca habían requerido los diseños anteriores. En el caso particular de la distribución espacial el diseño exige la introducción de las coordenadas de cada miembro de la población y no solo el promedio poblacional de ellas.

En este contexto cobra importancia el ejemplo inicial de la Figura 4.1 en donde se usaron covariables espaciales. Allí, de manera intuitiva, se asoció que una muestra bien distribuida es una muestra balanceada. Esta afirmación, útil como una primera aproximación, es verdadera pero su inversa no. En otras palabras, toda muestra balanceada no es, necesariamente, una muestra bien distribuida, pero toda muestra bien distribuida sí es, necesariamente, una muestra balanceada.

A continuación trabajaremos con la misma muestra balanceada de colegios de la sección anterior, pero le agregaremos la condición de que esa muestra *también* sea bien distribuida en los valores de las coordenadas geográficas de los establecimientos. Para eso primero agregaremos las coordenadas a la base de los establecimientos y luego nos quedaremos con solo aquellos establecimientos que tengan las coordenadas.

Agregadas las coordenadas ahora se puede aplicar la técnica del cubo con el adicional que el balanceo no solo se realice por los valores de tendencia central de la sección anterior, sino también con los valores de dispersión de las coordenadas de los establecimientos.

En cierto sentido, la inclusión de las variables «Ámbito» y «Región» en el diseño balanceado (Sec. 4.2.1) ya mejoraban la distribución geográfica o espacial de la muestra (con respecto a una muestra de azar simple) pero lo hacían focalizándose en sus valores de tendencia central. Los valores de las coordenadas permiten una información de un grano más fino sobre la distribución espacial de la muestra lo que no es un dato menor. Si se asume que el espacio es una especie de meta-variable en las ciencias sociales (Small & Adler, 2019), controlar la muestra por el espacio ayuda a controlar una serie de otras características que poseen eficacia causal, pero que usualmente son inobservables o de difícil registro. Expresado en la jerga del diseño estadístico de las investigaciones, este tipo de mejoras ayudan a que dentro del conjunto de variables extrañas al comienzo de la investigación, gracias al diseño de la misma, pasen ser variables controladas en vez de pasar a ser variables perturbadoras (Kish, 1987). De todos modos, cabe destacar que las coordenadas son de los establecimientos y no de los estudiantes o, más en general, de las personas. El supuesto implícito es que la ubicación de los establecimientos guarda una relación estrecha con la ubicación de los estudiantes.

Desde un costado más operativo el algoritmo que se utiliza es el algoritmo del «*local cube*» (Tillé & Grafström, 2013) que ya había sido utilizado en el muestro PPS. Este algoritmo penaliza si se seleccionan 2 casos «localmente» cercanos entre sí y luego de haber seleccionado un caso hay pocas chances que se seleccione otro caso muy cercano. La idea de distancia entre los casos es abstracta aunque en nuestro ejemplo se puede interpretar como distancia espacial.


Tabla 4.4: Comparación entre muestra bien distribuida, balanceada y población de establecimientos

	Bien distribuida	Balanceo colegios	Pob. Colegios
Característica	N = 4.156 ¹	N = 4.159 ¹	N = 4.168
matricula, Media (SE)	268,0 (2,8)	269,2	267,9
secciones, Media (SE)	11,1 (0,1)	11,2	11,2
sondeo_primero, Media (SE)	58,0 (0,2)	57,4	57,3
sondeo_segundo, Media (SE)	68,5 (0,2)	69,1	69,5
region, % (n=n (un-weighted))			
01	4,3% (n=13)	4,0% (n=12)	4,5% (189)
02	5,7% (n=17)	4,7% (n=14)	5,4% (223)
03	5,0% (n=15)	5,0% (n=15)	5,0% (210)
04	5,0% (n=15)	4,0% (n=12)	5,1% (213)
05	4,3% (n=13)	3,7% (n=11)	4,7% (194)
06	3,7% (n=11)	3,3% (n=10)	3,6% (148)
07	3,3% (n=10)	2,7% (n=8)	3,3% (138)
08	3,7% (n=11)	3,7% (n=11)	3,6% (149)
09	5,3% (n=16)	5,0% (n=15)	4,9% (205)
10	5,3% (n=16)	6,0% (n=18)	5,4% (224)
11	3,7% (n=11)	6,0% (n=18)	4,0% (166)
12	4,0% (n=12)	4,3% (n=13)	3,7% (155)
13	2,7% (n=8)	3,0% (n=9)	3,1% (131)
14	3,7% (n=11)	5,0% (n=15)	4,1% (169)
15	5,0% (n=15)	3,7% (n=11)	4,2% (174)
16	2,3% (n=7)	5,3% (n=16)	3,0% (125)
17	3,7% (n=11)	6,0% (n=18)	3,2% (133)
18	3,7% (n=11)	4,3% (n=13)	3,8% (160)
19	3,0% (n=9)	2,7% (n=8)	2,8% (118)
20	3,3% (n=10)	2,3% (n=7)	3,8% (159)
21	3,3% (n=10)	3,3% (n=10)	2,8% (117)
22	4,0% (n=12)	3,3% (n=10)	3,7% (153)
23	4,0% (n=12)	3,0% (n=9)	3,7% (153)
24	4,7% (n=14)	4,0% (n=12)	4,7% (196)
25	3,3% (n=10)	1,7% (n=5)	4,0% (166)
ambito, % (n=n (un-weighted))			
Bien distribuido	65,7% (n=273)	65,7% (n=273)	65,7% (n=273)
Balancedo	28,3% (n=117)	28,3% (n=117)	28,3% (n=117)
Población	6,0% (n=25)	6,0% (n=25)	6,0% (n=25)

¹ Media (DE); % (n sin ponderar)

Como puede observarse en Tabla 4.4, al usarse la distribución de las coordenadas como covariables se aprecia una leve mejora en los valores que tienen una fuerte influencia espacial (p.e «Ambito» y «Región»). Sin embargo, una manera más visual de captar esta mejora es, al igual que en la Figura 4.1, a través de un mapa como el de la Figura 4.2.

Figura 4.2: Distribución de la población de los establecimientos (puntos negros) y de la muestra bien distribuida (puntos azules)



5. Calibración

La estrategia de la calibración está compuesta por un conjunto de prácticas que aspiran a lograr objetivos similares al proceso del balanceo del cubo, pero con métodos cualitativamente diferentes. La principal diferencia radica en que la calibración se realiza *ex-post* la ejecución de la muestra (o sea, en el momento de la estimación) y no *ex-ante* (o sea, en el momento del diseño) (Deville & Tillé, 2004, pág. 907). Esto es una diferencia fundamental que emparenta a la calibración con el enfoque del «*Model Assisted*» y la aleja del «*Design Based*»¹⁴. En efecto, tanto el balanceo como la calibración pueden considerarse prácticas relativamente generales que, en su interior, incluyen otras prácticas más específicas. Esto es lo que habilita a afirmar que, por ejemplo, la estratificación es un caso particular del balanceo así como la post-estratificación es un caso particular de la calibración (Tillé, 2011, pág. 223).

Otra diferencia entre el balanceo y la calibración es que para realizar la calibración en algunas situaciones (esto depende de la técnica específica seleccionada) solo es necesario los totales de la población y no, como en el balanceo, los valores de cada unidad que compone esa población.

Las características anteriores hacen que el proceso de calibración sea muy útil en momentos en donde existe conocimientos sobre algunos totales de la población y no se haya podido controlar mucho el proceso de diseño de la muestra (p.e. diseños no probabilistas) o diseños probabilistas, pero con una alta o muy diferentes tasa de no respuestas entre las unidades seleccionadas. Estas características hacen al proceso de calibración algo muy deseado para muchas investigaciones contemporáneas en donde pueda admitirse que se conocen algunos parámetros poblacionales y, por ejemplo, se ha realizado una muestra que se difundió de manera virtual a través de un link que circuló por diferentes redes sociales. Esto deja en pie la discusión sobre que «tan buenos» podrán ser los resultados de esa investigación, pero no parece haber muchas dudas que la investigación del ejemplo anterior será mejor si se le realiza un proceso de calibración mientras que será peor si no se realiza ese proceso.¹⁵

En cuanto a su pertinencia, siempre que haya disponibilidad de tiempo (y el saber necesario para su efectiva ejecución) es aconsejable realizar una calibración. Esto es cierto al menos porque cualquier diseño muestral tiene el problema del redondeo (las muestras son selecciones de números enteros de los objetos elegibles/seleccionables) y la calibración no, ya que puede construirse calibradores con números racionales. Por esta misma razón, aun cuando se haya realizado una muestra con un diseño adecuado (p.e. un balanceado), es recomendable calibrar con los totales de las variables que se usaron en el proceso de balanceo. La calibración, al igual que cualquier otro proceso de ponderación, tiene como objetivo generar buenos estimadores, esto es, ayudar a reducir su sesgo y su varianza (Valliant et al., 2018, pág. 323).

Detalladas algunas diferencias entre la calibración y el balanceo ahora se pasa a diferenciar la calibración (de una muestra) de la imputación (de variables específicas).

- En cuanto a su producto, la calibración produce como resultado un calibrador (o un nuevo ponderador en la situación que el diseño de la muestra ya cuente con un ponderador) que es único para cada caso seleccionado en la muestra. En cambio la imputación, al menos como acá se la está entendiendo, es un proceso que tiene como objetivo estimar el valor faltante de una variable de los casos que respondieron de forma incompleta la muestra. En este sentido, **un caso** efectivamente seleccionado en la muestra puede tener **más de un valor** imputado (p.e. para la variable ingresos y para la variable autopercepción de género) y, en cambio, otro caso puede que no tenga ninguno (p.e. si ese caso tuvo respuestas en todas las variables). En otros contextos se suele diferenciar a ambos procesos afirmando que la calibración

¹⁴En cambio, el balanceo, si bien en su origen tiene una fuerte vinculación con el enfoque del «*Model Assisted*», no se encuentra tan alejado del «*Design Based*» dado que el algoritmo del cubo selecciona muestras balanceadas dentro del conjunto de muestras aleatorias (Tillé, 2010, pág. 39).

¹⁵Este tipo de discusiones ha enfrentado (y por ahora continúa enfrentando) a los representantes de los enfoques de la «*design based sample*» y del «*model assisted*». Los primeros suelen dudar de los beneficios de aplicar la calibración sobre diseños no probabilísticos, aunque no suelen tener objeciones cuando la calibración se realiza sobre diseños probabilísticos (Elliott & Valliant, 2017). En el fondo, lo que está en juego son los grados de garantía que ofrece cada técnica acerca de la representatividad y esto no solo incluya la discusión sobre las heterogeneidades observables (algo mantenido por ambos enfoques), sino también sobre las heterogeneidades no observables (algo históricamente mantenido por el enfoque de «*design based*»).

ayuda a mitigar el problema del *unit-not-response* y la imputación ayuda a mitigar el problema del *item-not-response* [Lumley (2010), pág. 136](Lundström & Särndal, 2009, pág. 9).

- En cuanto a los insumos, la calibración necesita los totales poblacionales y, en cambio, la imputación necesita los valores de las otras variables que el caso a imputar sí ha respondido, así como los valores de las covariables y la variable a imputar de los otros casos seleccionados.
- En cuanto al momento de la investigación, siempre que se usen ambos procesos, usualmente primero se imputa los casos particulares de las variables que se considera pertinente y luego se calibra la muestra incluyendo los valores de los casos imputados. Este orden es particularmente importante si se confía en el proceso de la imputación y la/s variable/s imputadas son parte del proceso de calibración como covariables.

Por último, a veces se suele asimilar como sinónimos en término **calibración** con el término **post-estratificación**. Más arriba ya se había comentado que el segundo puede considerarse como un caso particular (aunque quizás el más difundido) del primero en donde solo se utilizan variables categóricas (estratos) para el proceso de la calibración. Lo mismo puede afirmarse del método menos difundido del «raking» que también permite la calibración de múltiples variables categóricas. Una ventaja particular de este es que no tiene la necesidad de realizar cruces entre esas variables, evitando de ese modo el riesgo de no tener casos en la muestra de algunas de las celdas de los múltiples cruces (Lumley, 2010, pág. 139). Por esta razón, aquí usaremos directamente el término de calibración por ser el más general, ya que permite la inclusión tanto de variables categóricas como continuas y no presenta los riesgos de la post-estratificación en cuanto a la posible ausencia de casos en los cruces de las variables categóricas.

A continuación vamos a trabajar con 2 ejemplos alternativos. Uno, en donde la calibración se realiza sobre la muestra aleatoria simple y otra que se realiza sobre la muestra balanceada y bien distribuida. En función de lo visto anteriormente (Sec. 3.2, Sec. 4.1 y Sec. 4.3) ya sabemos que ambas calibraciones van a partir desde un punto de inicio diferente. Veremos que tanta distancia existe entre ambos puntos de partida y la distancia que finalmente, luego de la calibración, obtienen cada uno con respecto a los parámetros poblacionales que van a operar como puntos de llegada ideales luego de realizar la calibración. En otras palabras, la muestra balanceada y bien distribuida ya se encontraba (en general) bastante cerca de los parámetros poblacionales por lo que, *a priori*, cuenta con alguna ventaja desde su posición de partida.

5.1 Calibración muestra azar simple

Comenzaremos haciendo la calibración sobre nuestra muestra realizada por azar simple y su resultado lo comparemos con la respectiva muestra de azar simple (sin calibrar) y con los respectivos parámetros poblacionales. Vamos a ver que, en comparación con otras técnicas, la mayor generalidad conceptual de la calibración (y su correspondiente traducción a funciones y parámetros de un lenguaje de programación) se paga con una mayor especificación de los parámetros de sus funciones¹⁶.

Para eso vamos a recuperar el objeto con el cual le informábamos a R que habíamos realizado una muestra aleatoria simple (Sec. 3.2). Ese va a ser nuestro primer insumo al cual le vamos a realizar la calibración y para eso es importante el proceso de la selección y armado de las covariables. Esta parte es similar en espíritu a lo realizado en el proceso de balanceo, pero la parte operativa tiene pequeñas diferencias como se observa en el siguiente código.

```
muestra_azar_simple_sv = read_rds(here("Outputs", "muestra_azar_simple_sv.rds"))

base = base |>
  select(clave, matricula, secciones, sondeo_primero, sondeo_segundo, region, ambito)

# Calculo la cantidad de casos de la población. No de la muestra.

N = nrow(base)

# Los totales poblacionales son especificados como una matriz (no como un vector o como
un dataframe) en función del modelo o fórmula especificada en el parámetro "formula"
de la función "calibrate" de la librería survey
```

¹⁶En otras palabras, si ya se sabe de antemano que se va a realizar una post-estratificación es más simple utilizar una función específica para post-estratificar (p.e. la función `poststratify` de la librería `survey` o `poststrata` de la librería `sampling`).


```

totals = unlist(c(nrow(base),
  sum(base$matricula, na.rm = TRUE),
  count(base[base$ambito == "Rural Disperso", ]),
  count(base[base$ambito == "Rural Agrupado", ]),
  count(base[base$region == "02", ]),
  count(base[base$region == "03", ]),
  count(base[base$region == "04", ]),
  count(base[base$region == "05", ]),
  count(base[base$region == "06", ]),
  count(base[base$region == "07", ]),
  count(base[base$region == "08", ]),
  count(base[base$region == "09", ]),
  count(base[base$region == "10", ]),
  count(base[base$region == "11", ]),
  count(base[base$region == "12", ]),
  count(base[base$region == "13", ]),
  count(base[base$region == "14", ]),
  count(base[base$region == "15", ]),
  count(base[base$region == "16", ]),
  count(base[base$region == "17", ]),
  count(base[base$region == "18", ]),
  count(base[base$region == "19", ]),
  count(base[base$region == "20", ]),
  count(base[base$region == "21", ]),
  count(base[base$region == "22", ]),
  count(base[base$region == "23", ]),
  count(base[base$region == "24", ]),
  count(base[base$region == "25", ]))

# Las totales de las variables numéricas son más fáciles de agregar a la matrix porque
# alcanza con sumarlos. En cambio los totales de las variables categóricas es algo más
# difícil porque hay que hacer los totales para cada categoría. En este sentido, no es
# lo mismo hacer una calibración para 3 categorías como "Ambito" que para más de 20 como
# "Región". Al igual que muchas otras funciones (p.e. regresiones) cuando se trabaja con
# categorías se deja la primera afuera para actuar de intercepto. En este ejemplo Ambito
# "Urbano" y Región "1" no están presentes.

muestra_azar_simple_cal =
  calibrate(muestra_azar_simple_sv,
    formula = ~ matricula + ambito + region,
    population = totals,
    calfun = "linear",
    verbose = FALSE)

tbl_azar_simple_cal = muestra_azar_simple_cal |>
  tbl_svsummary(
    include = c(matricula, secciones, sondeo_primerio, sondeo_segundo, region, ambito),
    digits = list(deff = label_style_number(digits = 3),
      sd = label_style_number(digits = 3)),
    statistic = list(all_continuous() ~ "{mean} ({mean.std.error})",
      all_categorical() ~ "{p}% (n={n_unweighted})") |>
  add_ci()

tbl_comp_azar_simple_cal =
  tbl_merge(tbls = list(tbl_azar_simple_cal, tbl_azar_simple, tbl_pob_param),
    tab_spanner = c("AS Calibrado", "AS sin calibrar", "Poblacion"))

```

Tabla 5.1: Calibración muestra azar simple

Característica	AS Calibrado		AS sin calibrar		Poblacion
	N = 4.168	95% CI	N = 4.168	95% CI	N = 4.168
matricula, Media (SE)	267 (0)	267, 267	276,6 (2,9)	271, 282	267,9
secciones, Media (SE)	11 (0)	11, 11	11,6 (0,1)	11, 12	11,2
sondeo_primer, Media (SE)	57 (0)	56, 57	56,2 (0,2)	56, 57	57,3
Desconoci- do	568		472		560
sondeo_segundo, Media (SE)	70 (0)	69, 70	69,8 (0,2)	69, 70	69,5
Desconoci- do	647		556		570
region, % (n=n (un- weighted))					
01	4,5% (n=7)	4,5%, 4,5%	2,3% (n=7)	2,0%, 2,7%	4,5% (189)
02	5,4% (n=19)	5,4%, 5,4%	6,3% (n=19)	5,8%, 6,9%	5,4% (223)
03	5,0% (n=16)	5,0%, 5,0%	5,3% (n=16)	4,9%, 5,8%	5,0% (210)
04	5,1% (n=21)	5,1%, 5,1%	7,0% (n=21)	6,5%, 7,6%	5,1% (213)
05	4,7% (n=8)	4,7%, 4,7%	2,7% (n=8)	2,3%, 3,0%	4,7% (194)
06	3,6% (n=11)	3,6%, 3,6%	3,7% (n=11)	3,3%, 4,1%	3,6% (148)
07	3,3% (n=11)	3,3%, 3,3%	3,7% (n=11)	3,3%, 4,1%	3,3% (138)
08	3,6% (n=16)	3,6%, 3,6%	5,3% (n=16)	4,9%, 5,8%	3,6% (149)
09	4,9% (n=20)	4,9%, 4,9%	6,7% (n=20)	6,1%, 7,2%	4,9% (205)
10	5,4% (n=20)	5,4%, 5,4%	6,7% (n=20)	6,1%, 7,2%	5,4% (224)
11	4,0% (n=13)	4,0%, 4,0%	4,3% (n=13)	3,9%, 4,8%	4,0% (166)
12	3,7% (n=7)	3,7%, 3,7%	2,3% (n=7)	2,0%, 2,7%	3,7% (155)
13	3,1% (n=8)	3,1%, 3,1%	2,7% (n=8)	2,3%, 3,0%	3,1% (131)
14	4,1% (n=12)	4,1%, 4,1%	4,0% (n=12)	3,6%, 4,4%	4,1% (169)
15	4,2% (n=10)	4,2%, 4,2%	3,3% (n=10)	3,0%, 3,7%	4,2% (174)
16	3,0% (n=6)	3,0%, 3,0%	2,0% (n=6)	1,7%, 2,3%	3,0% (125)
17	3,2% (n=10)	3,2%, 3,2%	3,3% (n=10)	3,0%, 3,7%	3,2% (133)
18	3,8% (n=9)	3,8%, 3,8%	3,0% (n=9)	2,7%, 3,4%	3,8% (160)
19	2,8% (n=8)	2,8%, 2,8%	2,7% (n=8)	2,3%, 3,0%	2,8% (118)
20	3,8% (n=11)	3,8%, 3,8%	3,7% (n=11)	3,3%, 4,1%	3,8% (159)
21.	2,8% (n=6)	2,8%, 2,8%	2,0% (n=6)	1,7%, 2,3%	2,8% (117)
ambito, % (n=n (un- weighted))	3,7% (n=12)	3,7%, 3,7%	4,0% (n=12)	3,6%, 4,4%	3,7% (153)
Desconoci- do	647		556		570

CI = Intervalo de confianza

Como puede observarse en Tabla 5.1 la calibración ha mejorado sensiblemente la muestra de azar simple en casi todas las variables, aun en aquellas que no se usaron activamente en la matriz de calibración (matrícula, ámbito y región). En efecto, en la mayoría de las variables los valores de la muestra calibrada se acercan mucho a los parámetros poblacionales.

Un paso adicional, especialmente si luego se quiere trabajar en una planilla de cálculo o, más en general, por fuera de R, es agregar los respectivos ponderadores del proceso de calibración al propio dataframe para así tenerlos como una variable más. En este sentido, la base de datos con los casos seleccionados de la muestra ahora pasaría a tener 2 variables especiales que servirían para el proceso de expansión de la muestra a la población. Uno, un ponderador, o más precisamente un expansor, que ya existía luego de haber realizado el azar simple (y que era igual para todos los casos) y otro recientemente agregado, que se podría denominar calibrador, que es específico para cada caso. El primero expande por la inversa de la probabilidad de ingresar en la muestra y el segundo realiza, sobre el valor anterior, un proceso de calibración. En este caso, dado que nuestra muestra es una muestra de establecimientos sobre el propio marco muestral y no hay factores de no respuesta (todos los establecimientos «responden») el calibrador funciona casi a la perfección. Si la muestra fuera de estudiantes y estos incluyen un factor no marginal de no respuesta, el calibrador también tendría la difícil misión de calibrar/corregir este último factor.

En la jerga muestral y especialmente dentro del mundo de la calibración, al primer ponderador se lo suele denominar `weight_base`. En un diseño de azar no simple y no proporcional (p.e. estratificado, cluster, PPT, etc.) la lógica es la misma aunque al tratarse de diseños no propocianales los valores no serán iguales para todos los casos.

A modo de ejemplo, vemos 3 casos en donde, como varía la matrícula del establecimiento también varía ponderador del calibrador (`cal_weight`). En cambio, el valor del `base_weight` siempre se mantiene fijo.

Tabla 5.2: Ponderadores y calibradores. Base muestra azar simple.

matricula	seccio- nes	ambito	sondeo_primer	sondeo_segundo	base_weight	cal_weight
100	6	Urbano	42.46154	52.88889	13.89333	12.51390
122	6	Urbano	57.11538	50.27273	13.89333	14.50510
78	6	Urbano	79.93750	75.41667	13.89333	23.16509

5.2 Calibración muestra bien distribuida

En el caso de la calibración de la muestra bien distribuida el proceso de calibración es similar con la diferencia que cambia el insumo al cual se le realiza la calibración. Aquí el código es un poco más simple porque se reutiliza la matriz de covariables construida para la calibración de la muestra de azar simple.

```
muestra_bien_distribuida_cal =
calibrate(muestra_bien_distribuida_sv,
  formula = ~ matricula + ambito + region,
  population = totals,
  calfun = "linear")

tbl_bien_distribuida_cal = muestra_bien_distribuida_cal |>
tbl_svsummary(
  include = c(matricula, secciones, sondeo_primer, sondeo_segundo, region, ambito),
  digits = list(deff = label_style_number(digits = 3),
    sd = label_style_number(digits = 3)),
  statistic = list(all_continuous() ~ "{mean} ({mean.std.error})",
    all_categorical() ~ "{p}% (n={n_unweighted})") |>
add_ci()

tbl_comp_bien_distribuida_cal =
tbl_merge(tbls = list(tbl_bien_distribuida_cal, tbl_bien_distribuida, tbl_pob_param),
  tab_spanner = c("BD calibrado", "BD sin calibrar", "Poblacion"))
```

```
tbl_comp_bien_distribuida_cal
```

Tabla 5.3: Calibración muestra bien distribuida

Característica	BD calibrado		BD sin calibrar	Poblacion
	N = 4.168	95% CI	N = 4.156 ¹	N = 4.168
matricula, Media (SE)	267 (0)	267, 267	268,0 (2,8)	267,9
secciones, Media (SE)	11 (0)	11, 11	11,1 (0,1)	11,2
sondeo_primer, Media (SE)	58 (0)	58, 58	58,0 (0,2)	57,3
Desconocido	478			560
sondeo_segundo, Media (SE)	69 (0)	68, 69	68,5 (0,2)	69,5
Desconocido	543			570
region, % (n=n (unweighted))				
01	4,5% (n=13)	4,5%, 4,5%	4,3% (n=13)	4,5% (189)
02	5,4% (n=17)	5,4%, 5,4%	5,7% (n=17)	5,4% (223)
03	5,0% (n=15)	5,0%, 5,0%	5,0% (n=15)	5,0% (210)
04	5,1% (n=15)	5,1%, 5,1%	5,0% (n=15)	5,1% (213)
05	4,7% (n=13)	4,7%, 4,7%	4,3% (n=13)	4,7% (194)
06	3,6% (n=11)	3,6%, 3,6%	3,7% (n=11)	3,6% (148)
07	3,3% (n=10)	3,3%, 3,3%	3,3% (n=10)	3,3% (138)
08	3,6% (n=11)	3,6%, 3,6%	3,7% (n=11)	3,6% (149)
09	4,9% (n=16)	4,9%, 4,9%	5,3% (n=16)	4,9% (205)
10	5,4% (n=16)	5,4%, 5,4%	5,3% (n=16)	5,4% (224)
11	4,0% (n=11)	4,0%, 4,0%	3,7% (n=11)	4,0% (166)
12	3,7% (n=12)	3,7%, 3,7%	4,0% (n=12)	3,7% (155)
13	3,1% (n=8)	3,1%, 3,1%	2,7% (n=8)	3,1% (131)
14	4,1% (n=11)	4,1%, 4,1%	3,7% (n=11)	4,1% (169)
15	4,2% (n=15)	4,2%, 4,2%	5,0% (n=15)	4,2% (174)
16	3,0% (n=7)	3,0%, 3,0%	2,3% (n=7)	3,0% (125)
17	3,2% (n=11)	3,2%, 3,2%	3,7% (n=11)	3,2% (133)
18	3,8% (n=11)	3,8%, 3,8%	3,7% (n=11)	3,8% (160)
19	2,8% (n=9)	2,8%, 2,8%	3,0% (n=9)	2,8% (118)
20	3,8% (n=10)	3,8%, 3,8%	3,3% (n=10)	3,8% (159)
21	2,8% (n=10)	2,8%, 2,8%	3,3% (n=10)	2,8% (117)
22	3,7% (n=12)	3,7%, 3,7%	4,0% (n=12)	3,7% (153)
amplitud, % (near- Bessel) (n sin ponderar)	3,7% (n=12)	3,7%, 3,7%	4,0% (n=12)	3,7% (153)
Media (DE), % (n sin ponderar)	3,7% (n=12)	3,7%, 3,7%	4,0% (n=12)	3,7% (153)

Abreviacion: CI = Intervalo de confianza

Al igual que con la calibración de la base de la muestra de azar simple, aquí vamos a extraer los calibradores para luego agregarlos a la base de datos.

Es interesante destacar, como se observa en la Tabla 5.4 (y a diferencia de lo visto en la Tabla 5.1) que acá los calibradores varían entre sí. Más adelante veremos que cuanto los calibradores varían entre sí también es una medida a tener en cuenta para algunos autores.

Tabla 5.4: Ponderadores y calibradores. Base muestra bien distribuida.

matricula	seccio- nes	ambito	total	muestreo_primo	muestreo_segundo	base_weight	cal_weight
533	24	Urbano	58.11111	70.60484	13.85333	14.46208	
668	24	Urbano	38.02857	73.39394	13.85333	14.32084	
340	14	Urbano	60.08219	85.81707	13.85333	14.66400	

5.3 Comparación calibración muestra balanceada y azar simple

Finalmente, vamos a realizar una comparación entre los resultados de los procesos de calibración antes realizados y los respectivos parámetros poblacionales. Esto es lo que precisamente se observa en la Tabla 5.5.

Tabla 5.5: Comparación entre calibración de las muestras bien distribuidas, de azar simple y los respectivos parámetros poblacionales

Característica	BD calibrado		AS calibrado		Poblacion
	N = 4.168	95% CI	N = 4.168	95% CI	N = 4.168
matricula, Media (SE)	267 (0)	267, 267	267 (0)	267, 267	267,9
secciones, Media (SE)	11 (0)	11, 11	11 (0)	11, 11	11,2
sondeo_primero, Media (SE)	58 (0)	58, 58	57 (0)	56, 57	57,3
Desconoci-do	478		568		560
sondeo_segundo, Media (SE)	69 (0)	68, 69	70 (0)	69, 70	69,5
Desconoci-do	543		647		570
region, % (n=n (un-weighted))					
01	4,5% (n=13)	4,5%, 4,5%	4,5% (n=7)	4,5%, 4,5%	4,5% (189)
02	5,4% (n=17)	5,4%, 5,4%	5,4% (n=19)	5,4%, 5,4%	5,4% (223)
03	5,0% (n=15)	5,0%, 5,0%	5,0% (n=16)	5,0%, 5,0%	5,0% (210)
04	5,1% (n=15)	5,1%, 5,1%	5,1% (n=21)	5,1%, 5,1%	5,1% (213)
05	4,7% (n=13)	4,7%, 4,7%	4,7% (n=8)	4,7%, 4,7%	4,7% (194)
06	3,6% (n=11)	3,6%, 3,6%	3,6% (n=11)	3,6%, 3,6%	3,6% (148)
07	3,3% (n=10)	3,3%, 3,3%	3,3% (n=11)	3,3%, 3,3%	3,3% (138)
08	3,6% (n=11)	3,6%, 3,6%	3,6% (n=16)	3,6%, 3,6%	3,6% (149)
09	4,9% (n=16)	4,9%, 4,9%	4,9% (n=20)	4,9%, 4,9%	4,9% (205)
10	5,4% (n=16)	5,4%, 5,4%	5,4% (n=20)	5,4%, 5,4%	5,4% (224)
11	4,0% (n=11)	4,0%, 4,0%	4,0% (n=13)	4,0%, 4,0%	4,0% (166)
12	3,7% (n=12)	3,7%, 3,7%	3,7% (n=7)	3,7%, 3,7%	3,7% (155)
13	3,1% (n=8)	3,1%, 3,1%	3,1% (n=8)	3,1%, 3,1%	3,1% (131)
14	4,1% (n=11)	4,1%, 4,1%	4,1% (n=12)	4,1%, 4,1%	4,1% (169)
15	4,2% (n=15)	4,2%, 4,2%	4,2% (n=10)	4,2%, 4,2%	4,2% (174)
16	3,0% (n=7)	3,0%, 3,0%	3,0% (n=6)	3,0%, 3,0%	3,0% (125)
17	3,2% (n=11)	3,2%, 3,2%	3,2% (n=10)	3,2%, 3,2%	3,2% (133)
18	3,8% (n=11)	3,8%, 3,8%	3,8% (n=9)	3,8%, 3,8%	3,8% (160)
19	2,8% (n=9)	2,8%, 2,8%	2,8% (n=8)	2,8%, 2,8%	2,8% (118)
20	3,8% (n=10)	3,8%, 3,8%	3,8% (n=11)	3,8%, 3,8%	3,8% (159)
21	2,8% (n=10)	2,8%, 2,8%	2,8% (n=6)	2,8%, 2,8%	2,8% (117)
21. ambito, % (n=n (un-weighted))	3,7% (n=12)	3,7%, 3,7%	3,7% (n=12)	3,7%, 3,7%	3,7% (153)
Desconoci-do	478		568		560

CI = Intervalo de confianza

En la Tabla 5.5 puede observarse como ambas estrategias de calibración parecen igual de eficaces, ya que ambas arrojan resultados muy similares entre sí y, a su vez, muy similares con los parámetros poblacionales. En este contexto se recuerda que, si bien los valores de las estimaciones son muy similares, la mejora realizada en el proceso de calibración es mayor sobre el diseño de azar simple, ya que esa muestra no era tan precisa como la muestra bien distribuida y, por lo tanto, existía la oportunidad de mejorarla bastante.

Una diferencia importante entre ambas estrategias en la dispersión o heterogeneidad presente en los propios valores de los calibradores. Como regla general cuanto menor sea la dispersión de estos valores más robustas serán las estimaciones. Por detrás de esta afirmación, hay cuestiones teóricas importantes como que cuanto más la estimación se base en los calibradores (*ex-post*) y no tanto en el diseño (*ex-ante*), la misma se basa en modelos de superpoblaciones (*model based*) que en las propias acciones del diseño muestral (*design based*). Sin embargo, desde un punto de vista más utilitario la diferencia también es clara. Solo basta pensar en los problemas que se presentan cuando se usan ponderadores/expansores que fueron calibrados para una población objetivo determinada y luego se aplican para un subconjunto arbitrario de aquella población (Lumley, s. f., pág. 3).

Tabla 5.6: Comparación de los ponderadores calibrados según tipo de muestra

Metodo	Mini-mo	Maxi-mo	Rango	Media	Varianza	CW	Kish_Ratio	RAVE_Min	RAVE_Max
Calibración AS	2.066034	29.45033	27.38429	13.89333	25.27181	0.361836	1.130925	14.25452	52.5
Calibración Balanceada	10.41125	19.19197	8.78072	13.89333	2.31254	0.109455	1.01198	11.84338	8

II

Aplicaciones prácticas

6	Muestras PEB 2025	59
6.1	Muestra 2023	59
6.2	Muestra 2025	64
6.3	Primera Etapa	65
6.4	Distribución a nivel de establecimientos	66
6.5	Simulación a nivel de estudiantes	67
6.6	Segunda etapa	69
7	Calibración con Metas Cuasicensales (PEB 2025)	73
7.1	Análisis <i>ex-post</i> . Construcción de ponderadores base, ponderadores por no respuesta y ponderadores de calibración.	73
7.2	Tercer Año	73
7.3	Calibración	83
7.4	Sexto año	89
7.5	Exportación de Bases de Estudiantes con Ponderadores	94
8	Muestra EJAyAM	95
8.1	Introducción	95
8.2	Objetivos	95
8.3	Población objetivo	96
8.4	Marco muestral	98
8.5	Dominios de estimación	105
8.6	Alternativas muestrales	108
8.7	Diseño muestra	115
8.8	Construcción de ponderadores y expansores	116
8.9	Testeo de la muestra seleccionada	116
9	Muestra Paro - 03/08/26	127
9.1	Introducción y objetivos	127
9.2	Metodología	127
9.3	Cálculo del Tamaño Muestral	128
9.4	Simulación y Validación (Muestra vs. Población)	133

6. Muestras PEB 2025

Las pruebas PEB (Pruebas Escolares Bonaerenses) son un programa orientado a mejorar la enseñanza y el aprendizaje de Matemática y Prácticas del Lenguaje en el nivel Primario, tanto en el sector estatal como en el privado, que se puso en marcha en 2022 en la Provincia de Buenos Aires (Subsecretaría, 2025, pág. 5).

Desde el punto de vista metodológico que tiene que ver con cuestiones muestrales es pertinente destacar que estas pruebas aspiran a ser realizadas al total de los estudiantes aunque luego se registran sus resultados a través de dos componentes diferentes. Un primer componente censal aunque con datos agregados y un segundo componente muestral con datos nominales. Lo que se detalla a continuación es el proceso de selección muestral de este segundo componente nominal. Primero lo haremos haciendo referencia a la muestra diseñada en 2023 y luego para la de 2025.

6.1 Muestra 2023

Para tener como referencia vamos a intentar representar el método de selección de la muestra que se utiliza desde 2023. Primero la vamos a intentar describir y luego clasificar.

6.1.1 Descripción

Un resumen descriptivo de la misma es la siguiente afirmación:

«En paralelo, se relevaron resultados por estudiante en una muestra probabilística de 680 escuelas. Para cada institución, se solicitó información sobre las respuestas a las actividades de 5 estudiantes seleccionados al azar por las y los docentes de cada sección» (Subsecretaría, 2024, pág. 18).

Más en detalle también se afirma «La construcción de la muestra siguió un diseño probabilístico, con selección sistemática de las unidades de muestreo. Previo a la selección, en el marco muestral (nómina de establecimientos de nivel primario) se agruparon los establecimientos en estratos constituidos por el cruce de las variables «dependencia de los establecimientos educativos» (provincial y resto-incluyendo en este último grupo a los establecimientos privados, municipales y nacionales), «porcentaje de estudiantes con AUH», «presencia o no de jornada completa» y «ámbito». Luego, se ordenaron los establecimientos por estrato, y se realizó una selección sistemática siguiendo la fracción de muestreo correspondiente» (Subsecretaría, 2024, pág. 18).

La descripción anterior alcanzaría para una descripción de la selección de establecimientos. Pero todavía falta el paso que describe la selección de los estudiantes:

«Para cada sección de los años de estudio evaluados, se solicitó la selección de las/los primeros o últimos estudiantes de la lista (por orden alfabético) que hayan realizado la prueba. En secciones pequeñas (de hasta 10 estudiantes), se requirió la carga de información de todas y todos los estudiantes» (Subsecretaría, 2024, pág. 18).

Precaución

No hace falta aclarar que intentar reconstruir una muestra a partir de descripciones en prosa suele ser una actividad arriesgada. Esto se debe a que puede haber confusiones entre los objetivos de la muestra, las acciones que se hicieron en el momento del diseño, las que efectivamente se hicieron en campo y, algo no menos importante, los términos que se usan para describir todo lo anterior.

Hay veces que, aunque parezca paradójico, para alguien que tiene que clasificar a una muestra, es preferible que le digan paso a paso que hicieron en un lenguaje cercano al sentido común sin usar términos propios de la jerga del muestreo. La razón es que en muestreo hay términos que tienen un significado particular que no es el mismo que tienen en otras disciplinas no tan lejanas. Por ejemplo, la palabra «estratificación» tanto en ciencias sociales como en el lenguaje común, suele tener una connotación ordinal, pero en muestreo tiene una connotación muy particular y no necesariamente ordinal. Del mismo modo, alguien con experiencia en análisis de datos entiende por «análisis de clústers (o conglomerados)» algo muy diferente a lo que un muestrista entiende cuando afirma que se realizó un «diseño muestral por conglomerados».

Lo anterior se complica porque es usual que en los diseños muestrales de las ciencias sociales se hagan diseños polietápicos lo que hace que, por ejemplo, circulen afirmaciones como «muestreo estratificado por conglomerados». En este caso es posible suponer más de una manera de entender esta afirmación y, *a posteriori*, más de una manera de haber diseñado o ejecutado esa muestra. Por ejemplo, ¿Se ejecutó primero en campo la parte de los conglomerados y luego se seleccionó por estratos? ¿O se hizo al revés? ¿El orden escrito se refiere a la «ejecución» de los pasos o refiere que momento se «diseñó» cada parte del diseño?

6.1.2 Clasificación

En función de la bibliografía/léxico usado en las secciones anteriores se podría realizar los siguientes comentarios sobre las afirmaciones anteriores:

Antes que nada se observa una particularidad importante. En las PEB efectivamente se va a (casi) todas las unidades de la población de estudiantes. La muestra es solo para ver a cuáles de ellos se «registra» de forma individual. Esto es algo particular porque muchas de las técnicas de muestreo están pensadas para justamente evitar ir a todas las unidades de la población o, en su defecto, para a que a una determinada subpoblación (muestra) se le pueda hacer más preguntas, mediciones, ensayos, etc. que hacen más extensa y profunda y, por lo general, más onerosa la investigación. En lo que acá respecta, lo oneroso no parece la prueba en sí, sino su posterior carga nominal. Esto hace (re)pensar cuál es la población de la muestra:

¿Es la población de estudiantes de todo el nivel primario?

¿Es la población de estudiantes de algunos años específicos de nivel primario (p.e. 3 y 6) a los cuales se les piensa realizar las PEB?

¿Es la población de estudiantes de algunos años específicos de nivel primario (p.e. 3 y 6) a los que efectivamente se les realizó las PEB?

Cabe destacar que en una muestra típica solo se podría decidir entre las primeras dos poblaciones porque, como se comentó arriba, muchas veces uno de los objetivos de la muestra es evitar «ir» o «medir» a cada componente de la población. Sin embargo, en la PEB es posible también decidir que la tercera población sea la más idónea. En efecto, más allá de los posibles problemas de conseguir datos de esa población es claro que no tiene mucho sentido seleccionar estudiantes o secciones que no pertenecen a los establecimientos del «censo» previo.

Dejando estas cuestiones referidas sobre qué población se debería hacer la muestra, el diseño muestral anterior se podría **clasificar** del siguiente modo:

- Un diseño **polietápico**. En una primera etapa se seleccionan a los establecimientos y luego, en una segunda etapa, se seleccionan a los estudiantes de ese establecimiento a través de sus respectivas secciones. Se suele afirmar que los establecimientos son la unidad de selección primaria y los estudiantes son la unidad de selección secundaria y final. Es importante destacar que los establecimientos cumplen la función de ser un **conglomerado** en este diseño. En otras palabras, cada establecimiento es como un racimo (*cluster*) en donde se agrupan secciones y estudiantes. Por cuestiones logísticas es útil seleccionar primero a los establecimientos y luego a los estudiantes que están en su interior. En esta descripción no decimos nada sobre las secciones porque en las descripciones de arriba parecería que ellas no se «seleccionan» aunque más adelante diremos algo sobre esto.

- En la primera etapa se hace un diseño muestral **estratificado** de establecimientos con asignación proporcional mediante un método de selección sistemático. Este diseño primero crea una serie de categorías discretas en las que se presume que la varianza de la/s variables a estimar son algo menor a la varianza promedio de toda la población. Esto permite una ganancia estadística que se puede usar tanto para aumentar la precisión de la estimación o para reducir la cantidad de casos de la muestra. Cuanto se logre esto último es una cuestión que depende de la asociación de las variables seleccionadas para construir los estratos con las variables a estimar. Lo que también (parcialmente) asegura este diseño es que se incluyan en la muestra casos de estratos chicos en tamaño que, mediante un diseño por azar simple, podrían quedar subrepresentados en la muestra.
- Decimos que la **estratificación es de una asignación proporcional** porque la cantidad de casos a seleccionar para cada estrato estará en línea con los tamaños de estratos (no con los tamaños de los establecimientos). Esta muestra, al menos en este paso, intenta replicar la distribución porcentual de los estratos.
- Dentro de cada estrato la selección es **sistemática**, y por lo tanto, probabilística.
- En la segunda etapa se aplica una regla que apunta a resolver dos cuestiones diferentes. A «cuantos» y «a quienes» se le van a cargar los datos nominales. Respecto al «cuantos» parece que se resuelve con la regla de cargar todos los casos para las secciones de hasta 10 estudiantes y 5 para el resto. Aunque quizá pase más desapercibido, en esta segunda etapa las secciones cumplen la función de estrato, por lo que la segunda etapa se podría decir que se trata de una selección de estudiantes **estratificada** por las secciones. En cambio, el «a quienes» se resuelve mediante una regla que selecciona a los «primeros o últimos estudiantes de la lista (por orden alfabético)». Esta regla tiene el beneficio de ser simple (siendo esto un punto a favor) aunque, en principio, es **no probabilística** en el sentido que no se trata de selección por azar simple ni sistemática, etc. Su carácter no probabilística, no asegura que sea sesgada.

Si la **clasificación** anterior es correcta se podrían hacer también los siguientes comentarios sobre esa muestra:

La afirmación «Para cada institución, se solicitó información sobre las respuestas a las actividades de 5 estudiantes seleccionados al azar por las y los docentes de cada sección» no parece coincidir con lo realizado. Lo que la muestra selecciona al azar son «establecimientos» pero no «estudiantes».

La regla sobre la discrecionalidad para que el docente elija los 5 primeros o los 5 últimos induce una dosis de arbitrariedad. La traducción de sí esto en un sesgo (o no) es una cuestión que, de forma aproximada, se puede resolver de forma empírica¹⁷. Por otro lado, si se asume que cada docente elegirá siempre al «mejor» grupo (comparando a los 5 primeros versus los 5 últimos) esto no generará un mayor problema en las comparaciones entre establecimientos, secciones, etc. pero, posiblemente, sesga todos los resultados nominales de las pruebas hacia «arriba». En principio, esto se podría testear empíricamente comparando las medias de las notas muestrales de cada sección/establecimiento con las medias de las respectivas notas censales de las mismas secciones/establecimientos que entraron en la muestra.

En este diseño, al menos en su primera etapa, los estudiantes de los establecimientos más grandes tienen menores chances de salir en la muestra. Si esto no se corrige mediante ponderadores (*ex-ante*) o calibradores (*ex-post*) explícitos esto podría generar un sesgo en los análisis de los resultados. En otras palabras, si cada establecimiento dentro de un estrato tuvo la misma probabilidad de ser elegido de forma independientemente de su matrícula, entonces para esa primera etapa **la probabilidad final de selección para un estudiante no es constante**.

Algo de esto se corrige en la segunda etapa. Acá influye que la regla de cargar los datos sea por **sección** y no por **establecimiento**. Esta regla es la que legitima entender a la muestra anterior como una muestra polietápica en donde en la segunda etapa se usa un diseño estratificado por sección.

A primera vista las secciones podrían ser consideradas como conglomerados en donde seleccionar estudiantes de su interior asumiendo alguna ventaja logística si se selecciona solo una de ellas, por ejemplo, por azar simple. Sin embargo, la acción anterior podría ser conveniente si se asume que las secciones (de un mismo establecimiento) poseen una similar heterogeneidad con respecto a al variable de estudio (p.e. las notas en las PEB). De todos modos, dada la peculiaridad de las PEB, la ventaja logística residiría en que hay menos docentes/administrativos que contactar y, no menos importante, menos por controlar después.


¹⁷Cuanto (o no) esta regla no probabilística es un sesgo en la muestra es una cuestión empírica. Una manera de generar un testeo podría ser la comparación de las medias porcentuales de la posesión de AUH, a nivel de sección y establecimiento, de los primeros 5 estudiantes con la media del respectivo grupo conformado por la sección y el establecimiento. Esto se puede hacer partiendo de una base nominal de estudiante y ordenando los apellidos por orden alfabético para cada sección y establecimiento. En el primer caso, se calcula la media de los 5 primeros de cada grupo y en la segunda se incluyen a todos los estudiantes de cada grupo. Al realizar el cálculo a nivel de cada sección no solo se puede testear si ambas medias coinciden, sino que también se puede calcular su respectivo desvío.

Acá no habría nada de ventaja logística, por ejemplo, desde el punto de vista geográfico. La razón es que, por un lado, «ya se fue» a evaluar a cada estudiante y ahora quedaría decidir los datos de quien se registra de modo nominal.

Si se pasa al otro extremo de seleccionar a todas las secciones del establecimiento elegido (como efectivamente se hizo en la muestra 2024) no hay tal etapa de «selección» a nivel de las secciones. En ese caso las etapas de selección de la muestra son a nivel de los establecimientos y a nivel de los estudiantes, pasando por alto el nivel de las secciones. En efecto, la acción de ir a todas las secciones es *como si* se hubiera tenido la intención de estratificar debido, quizás, a la sospecha de una posible escasa similitud entre las secciones de un mismo establecimiento. Siguiendo este modo de razonar, el investigador se asegura que los estudiantes sean seleccionados a través de diferentes secciones cumpliendo el deseo de un muestrista que estratifica para que luego se seleccionen los casos dentro de cada estrato. Hace unas líneas se dijo «*como si*» hubiera tenido la intención de estratificar porque, estrictamente, no sabemos si se estratificó por la razón de reducir el error de la estimación (lo usual en esta técnica) o por sí, por el contrario y/o de forma complementaria, por la consecuencia que trae usar este método en las probabilidades de selección de los estudiantes de los establecimientos con mayor matrícula.

De esta manera, a pesar de no ser la típica consecuencia buscada de la estratificación, aquellos establecimientos con mayor cantidad de secciones (y en general con mayor matrícula) pueden tener una mayor chance de incluir a sus estudiantes en la muestra. En efecto, en la Figura 6.1 se observa una relación estrecha entre el tamaño de la matrícula y la cantidad de secciones del establecimiento.

Figura 6.1: Relación entre el tamaño de la matrícula y la cantidad de secciones de los establecimientos



Fuente: Elaboración propia basada en nómina de establecimientos

Sin embargo, hacer un «censo» para las secciones pequeñas hace que se aumente la chance de seleccionar estudiantes de secciones pequeñas que, en general, pertenecen a establecimientos con una menor matrícula. A continuación se muestra en la Tabla 6.1 como las secciones de hasta 10 estudiantes suelen pertenecer a establecimientos con una media y una mediana de la matrícula muy por debajo de la que poseen las secciones más grandes.

Tabla 6.1: Comparación de la media y mediana de los establecimientos en función del tamaño de la sección (+- 10 estudiantes)

Variable de Matrícula	Chicas N = 7.026	No chica N = 65.866
Matrícula Inicial 2025, Media Mediana	61,9 16,0	461,6 430,0
Desconocido	4	0

En cualquier caso, las reglas identificadas de la selección de los estudiantes parece tener efectos contrapuestos y es algo difícil de estimar el impacto de cada uno por separado. En particular es difícil de construir ponderadores que anticipen (*ex-ante*) el sesgo de estas decisiones. Claro que siempre se podrá recurrir al recurso de los calibradores (*ex-post*) para usarlos al momento del análisis, aunque parece una estrategia algo arriesgada.

Una opción que se puede tener cuenta en estos casos es la inclusión del tamaño de la matrícula en la probabilidad de seleccionar al establecimiento en la primera etapa. Esta estrategia puede tener más de un beneficio. Uno de ellos es que permite una regla simple para la segunda etapa. En efecto, se podría registrar una misma cantidad de estudiantes por establecimiento de forma independiente a la cantidad de secciones. Esto tiene el beneficio adicional que, siguiendo ese diseño, la muestra se vuelve autoponderada lo que facilita los análisis posteriores. Claro está que serán necesario la construcción de calibradores que corrijan la no-respuesta, pero esto es un escenario cualitativamente diferente al descrito en el párrafo anterior. En este contexto, si la muestra no tiene, *a posteriori*, problemas de no-respuesta, no sería necesario la construcción de calibradores. Sin entrar en detalles (porque en parte se entremezclan un lenguaje de intenciones u objetivos con un lenguaje de métodos) se podría decir que se podrían aprovechar algunas de las características que ofrece el método conocido como muestreo proporcional al tamaño (Sec. 3.6).

Por último algunos comentarios van en línea sobre el espectro de inferencias posibles con la muestra 2023. En la bibliografía sobre muestreo se suele hacer una distinción clásica entre los **estratos** y los **dominios** de estimación (Sec. 3.4). Los primeros se suelen usar en el diseño (*ex-ante*) con la presunción de que en la población existen «clases» discretas que son parecidas en su interior y diferentes entre sí. Si esto es así, su inclusión en el diseño trae mejoras en la precisión en la estimación. En cambio, los dominios tienen que ver con los objetivos o intenciones posteriores del investigador para con la muestra. Por ejemplo, aun el contexto en que se tenga la hipótesis que los establecimientos y los estudiantes rurales poseen fuertes particularidades en contraposición a los urbanos. Un escenario es la inclusión de «ambito» como variable para la estratificación y otro escenario es que se quieran realizar inferencias para cada ámbito. En este último caso se dice que los diferentes ámbitos son dominios de estimación de la muestra.

Cuando los estratos con los cuales se diseñan las muestras tienen una cantidad de casos similares la distinción con los dominios se vuelve algo ociosa. En cambio, cuando los estratos tienen diferentes números de casos (p.e. Urbano vs. Rural Agrupado) y luego se desea realizar estimaciones para todos los estratos, es importante la utilidad de la distinción. La razón es que un muestreo estratificado proporcional ayudará poco para tener buenas estimaciones de los dominios pequeños (p.e. Rural Agrupado). En esos casos puede ser preferible un muestreo estratificado con asignación no proporcional óptima (Neyman, 1934).

6.1.3 Evaluación actual de la muestra usada en 2024

Desde el momento en que se diseñó la muestra (2023), la población de estudiantes y establecimientos fue cambiando. En especial, es notorio el aumento de establecimientos con jornada completa en los últimos años. Estos cambios poblacionales pueden sugerir dudas acerca de la adecuación de una muestra que fue diseñada para representar a una población con otras características. A pesar de estos supuestos razonables, la muestra actual no parece —al menos en lo que respecta a los establecimientos— haber quedado desfasada para captar el incremento de la jornada completa. Más en particular, se observa una pequeña sobrerrepresentación de los establecimientos con jornada completa en esta primera etapa de la muestra. Esto puede deberse a que la expansión de la jornada completa se dio principalmente en establecimientos con matrícula no muy grandes que es justamente el tipo de establecimientos en donde la muestra anterior parecía tener más casos. A continuación, en la Tabla 6.2, se comparan parámetros poblacionales de los establecimientos con las respectivas estimaciones de la muestra.

Tabla 6.2: Comparación parámetros poblacionales de establecimientos vs muestra 2024

	Población Total (N = 5884)	Muestra 2024(n = 669)
Variable	N = 5.884	N = 669
jornada_completa, n (%)		
NO	4.757 (81%)	493 (74%)
SI	1.127 (19%)	176 (26%)
sector, n (%)		
Estatal	4.189 (71%)	487 (73%)
Privado	1.695 (29%)	182 (27%)
ambito, n (%)		
Rural Agrupado	372 (6,3%)	77 (12%)
Rural Disperso	1.064 (18%)	133 (20%)
Urbano	4.448 (76%)	459 (69%)
matricula_inicial_2025, Mediana (IQR)	256 (82 – 429)	234 (75 – 413)
Desconocido	10	
auh_pct, Mediana (IQR)	32 (13 – 50)	32 (14 – 50)
Desconocido	48	4

6.2 Muestra 2025

Teniendo en mente las características destacadas de la muestra anterior, ahora vamos a pasar a describir los objetivos de la muestra de 2025. En general se conservan muchos de ellos aunque también se agregan otros. Esto hace que, en términos de las técnicas empleadas para llegar a esos objetivos, se exceda el léxico clásico de la estratificación y la conglomeración. Los objetivos son:

1. Incluir los mismos criterios (actualizados a valores de 2025) que anteriormente se incluyeron en la construcción de los estratos para la construcción de una muestra **balanceada**. Esto son:

- a) Sector (Estatal/Privado)
- b) Porcentaje de estudiantes con AUH
- c) Presencia de jornada completa
- d) Ámbito

La idea de estos es que la muestra (de estudiantes y no de establecimientos) se acerque a los valores de tendencia central de esas variables. En otras palabras, que la muestra se encuentra balanceada en un punto óptimo que reduzca las distancias con las diferentes medidas de tendencia central de las variables anteriores.

2. Dado que algunas variables numéricas se encuentran disponibles como marco muestral para cada establecimiento también se va a implementar una muestra (balanceada y) **bien distribuida**. En otras palabras, el objetivo es también exigir una convergencia con la distribución (esto es, no solo con sus valores de tendencia central) de las siguientes variables:

- a) Latitud
- b) Longitud
- c) Porcentaje de AUH

3. En términos de las **probabilidades de inclusión** se esperan cumplir con las siguientes restricciones:

3.1. Otorgarle una mayor probabilidad de entrar a la primera etapa a los establecimientos que entraron en la muestra anterior. La idea es hacer un diseño compatible con una muestra tipo panel que se renueve (aproximadamente) por cuartos en cada edición. De esta manera, ningún establecimiento estaría más de 4 años seguidos y, de manera complementaria, el cuarto que se renueva permitiría ajustar la muestra a los cambios poblacionales sucedidos en el último año.

3.2. Otorgarle una probabilidad de entrar en la primera etapa a los establecimientos en función del tamaño de la matrícula.

3.3. Otorgarle una probabilidad de entrar en la segunda etapa a las secciones en función del tamaño de las mismas.

El punto 3.2 y el punto 3.3 merecen algo más de justificación porque pueden parecer contraintuitivos. En efecto, que en la primera etapa los establecimientos sean seleccionados en función del tamaño de la matrícula permite que, para la segunda etapa de la muestra, se pueda tener una regla simple como la asignación de un número fijo de estudiantes para cada establecimiento. Esto, además, permite (en ausencia de problemas de no-respuesta) hacer análisis con una muestra autoponderada. Más concretamente, se aspira a registrar 10 estudiantes de cada establecimiento.

En los establecimientos en donde haya más de una sección, se puede armar un orden de prioridad entre las secciones disponibles y quedarse, en principio, solo con la que mayor prioridad obtenga. Previamente se puede generar un número para cada caso/establecimiento seleccionado que ordene a los establecimientos en función de algún criterio (p.e. matrícula). Algunos establecimientos obtendrán un número par y otros tendrán uno impar. En este sentido, una vez sorteada la sección, se usa el valor del número anterior para indicar el modo de selección de los 10 estudiantes. Si ese establecimiento posee un número par, se elige a los primeros 10 estudiantes. Si ese establecimiento posee un número impar, se elige los últimos 10 estudiantes. Si la sección seleccionada se agota sin llegar a los 10 casos se pasa a la sección siguiente en el orden de prioridad siguiendo luego el mismo criterio de selección de los estudiantes que en la sección anterior.

De este modo se tiene una regla no arbitraria (en el sentido que no decide el docente o el establecimiento qué caso cargar), la misma parece ser probabilística y, de manera derivada, permite trabajar (en ausencia de problemas de no-respuesta) con los datos sin ponderar.

6.3 Primera Etapa

Teniendo presente las restricciones anteriores se realizó una primera etapa de la muestra a nivel de establecimientos. Se recuerda que la muestra aspira a ser una muestra de estudiantes más que de establecimientos por lo que algunas desviaciones en esta etapa son más esperables que otras. En particular, es esperable que la media de la matrícula de los establecimientos seleccionados sea mayor a la media de la matrícula de la población de establecimientos. Algunos de los resultados, principalmente en cuanto a valores de tendencia central, se pueden ver en la Tabla 6.3.

Tabla 6.3: Comparación parámetros poblacionales de establecimientos vs muestra 2025

Variable	Población Total (N = 5836)	Muestra 2025(n = 675)
	N = 5.836	N = 675
sector, n (%)		
Estatat	4.157 (71%)	438 (65%)
Privado	1.679 (29%)	237 (35%)
ambito, n (%)		
Rural Agrupado	371 (6,4%)	23 (3,4%)
Rural Disperso	1.039 (18%)	20 (3,0%)
Urbano	4.426 (76%)	632 (94%)
matricula_inicial_2025, Mediana (IQR)	257 (85 – 430)	390 (268 – 553)
jornada_completa, n (%)		
NO	4.711 (81%)	572 (85%)
SI	1.125 (19%)	103 (15%)
latitud, Mediana (IQR)	–34,77 (–35,81 – –34,59)	–34,72 (–34,92 – –34,56)
longitud, Mediana (IQR)	–58,69 (–59,78 – –58,40)	–58,61 (–58,82 – –58,38)
auh_pct, Mediana (IQR)	32 (13 – 50)	37 (16 – 53)
muestra_2024, n (%)		
SI	665 (100%)	433 (100%)
Desconocido	5.171	242

6.4 Distribución a nivel de establecimientos

Dado que la muestra no es solo balanceada en sus medidas de tendencia central, sino también en la distribución de otras covariables ahora veremos justamente como la distribución de la muestra difiere, en las variables latitud, longitud (?@fig-mapa_muestra_2025 y Figura 6.2) y porcentaje de AUH (Figura 6.3), de la distribución de las mismas a nivel del marco muestral.

Figura 6.2: Mapa de calor sobre la distribución de los casos. Población y muestra 2025.





Figura 6.3: Distribución de densidad de porcentaje de AUH. Población y muestra 2025.



Nota: El solapamiento indica la calidad del 'spreading' multivariado.

6.5 Simulación a nivel de estudiantes


Dado que en el actual diseño se emplea una muestra en donde la probabilidad de inclusión deviene en parte del tamaño del establecimiento es esperable, como se anticipó más arriba, encontrar diferencias entre las tendencias centrales de algunas variables consideradas importantes entre la muestra de establecimientos y la población de los mismos. Por esta razón, partiendo del marco muestral de los establecimientos vamos a crear una población sintética de estudiantes (de todos los años) en función de la matrícula total de cada

establecimiento. Luego vamos a comparar esa población con otra población de estudiantes asumiendo que se seleccionan «x» estudiantes por cada establecimiento seleccionado (10 en este caso).

Tabla 6.4: Comparación entre poblaciones sintéticas de estudiantes

Variable	Muestra de Estudiantes (k=10) N = 6.750	Población de Estudiantes (todos los años) N = 1.666.253
sector, n (%)		
Estatad	4.380 (65%)	1.081.271 (65%)
Privado	2.370 (35%)	584.982 (35%)
ambito, n (%)		
Rural Agrupado	230 (3,4%)	22.877 (1,4%)
Rural Disperso	200 (3,0%)	21.001 (1,3%)
Urbano	6.320 (94%)	1.622.375 (97%)
matricula_inicial_2025, Mediana (IQR)	390 (268 – 553)	452 (313 – 624)
jornada_completa, n (%)		
NO	5.720 (85%)	1.485.455 (89%)
SI	1.030 (15%)	180.798 (11%)
latitud, Mediana (IQR)	–34,72 (–34,92 – –34,56)	–34,72 (–34,88 – –34,57)
longitud, Mediana (IQR)	–58,61 (–58,82 – –58,38)	–58,59 (–58,79 – –58,36)
auh_pct, Mediana (IQR)	37 (16 – 53)	38 (18 – 54)
muestra_2024, n (%)		
SI	4.330 (100%)	182.586 (100%)
Desconocido	2.420	1.483.667

Figura 6.4



Nota: La coincidencia de las curvas valida la propiedad de autoponderación.

Cabe destacar que si se realiza algún test estadístico entre ambas distribuciones (p.e. Kolmogorov-Smirnov) se observa un aceptable ajuste entre ambas distribuciones lo que sugiere que la muestra logra «copiar» aceptablemente la distribución (y no solo la tendencia central) poblacional de la variable posesión de AUH.

6.6 Segunda etapa

En esta segunda etapa aparece una cuestión particular a considerar. Se trata del tamaño de las secciones de los establecimientos como algo diferente a la cantidad de secciones del mismo. Con respecto a la muestra de 2024, esto es un problema algo nuevo porque el diseño de la muestra 2025 aspira a, efectivamente, seleccionar *algunas* secciones dentro de los establecimientos en vez de ir a *todas*.


Antes vimos que si la probabilidad de inclusión de un establecimiento en la primera etapa de la muestra depende del tamaño de la matrícula eso permite que la cantidad de estudiantes a seleccionar en la segunda etapa pueda ser única para todos los establecimientos. Dado que en la mayoría de los establecimientos existe más de una sección para cada año (3^{ro} y 6^{to}) nos encontramos con el problema de como seleccionar a las propias secciones. Expresado en léxico muestral, ahora las secciones se convierten en unidades de selección secundarias lo que implica que la selección de las secciones puede considerarse como una segunda etapa de selección. En este sentido, el problema del tamaño de los establecimientos en la primera etapa se traduce al problema del tamaño de cada sección en la segunda etapa. Si solo se realiza un sorteo por azar simple dentro de cada establecimiento para seleccionar a las secciones, los estudiantes de las secciones más grandes van a tener una menor chance de salir en la muestra que los estudiantes de secciones chicas. En función de esto podría ser pertinente que, a la hora de realizar el sorteo de las secciones, se incluya en la probabilidad de inclusión el tamaño de la sección (Punto 3.3). Para tener de referencia, los establecimientos seleccionados en 2025 poseen, en promedio, más secciones que los seleccionados en 2024. Si se cuenta los diferentes turnos ahora hay que seleccionar entre 2,8 secciones en cada establecimiento para cada año. En cambio, este valor para la muestra de 2024 fue de alrededor de 2,2 secciones por cada establecimiento/año seleccionado en su respectiva primera etapa.

Sin embargo, el problema no se trata solo de que antes se iba a *todas* las secciones *entre las pocas* del establecimiento elegido y ahora a se vaya a *algunas entre muchas*. Un problema adicional es el siguiente. Supongamos que se tenga en mente la hipótesis que la relación en cuanto al ratio estudiantes/docente sea importante con respecto a los aprendizajes. En ese caso, una regla simple como la de «seleccione siempre a la sección más grande del establecimiento» sería, en presencia de la hipótesis anterior, una

regla que, artificialmente, bajaría el promedio de las notas PEB por cenirse a las secciones en donde ese ratio es mayor. La regla anterior se podría mantener si, dentro de cada establecimiento y dentro de cada año seleccionado, hubiera muy poca diferencia de tamaño entre sus diferentes secciones. Esta hipótesis, si bien razonable dentro de ciertos parámetros, es algo arriesgada. Por otro lado, asumir que sea usual la situación en donde un establecimiento tenga 3 secciones en 6^{to} grado, de las cuales una tenga un tamaño de 10 estudiantes, otra de 20 y otra de 30, también parece ser algo arriesgada. Podría ser algo más probable esta situación en los establecimientos de jornada simple en donde habría que seleccionar secciones tanto de la tarde como de la mañana. También puede ser algo más probable de encontrarse esta situación en 6^{to} más que en 3^{ro}. Sin embargo, aun asumiendo que estos últimos casos pueden ser más probables en jornada simple y en 6^{to} es difícil anticipar su peso en el conjunto de las secciones.

Lo anterior puede analizarse de modo empírico de dos modos diferentes. Primero analizaremos la distribución, medida a través de la desviación estándar, de todas las secciones con respecto a su respectiva media de tamaño para su mismo establecimiento y año. Esto nos va a permitir captar la heterogeneidad en función de la misma unidad que se utiliza para calcular la media que, en este caso, es la cantidad de estudiantes. En la Figura 6.5 se observa como, si bien con una distribución normal, existen divergencias con respecto a la media. Esto asegura que, si se seleccionara siempre a las secciones más grandes del tandem establecimiento/año, efectivamente la muestra estaría compuesta casi exclusivamente por secciones que se encuentran por encima de su respectiva media. Más concretamente, la mayoría de ellas estaría compuesta por secciones que sobrepasan por pocos estudiantes (2 estudiantes) a su respectiva media.

Figura 6.5: Diferencias de tamaño de las secciones para igual establecimiento y año. Media estandarizada en 0 y desvío estándar en cantidad de estudiantes.



De todos modos, para evitar que la muestra de secciones se pueble exclusivamente de las secciones más mayoritarias, más que implementar la regla simple de «seleccionar la sección más grande» vamos a implementar, como se había anticipado anteriormente, un criterio probabilístico en función del tamaño de la sección. De este modo, a nivel agregado si se van a seleccionar con mayor probabilidad las secciones más grandes, pero también, en una menor probabilidad, se van a incluir como primera opción algunas secciones que no cumplan ese criterio.

En la Tabla 6.5 puede observarse como al tiempo que se respeta la tendencia central del tamaño de las secciones, la mayoría de las veces (60%) se ha seleccionado a la sección más numerosa aunque, justamente, no siempre. De este modo se respeta el principio que las secciones más numerosas sean más seleccionadas (y de ese modo se equiparan las probabilidades de los estudiantes que están en ellas) pero también se seleccionan secciones no numerosas para de ese modo evitar el sesgo de seleccionar las secciones con mayor ratio de estudiantes/docentes.

Tabla 6.5: Población y muestra de secciones

Característica	NO N = 2.384	SI N = 1.346
tamaño, Media (DE)}	26 (6)}	26 (7)}
anio, n (%)		
3	1.196 (50%)	673 (50%)
6	1.188 (50%)	673 (50%)
seccion_mas_grande, n (%)		
NO	2.384 (100%)	534 (40%)
SI	0 (0%)	812 (60%)

7. Calibración con Metas Cuasicensales (PEB 2025)

7.1 Análisis *ex-post*. Construcción de ponderadores base, ponderadores por no respuesta y ponderadores de calibración.

En la sección Cap. 5. se comentaron algunas cuestiones generales sobre la calibración en sentido amplio. La principal diferencia de lo allá realizado con lo que se realizará a continuación es la siguiente: En aquella sección, la calibración se hacía sobre diferentes muestras de establecimientos y se comparaba la diferencias en los valores entre una muestra realizada por azar simple y otra vía balanceo bien distribuido. Sin embargo, otros puntos usuales del proceso de calibración no estaban presentes. Quizá el más notorio sea el de la falta de corrección de la no respuesta porque en ambas muestras utilizadas todos los establecimientos «respondían» la muestra. En esta ocasión, dado que se trata de una muestra final de estudiantes (con una primera etapa de selección de establecimientos, una segunda etapa de selección de secciones y, finalmente, una tercera etapa de selección de estudiantes), efectivamente vamos a tener casos sin respuesta, por lo que, aparte de los ponderadores usuales (a veces demonimados *base weight* o *design weights*), también habrá que analizar/corregir el factor de no respuesta antes del proceso de calibración en sentido estricto.

Un punto importante en este proceso de calibración es que en esta investigación en particular no tenemos que dudar de la calidad del marco muestral al menos cuando a esto lo asociamos a información proveniente, en su mayor parte, a la nómina de establecimientos. Esto rara vez sucede en muchos tipos de investigaciones que ejecutan muestras, aunque es algo más usual en diseños muestrales realizados dentro de grandes organizaciones (Valliant & Dever, 2018, Capítulo 1; Valliant et al., 2018, pág. 322). El presente marco muestral no parece tener problemas de sub-cobertura (*undervoverage*) o sobre-cobertura (*overcoverage*). En el primer caso, existirían estudiantes o establecimientos en la población objetivo que no están presente en el marco muestral. Se afirma que en esa situación el marco muestral omite **casos elegibles** de la población objetivo. En el segundo caso, existirían estudiantes o establecimientos en el marco muestral que no están presentes en la población objetivo. A estos se lo denomina **casos inelegibles** (Valliant et al., 2018, pág. 321). En otras palabras, en esta calibración no se realizarán ajustes por defectos en el marco muestral, lo que en el léxico muestral se suele denominar ajustes por «elegibilidad desconocida» (*unknown eligibility*) (Valliant & Dever, 2018, pág. 58-59). Esto quiere decir que todos los casos de la muestra pertenecen a la población objetivo y, por lo tanto, poseen la condición de ser «elegibles».

Estrictamente, como ahora veremos, el proceso de calibración de las muestras PEB 2025, se trata de dos procesos de calibración. Uno para la muestra de estudiantes de tercer año y otra para la muestra de estudiantes de sexto año. Precisamente, hasta la primera etapa, esto es, la selección de las unidades primarias (UPS), la muestra es idéntica para ambas muestras. Las diferencias comienzan a aparecer en las etapas subsiguientes en donde hay que seleccionar secciones dentro del establecimiento y estudiantes dentro de las secciones seleccionadas. Por esta razón, en primer lugar haremos con algún detalle la calibración del tercer año y luego, *mutatis mutandis*, se hará el mismo proceso (pero de manera menos detallada) para sexto año. En ambos casos (3.º y 6.º), los pasos a seguir serán los siguientes:

- Construcción de los ponderadores de diseño o *weight_design*.
- Construcción de los ponderadores para el ajuste por no respuesta.
- Construcción de los ponderadores por el proceso de calibración con fuentes auxiliares.

7.2 Tercer Año

7.2.0.1 Ponderadores Base

El primer paso es reconstruir los *weight_design*, esto es, los ponderadores base que salen del propio diseño de la muestra. Estos informan, finalmente, sobre la inversa de la probabilidad de inclusión de cada caso (en este caso de estudiantes) efectivamente seleccionado en la muestra. Decimos finalmente por qué al

tratarse en este caso de una muestra polietápica, los *weight_design* son la inversa de la probabilidad de inclusión del estudiante k , de la sección j , del establecimiento i .

La probabilidad de inclusión de cada estudiante (efectivamente observado en la tercera etapa y no solo seleccionado) puede representarse como:

$$p_{ijk}^i = p_i^i \times p_{j|i}^i \times p_{k|ij}^i \quad (7.1)$$

donde:

p_i^i es la probabilidad de inclusión en la primera etapa (establecimiento),

$p_{j|i}^i$ es la probabilidad condicional de inclusión en la segunda etapa (sección) dado que el establecimiento i fue seleccionado, y

$p_{k|ij}^i$ es la probabilidad condicional de inclusión en la tercera etapa (estudiante) dado que la sección j del establecimiento i fue seleccionada.

Luego, el ponderador de diseño o base inicial (w_{ijk}) es, por definición, el inverso multiplicativo de dicha probabilidad conjunta:

$$w_{ijk} = \frac{1}{p_{ijk}^i} \quad (7.2)$$

En términos prácticos, esto implica que para calcular los *weight_design* (w_{ijk}) primero debemos obtener la probabilidad de inclusión de cada estudiante para recién luego calcular su inversa. Por otro lado, la construcción de los *weight_design* implica un trabajo sinérgico entre información que proviene del diseño de la muestra (*ex-ante*) y la información efectivamente conseguida en campo (*ex-post*).

Primera Etapa

Se recuerda que la probabilidad de inclusión en la primera etapa, esto es, que el establecimiento i sea seleccionado, devenía de diversos factores como:

- Su inclusión en la muestra de 2024 (para favorecer el seguimiento tipo panel)
- El tamaño del establecimiento (muestra tipo PPS)
- El tipo de jornada (Para registrar establecimientos con Jornada Completa)

Estas probabilidades de inclusión fueron las que se incluyeron, en su momento, como insumo en el método del cubo. En nuestro marco muestral de establecimientos se denominó a esta variable con el nombre «pi_corregido». Modificando `?@eq-pi_estudiante_peb_25` bajo esta premisa, la estructura del cálculo de la probabilidad conjunta para el estudiante k , de la sección j , en el establecimiento i se puede traducir como:

$$p_{ijk}^i = \pi_i^{\text{cubo}} \times p_{j|i}^i \times p_{k|ij}^i \quad (7.3)$$

Donde π_i^{cubo} es, precisamente, el valor numérico que se le asignó a ese establecimiento específico en el vector de entrada del método del cubo.

Segunda Etapa

Ahora pasaremos a construir/calcular las probabilidades de inclusión de la segunda etapa en donde se seleccionaron secciones. La probabilidad de inclusión es, aproximadamente, una probabilidad en función del tamaño de las secciones.

Tercera Etapa

La tercera etapa constaba, en principio, de una cantidad fija de estudiantes (10) por sección. Si se encontraban secciones con menos de 10 estudiantes se debía seguir con otra sección hasta llegar a la cantidad de 10 estudiantes por establecimiento. Esta etapa es la que, de manera algo previsible, se puede esperar mayores desviaciones entre lo esperado y lo encontrado.

Con la información de la probabilidad de inclusión en cada caso ahora es posible calcular, primero calcular una variable que indique la probabilidad de inclusión de cada estudiante (`pi_total_estudiante`) y luego otra variable que sea su inversa (`weight_design`).

Finalmente, antes de pasar a la construcción de los ponderadores por no respuesta vamos a hacer algunos análisis breves sobre la distribución de los `weight_design`. Pesos extremadamente altos pueden inflar de forma desmedida la varianza de los estimadores (Kish, 1987, pág. 231-238). Por otro lado, no

debería haber pesos con NA, valores infinitos o negativos. Esto es lo que precisamente se observa en la Tabla 7.1.

```
tbl_weight_design_test_1 = insumo_calibracion_3 |>
  summarise(
    casos_totales = n(),
    casos_na      = sum(is.na(weight_design)),
    casos_inf     = sum(is.infinite(weight_design)),
    casos_neg     = sum(weight_design < 1, na.rm = TRUE),
    peso_minimo   = min(weight_design, na.rm = TRUE),
    peso_maximo   = max(weight_design, na.rm = TRUE),
    suma_pesos    = sum(weight_design, na.rm = TRUE)
  ) |>
  gt()

tbl_weight_design_test_1
```

Tabla 7.1: Chequeos de los ponderadores de diseño

casos_totales	casos_na	casos_inf	casos_neg	peso_minimo	peso_maximo	suma_pesos
5230	0	0	0	1.913043	1315.554	164703.6

En la última columna de Tabla 7.1 puede observarse otra dimensión importante de los `weight_design` que es que tan bien se arriman a los totales conocidos del marco muestral.

```
# Hay más de una manera de hacerla. Por un lado está la base de secciones. Esto tiene el
# beneficio, a pesar de tener algunas secciones sin valor, de poder discriminar el peso
# de los 3 entre toda la matrícula primaria. Esa proporción es la que se puede utilizar
# tomando como un mejor indicador de toda la masa de estudiante el dato que sale de la
# base de establecimientos (marco_muestra)
n_poblacion_3_base_secciones = tb_secciones_2025 |>
  filter(anio == 3) |>
  filter(descripcionofertaeducativa == "Primaria (1° Y 2° ciclo)") |>
  summarise(matricula = sum(total))

n_poblacion_primaria_base_secciones = tb_secciones_2025 |>
  filter(descripcionofertaeducativa == "Primaria (1° Y 2° ciclo)") |>
  summarise(matricula = sum(total))

ratio_primaria_terceros = n_poblacion_primaria_base_secciones$matricula /
  n_poblacion_3_base_secciones$matricula

# Esto estima la matricula_3 de cada establecimiento
marco_muestra = marco_muestra |>
  mutate(matricula_3 = matricula_inicial_2025 / ratio_primaria_terceros)

n_poblacion_objetivo_3 = marco_muestra |>
  summarise(matricula_3 = sum(matricula_inicial_2025)/ratio_primaria_terceros)
```

En este caso, partiendo de una población objetivo de 273.300 estudiantes se obtienen unos 164.704 lo que implica un 60%. Esto puede deberse a poco o sugerir algún error en la construcción de los ponderadores base. Sin embargo, para saber esto todavía falta aproximarse a la dimensión de la no respuesta.

En cambio, en la Tabla 7.2, se indaga acerca de las medias de cada etapa de los ponderadores de diseño y su efecto o peso en la expansión final de los mismos.

Tabla 7.2: Chequeos descomposición weight_design

n_muestra	media_pi_1	media_pi_2	media_pi_3	media_pi_4	media_pi_5	media_pi_6	media_pi_7
5230	0.6565885	0.4497523	0.5426482	5.92203	2.739672	2.244933	

Finalmente, antes de pasar a la no respuesta, en la Tabla 7.3 y en la Tabla 7.4, veremos algunos valores acerca de la distribución del ponderador de diseño.

Tabla 7.3: Distribución de weight_design

Característica	N = 5.230
Factor de Expansión (weight_design), Media (DE) Mediana: Mediana [Min: Min, Max: Max]	31,49 (49,02) Mediana: 6,90 [Min: 1,91, Max: 1.315,55]

Tabla 7.4: Media del weight_design según diferentes percentiles

Percentil	Valor
0%	1.91
5%	2.77
25%	4.40
50%	6.90
75%	49.65
90%	101.76
95%	108.57
99%	132.75
100%	1,315.55

7.2.1 No respuesta

Una vez calculados los weight_design comenzamos el proceso de corrección por no respuesta. La falta de este proceso suele afectar más al sesgo (bias) que a la varianza del estimador (Valliant et al., 2018, pág. 322).

Uno de los puntos por los que se puede comenzar a analizar esto es en función de lo esperado/encontrado. Como en nuestro caso contamos con:

- Un marco muestral de establecimientos que sobre el cual se realizó una muestra de los mismos y
- Un tope de 10 estudiantes por establecimientos

Por una cuestión de practicidad vamos a enfocarnos en la corrección de la no respuesta a nivel del establecimiento y no tanto a nivel de la sección como del estudiante. Por un lado, vamos a considerar a lo «esperado» en función de lo anterior. Quizá lo más importante de justificar en este paso es porque no esperar alguna cantidad específica de secciones.

La construcción la haremos construyendo un índice de **Propensión de Respuesta** por establecimiento. Este tiene el beneficio de poder incorporar variables numéricas (p.e. tamaño de la matrícula o porcenatje de AUH) y no solo la construcción de clases discretas mediante variables categóricas (Valliant & Dever, 2018, 3.2). Tiene también algunas limitaciones que veremos de mejorar para futuras ediciones (Valliant & Dever, 2018, 3.3).

Por otro lado, si se mantiene la estrategia de trabajar con variables categóricas, la construcción de excesivos grupos de control de no respuesta puede hacer poco robustas las correcciones porque los grupos contruidos o bien poseen pocos casos en la muestra (*ex-ante*) o, de manera derivada, pueden directamente no encontrarse casos con respuestas en la muestra *ex-post*. En este último caso, los ponderadores por no respuesta podrían dar infinito lo que, previsiblemente, no es algo deseable desde un punto de vista metodológico.

Antes de pasar al calcular este último paso, vamos a explorar la distribución de secciones por establecimientos y de estudiantes por establecimientos. Esto puede ayudar a dar una idea de como se aplicó la muestra en campo y de la distancia con respecto a lo diseñado.


Empezamos con la Tabla 7.5 en donde se visualizan algunos valores resumen tanto para los establecimientos que «respondieron» como para los que no lo hicieron.

Tabla 7.5: Distribución de la no respuesta según características de los establecimientos

Característica	Respondiente N = 386	No Respondiente N = 289	Global N = 675
matricula_inicial_2025, Media (DE) [Mediana: Mediana]	403 (219) [Mediana: 375]	463 (246) [Mediana: 426]	429 (233) [Mediana: 390]
% Alumnos con AUH, Media (DE) [Mediana: Mediana]	31 (20) [Mediana: 29]	40 (21) [Mediana: 45]	35 (21) [Mediana: 37]
Region, n (%)			
01	20 (5,2%)	16 (5,5%)	36 (5,3%)
02	28 (7,3%)	25 (8,7%)	53 (7,9%)
03	29 (7,5%)	28 (9,7%)	57 (8,4%)
04	22 (5,7%)	25 (8,7%)	47 (7,0%)
05	20 (5,2%)	31 (11%)	51 (7,6%)
06	23 (6,0%)	17 (5,9%)	40 (5,9%)
07	24 (6,2%)	13 (4,5%)	37 (5,5%)
08	16 (4,1%)	16 (5,5%)	32 (4,7%)
09	40 (10%)	26 (9,0%)	66 (9,8%)
10	20 (5,2%)	12 (4,2%)	32 (4,7%)
11	21 (5,4%)	22 (7,6%)	43 (6,4%)
12	19 (4,9%)	0 (0%)	19 (2,8%)
13	9 (2,3%)	3 (1,0%)	12 (1,8%)
14	6 (1,6%)	6 (2,1%)	12 (1,8%)
15	3 (0,8%)	7 (2,4%)	10 (1,5%)
16	5 (1,3%)	2 (0,7%)	7 (1,0%)
17	4 (1,0%)	3 (1,0%)	7 (1,0%)
18	9 (2,3%)	1 (0,3%)	10 (1,5%)
19	24 (6,2%)	15 (5,2%)	39 (5,8%)
20	10 (2,6%)	6 (2,1%)	16 (2,4%)
21	3 (0,8%)	2 (0,7%)	5 (0,7%)
22	15 (3,9%)	5 (1,7%)	20 (3,0%)
23	5 (1,3%)	2 (0,7%)	7 (1,0%)
24	6 (1,6%)	2 (0,7%)	8 (1,2%)
25	5 (1,3%)	4 (1,4%)	9 (1,3%)
sector, n (%)			
Estatad	221 (57%)	217 (75%)	438 (65%)
Privado	165 (43%)	72 (25%)	237 (35%)
jornada_completa, n (%)			
ambos, n (%)	317 (82%)	259 (89%)	576 (85%)


En la Figura 7.1 se analiza distribución del tamaño de la matrícula del establecimiento en función de si fue un establecimiento respondiente o no.

Figura 7.1: Distribución de la no respuesta según tamaño de la matrícula



En la Figura 7.2, se realiza la misma operación pero ahora en función del porcentaje de AUH del establecimiento. Este punto es importante porque sugiere que la muestra subrepresenta a los establecimientos/estudiantes con más AUH (NSE = «Bajo») y que sobrerrepresentan a los de poco AUH (NSE = «Alto»).

Figura 7.2: Distribución de la no respuesta según porcentaje de AUH



A modo de resumen, se recuerda que, en primer lugar, los establecimientos seleccionados en el diseño fueron 673 y los que efectivamente se utilizaron en campo fueron 386, lo que representa algo más que

un 57%. Esto, previsiblemente, impacta en los estimadores en forma de sesgo (*bias*) porque la ausencia de establecimiento rara vez es azarosa. Por otro lado, la muestra esperada era de alrededor de 6730 estudiantes (10 estudiantes por cada uno de los 673 establecimientos) y finalmente se contactaron (sin todavía indagar sobre su calidad) unos 5320 casos. Esto implica un 79% de la muestra original. Esto ya anticipa que, si bien se fue a menos establecimientos de los diseñados, a pesar de cierta dispersión, en promedio se fue a más de 10 estudiantes por establecimiento.

En cuanto a las secciones, en la Tabla 7.6, se observa a cuantas secciones por establecimiento efectivamente se seleccionaron.

Tabla 7.6: Distribución de secciones seleccionadas por establecimiento

Variable	N = 386
Secciones por establecimiento, n (%)	
1	331 (85,8%)
2	32 (8,3%)
3	23 (6,0%)

A pesar de haber situaciones en donde se seleccionaron menos de 10 estudiantes y otros en donde se seleccionaron varios más, en la Tabla 7.7, se observa que la mediana se mantuvo en 10 estudiantes por establecimiento.

Tabla 7.7: Distribución de estudiantes seleccionados por establecimiento

Variable	N = 386
Estudiantes por establecimiento, Mediana (IQR)	10 (10 – 13)

Dado lo observado anteriormente parece necesario, o por lo menos útil, realizar un ajuste por no respuesta. En efecto, estos valores de no respuesta son los principales culpables que el total que arrojaban los `weight_design` no coincidieran con los totales del marco muestral.

Para eso, como se había anticipado más arriba, se va a realizar un ajuste de no respuesta por un `propensity_score` de no respuesta en función de las variables:

- Matrícula
- Porcentaje de AUH
- Región
- Sector
- Jornada completa
- Ámbito

Luego de algunos ejercicios exploratorios se vio que eran pertinente incorporar algunos efectos de interacción entre las variables principales anteriores. Más precisamente, teniendo en cuenta la magnitud de los errores y la cantidad de casos de cada categoría, se prefirió incorporar la interacción entre:

- Sector y Región
- Jornada completa y ámbito

7.2.1.1 Diagnóstico del ajuste por no respuesta

Antes de pasar a la calibración, se evalúa la calidad del ajuste por no respuesta. En las figuras Figura 7.1 y Figura 7.2 ya se analizó visualmente la distribución de la no respuesta mediante gráficos de densidad según el tamaño de la matrícula y el porcentaje de AUH respectivamente. Ahora, tras aplicar el modelo de propensión, se comparan las métricas de los ponderadores entre `weight_design` y `weight_no_respuesta` para verificar si la corrección acerca los totales estimados al target poblacional conocido.


```

# Defino el target poblacional como la suma de estudiantes de 3.er año del marco muestral
target_poblacional_3 = n_poblacion_objetivo_3$matricula_3

# Calculo las sumas de ambos ponderadores para usarlas en la tabla
suma_wd = sum(insumo_calibracion_3$weight_design, na.rm = TRUE)
suma_wnr = sum(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE)

# Construyo un dataframe con las métricas de resumen para cada ponderador
df_metricas_nr_3 = tibble(
  Indicador = c(
    "Suma de pesos (N estimado)",
    "Media del ponderador",
    "Mediana del ponderador",
    "Desvío estándar",
    "Peso mínimo",
    "Peso máximo",
    "Coeficiente de variación",
    "Target poblacional (N)",
    "Diferencia vs target (%)"
  ),
  peso_diseno = c(
    suma_wd,
    mean(insumo_calibracion_3$weight_design, na.rm = TRUE),
    median(insumo_calibracion_3$weight_design, na.rm = TRUE),
    sd(insumo_calibracion_3$weight_design, na.rm = TRUE),
    min(insumo_calibracion_3$weight_design, na.rm = TRUE),
    max(insumo_calibracion_3$weight_design, na.rm = TRUE),
    sd(insumo_calibracion_3$weight_design, na.rm = TRUE) /
      mean(insumo_calibracion_3$weight_design, na.rm = TRUE),
    target_poblacional_3,
    (suma_wd - target_poblacional_3) / target_poblacional_3 * 100
  ),
  peso_nr = c(
    suma_wnr,
    mean(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE),
    median(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE),
    sd(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE),
    min(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE),
    max(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE),
    sd(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE) /
      mean(insumo_calibracion_3$weight_no_respuesta, na.rm = TRUE),
    target_poblacional_3,
    (suma_wnr - target_poblacional_3) / target_poblacional_3 * 100
  )
)

# Genero la tabla gt con formato
df_metricas_nr_3 |>
  gt() |>
  tab_header(
    title = "Comparación de métricas: weight_design vs weight_no_respuesta",
    subtitle = "Tercer año – PEB 2025"
  ) |>
  cols_label(
    peso_diseno = "Peso de diseño",
    peso_nr = "Peso ajustado por NR"
  ) |>
  fmt_number(
    columns = c(peso_diseno, peso_nr),
    decimals = 2
  )

```

```

) |>
tab_style(
  style = cell_fill(color = "#f0f7ff"),
  locations = cells_body(
    rows = Indicador %in% c("Target poblacional (N)", "Diferencia vs target (%)")
  )
) |>
tab_options(table.width = pct(100))

```

Tabla 7.8: Comparación de métricas entre weight_design y weight_no_respuesta

Comparación de métricas: weight_design vs weight_no_respuesta

Tercer año – PEB 2025

Indicador	Peso de diseño	Peso ajustado por NR
Suma de pesos (N estimado)	164,703.60	297,591.37
Media del ponderador	31.49	56.90
Mediana del ponderador	6.90	12.24
Desvío estándar	49.02	99.38
Peso mínimo	1.91	1.97
Peso máximo	1,315.55	2,886.89
Coefficiente de variación	1.56	1.75
Target poblacional (N)	279,457.70	279,457.70
Diferencia vs target (%)	-41.06	6.49

En la Tabla 7.9 se analiza la distribución de la probabilidad de respuesta estimada y su inversa (*inv_no_respuesta*). Valores muy bajos de *prob_respuesta* (cerca de 0) generan factores de corrección extremadamente altos que pueden inflar la suma total de pesos por encima de la población objetivo. Cabe notar que al haberse calculado la propensión a nivel del establecimiento, todos los estudiantes de un mismo establecimiento comparten el mismo valor de *prob_respuesta* e *inv_no_respuesta*.

```

# Calculo los percentiles clave de la probabilidad de respuesta
# y derivo la inversa de esos mismos valores para que cada fila sea coherente
probs_diag = c(0, 0.05, 0.25, 0.50, 0.75, 0.95, 0.99, 1)

prob_quantiles_3 = quantile(
  insumo_calibracion_3$prob_respuesta,
  probs = probs_diag, na.rm = TRUE
)

df_diagnostico_inv_nr_3 = tibble(
  Percentil = c("Mínimo (P0)", "P5", "P25", "P50 (Mediana)",
    "P75", "P95", "P99", "Máximo (P100)"),
  prob_respuesta = prob_quantiles_3,
  inv_no_respuesta = 1 / prob_quantiles_3
)

# Genero la tabla gt

```

```
df_diagnostico_inv_nr_3 |>
  gt() |>
  tab_header(
    title = "Distribución del factor de no respuesta",
    subtitle = "Probabilidad de respuesta y su inversa – Tercer año PEB 2025"
  ) |>
  cols_label(
    prob_respuesta = "Prob. Respuesta",
    inv_no_respuesta = "Inversa (1/prob)"
  ) |>
  fmt_number(
    columns = c(prob_respuesta, inv_no_respuesta),
    decimals = 4
  ) |>
  tab_options(table.width = pct(100))
```

Tabla 7.9: Distribución de la probabilidad de respuesta y del factor de no respuesta

Distribución del factor de no respuesta		
Probabilidad de respuesta y su inversa – Tercer año PEB 2025		
Percentil	Prob. Respuesta	Inversa (1/prob)
Mínimo (P0)	0.1271	7.8702
P5	0.2725	3.6693
P25	0.4773	2.0951
P50 (Mediana)	0.6582	1.5192
P75	0.8295	1.2056
P95	1.0000	1.0000
P99	1.0000	1.0000
Máximo (P100)	1.0000	1.0000

7.3 Calibración

Finalmente, contruidos los ponderadores base o de diseño (*weight_design*), sobre los cuales se realizaron las correcciones por no-respuesta (*weight_no_respuesta*), ahora pasamos al proceso de calibración propiamente dicho. Para esto usaremos diferentes fuentes auxiliares. Algunas tendrán origen en el propio marco muestral y otras tendrán origen en los datos agregados cuasi-censales que informaron los establecimientos sobre los resultados de las PEB. Cabe destacar que ambas fuentes pueden no coincidir dado que los resultados de las PEB no fueron informados por todas los establecimientos. De ahí que afirmemos que se trata de un operativo cuasi-censal. El punto importante de incluir información censal de las PEB es, aparte de reducir la discrepancia en las publicaciones entre los resultados censales y los muestrales, es que estas informan sobre una serie de variables que eran consideradas claves en los objetivos de las PEB como, por ejemplo, las IRA.

Para este fin usaremos un método de calibración lo bastante general como el GREG (Särndal, s. f.) para así poder incluir tanto variables categóricas como continuas. Esto, como veremos a continuación, genera diferentes problemas a la hora de adaptar/transformar los insumos necesarios para la calibración. Los principales tienen que ver con la necesidad de no contar con valores faltantes (*missing values*) en las variables que intervienen en la calibración y, además, el tratamiento de las diferencias absolutas entre la información proveniente del marco muestral (que, a su turno, en su mayoría deviene de la nómina de establecimientos) y la proveniente del censo de las PEB. La razón de estos problemas es que, en general,

los totales poblacionales se deben pasar como valores absolutos o cantidades discretas. Esto suele ser así porque esos valores suelen ser los «objetivos» que tiene que maximizar las funciones de calibración. Esto plantea diferentes estrategias para las variables categóricas que para las numéricas. Por otro lado, algunas de las variables tienen origen en el marco muestral (de establecimientos) y otros en el censo (de estudiantes) de las pruebas PEB lo que generar problemas particulares porque ambas tienen diferentes totales.

En términos más concretos se intentó maximizar los datos de las IRA según el censo de las PEB (Tabla 7.10). Específicamente, se aspiró a acercarse a los valores de las IRA, tanto en Matemática como en Prácticas del Lenguaje de la tabla cruzada 3×2 entre **Sector** (Estatel / Privado) y **Nivel Socioeconómico (NSE)** (Bajo, Medio, Alto). Para eso fue necesario calcular:

- La matrícula poblacional estimada por celda (N_h).
- La media poblacional de la prueba de **Matemática** ($\bar{Y}_{mat,h}$).
- La media poblacional de la prueba de **Lengua / Prácticas del Lenguaje** ($\bar{Y}_{pl,h}$).

```
levels_NSE = c("Bajo", "Medio", "Alto")

# Medias publicadas por el operativo cuasicensal (Sector x NSE) para 3.º
medias_cuasicenso_3 = tribble(
  ~sector, ~NSE, ~media_mat_ref, ~media_pl_ref,
  "Estatel", "Bajo", 66.4, 68.10,
  "Estatel", "Medio", 67.0, 72.08,
  "Estatel", "Alto", 69.7, 75.54,
  "Privado", "Bajo", 68.8, 72.41,
  "Privado", "Medio", 72.0, 76.52,
  "Privado", "Alto", 72.5, 75.93
) |>
mutate(NSE = factor(NSE, levels = levels_NSE))

medias_cuasicenso_3 |>
gt() |>
tab_header(
  title = "Objetivos Poblacionales del censo PEB",
  subtitle = "Medias de IRA en Matemática y Prácticas del Lenguaje (3.º Año)"
) |>
cols_label(
  sector = "Sector",
  NSE = "NSE (Tercil AUH)",
  media_mat_ref = "Media Matemática",
  media_pl_ref = "Media Lengua (PL)"
) |>
fmt_number(columns = c(media_mat_ref, media_pl_ref), decimals = 2)
```

Tabla 7.10: Objetivos Poblacionales del censo PEB. Medias de IRA en Matemática y Prácticas del Lenguaje (3.º Año).

Objetivos Poblacionales del censo PEB			
Medias de IRA en Matemática y Prácticas del Lenguaje (3.º Año)			
Sector	NSE (Tercil AUH)	Media Matemática	Media Lengua (PL)
Estatal	Bajo	66.40	68.10
Estatal	Medio	67.00	72.08
Estatal	Alto	69.70	75.54
Privado	Bajo	68.80	72.41
Privado	Medio	72.00	76.52
Privado	Alto	72.50	75.93

También existía la estrategia complementaria de intentar maximizar los objetivos que provinieran exclusivamente del marco muestral. Esta estrategia era más simple ya que los datos de los establecimientos no tienen valores faltantes y podrían haber realizado una calibración con una inclusión mayor de variables como Región o Ámbito. El punto de negativo de esta estrategia era que, especialmente en las interacciones de las celdas condicionales (no tanto en las medias generales), se desentendía del valor de las IRA.

7.3.0.1 Preparación de los datos

Ahora vamos a preparar los totales que provienen del censo de las PEB. Estos tienen que ver con variables continuas como el IRA de matemática y el IRA de prácticas del lenguaje. Es importante destacar que por razones de no respuesta, en la **muestra**, existen una fracción no marginal de estudiantes que han completado parte de las preguntas de matemática y no las de prácticas del lenguaje (o viceversa). Esto genera un problema a la hora de la construcción de los calibradores porque, como se anticipó más arriba, los algoritmos utilizados no permiten la introducción de casos con valores faltantes en las variables a calibrar.

Por otro lado, a la hora de realizar esta calibración nos encontramos con un problema adicional. Los datos censales de las PEB se registraron no solo por cada año (tercer y sexto) sino que también por materia. Esto implica trabajar con 4 bases de datos (con n diferentes) cada una con su respectivo ponderador. La cuestión del n diferente no es trivial. En efecto, en cada una de estas bases, había establecimientos (diferentes) que habían informado valores y otros que no por lo que los respectivos ponderadores eran ponderadores locales de cada base. Sin embargo, en la muestra cada fila es un estudiante que responde tanto en Matemática como en Prácticas del Lenguaje. Esto hace que si, en vez de 2 muestras se trabaje con 4 (año y materia), no se puedan realizar análisis sobre como responde el mismo estudiante en ambas materias. Por esta razón se intentó evitar esta estrategia para no limitar las posibilidades de análisis posteriores.

Imputación por donante de variables auxiliares continuas

Para la inclusión de las metas continuas en el vector de calibración GREG, se requiere que la muestra no presente valores faltantes en las variables a calibrar (IRA_{mat} e IRA_{pl}). Acá se abren dos caminos alternativos. Un camino se podría denominar del «Mínimo ancestro en común». El otro apuesta a la imputación de los valores faltantes.

El primero consiste en anexas a la base de la muestra una variable que informe sobre la nota de cada materia a algún nivel de agregación. Decimos a «algún nivel» y no tal o cual nivel específico (p.e. por establecimiento) porque no sabemos a partir de que nivel no vamos a tener valores faltantes. Ya adelantamos que, lamentablemente, si se agrega a nivel de establecimientos todavía persisten valores faltantes tanto en la base muestral como en la censal. Por esta razón, se desistió seguir por este camino dado que muchos valores serían idénticos y eso reduce el margen de maniobra para que trabaje el algoritmo de la calibración.

Dentro de las opciones de la imputación las opciones son varias. Si se recurre a una imputación simple por la media total o por sector se produce un colapso artificial de la variabilidad observada, asignando valores idénticos a los casos no respondientes y sobrecargando el posterior ajuste de los factores de calibración. Por tal motivo, se ha procedido a realizar una imputación mediante el método de emparejamiento de medias predictivas (*Predictive Mean Matching* o PMM). Este método permite incluir, como covariable, el valor de la (otra) nota IRA. Para evitar distorsiones derivadas de las diferencias en la escala absoluta de dificultad entre Prácticas del Lenguaje y Matemática, se estandariza el desempeño relativo mediante el cálculo del **rango percentil condicional** (posición relativa dentro la nota) de la materia observada. Asimismo, se incorporan como predictores directos del donante las variables contextuales de origen censal (*sector*, *NSE*, *ambito*, *region*) junto a *jornada_completa* con origen en el marco muestral, permitiendo que el donante seleccionado provenga de un entorno institucional y territorial análogo.

```
# Se calcula la posición relativa (rango percentil) de cada materia dentro del estrato censal
insumo_calibracion_3 = insumo_calibracion_3 |>
  group_by(sector, NSE) |>
  mutate(
    rango_mat = if_else(!is.na(ira_mat), percent_rank(ira_mat), NA_real_),
    rango_pl  = if_else(!is.na(ira_pl),  percent_rank(ira_pl),  NA_real_)
  ) |>
  ungroup()

# Se seleccionan las variables auxiliares contextuales y de rendimiento relativo para el donante
datos_imputar_3 = insumo_calibracion_3 |>
  select(
    id_estudiante, ira_mat, ira_pl,
    rango_mat, rango_pl,
    sector, NSE, ambito, region, jornada_completa
  )

# Se define la matriz de predictores excluyendo el identificador
pred_mat_3 = make.predictorMatrix(datos_imputar_3)
pred_mat_3[, "id_estudiante"] = 0

# Se ejecuta la imputación condicional por donante (PMM)
set.seed(123)
imp_obj_3 = mice(
  data = datos_imputar_3,
  m = 1,
  maxit = 5,
  method = "pmm",
  predictorMatrix = pred_mat_3,
  printFlag = FALSE
)

# Se extraen los valores completados
datos_completos_3 = complete(imp_obj_3)

# Se incorporan las notas imputadas a la base de calibración
insumo_calibracion_3 = insumo_calibracion_3 |>
  mutate(
    ira_mat_imp = datos_completos_3$ira_mat,
    ira_pl_imp  = datos_completos_3$ira_pl
  )
```

7.3.1 Contraste muestra calibrada vs. parámetros poblacionales censo PEB (3.er Año)

Contraste de Medias y Totales: Muestra Calibrada vs. Cuasicenso

Tercer Año (PEB 2025)

Sector	NSE	Mat Calibrada	Mat Meta	Dif Mat	PL Calibrada	PL Meta	Dif PL	N Calibrado	N Meta
Estatal	Bajo	67.11	66.40	0.71	67.81	68.10	-0.29	113,531	113,531
Estatal	Medio	66.42	67.00	-0.58	71.89	72.08	-0.19	59,825	59,825
Estatal	Alto	70.05	69.70	0.35	75.55	75.54	0.01	7,991	7,991
Privado	Bajo	68.51	68.80	-0.29	73.46	72.41	1.05	962	962
Privado	Medio	72.36	72.00	0.36	77.67	76.52	1.15	27,643	27,643
Privado	Alto	72.50	72.50	0.00	76.08	75.93	0.15	69,506	69,506

7.3.2 Constraste muestra calibrada vs. parámetros poblacionales marco muestral (3.er Año)

En esta tabla comparo las distribuciones marginales (porcentajes de estudiantes y notas medias) obtenidas con la muestra calibrada respecto a la población objetivo total del marco muestral de establecimientos:

Tabla 7.11

Característica	Muestra Calibrada (3.º Año)	Población Objetivo (Marco)
	N = 279.458	N = 279.458
Sector, % (n=n (unweighted))		
Estatad	64,9% (n=2.938)	64,9%
Privado	35,1% (n=2.292)	35,1%
Nivel Socioeconómico (NSE), % (n=n (unweighted))		
Bajo	41,0% (n=1.530)	41,0%
Medio	31,3% (n=1.762)	31,3%
Alto	27,7% (n=1.938)	27,7%
Zona (Conurbano vs. Interior), % (n=n (unweighted))		
Conurbano	80,2% (n=3.663)	78,9%
Interior	19,8% (n=1.567)	21,1%
Región Educativa, % (n=n (unweighted))		
01	5,6% (n=215)	5,9%
02	6,1% (n=390)	8,5%
03	8,1% (n=424)	9,4%
04	7,3% (n=324)	9,0%
05	15,1% (n=313)	8,7%
06	6,1% (n=328)	6,0%
07	6,6% (n=335)	4,3%
08	2,2% (n=233)	6,2%
09	11,7% (n=482)	10,7%
10	3,6% (n=224)	3,6%
11	7,7% (n=395)	6,6%
12	1,8% (n=200)	2,0%
13	2,0% (n=85)	1,3%
14	0,9% (n=90)	1,4%
15	1,8% (n=111)	1,3%
16	0,3% (n=60)	0,8%
17	0,5% (n=40)	0,7%
18	2,2% (n=125)	1,7%
19	3,1% (n=296)	3,9%
20	1,0% (n=128)	1,7%
21	0,2% (n=49)	0,8%
Mediana de la muestra (unweighted)	1,6% (n=195)	2,4%
Mediana de la población (unweighted)	98,4% (n=279.458)	97,6%

7.4 Sexto año

A diferencia de lo realizado en tercer año, para sexto año las explicaciones serán mucho más lacónicas y dictatoriales, dado que, en esencia, se aplicó la misma metodología que antes tanto para la construcción de los ponderadores base, los ponderadores de no respuesta y los ponderadores producto de la calibración.

7.4.1 Objetivos poblacionales Censo PEB

Extraigo las metas cuasicensales directamente a partir de las bases de 6.º año evaluadas (PEB_2025_Primeria_MAT_A6.sav y PEB_2025_Primeria_PL_A6.sav):

```
# Medias del cuasicenso para 6.º año
medias_cuasicenso_6 = tribble(
  ~sector, ~NSE, ~media_mat_ref, ~media_pl_ref,
  "Estatad", "Bajo", 66.53, 71.09,
  "Estatad", "Medio", 65.57, 71.88,
  "Estatad", "Alto", 66.93, 76.25,
  "Privado", "Bajo", 64.67, 74.43,
  "Privado", "Medio", 69.60, 78.07,
  "Privado", "Alto", 68.46, 76.65
) |>
mutate(NSE = factor(NSE, levels = levels_NSE))

medias_cuasicenso_6 |>
gt() |>
tab_header(
  title = "Metas Poblacionales del Cuasicenso (6.º Año)",
  subtitle = "Medias de IRA en Matemática y Prácticas del Lenguaje"
) |>
cols_label(
  sector = "Sector",
  NSE = "NSE (Tercil AUH)",
  media_mat_ref = "Media Matemática",
  media_pl_ref = "Media Lengua (PL)"
) |>
fmt_number(columns = c(media_mat_ref, media_pl_ref), decimals = 2)
```

Metas Poblacionales del Cuasicenso (6.º Año)

Medias de IRA en Matemática y Prácticas del Lenguaje

Sector	NSE (Tercil AUH)	Media Matemática	Media Lengua (PL)
Estatad	Bajo	66.53	71.09
Estatad	Medio	65.57	71.88
Estatad	Alto	66.93	76.25
Privado	Bajo	64.67	74.43
Privado	Medio	69.60	78.07
Privado	Alto	68.46	76.65

7.4.2 Carga del Marco Muestral

7.4.3 Construcción de Ponderadores de Diseño y No Respuesta

7.4.4 Calibración y Diagnóstico

```
# Se calcula la posición relativa (rango percentil) de cada materia dentro del estrato
censal para 6.º
insumo_calibracion_6 = insumo_calibracion_6 |>
  group_by(sector, NSE) |>
  mutate(
    rango_mat = if_else(!is.na(ira_mat), percent_rank(ira_mat), NA_real_),
    rango_pl  = if_else(!is.na(ira_pl),  percent_rank(ira_pl),  NA_real_)
  ) |>
  ungroup()

# Se seleccionan las variables auxiliares contextuales y de rendimiento relativo para
el donante de 6.º
datos_imputar_6 = insumo_calibracion_6 |>
  select(
    id_estudiante, ira_mat, ira_pl,
    rango_mat, rango_pl,
    sector, NSE, ambito, region, jornada_completa
  )

# Se define la matriz de predictores excluyendo el identificador
pred_mat_6 = make.predictorMatrix(datos_imputar_6)
pred_mat_6[, "id_estudiante"] = 0

# Se ejecuta la imputación condicional por donante (PMM)
set.seed(123)
imp_obj_6 = mice(
  data = datos_imputar_6,
  m = 1,
  maxit = 5,
  method = "pmm",
  predictorMatrix = pred_mat_6,
  printFlag = FALSE
)

# Se extraen los valores completados
datos_completos_6 = complete(imp_obj_6)

# Se incorporan las notas imputadas a la base de calibración de 6.º
insumo_calibracion_6 = insumo_calibracion_6 |>
  mutate(
    ira_mat_imp = datos_completos_6$ira_mat,
    ira_pl_imp  = datos_completos_6$ira_pl
  )
```

7.4.5 Contraste muestra calibrada vs. parámetros poblacionales censo PEB

Contraste de Medias y Totales: Muestra Calibrada vs. Cuasicen-
SO

Sexto Año (PEB 2025)

Sec- tor	NSE	Mat Cali- brada	Mat Meta	Dif Mat	PL Cali- brada	PL Meta	Dif PL	N Ca- libra- do	N Meta
Esta- tal	Bajo	66.42	66.53	-0.11	71.06	71.09	-0.03	118,130	118,130
Esta- tal	Me- dio	65.62	65.57	0.05	72.05	71.88	0.17	62,248	62,248
Esta- tal	Alto	66.83	66.93	-0.10	76.58	76.25	0.33	8,314	8,314
Priva- do	Bajo	64.55	64.67	-0.12	76.10	74.43	1.67	1,001	1,001
Priva- do	Me- dio	69.91	69.60	0.31	78.79	78.07	0.72	28,763	28,763
Priva- do	Alto	68.09	68.46	-0.37	76.56	76.65	-0.09	72,321	72,321

7.4.6 **Constraste muestra calibrada vs. parámetros oblacionales marco mues- tral**

Tabla 7.12

Característica	Muestra Calibrada (6.º Año)	Población Objetivo (Marco)
	N = 290.777	N = 290.777
Sector, % (n=n (unweighted))		
Estatad	64,9% (n=2.842)	64,9%
Privado	35,1% (n=2.184)	35,1%
Nivel Socioeconómico (NSE), % (n=n (unweighted))		
Bajo	41,0% (n=1.473)	41,0%
Medio	31,3% (n=1.692)	31,3%
Alto	27,7% (n=1.861)	27,7%
Zona (Conurbano vs. Interior), % (n=n (unweighted))		
Conurbano	81,4% (n=3.525)	78,9%
Interior	18,6% (n=1.501)	21,1%
Región Educativa, % (n=n (unweighted))		
01	5,3% (n=224)	5,9%
02	6,5% (n=356)	8,5%
03	8,5% (n=414)	9,4%
04	8,6% (n=328)	9,0%
05	13,8% (n=292)	8,7%
06	5,3% (n=257)	6,0%
07	6,1% (n=323)	4,3%
08	2,1% (n=211)	6,2%
09	14,4% (n=473)	10,7%
10	3,0% (n=217)	3,6%
11	7,8% (n=430)	6,6%
12	1,7% (n=220)	2,0%
13	1,4% (n=63)	1,3%
14	1,5% (n=74)	1,4%
15	1,6% (n=81)	1,3%
16	0,2% (n=60)	0,8%
17	0,5% (n=38)	0,7%
18	1,5% (n=103)	1,7%
19	3,1% (n=306)	3,9%
20	0,9% (n=130)	1,7%
21	0,2% (n=50)	0,8%
Media Urbana, % (n=n (unweighted))	1,7% (n=201)	2,4%
Media Rural, % (n=n (unweighted))	98,3% (n=288.776)	97,6%

7.4.7 Diagnóstico Comparado de Ponderadores (3.er vs. 6.º Año)

Diagnóstico Comparado de Ponderadores Calibrados

Muestras de 3.er y 6.º Año PEB 2025

Año	n Mues- tral	Míni- mo	Me- diana	Me- dia	Máxi- mo	Ca- sos < 0	Ca- sos < 1	Suma w_cal	N Tar- get Po- bla- ción
3.er Año	5230	0.34	12.59	53.432,998.86		0	61279,458279,458		
6.º Año	5026	0.52	11.97	57.852,992.90		0	26290,777290,777		

7.5 Exportación de Bases de Estudiantes con Ponderadores

En este bloque se exportan/graban las bases finales de estudiantes (tanto en formato `.csv` como en `.rds`) conservando las variables originales del operativo y agregando únicamente la trazabilidad de las etapas de muestreo y ponderación descritas a lo largo del documento:

- `pi_1`: Probabilidad de inclusión del establecimiento (primera etapa - cubo).
- `pi_2`: Probabilidad condicional de selección de la sección (segunda etapa).
- `pi_3`: Probabilidad condicional del estudiante dentro de la sección (tercera etapa).
- `pi_total_estudiante`: Probabilidad conjunta de inclusión ($pi_1 \times pi_2 \times pi_3$).
- `weight_design`: Ponderador base / de diseño inicial ($1/pi_{total}$).
- `prob_respuesta` e `inv_no_respuesta`: Ajuste por propensión a la respuesta.
- `weight_no_respuesta`: Ponderador ajustado por no respuesta ($weight_design \times inv_no_respuesta$).
- `weight_calibrate`: Ponderador final de calibración.

Bases exportadas con éxito en la carpeta `Outputs/`:

- `muestra_estudiantes_3_calibrada.csv` / `.rds` (n = 5230 , cols = 85)
- `muestra_estudiantes_6_calibrada.csv` / `.rds` (n = 5026 , cols = 85)

8. Muestra EJAYAM

8.1 Introducción

El objetivo es realizar una muestra de los estudiantes jóvenes, adultos y adultos mayores (EJAYAM) que asisten, en 2026, a establecimientos de dependencia oficial en la provincia de Buenos Aires. Como se verá a continuación, esta aplicación es interesante porque, entre otras cuestiones:

- Tensiona la percepción de los dominios de estimación como sinónimos de los estratos de una muestra.
- En parte relacionado con el punto anterior, se verá de forma explícita las virtudes de distinguir entre los objetivos o fines de la muestra con los modos o medios para cumplir con ellos.
- Por último, se verá que, al menos al principio o *a priori* (y con las limitaciones propias del que esto escribe) no queda claro que «medios» son los más óptimos para conseguir los «fines» propuestos.

El presente diseño muestral, a diferencia de Sec. 6.2, no tiene que ser compatible o mejorar en algunos puntos específicos de un diseño muestral anterior. Por otro lado, en este caso sí hay exigencias o restricciones específicas en cuanto a la precisión estadística del resultado esperado sobre diferentes dominios de estimación.

En otras situaciones relativamente similares, esas exigencias/restricciones se explicitan o se traducen en términos de costo operativo o económico del estilo «Nosotros podemos/queremos una muestra de X casos» o «Recolectar tal tipo de caso nos cuesta más que tal u otro así que, en lo posible, tenga eso en cuenta dentro del diseño». Si bien no se trata de una investigación que se espera realizar de manera virtual (lo que haría que su coste fuera muy marginal) se trata de una investigación en donde la organización posee una capacidad destacable para acceder a los diferentes establecimientos educativos aunque su capacidad para acceder a los estudiantes sea algo menor. Veremos que estos detalles serán importantes para definir algunos puntos particulares del diseño muestral.

En cualquier caso, en el diseño de una muestra siempre es importante distinguir cuáles son los objetivos, cuáles son las restricciones y cuáles son los márgenes de maniobra para obtener una solución relativamente óptima al problema (Valliant et al., 2018, Capítulo 5).

El orden de presentación será el siguiente. Se comenzará enunciando los objetivos originales de la muestra (Sec. 8.2) lo que, a su turno, facilitará el proceso de delimitar la población objetivo (Sec. 8.3). Posteriormente, se presentará de manera exploratoria algunas características del marco muestral (Sec. 8.4). Todo lo anterior permitirá aportar información para estimar las dimensiones de los dominios de estimación, de manera posterior a una distinción semántica previa entre estos y los estratos (Sec. 8.5).

Dado los diferentes objetivos en danza se pasa a una sección en donde se analizan simulaciones que intentan visibilizar los efectos de los cambios de algunos parámetros claves de un diseño polietápico (Sec. 8.6). Finalmente, en la sección Sec. 8.7, se detalla el diseño finalmente ejecutado.

8.2 Objetivos

A diferencia de otras investigaciones, en la presente y solamente teniendo como contexto la información que se comunicó para el diseño de la muestra, no se sabe bien cuál es el objetivo de la investigación, aunque sí se tienen algunas precisiones para con los objetivos de la muestra. Esta distinción es importante porque algunas decisiones de diseño muestral son más óptimas cuando se tienen algunos objetivos específicos, pero también pueden producir un efecto de sobreadaptación (*overfitting*) si luego se quiere utilizar la muestra para fines diferentes a los originalmente previstos.

Expresado en el lenguaje clásico de los márgenes de error, como regla general se comunicó que la precisión de las inferencias sean con:

- Un nivel de confianza de 90%
- Una heterogeneidad para las proporciones de $P = 50$

Sin embargo, la complejidad de esta muestra es que, con estos supuestos de fondo, los márgenes de error que se piden son diversos para diferentes subpoblaciones que surgen o se construyen, en general,

mediante un cruce entre otras variables disponibles en el marco muestral. Algunos de esos cruces tienen la particularidad que implican variables que podrían considerarse como jerárquicas (p.e. Región y Distrito) lo que plantea sus problemas particulares (ver Sec. 8.5). Finalmente, en el pedido original se pide explícitamente poder hacer inferencias para:

- Establecimientos FINES a nivel de regiones agregadas con un margen de error del 5%.
- Establecimientos EPA y CENS se espera poder hacer inferencias a nivel de Gran Área con un margen de error del 3%.

Por otro lado, para otra serie de establecimientos se espera, dada su escasa presencia en la población, una recolección censal de los mismos. Por esta razón no habrá margen de error predeterminado para estos casos. Se incluyen en esta situación a:

- Establecimientos CEBAS
- Establecimientos EPA y FINES en situación de encierro.

Implícitamente, la idea que está por detrás de esto último es que, a para aquellos tipos de establecimientos que tienen una mayor incidencia en la población, se espera una mayor exigencia en cuanto a la precisión de la estimación, especialmente en términos de desagregaciones espaciales.

Por ahora no diremos algo más específico con referencia a los medios para lograr estos objetivos. La razón de esto es, justamente, distinguir los objetivos del estudio de los medios para lograrlos. Incluso los mismos objetivos se podrían expresar de manera alternativa basándose en el léxico del coeficiente de variación (*CV*) que puede considerarse como un error estándar relativo (Valliant et al., 2018, pág. 3). El cómo enunciar los objetivos de una muestra no algo banal. En efecto, suele haber diferencias entre las disciplinas a la hora de que pedirle a una muestra. Por ejemplo, en contextos epidemiológicos es usual hablar de *power requirements* aunque lo usual en las ciencias sociales es hablar sobre *precision goals* (Valliant et al., 2018, pág. 8). Más adelante veremos que esta distinción será pertinente para esta muestra.

8.3 Población objetivo

La población objetivo (*target population*) es la población a la cual se va a intentar realizar, explícitamente, las inferencias (totales o agregadas) con los análisis de los datos de la muestra. Por esta razón, es aconsejable pensarla y mantenerla firme en mente durante el diseño de la muestra, para entre otras cuestiones, anticipar potenciales divergencias con otros tipos de poblaciones como, por ejemplo, el marco muestral o la población efectivamente muestrada (Kish, 1987, pág. 30).

En este contexto, más allá que se cuente previamente o se construya especialmente para la ocasión, siempre es importante saber el origen del marco muestral. La indagación sobre este punto infoma sobre las posibles divergencias entre la población objetivo y el marco muestral. En este sentido, no es lo mismo que el marco muestral deje afuera algo deseado, pero impráctico de obtener que, por otro lado, algo que si bien desde lejos parecía cercano a la población objetivo, luego se prefirió no incluir. En el primer caso, se mantiene la definición intensiva de la población objetivo, pero se restringue la extensión empírica del marco muestral creando una distancia entre uno y otro (p.e problemas de cobertura). En el segundo caso, lo que se cambia/ajusta es la definición misma de la población objetivo y se evita una distancia entre lo deseado/buscado y lo realizable con el marco muestral disponible.

Aplicado lo anterior al presente problema, una cuestión a discernir es el nivel de población objetivo. En este caso, más allá que la parte del león de un diseño como el presente se le lleve como seleccionar a los establecimientos, el objetivo (de ahí lo de población objetivo) es obtener una muestra de los estudiantes **adultos** de nivel primario y secundario de la provincia de Buenos Aires.

Sin embargo, como se observa en Tabla 8.1, existen una serie de establecimientos (y por ende, sus estudiantes) de educación de jóvenes y adultos que, a pesar de ser establecimientos de estudiantes adultos, quedan por fuera de la población objetivo de esta muestra. Más concretamente, existe un 19% que no posee todas las características necesarias.

Tabla 8.1: Población objetivo dentro del universo de establecimiento de educación adulta de la provincia de Buenos Aires

Característica	N = 3.958
Población Objetivo, n (%)	
SI	3.211 (81%)
NO	747 (19%)

Entre las características que se tuvieron en cuenta se encuentran en la confección de la población objetivo se encuentra la dependencia y el tipo de establecimiento. Como se observa en Tabla 8.2 todos los establecimientos de la población objetivo son de dependencia oficial. Dada que la presencia de otros tipos de dependencia en la educación adulta es muy baja, este criterio no parece ser muy crítico desde un punto de vista empírico.


Sin embargo, esto no significa que todos los establecimientos de dependencia oficial de educación de adultos pertenecen a la población objetivo. En efecto, existe un 19% de estos que no pertenecen a la población objetivo. Dentro del nivel primario, se trata de los establecimientos CEPA (671) y los centros de alfabetización (45) y dentro del nivel secundario se trata de aquellos establecimientos denominados «Escuelas de educación media o secundaria». Los que sí entran a la población objetivo, siempre que sean de dependencia oficial, son los establecimientos FINES, los CENS, los EPA y los CEBAS.

Tabla 8.2: Distribución de tipos de establecimiento de educación adulta

Característica	Población Objetivo		
	Total N = 3.958	NO N = 747	SI N = 3.211
Tipo de establecimiento, n (%)			
FINES	2.319 (100%)	0 (0%)	2.319 (100%)
NULL	747 (100%)	747 (100%)	0 (0%)
CENS	534 (100%)	0 (0%)	534 (100%)
EPA	338 (100%)	0 (0%)	338 (100%)
CEBAS	20 (100%)	0 (0%)	20 (100%)
Dependencia, n (%)			
Oficial	3.930 (100%)	719 (18%)	3.211 (82%)
Privada	23 (100%)	23 (100%)	0 (0%)
Nacional	3 (100%)	3 (100%)	0 (0%)
Municipal	2 (100%)	2 (100%)	0 (0%)

En la Figura 8.1 se intenta sintetizar parte de los comentarios anteriores. Esta contiene el agregado, no menor desde lo institucional (pero menos importante para el diseño muestral), de la distinción dentro del nivel secundario entre la oferta institucional (CENS y CEBAS) y la oferta extrainstitucional (FINES).

Figura 8.1: Establecimientos de educación adulta y población objetivo



8.4 Marco muestral

Una vez definida la población objetivo comenzamos a trabajar para mejorar el marco muestral recibido. Decimos que comenzamos a «mejorar» porque, por suerte, ya tenemos un marco muestral básico que nos permite identificar a las unidades de selección primarias (*PSU* en inglés). Decimos «por suerte» porque una característica particularmente interesante de trabajar en grandes organizaciones, que no es lo usual por fuera de ellas, es la posibilidad de trabajar con un marco muestral (*sampling frame*) que se ajuste bastante bien a la población objetivo (*population target*). Por ejemplo, en una universidad o colegio podemos tener un listado de estudiantes relativamente actualizado. En este caso, el marco muestral es a nivel de los establecimientos y está equipado con información auxiliar que se usará explícitamente en el diseño muestral.

En cambio, en otro tipo de investigaciones, los investigadores suelen dedicar un tiempo considerable a conseguir un marco muestral que o bien sobrerrepresente o subrepresente empíricamente a la población objetivo. Cabe recordar que el marco muestral no es solo una lista de elementos a seleccionar, sino que también debe contar con alguna información que ayude a su contacto/localización. Tener una lista de DNI para cada uno de los miembros del marco muestral de personas es una ayuda, pero no es muy útil si esa información no viene anexada con algún dato que permita contactar/localizar a los DNI efectivamente seleccionados en la muestra.

Antes anticipamos dijimos el marco muestral básico con el que vamos a trabajar nos permite identificar a las unidades de selección primarias. En otras palabras, vamos a trabajar con un listado de establecimientos y no de estudiantes y vamos a desarrollar un muestreo polietápico en donde en primera instancia (de ahí lo de unidades «primarias») se seleccionan establecimientos y recién luego se seleccionan secciones y/o estudiantes.

Para la selección de las unidades de selección, existen dos tipos generales de marcos muestrales: directos e indirectos (Valliant et al., 2018, pág. 6). Los marcos muestrales que contienen una lista de las unidades de observación finales se denominan **marcos directos**. Estos marcos facilitan/permiten los diseños de una sola etapa. Por ejemplo, si se tiene una lista de estudiantes y algún contacto virtual (p.e. mail), se puede perfectamente realizar un diseño en una sola etapa. En ese caso, no será necesario seleccionar primero a unidades de selección primarias como, por ejemplo, los establecimientos educativos.

Los **marcos indirectos**, en cambio, requieren de mucha menor información, se pueden construir con datos agregados y permiten realizar la selección de las unidades de selección primarias (*clusters* o conglomerados). Este tipo de marcos se utilizan típicamente en diseños polietápicos. En cambio, los marcos

directos se pueden usar tanto en diseños de una sola etapa o, vía agregación de su información, en diseños polietápicos.

Volviendo a nuestro marco muestral el mismo es del tipo **indirecto** y, suponemos, que es de una muy buena calidad en términos de su ajuste a la población objetivo. La posibilidad de contar con información auxiliar sobre cada uno de los establecimientos, que a continuación comenzaremos a explorar, permite la realización de una serie de diseños que de otra manera serían inviables de llevar a la práctica.

Como vemos en la Tabla 8.3 tenemos información auxiliar a nivel de cada establecimiento tanto de variables discretas como continuas:

Variables **discretas**:

- Distrito
- Región
- Región Agrupada
- Ámbito
- Área
- Nivel
- Tipo de establecimiento
- Condición de encierro

Variables **continuas**:

- Matrícula
- Secciones
- Media de estudiantes por sección
- índice de vulnerabilidad socioeconómico - IVSE

[illegible][illegible]

Para tener una idea de las distribuciones de estas variables vamos a realizar un análisis exploratorio de las mismas. Para esto, vamos a realizar un análisis descriptivo de cada una de las variables discretas y continuas tanto a nivel de la población de establecimientos como a nivel de la población (sintética) de los estudiantes. Para las variables discretas vamos a mostrar su distribución en términos de tablas de frecuencias y porcentajes. Para las variables continuas, vamos a mostrar su distribución a través de histogramas o gráficos de densidad.

Como puede observarse en Tabla 8.4, de las 25 regiones, algunas poseen menos del 1% de los estudiantes (p.e. 16, 17, 21, 23). Estas regiones son buenas candidatas para agruparse con otras regiones para facilitar la estimación en subpoblaciones espaciales. Eso es lo que se hace con la variable «Región agrupada» que logra el modesto avance de que las regiones más pequeñas en términos de estudiantes sean la 13 (1.4%) y la 20 (1.6%).

Para lo que respecta a los dominios de estimación (Sec. 8.5) la agregación de «Gran Área» no parece mostrar una agrupación muy desbalanceada (58% vs. 42%). Esto asegura, en la práctica, que con una buena representación de la variable «Región Agrupada» en el camino también se obtiene una aceptable distribución de la variable «Gran Área».

En cuanto a la variable «Tipo de establecimiento» se observa la siguiente distribución. La situación más problemática parece ser los CEBAS que poseen menos del 1% de los estudiantes. A diferencia que con las regiones, con los tipos de establecimientos no es posible una agregación mayor.

En cuanto a los niveles tampoco parece haber mayores problemas aunque, estrictamente, esta variable no está incluida dentro de los dominios de estimación.

Tabla 8.4: Comparación exploratorio del marco muestral. Nivel establecimiento y nivel estudiantes

Característica	Establecimientos N = 3.211	Estudiantes N = 205.828
Región, n (%)		
01	242 (7,5%)	15.254 (7,4%)
02	271 (8,4%)	17.390 (8,4%)
03	360 (11%)	21.093 (10%)
04	255 (7,9%)	18.473 (9,0%)
05	274 (8,5%)	19.053 (9,3%)
06	103 (3,2%)	8.160 (4,0%)
07	144 (4,5%)	9.111 (4,4%)
08	190 (5,9%)	12.278 (6,0%)
09	175 (5,5%)	14.346 (7,0%)
10	158 (4,9%)	8.786 (4,3%)
11	152 (4,7%)	11.207 (5,4%)
12	77 (2,4%)	4.859 (2,4%)
13	52 (1,6%)	2.869 (1,4%)
14	61 (1,9%)	3.753 (1,8%)
15	51 (1,6%)	2.636 (1,3%)
16	35 (1,1%)	1.599 (0,8%)
17	33 (1,0%)	1.521 (0,7%)
18	82 (2,6%)	4.177 (2,0%)
19	183 (5,7%)	9.848 (4,8%)
20	74 (2,3%)	3.355 (1,6%)
21	42 (1,3%)	1.898 (0,9%)
22	69 (2,1%)	4.936 (2,4%)
23	38 (1,2%)	1.616 (0,8%)
24	32 (1,0%)	2.352 (1,1%)
25	58 (1,8%)	5.258 (2,6%)
Región Agrupada, n (%)		
01	242 (7,5%)	15.254 (7,4%)
02	271 (8,4%)	17.390 (8,4%)
03	360 (11%)	21.093 (10%)
04	255 (7,9%)	18.473 (9,0%)
05	274 (8,5%)	19.053 (9,3%)
06	103 (3,2%)	8.160 (4,0%)
07	144 (4,5%)	9.111 (4,4%)
08	190 (5,9%)	12.278 (6,0%)
09	175 (5,5%)	14.346 (7,0%)
10	158 (4,9%)	8.786 (4,3%)
11	152 (4,7%)	11.207 (5,4%)
12	77 (2,4%)	4.859 (2,4%)
13	52 (1,6%)	2.869 (1,4%)
14	61 (1,9%)	3.753 (1,8%)
15	51 (1,6%)	2.636 (1,3%)
16	35 (1,1%)	1.599 (0,8%)
17	33 (1,0%)	1.521 (0,7%)
18	82 (2,6%)	4.177 (2,0%)
19	183 (5,7%)	9.848 (4,8%)
20	74 (2,3%)	3.355 (1,6%)
21	42 (1,3%)	1.898 (0,9%)
22	69 (2,1%)	4.936 (2,4%)
23	38 (1,2%)	1.616 (0,8%)
24	32 (1,0%)	2.352 (1,1%)
25	58 (1,8%)	5.258 (2,6%)
Estudiante por sección, Me- diana (IQR)	0,4 (0,3-0,5)	0,1 (0,0-0,3)

Figura 8.2: Comparación exploratorio del marco muestral. Nivel establecimiento (1 fila) y nivel estudiantes (2 fila)




Figura 8.3: Mapa según distrito. Color según matrícula.

Porcentaje de matrícula por distrito






Figura 8.4: Mapa según regiones. Color según matrícula.

Porcentaje de matrícula por región



Por último, antes de pasar a la siguiente sección, analizaremos la relación entre la cantidad de secciones y el tamaño de los establecimientos. Esto nos puede anticipar una idea de como se comportarían diferentes diseños muestrales en función de como seleccionen o censan a las secciones de cada establecimiento seleccionado en la primera etapa.

Figura 8.5: Relación entre el tamaño de la matrícula y la cantidad de secciones de los establecimientos



Fuente: Elaboración propia basada en marco muestral

8.5 Dominios de estimación

Muchas veces el concepto de **estrato** se confunde con el de **dominio de estimación**. Parte de esta confusión tiene su origen que en muchas investigaciones ambos conceptos son coextensivos. Sin embargo, para parte de la bibliografía, se trata de dos conceptos con significados diferentes. El estrato es más una herramienta, en especial en comparación para con el azar simple, para mejorar la precisión de las estimaciones y/o controlar el tamaño muestral de los dominios de estimación (Kish, 1965, pág. 76-77). En cambio, el dominio de estimación tiene más que ver con los objetivos que se espera que la muestra estime de la población. En otras palabras, el primero es un medio (entre otros) y el segundo un fin (entre otros). El problema es que, usualmente, en el contexto de tener como objetivos varios dominios de estimación, es un buen medio crear un estrato para cada uno de ellos (Tillé, 2020, pág. 79). En efecto, como señala Valliant y *cía*, una pregunta sumamente legítima es «¿Si los dominios serán importantes para el análisis, por qué no hacer que cada dominio sea un estrato de diseño y que entonces el tamaño muestral de cada uno pueda ser controlado?» (Valliant et al., 2018, pág. 70). La respuesta es que algunas veces el muestreo estratificado no es la mejor respuesta y lo difícil es saber o anticipar cuando hay otras mejores opciones.

Dado que parte de la confusión tiene que ver por su gran coextensión puede ser útil pensar en situaciones en donde estos conceptos no sean, justamente, coextensivos. Por un lado, puede que el dominio de estimación sea la propia población total (como algo diferente a alguna subpoblación de ella). En ese caso se puede construir estratos para realizar un diseño estratificado simplemente porque este diseño, al menos en comparación con el azar simple, es más eficiente. En este ejemplo hay estratos y no hay dominios de estimación como subpoblaciones. En cualquier caso, lo importante es que en este ejemplo hay más estratos que dominios de estimación y, por lo tanto, en este ejemplo ambos conceptos no serían coextensivos.

Otro ejemplo podría ser donde efectivamente sí haya varios dominios de estimación, esto es, se desea realizar inferencias para diversas subpoblaciones, pero no se realice un diseño estratificado. Para muchos este ejemplo puede resultar forzado porque suponen que se trata de un ejemplo ficticio en donde se asume cierta ignorancia del diseñador de la muestra. El supuesto por detrás de esta opinión es que si bien puede ser realizable la combinación que propone el ejemplo, la misma se encuentra fuera lo óptimo y de ahí que se considere como un caso forzado. Sin embargo, esto no siempre es así. Puede que existan algunos casos en donde se requiera múltiples dominios de estimación y donde el mejor medio para ese fin no sea la construcción de múltiples estratos. Diseños como el balanceado o el bien distribuido (Sec. 4.1) no necesitan, explícitamente, la construcción de estratos y puede, en algunos casos, ser más aconsejables que un diseño estratificado.

Dejando las similitudes extensivas y volviendo a las diferencias intensivas o de sentido entre ambos conceptos, los dominios de estimación son partes de la población para los cuales diferentes estimaciones son planificadas en el diseño muestral (Kish, 1965, pág. 77). Estas suelen tener como referentes a la propia población y no a una muestra de la misma (Kish, 1987, pág. 34). Esto no quiere decir que todo dominio de estimación tenga como objetivo estimar un valor de toda la población. Claro que es posible (y usual) tener dominios de estimación que impliquen alguna subdivisión de la población o, de forma más precisa, alguna subpoblación. Lo que quiere afirmar Kish es que esa subpoblación tiene como referente a la población y no a la muestra.

Muchas veces los dominios de estimación se estipulan en función de criterios administrativos/políticos. Usualmente, este es el caso de los dominios distritales o regionales. Esta distinción, muchas veces (pero no siempre) puede también implicar similitudes y diferencias sociales por detrás. Si esto es así, estamos en presencia de buenos candidatos para que esos dominios también se consideren como estratos, dado que su construcción agrupará casos relativamente más similares entre sí que si se hubieran elegido al azar dentro de toda la población. El punto crítico de la afirmación anterior es el «pero no siempre» que, nuevamente, habilita la distinción entre dominios de estimación y estratos. Para poner un ejemplo, los distritos de General Pueyrredón y Bahía Blanca son distritos que contienen tanto población urbana como rural dentro de sus límites. En efecto, cada uno de ellos contiene una gran ciudad en su interior con su respectivo conurbano. En otras palabras, es clara su utilización como dominio de estimación, pero no es clara la utilización de esos casos, en términos de asegurar una menor heterogeneidad de alguna variable de interés, dentro de un estrato denominado como «Interior» como algo diferente a «AMBA».

En cualquier caso, la explicitación de los dominios de estimación en conjunción con alguna otra preferencia (en este caso la preferencia sobre determinados niveles de precisión de esas estimaciones), funciona como variables críticas a la hora de decidir sobre el combo de diseño y tamaño muestral (Kish, 1965, Capítulo 8). En muchas situaciones es útil representar estas descripciones como objetivos y restricciones dentro de un problema de optimización multicriterio (Valliant et al., 2018, Capítulo 5).

8.5.1 Dominios de estimación originales

A continuación, en la Tabla 8.5, se explicita los dominios de estimación. En general parecen ser una combinación de cuestiones de tipo de oferta educativa y diferentes agrupaciones espaciales. En total son 26 dominios de estimación que se encuentran ordenadas en función del porcentaje de establecimientos. Como regla general, para los dominios espaciales se espera un margen de error de:

- 5 pp. para los análisis a nivel de Región Agregada
- 3 pp. para los análisis a nivel de Gran Área

Tabla 8.5: Comparacion dominios de estimación. Nivel establecimientos y nivel estudiantes.

Característica	Establecimientos N = 3.211	Estudiantes N = 205.828
Dominio, n (%)		
CENS_AMBA	330 (10%)	51.175 (25%)
FINES_R03	289 (9,0%)	11.126 (5,4%)
FINES_R05	223 (6,9%)	11.546 (5,6%)
FINES_R04	200 (6,2%)	7.498 (3,6%)
EPA_AMBA	198 (6,2%)	24.834 (12%)
FINES_R02	194 (6,0%)	6.113 (3,0%)
FINES_R01	175 (5,5%)	4.816 (2,3%)
CENS_INTERIOR	165 (5,1%)	19.658 (9,6%)
FINES_R19	144 (4,5%)	4.602 (2,2%)
FINES_R10	132 (4,1%)	3.532 (1,7%)
FINES_R08	129 (4,0%)	4.690 (2,3%)
FINES_R09	121 (3,8%)	5.148 (2,5%)
FINES_R15172425	112 (3,5%)	2.800 (1,4%)
FINES_R11	111 (3,5%)	5.110 (2,5%)
FINES_R16212223	105 (3,3%)	2.448 (1,2%)
EPA_INTERIOR	97 (3,0%)	7.654 (3,7%)
FINES_R07	95 (3,0%)	2.934 (1,4%)
FINES_R06	58 (1,8%)	1.915 (0,9%)
FINES_R18	56 (1,7%)	2.074 (1,0%)
FINES_R20	50 (1,6%)	1.584 (0,8%)
FINES_R12	49 (1,5%)	1.568 (0,8%)
ECE-EPA_UNICO	43 (1,3%)	8.677 (4,2%)
ECE-CENS_UNICO	39 (1,2%)	9.960 (4,8%)
FINES_R14	39 (1,2%)	1.293 (0,6%)
FINES_R13	37 (1,2%)	1.483 (0,7%)
CEBAS_UNICO	20 (0,6%)	1.590 (0,8%)

La Tabla 8.5 está también coloreada en función de la cantidad o porcentaje de cada columna. Esto sirve para percibir, entre otras cuestiones, los cambios de distribuciones a nivel de establecimientos en comparación con el nivel de los estudiantes. Dado que estos dominios son, en principio disyuntos o mutuamente excluyentes (aunque más adelante veremos que esto se puede relajar por la relación jerárquica de algunas variables) es claro que esto tensiona en demasía al diseño muestral. Si todos estos dominios tuvieran un mismo peso en la población estaríamos hablando de dominios que no superarían, en promedio, el 4% (100/26) en la población. En la práctica, a nivel de los establecimientos tenemos más de 18 dominios por debajo del 5%. Ese número sube a más de 20 dominios en el nivel de los estudiantes.

Esto último sucede porque a nivel de los estudiantes existe una mayor variabilidad en la distribución de los dominios. Por ejemplo, los CENS de AMBA concentran el 25% de los estudiantes (con el 10% de los establecimientos) y los EPA de AMBA concentran al 12% (con el 6% de los establecimientos).

También puede observarse que, como regla general, los establecimientos FINES poseen un menor tamaño o matrícula de los establecimientos. Inversamente, los CENS y EPA, incluso los de condición de encierro, poseen una media de estudiantes mayor a los FINES y por eso aumentan su porcentaje a nivel de estudiantes.

8.5.2 Comentarios sobre los dominios

Más allá de lo expresado explícitamente en la sección anterior, es pertinente realizar las siguientes aclaraciones. En este diseño muestral en particular, los dominios de estimación se pueden interpretar como una combinación de variables categóricas o discretas, pero con la característica que dos de ellas son variables que se encuentran jerárquicamente relacionadas. Otra complejidad relacionada es que no se espera la misma precisión para todos los dominios (Sec. 8.2). Nos explicamos.

Las variables que se han tenido en cuenta en los dominios de estimación son:

- El tipo de organización (EPA, CEBAS, CENS, FINES)
- Condición de Encierro (SI, NO)
- La Región Agrupada (19 regiones)
- Gran Área (AMBA, INTERIOR)

Se puede discutir, quizá de modo bizantino, si estas 4 «variables» son diferentes o algunas son agrupaciones (p.e. Gran Área) de otra variable más desagregada (p.e. Regiones Agrupada) o si es mejor entender algunas de ellas (p.e. Condición de encierro) como una condición previa que, luego de cruzarlos con los diferentes tipos de organización (p.e. CENS o EPA), produce una nueva variable que se podría denominar «Tipo de establecimiento» (p.e. ECE-CENS o ECE-EPA).

Con respecto a la relación entre «Gran Área» y «Regiones Agrupadas» nos inclinamos por afirmar que se tratan de dos variables jerárquicas porque «Gran Área» se puede considerar como una mayor agregación de la propia agrupación de regiones. Claramente, más allá de su posible relación con un centro de decisión política/administrativa, ambas se relacionan con cuestiones espaciales y, por lo tanto, también pueden suponerse como una agrupación particular de las 25 regiones y estas, a su turno, como una agregación de los distritos. Esta situación jerárquica no es menor porque la variable distrito también se encuentra disponible en el marco muestral.¹⁸

La cuestión de la **jerarquía de las variables** es importante en el diseño muestral por lo siguiente. En principio, si se obtiene una muestra balanceada a nivel de los distritos, esta también, de forma necesaria, lo será a nivel de las regiones, de las regiones agrupadas y de las grandes áreas. El camino inverso es probable pero nada seguro. Una muestra balanceada a nivel de las grandes áreas tiene chances de serlo para niveles inferiores, pero no existe ninguna seguridad. Pongamos un ejemplo para que se entienda mejor el problema. Supongamos que priorizamos el objetivo de tener una buena estimación a nivel de Gran Área y establecimientos EPA. Podría ser el caso que casi todos los establecimientos seleccionados en la categoría «AMBA» caigan en el distrito de «La Matanza» lo que desbalancea la muestra a nivel región y distrito. Esto no implica que la estimación «Gran Área - EPA» tenga algún problema en particular, pero sí implica que en el diseño de la muestra no se hace nada en particular para evitar los desbalances a nivel de región y distrito. Por esta razón, la existencia de variables jerárquicas en los dominios de estimación permite, vía una estrategia «*botton-up*», una selección de establecimientos que, al tiempo que cumple los

¹⁸Cabe destacar que algunas construcciones de la variable «Gran Área» no son simplemente una agregación de regiones sino, más específicamente, solo una agregación de distritos. Por ejemplo, a veces se utiliza el criterio que algunos distritos de la Región 5 pertenecen a la categoría AMBA (p.e. Almirante Brown) y otros pertenecen a la categoría «Interior» (p.e. San Vicente). En este caso, como se trata de una agregación explícita de regiones, la variable «Gran Área» puede considerarse como una variable jerárquica de distrito y también de regiones.

requisitos que exigen los dominios de estimación, también la hacen robusta a otros niveles y, de manera derivada, para responder otras preguntas de investigación diferentes a las originales.

8.5.3 Dominios en el espacio

En parte por los comentarios sobre la relación jerárquica de los dominios, a continuación vamos a realizar una serie de mapas para que estos nos ayuden a visualizar las diferentes zonas espaciales en función del tipo de organización. Estrictamente, los dominios de estimación anteriores vinieron ya contruidos en una columna que se llamaban «estrato_oferta». Ahora nos va a interesar su visualización espacial a un nivel levemente más agregado, ya que se trata de usar otra variable que tiene que con el «tipo de organización».

De esta manera, esperamos observar, de un modo diferente a la Tabla 8.5 como se distribuyen los diferentes tipos de establecimientos educativos a lo largo de las diferentes agrupaciones espaciales.

Ahora haremos lo mismo, pero a nivel de «Gran Área».

Lo importante de los mapas anteriores es la visualización de distribuciones extremas en el espacio. Lo importante es destacar tanto las áreas que acumulen una excesiva porción de los casos como, de manera inversa, aquellas en donde casi no existan casos.

8.6 Alternativas muestrales

Para cumplir con lo anterior, no parece haber muchas dudas de que es necesario la realización de un **muestreo polietápico** en donde en una primera etapa seleccione a los establecimientos y luego a los estudiantes que concurren a ellos. La principal justificación de esta afirmación es que se desea estimar algunas características de los estudiantes y no se tiene un marco muestral de los mismos, aunque sí de sus establecimientos. En algunos diseños específicos podrá quedar la duda sobre como tratar a las secciones de cada establecimiento o si esa acción se debe considerar como una «etapa» más en el diseño muestral.

Por otro lado, dado que seguramente se querrán hacer afirmaciones tanto a nivel de los estudiantes como también, mediante alguna agregación de los resultados, a nivel de los establecimientos, parece conveniente utilizar un muestreo **PPS**. Este tipo de diseño es particularmente robusto cuando se piensa realizar inferencias a ambos niveles (Kish, 1965, Capítulo 7; Kish, 1965, pág. 422).

Tampoco parece haber muchas dudas acerca de la relativa utilidad de evitar la proporcionalidad a ultranza. Esto parece claro dado que, como se observó en la sección Sec. 8.5, existen algunos dominios de estimación sumamente pequeños en la población. En esos casos parece razonable la realización de un cuasi censo de algunos tipos de establecimientos y/o estudiantes según el caso y de no respetar una proporcionalidad exacta para el resto.

Sin embargo, las dudas comienzan a aparecer en otros aspectos del diseño muestral. Por ejemplo:

- ¿Cuánto se prioriza la precisión de los estimadores de las medias (p.e. media provincial del IVSE) y cuanto la precisión de los dominios de estimación explicitados con todos son cruces de variables (p.e. Región y Tipo de establecimiento)? A igual cantidad de casos totales, un diseño que prioriza la precisión los dominios de estimación pequeños (p.e. *power allocation* (Bankier, 1988)) reduce la precisión de los estimadores totales porque aumenta la variabilidad de los ponderadores. En cambio, si se valoran más los estimadores totales, existen diseños que lo logran a cambio de no necesariamente aumentar la cantidad de casos en los dominios más pequeños (p.e. a la Neyman (Neyman, 1934)). En palabras de Kish:

«Un muestreo proporcional es usualmente preferido para las medias generales...cuando los tamaños de los dominios N_h son aproximadamente iguales, no existe conflicto entre los objetivos de diseñar para la población y para los dominios» (Kish, 1965, p. pág.97)

Un consejo que señala Kish para aminorar este problema es rectificar los dominios en tamaños aproximadamente similares. Esto es lo que precisamente parece haber hecho la Subsecretaría de Planeamiento previamente al trabajar con regiones agrupadas o, en su defecto, con grandes áreas. Sin embargo, el problema está lejos de resolverse porque las regiones agrupadas siguen siendo muchas y la proporción de los tipos de establecimientos también están lejos de ser similares en tamaños.

- ¿Cuántos establecimientos seleccionar y cuantos estudiantes por cada establecimiento? A igualdad de condiciones es claro que, por ejemplo, para una muestra de 10.000 estudiantes no es lo mismo seleccionar a 5 estudiantes de 2000 establecimientos que 10 de 1000, 15 de 666 o 20 de 500. En cada situación de las anteriores, aun sin haberse medido de forma empírica, se puede anticipar que la influencia de la varianza intercluster (R_{ho}) será diferente. Menor en los primeros y mayor en los últimos. Por otro lado,

dado que se trata de una población de algo más de 3000 establecimientos el impacto del *fpc* (*finite population correction*) en la primera etapa cambia fuertemente en función de que se elijan 500, 1000 o 2000 establecimientos. De manera formal, la subsecretaría ha informado que, a pesar de contar con cierta capacidad territorial para ejecutar la muestra, se valora positivamente ir a menos establecimientos y compensar la pérdida de precisión vía una mayor cantidad de encuestados en cada uno de ellos. Este pedido parece ser específicamente más fuerte para los establecimientos EPA y CENS, que, por otro lado, son establecimientos con una matrícula, en promedio, mayor a los FINES.

- ¿Se tiene que seleccionar una cantidad fija de estudiantes para todos los establecimientos seleccionados en la primera etapa? Si nos alejamos de una misma cantidad de estudiantes por establecimiento seleccionado nos alejamos de unos de los beneficios más preciados de un muestreo PPS que es la posibilidad de una muestra autoponderada y su robustez para hacer inferencias al nivel tanto de los establecimientos y como al nivel de los estudiantes. Dado que algunos dominios de estimación ya implican, sin mucha duda, un tratamiento casi censal, es claro que de todas formas para el momento de los análisis se iban a utilizar algunos ponderadores (como algo diferente a los expansores). En este contexto, la duda es ¿Cuánto usar el mecanismo de la asignación no proporcional en las demás situaciones en donde se pensaba hacer una muestra (más que un censo)? Se aclara que, si los establecimientos se consideran las unidades primarias de selección, seleccionar x cantidad de estudiantes en **todas las secciones** de los establecimientos seleccionados rompe automáticamente la autoponderación del PPS. Esto aumenta la varianza de las estimaciones e inclina la balanza, a la hora de volver a reducir esa varianza a utilizar herramientas vinculadas a la escuela del *model based* (p.e. calibración) alejándose del *desing based*.
- Por último, entre las especificaciones se indicaba que se debía hacer un muestreo sistemático luego de haber ordenado por la variable IVSE. Esto parece más un consejo de medios más que de fines, pero invita a pensar el porqué de esa decisión y esto, a su turno, puede ayudar a entender algún fin latente no explicitado. Dentro de la bibliografía, esta estrategia suele denominarse «estratificación implícita», ya que esa ordenación previa con la respectiva selección posterior sistemática es una manera simple de generar «estratos» como resultado, usando información contenida en una variable continua (Cochran, 1977, pág. 205; Valliant et al., 2018, pág. 63). Creemos que existen en la actualidad medios más explícitos y eficientes para incorporar información cuantitativa en el diseño con el fin de aumentar la precisión de las estimaciones que es uno de los objetivos típicos de la estratificación.

Dada una respuesta clara para las preguntas anteriores, no suele ser un mayor problema a cuales establecimientos se debe seleccionar. Sin embargo, es difícil anticipar una rápida respuesta a estas preguntas porque los niveles de precisión finalmente alcanzados por las diferentes alternativas varían, entre otros factores, por la *efectiva* varianza entre los establecimientos (R_{ho}) y por el efecto *fpc*. Esto, a su turno, modifican las precisiones de las estimaciones para un tamaño dado o, de manera alternativa, modifica los tamaños necesarios para así alcanzar la precisión deseada. Esta tensión se ve claramente ejemplificada en la siguiente afirmación de Kish:

«Antes de decidirnos por un muestreo desproporcionado, deberíamos hacer al menos una estimación aproximada de las varianzas de todos los elementos importantes, o de un subconjunto bien seleccionado. Si las diferentes respuestas apuntan al mismo diseño, no hay mayor problema. Pero si las respuestas son contradictorias, la elección requiere buen criterio y conocimientos teóricos que van más allá de este libro y, en gran medida, de los desarrollos teóricos existentes. Al decidir entre ellos, debemos tener en cuenta no solo la importancia relativa del elemento, sino también la importancia relativa de sus varianzas bajo diferentes diseños» (Kish, 1965, pág. 97).

Por estas razones, a las siguientes secciones vamos a realizar algunas simulaciones con el objetivo de poder decidir que diseño muestral es más idóneo para nuestro objetivo. Lamentablemente, al carecer de un marco muestral de estudiantes y no tener muy claro el objetivo sustantivo de la investigación, es difícil estimar algún componente de la varianza dentro de cada establecimiento. Sin embargo, sí será posible, con el marco muestral a nivel de los establecimientos, calcular la varianza para cada dominio de estimación. Dentro de las limitaciones/posibilidades de los datos disponibles surge un candidato como es el IVSE. El mismo sintetiza una serie de dimensiones sociales, está expresado de manera continua y no está presente en la definición de los dominios. En otras palabras, esperamos que este indicador nos ayude a decidir que diseño muestral realizar. La otra operación complementaria que vamos a realizar para facilitar la comparación de las simulaciones es trabajar con coeficientes de variación (CV) en vez de los márgenes de error (MOE).

8.6.1 Traducción de Margen de Error (MOE) a Coeficiente de Variación (CV)

El tamaño de una muestra no suele ser algo fácil de responder en un diseño con múltiples objetivos y estimadores (Valliant et al., 2018, pág. 26). Una situación similar es cuando no se sabe bien para qué finalmente se va a usar la muestra, pero no se duda que diferentes investigadores van a intentar contestar diversas preguntas de investigación con ella. Esto último es una de las razones por las cuales muchas veces es preferible expresar los objetivos estadísticos en términos de un coeficiente de variación (*CV*). Este es adimensional (no posee unidades) y puede usarse para comparar la relativa precisión de las estimaciones de diferentes tipos de cantidades o variables (Valliant et al., 2018, pág. 27). En otras palabras, nos permite comparar la precisión de las categorías de las variables discretas (como las categorías de género) con variables cuantitativas continuas (como la media de edad).

Las principales agencias oficiales de estadística (como el INDEC en Argentina, INEGI en México o Eurostat) suelen evaluar la calidad y la factibilidad de publicación de sus estimaciones a partir de los límites de sus *CV*: un $CV \leq 10\%$ se cataloga como una estimación de excelente precisión, mientras que estimaciones con un $CV > 20\%$ se consideran no publicables por su alta variabilidad. Más allá de lo estipulado convencionalmente aquí se va a intentar traducir los niveles de precisión expresados en *MOE* a *CV*.

Muchas veces suele solicitarse un determinado **Margen de Error absoluto** (*MdE*), asumiendo un escenario de máxima varianza para una proporción teórica ($p = 50\%$). Sin embargo, en comparación con el *CV* presenta **el peligro del error absoluto en proporciones pequeñas**. Si fijamos un margen de error absoluto del 3% (0,03) para medir un fenómeno de alta prevalencia en torno al 50%, el intervalo resultante (47% – 53%) es sumamente preciso. Pero si queremos estimar un fenómeno de baja prevalencia (por ejemplo, estudiantes de la modalidad con alguna condición socioeducativa o de salud particular que represente un 5%), un margen absoluto del 3% nos daría un intervalo de estimación de [2%, 8%]. En esos casos, el **error relativo** aumenta a niveles que suele afectar severamente la utilidad de esas estimaciones y esto es algo que suele visibilizar el *CV*. Al fijar un objetivo de *CV*, el error estándar se evalúa siempre en términos relativos ($CV = SE(\hat{p})/p$), lo que permite comunicar la calidad y precisión de la estimación sea robusta tanto para proporciones mayoritarias como para minoritarias.

Cabe recordar algo trivial que a veces pasa desapercibido. Cuando se especifica $P = 0.5$ se está pensando en algo más específico que una simple variable categórica o discreta. En efecto, a nivel de variables sería una variable binomial con solo dos valores: 1 y 0. A nivel de la categoría se trata de la vieja noción de atributo que se tiene o no se tiene. Las proporciones son las medias de los binomios (Kish, 1965, pág. 45). Una de las razones del uso extendido del $P = 0.5$ es que permite capturar el caso de mayor heterogeneidad de una manera sencilla. En cambio, cuando se trata de una variable continua, no hay tal convención acerca de como representar esa máxima heterogeneidad.

Para ser consistente con el pedido de precisión original (Nivel de confianza del 90%, $p = 50\%$ y márgenes de error de 3%, 4% y 5%) podemos establecer la siguiente equivalencia teórica.

El margen de error absoluto (*MOE*) se relaciona con el error estándar (*e*) de la siguiente manera:

$$MOE = e = z_{1-\alpha/2} \cdot SE(\hat{p})$$

y, por otro lado, el *CV* es:

$$CV = \frac{SE}{Media}$$

bajo un diseño de máxima varianza donde $p = 0,5$ y un nivel de confianza del 90% (con un valor crítico $z_{0,95} \approx 1,645$), la relación matemática para el *CV* es:

$$CV(\hat{p}) = \frac{SE(\hat{p})}{p} = \frac{MOE}{p \cdot z_{1-\alpha/2}} = \frac{MOE}{0,5 \cdot 1,645} \approx \frac{MOE}{0,8225} \quad (8.1)$$

Tabla 8.6: Traducción de MOE a CV

Equivalencia de Objetivos de Precisión

Conversión de Margen de Error Absoluto a Coeficiente de Variación (90% Confianza, $p=50\%$)

Dominio de Estimación	Margen de Error (MOE)	CV Objetivo
Gran Área	3.0%	3.65%
Región Agrup.	5.0%	6.08%

8.6.2 Cálculo del *Deff* y del *Ess*

Hecha las traducciones anteriores ahora vamos a pasar a estimar diferentes escenarios y su impacto en el *Deff* (*design effect*) y en el *Ess* (*effective size sample*). Estas son dos medidas sencillas, pero extremadamente útiles para expresar el efecto de usar *clusters* o conglomerados en las estimaciones de la encuesta (Kish, 1965). La existencia de *clusters* o conglomerados espaciales permite reducir los costos logísticos tanto en términos de transporte (especialmente en diseños presenciales) y reduce el costo de elaborar listas de direcciones/contactos de las unidades de selección finales (especialmente en diseños polietápicas). Mediante la combinación de ambos mecanismos, se reduce el costo unitario de realizar encuestas. A cambio, suele generar mayores varianzas para un tamaño de muestra determinado en comparación con una muestra de azar simple (Valliant et al., 2018, pág. 4).

Con base en la estrategia anterior de convertir los márgenes de error (*MOE*) en coeficientes de variación (*CV*), ahora vamos a pasar a modelar el *Deff* a partir de diferentes supuestos y escenarios. Si bien se hará un esfuerzo por utilizar información del marco muestral (p.e. IVSE), cabe recordar que el *Deff* real solo podrá ser calculado al final de la investigación. Su cálculo tiene la función instrumental de ayudar a decidir el diseño muestral *ex-ante* salida a campo (Kish, 1965, pág. 258). Zipf y Valliant afirman que se trata de un atajo (*shorcut*) (Zipf & Valliant, s. f.). La razón es que el *Deff* es **específico para cada estimador** que se quiera calcular por lo que, salvo que se quiera realizar un diseño complejo para estimar una sola variable del cual ya se sabe con certeza su varianza, desde un punto de vista estrictamente estadístico, solo de manera *ex-post* a la salida a campo se deberían calcular un *Deff* para cada estimación. Cuando decimos específico queremos decir que su valor es variable para diferentes estimadores dentro de un mismo diseño muestral. Esto último puede parecer algo no muy intuitivo dado que rara vez se publica esta información.

En este contexto, es pertinente recordar que el *Deff* posee algunas limitaciones. Si se calcula un *Deff* general para toda la muestra este puede ser algo diferentes en los casos en donde las varianzas difieren a través de los estratos, o en donde los subgrupos son seleccionados intencionalmente a diferentes porcentajes o donde diferentes subgrupos poseen diferentes tasas de respuesta. Hechas estas aclaraciones sobre el *Deff*, cable aclarar que se trata de un concepto muy intuitivo para captar que se pierde y que se gana con un diseño polietápico (versus un aleatorio simple), pero también sirve para comparar entre diferentes diseños polietápicos alternativos. Gracias a él, se entiende cuanto se gana en la **estratificación** cuando los elementos de cada estrato son homogéneos dentro de cada estrato, pero diferentes entre estratos (Kish, 1965, pág. 76). Del mismo modo, también es intuitivo para comprender que a mayor homogeneidad dentro de un **cluster o conglomerado** mayor aumento del *Deff* dado que los casos llegan a su saturación teórica más rápidamente. En otras palabras, se llega más rápido a la situación en donde cada nuevo caso marginal aporta información cada menos nueva y cada vez más redundante. Por esta razón, si se asume que los *cluster* son muy homogéneos en su interior, no es buena idea seleccionar muchos casos en cada uno de ellos, porque rápidamente parte de ellos se repetiran y comenzaran a aportar información redundante. De la misma manera, en una muestra polietápica por timbreo, y a igualdad de cantidad de casos totales, la precisión de las estimaciones mejora si se usan más puntos muestras y se encuestan menos personas en cada uno de ellos.

Expresado de modo alternativo, el *Deff* permite comprender los pros y contras de jugar el juego de cuantos casos más baratos (por estar más juntos espacialmente) estoy dispuesto a agregar para compensar, casi con seguridad, su peor eficiencia estadística (por ser más homogéneos entre sí). Lo anterior se complementa con cuanto se mejora por la estratificación. En este contexto, el *Deff* permite optimizar el tipo de diseño polietápico a seguir.

La definición típica del *Deff* es que el mismo es la razón de la varianza de un estimador en una muestra compleja sobre la varianza de ese mismo estimador en una muestra de muestreo simple (Kish, 1965, pág. 75). Una vez calculado el *Deff*, es posible calcular el *Ess*. Este último significa a cuántas personas de un muestreo aleatorio simple (perfecto e ideal) equivale realmente la muestra actual realizada con un diseño complejo. Este es útil, entre otras razones y especialmente en la década del 60', porque los cálculos necesarios para una muestra aleatoria simple son relativamente más fáciles de construir que los de una muestra compleja.

8.6.3 El Efecto del Diseño (*Deff*) y la Correlación Intracluster (ρ)

Como se ha analizado en la sección anterior, si los *clusters* (acá establecimientos) son muy homogéneos en su interior, no tiene sentido seleccionar muchos estudiantes por establecimiento porque estos nos aportarán información redundante. Esta homogeneidad interna se modela formalmente mediante la **Correlación Intracluster** (ρ o *ICC*) (Lumley, 2010, pág. 51):

- Si $\rho = 0$: Los estudiantes dentro de una misma escuela son tan heterogéneos como si los hubiéramos seleccionado al azar en toda la provincia. No hay «efecto de pertenencia escolar». Cada encuesta adicional nos aporta mucha información nueva.
- Si $\rho = 1$: Todos los estudiantes de una escuela son idénticos. Ir a encuestar al segundo, tercero o quinto estudiante de la misma escuela no nos aporta nada de información nueva.

En encuestas socioeducativas de perfil estudiantil en América Latina, el valor empírico de ρ suele oscilar entre 0,02 y 0,10 (Valliant et al., 2018, pág. 247; Grosh & Muñoz, 1996, pág. 58-59). Para nuestro diseño, utilizaremos un valor de $\rho = 0,1$, el cual representa una hipótesis conservadora, pero sumamente realista que nos protege de subestimar el error muestral.

Para estimar formalmente este incremento en la varianza del *Deff*, utilizamos la ecuación clásica de Kish (Kish, 1965, pág. 266):

$$deff = 1 + (b - 1)\rho \quad (8.2)$$

Donde b representa el tamaño del cluster. En este caso sería la cantidad de estudiantes seleccionados por escuela. Una opción que se puede tener en cuenta a la hora de indagar la diferencia intracluster es el valor del IVSE de cada establecimiento. Como cada establecimiento tiene un valor sería posible calcular esa diferencia intracluster con esa variable.

8.6.4 Alternativas de la segunda etapa para reducir el DEFF

El pedido original sugería relevar **todas las secciones** de cada escuela seleccionada. A pesar de que en este tipo de establecimientos de educación adulta parece haber pocos establecimientos con muchas secciones (Figura 8.2), esto puede generar que el número de estudiantes encuestados por escuela variara drásticamente. Esto tendría el efecto de afectar la preciada **autoponderación** de una muestra PPS, creando la necesidad tanto de construir ponderadores como de utilizarlos al momento del análisis. Por otro lado, esto incrementaría el tamaño medio de los estudiantes por cada cluster/establecimiento aumentando el parámetro (b) y, de ese modo, también aumentando el *deff* y requiriendo un tamaño de muestra (de estudiantes) total mayor (Ecuación (8.2)).

Para solucionar esto, una alternativa es rediseñar la segunda etapa del muestreo de la siguiente manera:

1. En cada escuela seleccionada en la primera etapa, **se sorteá, en primera instancia, una (1) sección** con probabilidad $1/B_i$, donde B_i es la cantidad de secciones de la sede i .

2. Dentro de esa sección sorteada, **se seleccionan exactamente 7 estudiantes** ($b = 7$). En algunos establecimientos se especificará que serán los primeros y en otros los últimos. En caso de que el tamaño de la sección sea igual o menor a 7 puede que se seleccione a todos los miembros de la sección y luego se complete los casos restantes con miembros de otra sección.

Al mantener el tamaño de cluster fijo y constante en $b = 7$ estudiantes para todas las escuelas, se logran dos ventajas metodológicas:

- Se evita aumentar la dispersión de los ponderadores
- **Minimizamos el Efecto del Diseño:** Al reducir el tamaño del cluster a solo 7 alumnos, el *deff* se reduce drásticamente:

$$deff = 1 + (7 - 1) \cdot 0,1 = 1 + 6 \cdot 0,1 = 1,6 \quad (8.3)$$

Un *deff* de 1,6 significa que se necesitan un 60% más de casos que un muestreo aleatorio simple, reduciendo el tamaño de muestra total necesario en campo en comparación con el supuesto inicial de *deff* = 2,0.

Finalmente, dado el costo operativo que implicaba en la práctica una propuesta como lo anterior (p.e. 1500 establecimientos y 10.000 estudiantes) se prefirió una estrategia más tradicional de menos establecimientos (+/- 800) aunque con una cantidad variable de estudiantes por establecimientos en función de la cantidad de secciones. Más concretamente, para establecimientos de hasta 6 secciones se seleccionaron 5 estudiantes por cada sección y para aquellos establecimientos con más de 6 secciones se seleccionó 3 de cada una de ellas. Esto produce, como media, una gran cantidad de estudiantes por establecimiento especialmente si se seleccionan establecimientos con una gran matrícula y con muchas secciones.

Un punto a notar de esta estrategia es que la cantidad final de estudiantes no es lineal ni a la matrícula ni a la cantidad de secciones. Por ejemplo, en un establecimiento con 6 secciones se terminan seleccionando 30 estudiantes ($6 \cdot 5$) y en otro establecimiento de 7 secciones se termina seleccionando 21 estudiantes ($7 \cdot 3$). Esto será a tener en cuenta al momento de construir un ponderador de estudiantes en ausencia de una base de secciones. Finalmente (porque al ser un número variable es difícil de estimar) con los establecimientos

seleccionados se obtuvo una media de estudiantes de aprox. ± 20 estudiantes por cada establecimiento. Esto permite calcular un $def f$ aproximado de:

$$def f = 1 + (20 - 1) \cdot 0,1 = 1 + 19 \cdot 0,1 = 2.9 \quad (8.4)$$

8.6.5 Simulación del impacto de la Correlación Intraclass (ρ) y el tamaño del cluster (b)

Para comprender de manera intuitiva cómo interactúan el tamaño del cluster por establecimiento (b) y la homogeneidad de ellas (ρ), se realiza una simulación que calcula el $def f$ y evalúa el tamaño de muestra teórico final requerido bajo escenarios alternativos de diseño para estimar una proporción con $CV = 3,65\%$ que era la estipulada para el cruce tipo de establecimiento y Gran Área (Tabla 8.6).

Tabla 8.7: Simulación del impacto de la correlación intracluster (ρ) y el tamaño del cluster por establecimiento (b) en la cantidad de casos finales

Simulación Comparativa de Escenarios de Diseño Muestral

Impacto en el tamaño muestral requerido para una precisión de CV = 3,65% (1) y CV = 6,08% (2)

Estrategia de Selección	Estudiantes por Estab. (b)	Homogeneidad Estab (Rho)	Efecto de Diseño (Deff)	Total Estudiantes (n) (1)	Tamaño Efectivo (ESS) (1)	Total Estab. a Visitar(1)	Total Estudiantes (n) (2)	Tamaño Efectivo (ESS) (2)	Total Estab. a Visitar(2)
Diseño 5 estudiantes por Estab. (b=5)	5	2%	1.08	811	751	162	292	270	58
Diseño 5 estudiantes por Estab. (b=5)	5	10%	1.40	1051	751	210	379	271	76
Diseño 5 estudiantes por Estab. (b=5)	5	18%	1.72	1291	751	258	465	270	93
Diseño 10 estudiantes por Estab. (b=10)	10	2%	1.18	886	751	89	319	270	32
Diseño 10 estudiantes por Estab. (b=10)	10	10%	1.90	1426	751	143	514	271	51
Diseño 10 estudiantes por Estab. (b=10)	10	18%	2.62	1967	751	197	709	271	71
Diseño 15 estudiantes por Estab. (b=15)	15	2%	1.28	961	751	64	346	270	23
Diseño 15 estudiantes por Estab. (b=15)	15	10%	2.50	1842	751	120	652	270	43
Diseño 15 estudiantes por Estab. (b=15)	15	18%	3.50	2642	751	264	1042	270	104

Como se observa en la tabla simulada, a medida que aumentamos el número de estudiantes por escuela (b), el $def f$ aumenta. Lo mismo ocurre, aunque con efectos más marcados, cuando sube el Rho de las correlaciones intraclusters (ρ).

Por ejemplo, si asumiéramos el escenario de relevar todas las secciones con un promedio de $b = 15$ encuestas por escuela y una homogeneidad escolar del 10%, el $def f$ se dispararía a 2,40, exigiéndonos encuestar un mínimo de 649 estudiantes por dominio de estimación para lograr la misma precisión ($CV = 6,08\%$) que con 379 estudiantes usando el diseño propuesto de $b = 5$ y $Rho = 10\%$ ($def f = 1,40$). El contrapunto es que en el primer caso se debería ir a solo 43 establecimientos y en el segundo a 76.

Por las razones anteriores preferimos, como regla general, ir a más establecimientos y seleccionar a menos casos dentro de cada uno de ellos. Esto implica un mayor costo de control por parte del centro (hay que contactar y seguir a más establecimientos), pero una mayor descentralización de la tarea a realizar (cada establecimiento seleccionado posee una pequeña carga de trabajo). Si la Secretaría tuviera que enviar físicamente un encuestador a cada establecimiento seleccionado quizá el diseño elegido hubiera sido otro.

8.7 Diseño muestra

Teniendo en mente, por un lado, la distribución poblacional, representada por la distribución del marco muestral y, por otro lado, los objetivos de estimación, es claro que, para algunos dominios de estimación no es una buena estrategia hacer una muestra al azar simple de toda la población. La razón es que algunos dominios de estimación implican pocos casos y estos tendrán pocas chances de estar incluidos en la muestra final. De manera derivada, *ceteris paribus*, sus márgenes de error o sus coeficientes de variación, serán mayores a los aceptables en los objetivos. Esta situación, aunque con menor intensidad, también se expresaría a través de un muestreo estratificado proporcional.

Por esta razón es esperable que esos dominios de estimación pequeños obtengan un trato diferencial en el proceso de selección para asegurar una cantidad de casos mínima que permita realizar las inferencias con los niveles de precisión requeridos. Si se sigue dentro de las opciones de los diseños estratificados es posible pensar en alguna de las siguientes versiones más o menos clásicas:

- Una asignación que optimiza la reducción de la varianza total (Neyman, 1934) y nos alejaríamos de una estratificación proporcional.
- También es posible pensar en un diseño basado en la asignación de potencia (*power allocation*) (Bankier, 1988) que es óptimo si se prefiere la detección de diferencias en estratos pequeños. También nos alejaríamos de una estratificación proporcional.
- Usar estratos muestrales que surgan de un análisis multivariado previo para crear *clusters* que minimicen la intra-varianza y maximicen la extra-varianza (Dalenius, 1950; Dalenius & Hodges, 1957, 1959). Dado que se prefiere optimizar las estimaciones para los dominios ya contruidos esta estrategia se descarta porque implicaría romper fuertemente con la lógica de ellos.

La realización de un diseño estratificado no proporcional tiene el riesgo que su resultado es muy dependiente de cuál sea la variable objetivo (Tillé, 2020, pág. 75). En contextos en donde exista más de una variable de interés (lo usual en muchas investigaciones sociales) y/o en casos en donde se presuma que determinada fuente primaria luego será utilizada como fuente secundaria por otros investigadores con objetivos que todavía se desconocen, se debe analizar los pros y contras de esta elección. Por ejemplo, algunos análisis estadísticos complejos (todavía) no permiten incorporar los valores de los ponderadores/expansores en sus cálculos.

Por otro lado, cuanto más estratos se construyan, más preciso será el estimador. Sin embargo, cabe advertir que un caso por cada estrato no es un buen diseño muestral (Tillé, 2020, pág. 77). La razón de esto es que, usualmente, el estimador de la varianza se convierte cada vez más inestable como el número de estratos se acrecienta por la pérdida de grados de libertad derivada de la estimación de la media de los estratos.

Los dominios de estimación que se seleccionaran de forma censal en la primera etapa de la muestra son:

Los CEBAS
Los ECE-CENS
Los ECE-EPA

El resto de los establecimientos tendrá una probabilidad de inclusión en función de:

- El tamaño de la matrícula (PPS) más
- Una corrección del tipo «*power allocation*» que permitirá sobrerrepresentar en la muestra a los establecimientos de los dominios más pequeños.

Esta sobrerrepresentación luego será corregida con ponderadores específicos. Cabe aclarar que por el diseño finalmente elegido, será importante el trabajo de calibración una vez realizado el trabajo de campo.

Estrictamente el diseño muestral será uno de probabilidades de inclusión desiguales basado en el método del cubo para generar una muestra balanceada y bien distribuida. El balanceo se hace en función de algunas variables categóricas como el tipo de establecimiento, el distrito, el ámbito y variables continuas como el IVSE. La buena distribución se espera lograr con a través de la dispersión de la variable IVSE.

Quizá pueda llamar la atención que, dados que los dominios se encontraban expresados a nivel de Región Agrupada o Gran Área, el balanceo se realice a nivel de distrito. La razón es la siguiente. Si se logra obtener una muestra que se ajuste a los parámetros conocidos de los distritos, esta deberá acercarse también a las de las regiones, así como también a las regiones agrupadas y, en última instancia, a nivel de Gran Área. En cambio, el camino inverso está lejos de garantizarse. Por ejemplo podría ser que, por azar, los casos de AMBA se seleccionen todos dentro de La Matanza, o que los de INTERIOR se seleccionen mayoritariamente dentro de Bahía Blanca o General Pueyrredón. Es claro que en estos casos, una buena muestra a nivel de Gran Área no asegura una buena muestra a niveles inferiores.

8.8 Construcción de ponderadores y expansores

Si bien la construcción final de los ponderadores casi con seguridad implique un proceso de calibración por la no respuesta, de modo provisorio se han construido algunos ponderadores y expansores básicos para chequear algunos resultados de control de la muestra. Por esta razón, por ahora no se justificará el detalle de este proceso porque tiene un carácter más instrumental y de control que de análisis.

8.9 Testeo de la muestra seleccionada

Existen muchas maneras alternativas de evaluar la bondad de una muestra. Una básica, siempre que existan dominios explícitos de estimación e información auxiliar disponible en el marco muestral, es comparar las estimaciones de la muestra con los parámetros del marco muestral. También se puede evaluar aspectos de la muestra que exceden a los dominios de estimación y, justamente, nos informan sobre la robustez de la misma para exigirle responder preguntas diferentes a las originales explicitadas en los dominios de estimación. Comenzaremos por el primer punto y luego seguiremos con el segundo.

Un cuadro importante en este contexto es recordar que esta muestra, si bien consta de una primera etapa de selección de establecimientos, esta selección se ejecuta con el objetivo de realizar una muestra de estudiantes. Por esta razón a continuación se muestra la distribución de estudiantes para cada dominio de estimación.

Tabla 8.8: Cantidad de estudiantes seleccionados según dominios. Valores absolutos sin ponderar.

Característica	N = 1.054¹
dominio	
CEBAS_UNICO	432
CENS_AMBA	1.079
CENS_INTERIOR	1.184
ECE-CENS_UNICO	942
ECE-EPA_UNICO	948
EPA_AMBA	899
EPA_INTERIOR	910
FINES_R01	564
FINES_R02	706
FINES_R03	443
FINES_R04	397
FINES_R05	592
FINES_R06	360
FINES_R07	410
FINES_R08	642
FINES_R09	543
FINES_R10	530
FINES_R11	685
FINES_R12	290
FINES_R13	275
FINES_R14	302
FINES_R15172425	434
FINES_R16212223	380
FINES_R18	424
FINES_R19	596
FINES_R20	315
region_agrupada	
01	1.176
02	1.108
03	739
04	1.027
05	985
06	507
07	669
08	500

¹ n_estudiantes_muestra: Suma

Otro chequeo que se realizará tendrá que ver con los porcentajes de establecimientos seleccionados por dominio de estimación. La función básica de esto es observar el efecto del «*power allocation*» que permitió aumentar la participación porcentual de los dominios más pequeños y reducir la participación porcentual de los dominios más grandes. Se recuerda que esto se usó para cambiar las probabilidades de inclusión para que luego se aplique el método del cubo a toda la muestra. En otras palabras, no se trata de un diseño estratificado no proporcional en donde se realizan «x» cantidad de muestras independientes. Para visualizar este efecto, en la siguiente tabla se muestran los resultados porcentuales con y sin ponderar (el primero sin paréntesis y el segundo con). La idea es que, sin ponderar, el porcentaje de los dominios pequeños sea mayor al porcentaje encontrado en la población por efecto de una sobrerrepresentación. De manera complementaria, se espera que con la ponderación, el porcentaje de los dominios pequeños se acerque al porcentaje real que tienen en la población.

Tabla 8.9: Porcentaje de establecimientos seleccionados según dominios. Valores ponderados y sin ponderar (entre paréntesis)

Característica	N = 3.209
dominio, % (% (unweighted)) n=n (unweighted)	
CEBAS_UNICO	0,6 (1,9) n=20
CENS_AMBA	11 (2,8) n=29
CENS_INTERIOR	5,2 (3,6) n=38
ECE-CENS_UNICO	1,1 (1,9) n=20
ECE-EPA_UNICO	1,2 (1,8) n=19
EPA_AMBA	5,7 (2,5) n=26
EPA_INTERIOR	3,1 (3,5) n=37
FINES_R01	5,6 (5,6) n=59
FINES_R02	6,1 (5,5) n=58
FINES_R03	9,0 (3,3) n=35
FINES_R04	6,4 (3,0) n=32
FINES_R05	6,6 (3,3) n=35
FINES_R06	1,9 (4,2) n=44
FINES_R07	2,9 (5,1) n=54
FINES_R08	4,1 (5,3) n=56
FINES_R09	3,6 (5,0) n=53
FINES_R10	4,0 (5,5) n=58
FINES_R11	3,2 (4,9) n=52
FINES_R12	1,5 (3,6) n=38
FINES_R13	1,3 (2,8) n=29
FINES_R14	1,2 (3,2) n=34
FINES_R15172425	3,7 (4,7) n=50
FINES_R16212223	3,0 (4,5) n=47
FINES_R18	1,8 (3,5) n=37
FINES_R19	4,3 (5,2) n=55
FINES_R20	1,6 (3,7) n=39
region_agrupada, % (% (unweighted)) n=n (unweighted)	
01	8,3 (7,3) n=77
02	8,3 (6,6) n=70
03	12 (4,1) n=43
04	8,5 (4,5) n=47
05	7,9 (4,2) n=44
06	3,2 (4,6) n=49
tipo_est_adulto, % (% (unweighted)) n=n (unweighted)	
01-05-24-25	1,7 (5,9) n=61

Ahora pasaremos a evaluar las bondades de la muestra con respecto a la precisión de los estimadores con respecto a parte de la información auxiliar disponible en el marco muestral. Lo probaremos con el IVSE a nivel de cada dominio de estimación con su respectivo CV, su límite inferior, superior, el error estándar y la varianza y la cantidad de casos de establecimientos efectivamente seleccionados.

Tabla 8.10: Precisión de la estimaciones IVSE según dominios


dominio	IVSE	IVSE_cv	IVSE_low	IVSE_upp	IVSE_se	IVSE_var	n
CEBAS_UNICO	0.2768	0.1403	0.2128	0.3407	0.0388	0.0015	20
CENS_AMBA	0.4980	0.0895	0.4247	0.5714	0.0446	0.0020	29
CENS_INTERIOR	0.2780	0.0944	0.2348	0.3212	0.0262	0.0007	38
ECE-CENS_UNICO	0.5346	0.1037	0.4434	0.6259	0.0554	0.0031	20
ECE-EPA_UNICO	0.5560	0.1251	0.4415	0.6705	0.0696	0.0048	19
EPA_AMBA	0.4764	0.0894	0.4063	0.5466	0.0426	0.0018	26
EPA_INTERIOR	0.3690	0.0673	0.3281	0.4098	0.0248	0.0006	37
FINES_R01	0.4544	0.0630	0.4073	0.5015	0.0286	0.0008	59
FINES_R02	0.5695	0.0584	0.5148	0.6243	0.0333	0.0011	58
FINES_R03	0.6316	0.0455	0.5843	0.6788	0.0287	0.0008	35
FINES_R04	0.5346	0.0614	0.4806	0.5886	0.0328	0.0011	32
FINES_R05	0.5814	0.0804	0.5044	0.6583	0.0467	0.0022	35
FINES_R06	0.3755	0.1035	0.3115	0.4395	0.0389	0.0015	44
FINES_R07	0.4782	0.0611	0.4301	0.5263	0.0292	0.0009	54
FINES_R08	0.5239	0.0567	0.4751	0.5728	0.0297	0.0009	56
FINES_R09	0.5766	0.0424	0.5364	0.6169	0.0245	0.0006	53
FINES_R10	0.4715	0.0516	0.4314	0.5115	0.0243	0.0006	58
FINES_R11	0.5048	0.0468	0.4660	0.5437	0.0236	0.0006	52
FINES_R12	0.4595	0.0745	0.4031	0.5159	0.0343	0.0012	38
FINES_R13	0.4029	0.0466	0.3720	0.4339	0.0188	0.0004	29
FINES_R14	0.3532	0.0491	0.3246	0.3817	0.0173	0.0003	34
FINES_R15	0.4382	0.0496	0.3510	0.4134	0.0190	0.0004	50
FINES_R16	0.2375	0.0529	0.3446	0.4104	0.0200	0.0004	47
FINES_R18	0.4155	0.0608	0.3739	0.4571	0.0253	0.0006	37
FINES_R19	0.4083	0.0820	0.3532	0.4634	0.0335	0.0011	55
FINES_R20	0.3960	0.0640	0.3543	0.4377	0.0253	0.0006	39

8.9.1 Análisis de robustez o sensibilidad de la muestra

Ahora vamos a empezar a evaluar a los valores del IVSE de la muestra con respecto a los valores de la población. Especialmente nos interesa indagar acerca su distribución más que su valor central. Esto es particularmente importante porque el IVSE se trata de una variable índice que aspira incluir en la muestra una serie de desigualdades sociales que, de otra forma, se colarían por detrás afectando la utilidad de la misma para diferentes usos. Todos los datos que se presentan de acá en adelante no tienen corrección alguna de ponderación para así poder observar el grado de balanceo y de distribución que se logró con el diseño del método del cubo sin ningún tipo de corrección adicional.


El orden será el siguiente. Comenzaremos con una visualización de la distribución del IVSE a nivel de toda la población y de toda la muestra. Luego, se repetirá esta operación, pero a nivel de cada dominio de estimación y los niveles de Grán Área como de Región Agrupada. Finalmente, se hará lo propio a nivel de tipo de establecimiento. Cabe recordar que este tipo de análisis no formaban parte de los objetivos de estimación, pero, justamente, se realizan para evaluar la robustez de la muestra para responder preguntas que exceden a los objetivos explícitos. En principio, si se hubiera seguido una estrategia de maximizar únicamente la precisión de los dominios de estimación explicitados, se hubiera corrido el riesgo de sobreajustar (overfitting) a los esos objetivos haciendo a la muestra excesivamente sensible o poco robusta a usos posteriores diferentes a los inicialmente explicitados.

Figura 8.6: Distribución de densidad del IVSE. Población y muestra.




Ahora vamos a repetir la operación anterior pero a nivel de cada dominio de estimación.

Figura 8.7: Distribución de densidad del IVSE según dominios. Población y muestra adultos.




Ahora volvemos a repetir la operación anterior pero a nivel de Región Agrupada

Figura 8.8: Distribución de densidad del IVSE según Región Agrupada. Población y muestra adultos.




Ahora volvemos a repetir la operación anterior pero a nivel de cada Gran Área

Figura 8.9: Distribución de densidad del IVSE según gran área. Población y muestra adultos.




Volvemos a repetir la operación anterior pero a nivel de tipo de establecimiento.

Figura 8.10: Distribución de densidad de IVSE según tipo de establecimiento. Población y muestra adultos.



Por último, volvemos a repetir la operación anterior pero a nivel de nivel del establecimiento.

Figura 8.11: Distribución de densidad de IVSE según nivel de establecimiento. Población y muestra adultos.



Nota: Se utiliza libre o sin escala el eje Y para apreciar la forma de la distribución en cada región.

9. Muestra Paro - 03/08/26

9.1 Introducción y objetivos

En esta ocasión vamos a realizar un diseño muestral con un objetivo relativamente acotado y simple como es estimar el alcance del paro del día 3 de agosto de 2026. Sin saber los detalles del formulario/encuesta se asumen dos cuestiones importantes a la hora del diseño. Por un lado, no parece ser una muestra sobre la cual luego se vayan a realizar una gran cantidad de investigaciones (p.e. difícilmente se convierta en fuente secundaria para otros investigadores) y los que van a contestar las preguntas son directivos en representación de los establecimientos. En otras palabras, no se trata de una muestra polietápica a través de la cual se intenta llegar a los estudiantes.

En cuanto a su precisión se espera que el diseño permita estimaciones para los cruces de los siguientes dominios:

- **Nivel:** Inicial, Primaria y Secundaria.
- **Área:** AMBA e Interior.
- **Sector de Gestión:** Estatal y Privado.

Para el sector **Estatal**, se definió un margen de error máximo del 3% por celda, mientras que para el sector **Privado** el margen de error máximo tolerado es del 5% por celda.

9.2 Metodología

Dados los objetivos de la muestra y la disposición de la información, se ha seleccionado el siguiente diseño:

1. Los diferentes dominios de estimación se considerarán estratos, por lo que se aspira a realizar una serie de muestras independientes dentro de cada uno de ellos.
2. Dentro de cada estrato se realiza un diseño proporcional al tamaño del establecimiento (PPS) para realizar un diseño relativamente económico. Dado que se esperan márgenes de error diferentes según sector, la muestra no será autoponderada.
3. En los casos donde la matrícula es faltante (139 establecimientos en la población), se le imputa el valor 1 para asegurar que conserven una probabilidad positiva y no nula de selección en el algoritmo PPS.
4. El diseño es conceptualmente **de una sola etapa**. La encuesta se realiza a directivos del establecimiento sin sub-selección de cursos o estudiantes. Por lo tanto, desde un punto de vista de la estimación del error, el efecto de diseño puede considerar $Def \approx 1$.
5. La variable continua referida al porcentaje de paros se utiliza para ordenar los casos y luego realizar un muestreo sistemático. Esta estrategia se conoce como estratificación implícita (Cochran, 1977, pág. 205)

```
library(readxl)
library(dplyr)
library(gt)
library(gtsummary)
library(ggplot2)
library(plotly)
library(here)
library(janitor)
library(writexl)
library(srvyr)
library(sampling)

theme_gtsummary_journal(journal = "jama")
```

```

theme_gtsummary_compact()
theme_gtsummary_language(
  language = "es",
  decimal.mark = ",",
  big.mark = "."
)

df_poblacion = read_excel(here("Inputs/muestra_paro/Base muestra paro 2026_Final
AML.xlsx"), sheet = 1) |>
clean_names() |>
rename(matricula = matricula_inicial_2026,
       paros_pct = percent_de_clases_afectadas_promedio_2026)

# Preparar variables
df_poblacion = df_poblacion |>
mutate(
  nivel_unificado = case_when(
    nivel == "1.2.Inicial" ~ "Inicial",
    nivel == "2.Primaria" ~ "Primaria",
    nivel %in% c("3.1.Secundaria", "3.2.Secundaria ETP") ~ "Secundaria",
    TRUE ~ nivel
  ),
  # Imputar matrícula NA con 1 para mantener probabilidad > 0
  matricula = if_else(is.na(matricula), 1, matricula),
  # Convertir a numérico la afectación
  paros_num = as.numeric(if_else(paros_pct == "NA", NA_character_, paros_pct))
)

```

9.3 Cálculo del Tamaño Muestral

Utilizamos la fórmula para estimación de proporciones en poblaciones finitas con corrección por población finita (*FPC*), asumiendo varianza máxima ($p = 0.5$ y $1 - p = 0.5$) y un nivel de confianza del 95% ($z = 1.96$). Esto se hace para cada muestra independiente dentro de cada estrato (h):

$$n_h = \frac{N_h \cdot z^2 \cdot p \cdot (1 - p)}{e_h^2 \cdot (N_h - 1) + z^2 \cdot p \cdot (1 - p)} \quad (9.1)$$

Donde $e_h = 0.03$ para Estatal y $e_h = 0.05$ para Privado.

```

calcular_n = function(N, e, z = 1.96, p = 0.5) {
  num = N * (z^2) * p * (1 - p)
  den = (e^2) * (N - 1) + (z^2) * p * (1 - p)
  return(ceiling(num / den))
}

res_tamano = df_poblacion |>
count(nivel_unificado, area, sector, name = "N") |>
mutate(
  e = if_else(sector == "Estatal", 0.03, 0.05),
  n_teorico = calcular_n(N, e),
  n_final = pmin(N, n_teorico)
)

res_tamano |>
gt() |>
tab_header(title = "Tamaño de Muestra Requerido por Estrato") |>
cols_label(
  nivel_unificado = "Nivel",
  area = "Área",

```



```

sector = "Sector",
N = "Población (N)",
e = "Margen de Error (e)",
n_teorico = "n calculado",
n_final = "n muestral final"
) |>
grand_summary_rows(
  columns = c(N, n_teorico, n_final),
  fns = list(Total = ~sum(.x, na.rm = TRUE)),
  fmt = ~ fmt_integer(.x)
)

```

Tamaño de Muestra Requerido por Estrato

	Nivel	Área	Sector	Pobla- ción (N)	Margen de Error (e)	n calcu- lado	n mues- tral final
	Inicial	AMBA	Estatal	1704	0.03	657	657
	Inicial	AMBA	Privado	1226	0.05	293	293
	Inicial	Interior	Estatal	1586	0.03	639	639
	Inicial	Interior	Privado	301	0.05	170	170
	Primaria	AMBA	Estatal	2066	0.03	704	704
	Primaria	AMBA	Privado	1366	0.05	301	301
	Primaria	Interior	Estatal	2084	0.03	706	706
	Primaria	Interior	Privado	333	0.05	179	179
	Secun- daria	AMBA	Estatal	1952	0.03	691	691
	Secun- daria	AMBA	Privado	1355	0.05	300	300
	Secun- daria	Interior	Estatal	1036	0.03	526	526
	Secun- daria	Interior	Privado	345	0.05	183	183
Total	—	—	—	15,354	—	5,349	5,349

```

# Fijamos semilla para reproducibilidad
set.seed(20260803)

# Unimos los tamaños de muestra requeridos a la población
df_marco = df_poblacion |>
  inner_join(
    res_tamano |> select(nivel_unificado, area, sector, n_final),
    by = c("nivel_unificado", "area", "sector")
  )

# Función para selección PPS Sistemático formal dentro de un estrato
seleccionar_estrato_pps = function(sub_df) {

```

```

n = unique(sub_df$n_final)
N = nrow(sub_df)

if (n >= N) {
  # Censo del estrato
  return(sub_df |>
    mutate(prob_inclusion = 1,
           ponderador = 1,
           muestra = 1))
}

# Ordenar de acuerdo a la estratificación implícita
if (unique(sub_df$sector) == "Estatal") {
  # Ordenar por afectación de paros (imputando NA con la media del estrato)
  paros_media = mean(sub_df$paros_num, na.rm = TRUE)
  if (is.nan(paros_media)) paros_media = 0

  sub_df = sub_df |>
    mutate(paros_orden = if_else(is.na(paros_num), paros_media, paros_num)) |>
    arrange(paros_orden, clave)
} else {
  # Orden al azar para privado
  sub_df = sub_df |>
    sample_frac(1) |>
    arrange(clave)
}

# Calcular probabilidades de inclusión PPS sin reemplazo usando la matrícula como
tamaño
pik = inclusionprobabilities(sub_df$matricula, n)

# Selección sistemática PPS sin reemplazo usando UPsystematic
selec = UPsystematic(pik)

# Devolver todos los casos del estrato agregando las variables de diseño y el
flag 'muestra'
sub_df = sub_df |>
  mutate(
    prob_inclusion = pik,
    ponderador = 1 / prob_inclusion,
    muestra = selec
  )

return(sub_df)
}

# Aplicar selección por estrato
df_marco_completo = df_marco |>
  group_split(nivel_unificado, area, sector) |>
  lapply(seleccionar_estrato_pps) |>
  bind_rows()

# Se crea la variable estrato para agregar en la base completa
df_marco_completo = df_marco_completo |>
  mutate(estrato = interaction(nivel_unificado, area, sector, drop = TRUE))

# Filtramos los casos seleccionados para los análisis del reporte
df_muestra = df_marco_completo |>
  filter(muestra == 1)

```

```
# Escribir la base completa (marco con flag de muestra) a disco
write_xlsx(df_marco_completo |> select(-starts_with("acum_"),
starts_with("afect_")),
           "Inputs/muestra_paro/muestra_paro.xlsx")
```

La muestra total seleccionada cuenta con 5349 establecimientos.


9.3.1 Visualización del Efecto PPS en la distribución de la Matrícula

En la Figura 9.1 se compara la distribución de la matrícula entre el marco muestral y la muestra. Se observa un desplazamiento hacia la derecha en la muestra seleccionada, reflejando que los establecimientos con mayor volumen de matrícula poseen probabilidades de selección superiores en contraste con el marco muestral original.

```
g_mat = ggplot(df_comparativa, aes(x = matricula, fill = origen, color = origen)) +
  geom_density(alpha = 0.4) +
  #scale_x_log10(labels = scales::label_comma()) +
  scale_fill_manual(values = c("Muestra Seleccionada" = "#2c7fb8", "Población (Marco)"
= "#bdbdbd")) +
  scale_color_manual(values = c("Muestra Seleccionada" = "#2c7fb8", "Población (Marco)"
= "#737373")) +
  labs(
    title = "Efecto PPS: Comparación de Matrícula (Escala Log)",
    x = "Matrícula",
    y = "Densidad",
    fill = "Origen",
    color = "Origen"
  ) +
  theme_minimal()

if (knitr::is_html_output()) {
  ggplotly(g_mat)
} else {
  g_mat
}
```

Figura 9.1: Distribución de la matrícula. Población versus muestra.



9.3.2 Validación del Balance de Afectación de Paros (Estratificación Implícita)


El muestreo sistemático ordenado por la variable continua de afectación de paros actúa como un mecanismo de estratificación implícita. Para validar que la muestra represente correctamente la distribución de los paros (para el sector Estatal), en la Figura 9.2 comparamos las densidades correspondientes. La superposición de las curvas indica que la muestra conserva el balance original en esta variable continua de control.

```
df_comp_estatal = df_comparativa |>
  filter(sector == "Estatal", !is.na(paros_num))

g_paros = ggplot(df_comp_estatal, aes(x = paros_num, fill = origen, color = origen)) +
  geom_density(alpha = 0.45) +
  scale_fill_manual(values = c("Muestra Seleccionada" = "#feb24c", "Población (Marco)" =
    "#bdbdbd")) +
  scale_color_manual(values = c("Muestra Seleccionada" = "#f03b20", "Población (Marco)" =
    "#737373")) +
  labs(
    # title = "Estratificación Implícita: Afectación Promedio de Paros (Estatal)",
    x = "% Paros",
    y = "Densidad",
    fill = "Origen",
    color = "Origen"
  ) +
  theme_minimal()

if (knitr::is_html_output()) {
  ggplotly(g_paros)
} else {
  g_paros
}
```

Figura 9.2: Estratificación Implícita: Distribución de paros (Estatal)



9.4 Simulación y Validación (Muestra vs. Población)

A continuación, comparamos las distribuciones de matrícula y las variables de diseño entre la población (marco muestral), la muestra obtenida sin ponderación y la muestra obtenida aplicando las ponderaciones del diseño de una etapa (ponderada por el inverso de la probabilidad de inclusión).

Para la muestra ponderada, se utiliza el paquete `srvyr` para declarar la muestra como un objeto de diseño complejo (`as_survey_design`) especificando las ponderaciones (`weights = ponderador`) y los estratos (`strata = interaction(nivel_unificado, area, sector)`).

```
# Definir la estructura básica del marco
df_poblacion = df_poblacion |>
  mutate(origen = "Población (Marco)")

df_muestra = df_muestra |>
  mutate(origen = "Muestra (Sin ponderar)")

# Declarar el diseño muestral complejo para la muestra ponderada usando srvyr
df_muestra_sv = df_muestra |>
  mutate(estrato = interaction(nivel_unificado, area, sector, drop = TRUE)) |>
  as_survey_design(
    strata = estrato,
    weights = ponderador
  )

# 1. Tabla resumen para la Población (Marco)
tbl_pob = df_poblacion |>
  select(nivel_unificado, area, sector, matricula, paros_num) |>
  tbl_summary(
    percent = "column",
    label = list(
      nivel_unificado ~ "Nivel",
      area ~ "Área",
      sector ~ "Sector",
      matricula ~ "Matrícula Inicial 2026"
    )
  )

# 2. Tabla resumen para la Muestra Sin Ponderar
tbl_muestra_sp = df_muestra |>
  select(nivel_unificado, area, sector, matricula, paros_num) |>
  tbl_summary(
    percent = "column",
    label = list(
      nivel_unificado ~ "Nivel",
      area ~ "Área",
      sector ~ "Sector",
      matricula ~ "Matrícula Inicial 2026"
    )
  )

# 3. Tabla resumen para la Muestra Ponderada (usando el objeto survey design)
tbl_muestra_pond = df_muestra_sv |>
  select(nivel_unificado, area, sector, matricula, paros_num) |>
  tbl_svsummary(
    percent = "column",
    label = list(
      nivel_unificado ~ "Nivel",
      area ~ "Área",
      sector ~ "Sector",
      matricula ~ "Matrícula Inicial 2026"
    )
  )
```

```

)

# Fusionar las tres tablas en una sola estructura comparativa
tbl_comparacion_paro = tbl_merge(
  tbls = list(tbl_muestra_sp, tbl_muestra_pond, tbl_pob),
  tab_spanner = c("**Muestra (Sin ponderar)**", "**Muestra (Ponderada)**", "**Población (Marco)**")
) |>
  modify_header(label = "**Variable**") |>
  as_gt()

tbl_comparacion_paro

```

Tabla 9.1: Comparación marco muestral, muestra sin ponderar y muestra ponderada

	Muestra (Sin ponderar)	Muestra (Ponderada)	Población (Marco)
Variable	N = 5.349	N = 15.427	N = 15.354
Nivel, n (%)			
Inicial	1.759 (33%)	4.983 (32)	4.817 (31%)
Primaria	1.890 (35%)	5.863 (38)	5.849 (38%)
Secundaria	1.700 (32%)	4.581 (30)	4.688 (31%)
Área, n (%)			
AMBA	2.946 (55%)	9.533 (62)	9.669 (63%)
Interior	2.403 (45%)	5.894 (38)	5.685 (37%)
Sector, n (%)			
Estatad	3.923 (73%)	10.337 (67)	10.428 (68%)
Privado	1.426 (27%)	5.089 (33)	4.926 (32%)
Matrícula Inicial 2026, Mediana (IQR)	286 (158 – 487)	186 (79 – 357)	183 (82 – 359)
paros_num, Mediana (IQR)	17 (8 – 32)	17 (7 – 25)	17 (6 – 26)
Desconocido	1.431	5.103	4.975

Al comparar las tres columnas en la Tabla 9.1 puede observarse que:

1. La muestra sin ponderar presenta un sesgo de diseño hacia establecimientos de mayor matrícula debido al algoritmo de selección PPS. Esto se refleja en un promedio de matrícula considerablemente mayor en la muestra sin ponderar en comparación con el marco poblacional.
2. Al aplicar los ponderadores de diseño (inversa de la probabilidad de inclusión), la distribución de la matrícula y la proporción de escuelas por nivel, área y sector se reestablecen acercándose a las medias, proporciones y totales del marco muestral.

Anexos

A. Referencias Bibliográficas

- Baker, R., Brick, M., Bates, N., Battaglia, M., Couper, M., Dever, J., Gile, K., & Tourangeau, R. (2013). *Report of the AAPOR task force on non-probability sampling*.
- Bankier, M. (1988). Power Allocation. Determining sample sizes for subnational areas. *The American Statistician*, 42(3), 174-177.
- Brus, D. (2022). *Spatial sampling with R*. Chapman & Hall /CRC.
- Bunge, M. (1974). *Semantics*. Dordrecht. Reidel.
- Campbell, D., & Stanley, J. (1963). *Experimental and quasi-experimental designs for research*. Houghton Mifflin Company.
- Cochran, W. (1977). *Sampling techniques*. John Wiley & Sons.
- Dalenius, T. (1950). The problem of optimum stratification. *Skandinavisk Aktuarietidskrift*, 33, 203-213.
- Dalenius, T., & Hodges, J. (1957). The choice of stratification points. *Skandinavisk Aktuarietidskrift*, (40), 198-203.
- Dalenius, T., & Hodges, J. (1959). Minimum variance stratification. *Journal of the American Statistical Association*, (54).
- Deville, J., & Tillé, Y. (2004). Efficient balanced sampling: The cube method. *Biometrika*, 91(4), 893-912.
- Elliott, M., & Valliant, R. (2017). Inference for nonprobability samples. *Statistical Science*, 32(2), 249-264.
- Everitt, B., Landau, S., Leese, M., & Stahl, D. (2011). *Cluster Analysis* (5 Edition). Wiley.
- Fienberg, S., & Tanur, J. (1988). From the inside out and the outside in: Combining experimental and sampling structures. *The Canadian Journal of Statistics*, 16(2), 135-151.
- Gigerenzer, G., Swijtink, Z., Porter, T., Beatty, J., & Krüger, L. (1997). *The empire of chance*. Cambridge University Press.
- Grosh, M., & Muñoz, J. (1996). *A Manual for Planning and Implementing the Living Standards Measurement Study Survey*. The World Bank.
- Hacking, I. (2004). *The taming of chance*. Cambridge University Press. (Obra original publicada en 1990)
- Hacking, I. (2006). *The emergence of probability: A philosophical study of early ideas about probability, induction and statistical inference*. Cambridge University Press.
- Hansen, M., & Hurwitz, W. (1943). On the Theory of Sampling from Finite Populations. *The Annals of Mathematical Statistics*, 14, 333-362.
- Hedlin, D. (2015). *Why are design in survey sampling and design of randomised experiments separate areas of statistical science?*
- Horvitz, D., & Thompson, D. (1952). A Generalization of Sampling Without Replacement From a Finite Universe. *Journal of the American Statistical Association*, 47(260), 663-685.
- Kish, L. (1965). *Survey Sampling*. John Wiley & Sons.
- Kish, L. (1980). Design and estimations for domains. *The Statistician*, 29(4), 209-222.
- Kish, L. (1987). *Statistical design for research*. John Wiley.
- Klima, G. (2022). *The medieval problem of universals* (E. Zalta, Ed.; Spring 2022). Stanford University.
- Lumley, T. (s. f.). *Making use of pre-calibrated weights*.
- Lumley, T. (2010). *Complex surveys. A guide to analysis using R*. John Wiley & Sons.
- Lundström, S., & Särndal, C. E. (2009). *Calibration of weights in surveys with nonresponse and frame imperfections*.
- Morgan, S., & Winship, C. (2015). *Counterfactuals and Causal Inference* (Second Edition). Cambridge University Press.
- Neyman, J. (1934). On the Two Different Aspects of the Representative Method: The Method of Stratified Sampling and the Method of Purposive Selection. *Journal of the Royal Statistical Society*, 97(4), 558-625.
- Pearl, J. (2018). *The book of why*. New York. Basic Books.
- Platón. (2002 [370AVC]). *Phaedrus*. Oxford University Press.
- Särndal, C. E. (s. f.). The calibration approach in survey theory and practice. *Survey Methodology*, 33(2), 99-119.
- Small, M., & Adler, L. (2019). The role of space in the formation of social ties. *Annual Review of Sociology*, 45, 111-132.
- Subsecretaría, de planeamiento. (2024). *PRUEBAS ESCOLARES BONAERENSES EN EL NIVEL PRIMARIO Resultados de Matemática y de Prácticas del Lenguaje en 3°, 5° y 6°*.

- Subsecretaría, de planeamiento. (2025). *Qué son las pruebas escolares bonaerenses? Evaluación formativa para la mejora de la enseñanza y de los aprendizajes*. Subsecretaría de Planeamiento, Dirección Provincial de Evaluación e Investigación.
- Tillé, Y. (2010). *Balanced sampling by means of the cube method*.
- Tillé, Y. (2011). Ten years of balanced sampling with the cube method: An appraisal. *Survey Methodology*, 37(2), 215-226.
- Tillé, Y. (2020). *Sampling and estimation from finite populations*. John Wiley & Sons.
- Tillé, Y., & Grafström, A. (2013). Doubly balanced spatial sampling with spreading and restitution of auxiliary totals. *Environmetrics*, 24(2), 120-131.
- Tillé, Y., & Matei, A. (2023). *Package "sampling"*.
- Valliant, R., & Dever, J. (2018). *Survey Weights. A step by step guide to calculation*. Stata Press.
- Valliant, R., Dever, J., & Kreuter, F. (2018). *Practical Tools for Designing and Weighting Survey Samples* (Second Edition). Springer.
- Zipf, G., & Valliant, R. (s. f.). *Design Effects and Effective Sample Size*.